Ciencia de Datos

Metodologías para Proyectos de Ciencia de Datos

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

UTN - FRCU

Contexto: Big Data

En la actualidad, la sociedad está "datificada": los datos se están generando de forma masiva, a grandes velocidades y en múltiples formatos distintos, en una multiplicidad de escenarios posibles.

Son estas características, el **volumen**, la **velocidad** y la **variedad**, las que describen al fenómeno del big data.

Aprovechar estos datos para la toma de decisiones resulta una tarea crucial.

Contexto: Ciencia de Datos

La **ciencia de datos**, es una sub-disciplina de la informática que brinda a la **Inteligencia de Negocios** herramientas para la **extracción de conocimiento** que se encuentra implícito en los repositorios de datos de las organizaciones.
La ciencia de datos permite sistematizar el proceso de extracción de conocimiento considerando las distintas actividades que se encuentran involucradas para tal objetivo.

Contexto: Minería de Datos

La **minería de datos**, en cambio, hace referencia a los **algoritmos** que son utilizados para explorar el conjunto de datos y encontrar **regularidades o patrones** implícitos en los mismos.
Estos algoritmos y métodos, basados en **estadísticas**, **inteligencia artificial**, **aprendizaje automático** y visualizaciones, nos permiten analizar bases de datos que resultan desproporcionadas para el análisis manual, siendo escalables para adaptarse a las necesidades asociadas al big data.

Necesidad de gestión de proyectos de ciencia de datos

Recordemos la crisis del software...

Necesidad de gestión de proyectos de ciencia de datos

Recordemos la crisis del software...

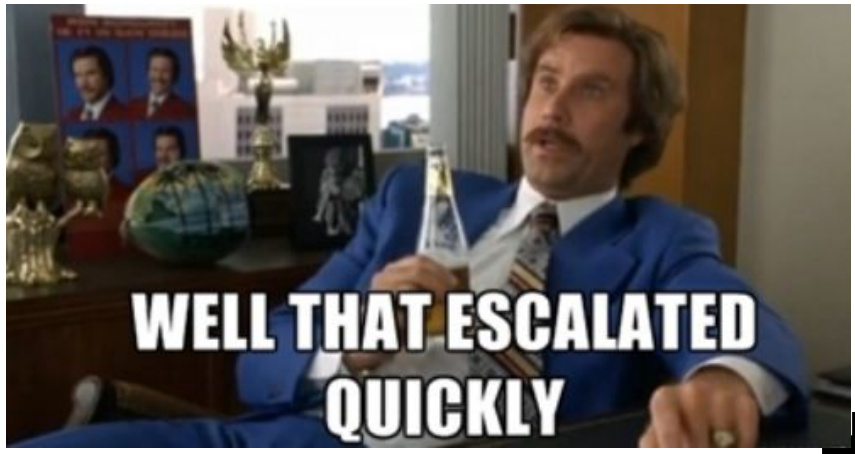
Los proyectos de software fallaban debido a que la actividad de la industria se enfocaba en la **generación de código** sin asegurar la calidad de las producciones.

Necesidad de gestión de proyectos de ciencia de datos

Recordemos la crisis del software...

Los proyectos de software fallaban debido a que la actividad de la industria se enfocaba en la **generación de código** sin asegurar la calidad de las producciones.

Esto provoca que la gran cantidad de código sin gestionar se torne inmanejable.



UTN FRCU

Necesidad de gestión de proyectos de ciencia de datos

La crisis del software dio origen a la **Ingeniería de Software** en 1980.

La Ingeniería de Software es la aplicación de un enfoque sistemático, disciplinado y cuantificable al desarrollo, operación y mantenimiento de software

Necesidad de la explotación de información

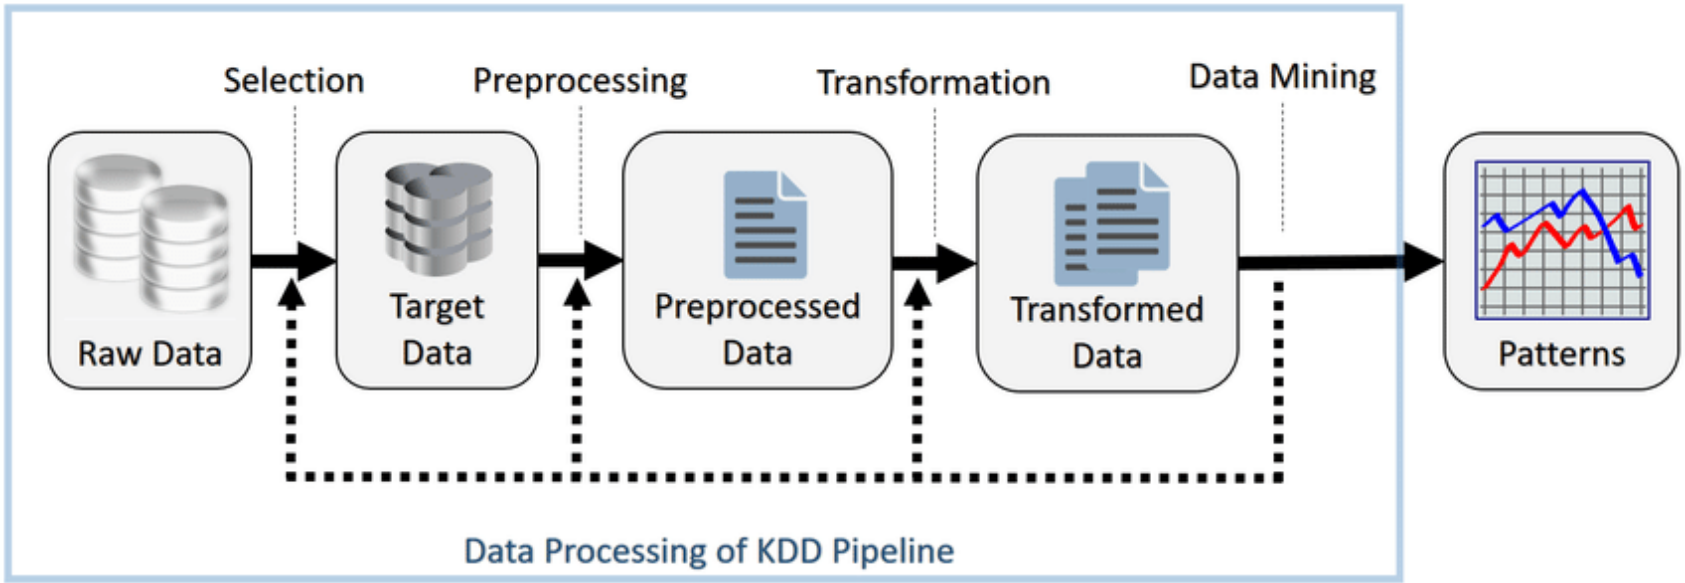
De forma análoga, la aplicación apresurada de algoritmos de minería de datos sin considerar actividades de gestión de recursos conllevaría a no dar respuesta a las necesidades de los stakeholders de manera satisfactoria



Proceso KDD

El primer intento de generalizar el proceso de extracción de conocimiento a partir de los datos fue propuesto por Fayyad et al. en 1996:

Process for Knowledge Discovery in Databases (KDD).



Proceso KDD: problemas

- Se centra en las actividades relacionadas directamente con la **aplicación de algoritmos de minería de datos**: la preparación de los datos y la evaluación de los resultados de forma técnica.

Proceso KDD: problemas

- Se centra en las actividades relacionadas directamente con la **aplicación de algoritmos de minería de datos**: la preparación de los datos y la evaluación de los resultados de forma técnica.
- El proceso KDD no tiene en cuenta los intereses del cliente.

Proceso KDD: problemas

- Se centra en las actividades relacionadas directamente con la **aplicación de algoritmos de minería de datos**: la preparación de los datos y la evaluación de los resultados de forma técnica.
- El proceso KDD no tiene en cuenta los intereses del cliente.
- El proceso KDD no contemplas actividades de implementación del conocimiento obtenido.

CRISP-DM
Cross Industry Standard Process for Data Mining

- Es un proceso (o metodología) **estandar** desarrollado en 1999.

CRISP-DM
Cross Industry Standard Process for Data Mining

- Es un proceso (o metodología) **estandar** desarrollado en 1999.
- Fue diseñado **conjuntamente** por más de 300 organizaciones.

CRISP-DM
Cross Industry Standard Process for Data Mining

- Es un proceso (o metodología) **estandar** desarrollado en 1999.
- Fue diseñado **conjuntamente** por más de 300 organizaciones.
- Incorpora las mejores prácticas para asegurar **calidad**.

CRISP-DM
Cross Industry Standard Process for Data Mining

- Es un proceso (o metodología) **estandar** desarrollado en 1999.
- Fue diseñado **conjuntamente** por más de 300 organizaciones.
- Incorpora las mejores prácticas para asegurar **calidad**.
- Es una propuesta **abierta**.

CRISP-DM
Cross Industry Standard Process for Data Mining

- Es un proceso (o metodología) **estandar** desarrollado en 1999.
- Fue diseñado **conjuntamente** por más de 300 organizaciones.
- Incorpora las mejores prácticas para asegurar **calidad**.
- Es una propuesta **abierta**.
- Incorpora actividades relacionadas al **negocio**.

CRISP-DM
Cross Industry Standard Process for Data Mining

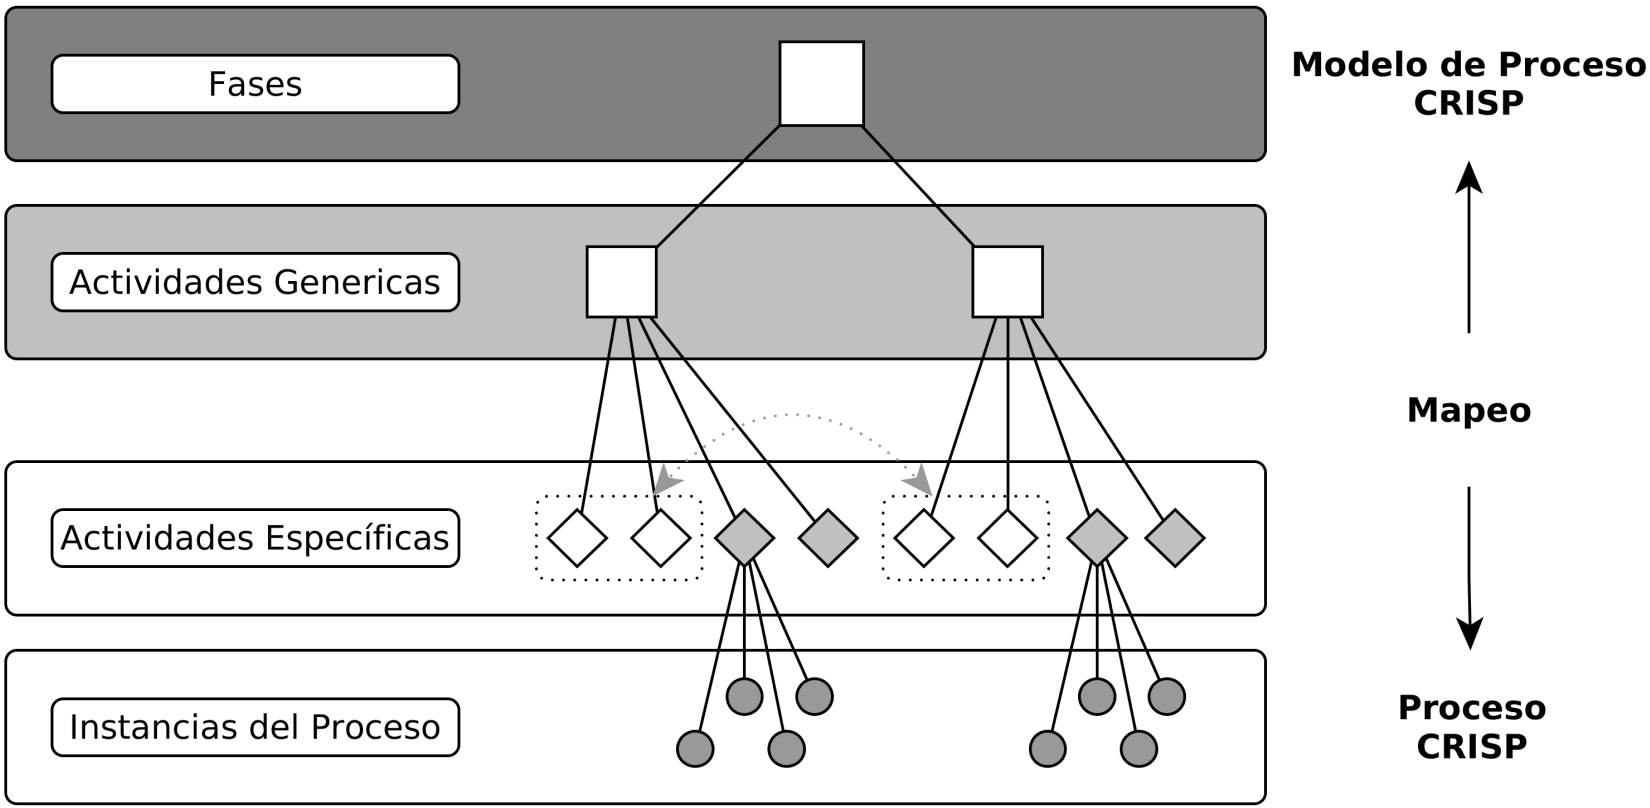
- Es un proceso (o metodología) **estandar** desarrollado en 1999.
- Fue diseñado **conjuntamente** por más de 300 organizaciones.
- Incorpora las mejores prácticas para asegurar **calidad**.
- Es una propuesta **abierta**.
- Incorpora actividades relacionadas al **negocio**.
- No especifica el cómo, sino el **qué**.

CRISP-DM
Cross Industry Standard Process for Data Mining

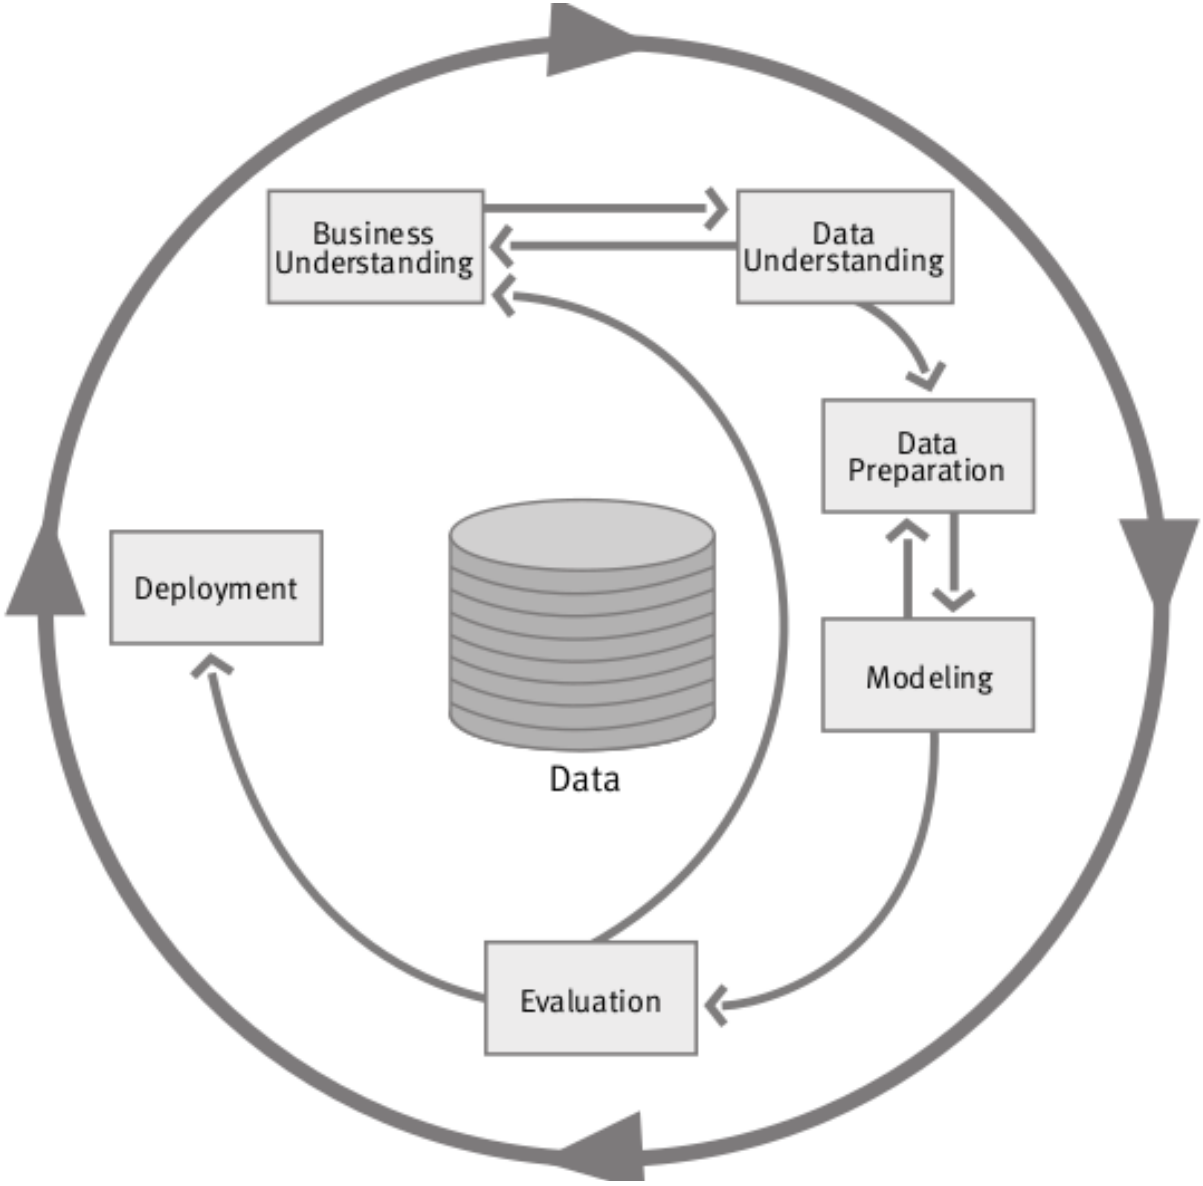
- Es un proceso (o metodología) **estandar** desarrollado en 1999.
- Fue diseñado **conjuntamente** por más de 300 organizaciones.
- Incorpora las mejores prácticas para asegurar **calidad**.
- Es una propuesta **abierta**.
- Incorpora actividades relacionadas al **negocio**.
- No especifica el cómo, sino el **qué**.
- Es **independiente** de las herramientas que se usan.

CRISP-DM

Actividades agrupadas jerárquicamente:



CRISP-DM
Fases



CRISP-DM

Fases

- **Entendimiento del Negocio:** Entender los objetivos del proyecto y los requerimientos de los stakeholders.
- **Entendimiento de los Datos:** Familiarización y comprensión. de los datos disponibles, sus características y sus aspectos de calidad. Se extraen también patrones que son obvios
- **Preparación de los Datos:** Selección, integración, limpieza, formateo, transformación, entre otros.
- **Modelado:** Ejecutar los algoritmos de minería de datos para hallar patrones.
- **Evaluación:** Determinar si los resultados satisfacen los objetivos planteados.
- **Implementación:** Comunicar los resultados para su utilización.

Fase 1
Entendimiento del Negocio

- Establecer los objetivos del negocio (expresados en términos utilizados por el negocio).
- Conocer los recursos disponibles en la organización.
- Establecer los objetivos de minería de datos (expresados en términos técnicos).
- Crear la planificación.

Se busca poder comprender el problema de los clientes y traducirlos al lenguaje de la minería de datos.

- ¿Qué es lo que el cliente quiere lograr?
- ¿Cuáles son las restricciones?

Fase 2
Entendimiento de los Datos

- Adquirir los datos.
- Explorar los datos.
- Verificar la calidad de los datos.

Se comienza recolectando los datos y se busca familiarizarse con los datos, sus formatos, sus estructuras, y su semántica.

Además se intenta determinar la calidad de los mismos para formular posibles hipótesis.

Fase 3
Preparación de los Datos

- Seleccionar y preparar los datos para ser utilizados
- Toma generalmente el 90 % del tiempo de explotación de información.

Incluye todas las actividades para construir el conjunto de datos a partir de los datos crudos

Generalmente son actividades que se realizan repetidamente y sin un orden en especial.

Se incluye la integración, la limpieza, el formateo y la transformación de datos

Fase 4
Modelado

- Seleccionar las técnicas de modelado basándonos en los objetivos de minería de datos.
- Generar el diseño de los tests.
- Construir el modelo.
- Establecer los valores de los atributos.
- Evaluar el modelo.

Generalmente, debido a la gran variedad de técnicas y algoritmos para un mismo objetivo, es necesario ciclar numerosas veces entre esta etapa y la de preparación de datos.

Fase 5
Evaluación

- Evaluación de los resultados del proceso
  - Se evalúa en relación con los objetivos de negocio planteados.
  - Se deciden posibles caminos de acción para usar los resultados.

Un aspecto importante es determinar si existen cuestiones importantes del negocio que no hayan sido consideradas.

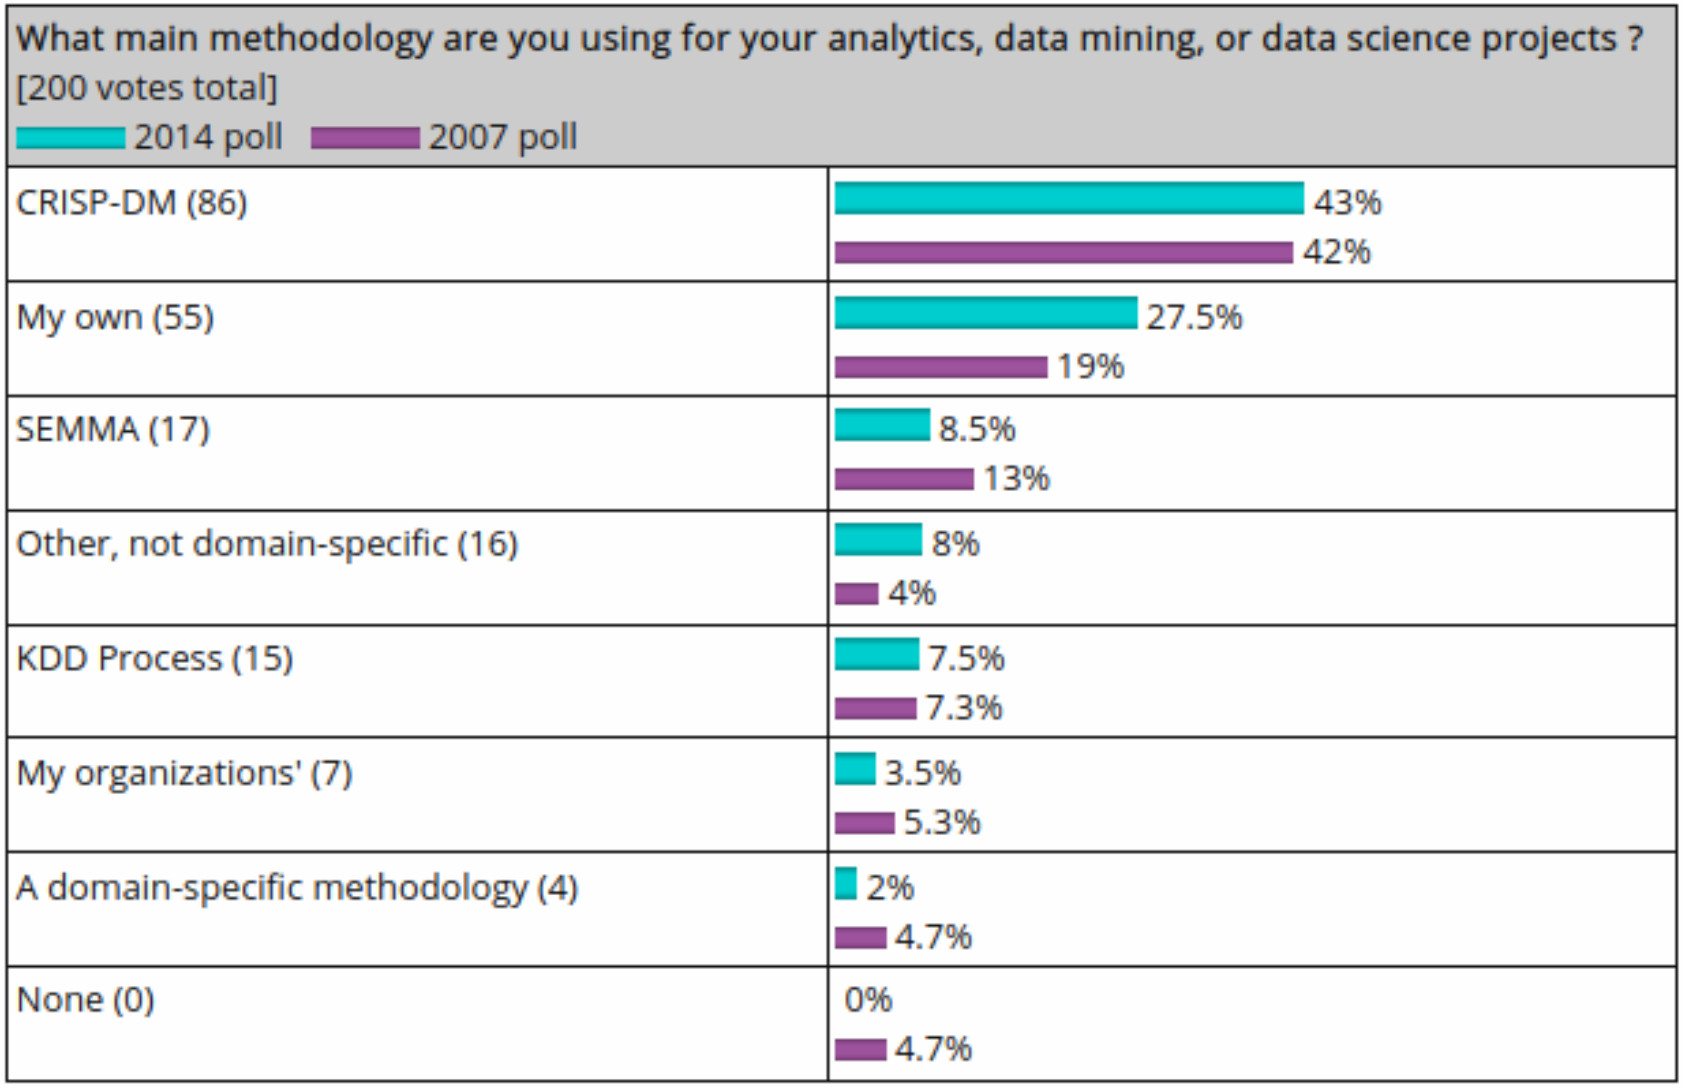
Fase 6
Implementación

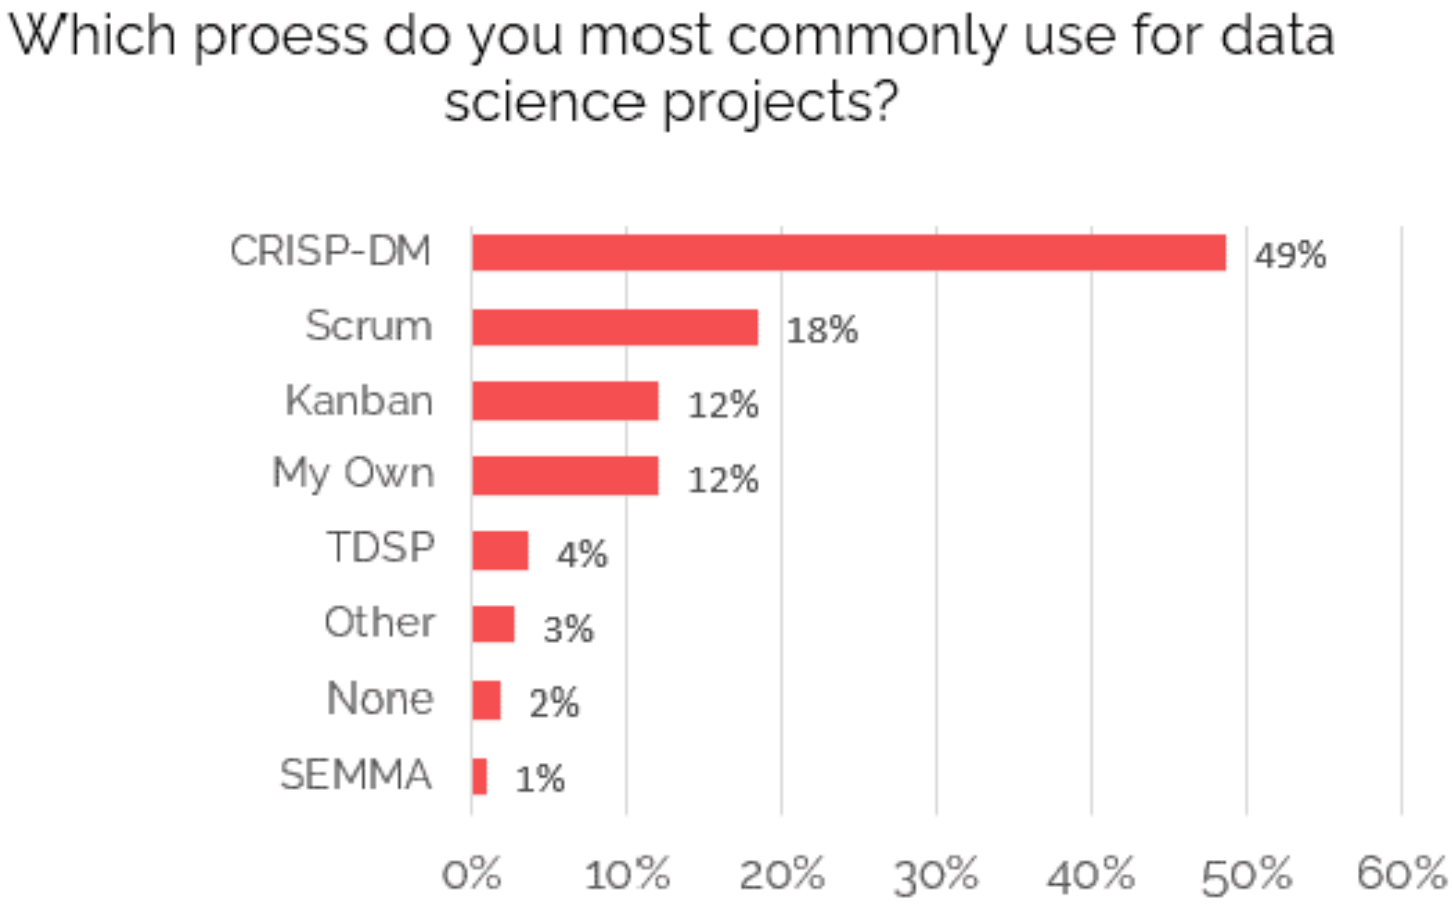
- Desarrollo de informes donde se especifican todas las cuestiones referidas al proyecto y los resultados a los cuales se ha llegado.

Se pueden realizar herramientas o software que faciliten la toma de decisiones.

Entonces...¿por qué CRISP-DM?

- El proceso es genérico, uniforme y estándar.
- Permite que se hable el mismo idioma entre los responsables.
- Es flexible, por lo que puede implementarse en múltiples escenarios que incluyan diversos tipos de problemas y de datos.
- Es independiente de las herramientas utilizadas
- Sus actividades bien definidas permiten comprender bien el curso.


What main methodology are you using for your analytics, data mining, or data science projects ?
[200 votes total]
2014 poll
2007 poll
CRISP-DM (86)
43%
42%
My own (55)
27.5%
19%
SEMMA (17)
8.5%
13%
Other, not domain-specific (16)
8%
4%
KDD Process (15)
7.5%
7.3%
My organizations' (7)
3.5%
5.3%
A domain-specific methodology (4)
2%
4.7%
None (0)
0%
4.7%



Data collected in 2020

Fuentes de consulta

- Chapman et al. 2001. CRISP-DM 1.0: Step-by-step data mining guide. SPSS. https://www.the-modeling-agency.com/crisp-dm.pdf
- Piatetsky (Kdnuggets). 2014. CRISP-DM, still the top methodology for analytics, data mining, or data science projects. https://www.kdnuggets.com/2014/10/crisp-dm-top-methodology-analytics-data-mining-dat html
- Prince Canuma. 2022. Data Science Project Management [The New Guide For ML Teams]. Neptune Blog. https://neptune.ai/blog/data-science-project-management