Unidad 2: Conocimiento de los Datos

Motivación
Descriptores Estadísticos
Visualización

Licencia Creative Commons
Atribución 4.0 Internacional

Motivación

La segunda fase de CRISP-DM es la encargada de conocer los datos disponibles en la organización para determinar si son adecuados para extraer conocimiento útil para la toma de decisiones.

Conocer los datos nos permite saber cuáles son las estrategias y actividades necesarias para la preparación de datos.

Además, el conocimiento de los datos permite extraer patrones de conocimiento obvios o triviales, como correlaciones simples entre variables.

Definiciones

Un **dato**, ejemplo, instancia, fila, u objeto, es una representación de una entidad determinada en el dominio del problema

Los datos se describen mediante **atributos**, dimensiones, variables o columnas, que representan características determinadas del objeto modelado.

Los datos que solo poseen un atributo se denominan **univariados**, mientras que los que poseen múltiples atributos se llaman **multivariados**.

El **tipo** de un atributo está determinado por el conjunto de posibles valores que puede tomar el mismo.

Tipos de atributos

Atributos Nominales

> “Relativo a los nombres”

> Pueden tomar símbolos o “nombres de cosas” como valor.

> Son generalmente conocidos como **categóricos**, porque representan categorías, códigos o estados de algún aspecto del dato.

Tipos de atributos

Atributos Nominales

> “Relativo a los nombres”

> Pueden tomar símbolos o “nombres de cosas” como valor.

> Son generalmente conocidos como **categóricos**, porque representan categorías, códigos o estados de algún aspecto del dato.

Ej: color de pelo, color de ojos, estado civil.

Aunque un atributo nominal puede consistir en valores numéricos, estos poseen una semántica categórica y no cuantitativa.

Tipos de atributos

Atributos Binarios

> Son un tipo especial de atributos nominales

> Solo poseen dos categorías o estados: 0 y 1

> También son llamados booleanos

Un atributo binario puede ser **simétrico**, si ambos valores poseen igual peso o importancia (Ej. Argentino o Extranjero), o **asimétrico**, si los valores son semánticamente dispares (Ej. Positivo o Negativo en un test de Cancer).

Tipos de atributos

Atributos Ordinales

> Son atributos nominales

> Los valores de este atributo poseen un orden determinado.

> Por ejemplo {Niño, Adolescente, Adulto, Anciano}

> Muchas veces la magnitud entre cada valor consecutivo no se conoce.

> Se puede calcular una distancia entre cada par de atributos.

> Se pueden obtener de la discretización de atributos continuos.

Se suelen usar números para codificar estos valores, sin embargo no pueden ser tratados como valores cuantitativos. Dicho esto, puede calcularse la moda y la mediana, pero no el promedio.

Tipos de atributos

Atributos Numéricos

> Un atributo numérico es cuantitativo.

> Se obtienen generalmente de mediciones.

> Se utilizan generalmente números reales o enteros.

Los atributos numéricos pueden ser intervalados (interval-scaled) o proporcionados (ratio-scaled)

Tipos de atributos

Atributos Intervalados

> Sus valores se encuentran en una escala de valores que se encuentran a la misma distancia entre si.

> Estos valores son ordenados, y pueden ser positivos, negativos o cero.

> Se puede calcular una diferencia entre valores.

Ej. Temperatura en Celcius, fechas de calendario

Tipos de atributos

Atributos ratio-scaled

> Atributos numéricos con un “cero” absoluto.

> Los valores son ordenados

> Se puede calcular la diferencia entre dos valores, así como otras medidas (promedio, mediana, etc.)

Un ejemplo es la temperatura en Kelvin (cuyo cero absoluto 0K=-273.15°C), atributos de conteo como “años de experiencia” o “cantidad de palabras”, o atributos como “peso”, “largo”, “ancho”, “latitud”, “longitud” o “precio”.

Tipos de atributos

Discretos Vs Continuos

Para algunos algoritmos es útil clasificar a los atributos en Discretos y Continuos.

Los atributos discretos tienen un conjunto **finito** o **infinito contable** de valores, que pueden o no ser enteros.

Si el atributo no es discreto entonces es continuo, y generalmente representan números reales.

Descriptores básicos

Es necesario tener una idea general de como se comporta el conjunto de datos.

Los descriptores estadísticos son utilizados para identificar propiedades de los datos y encontrar ruido o anomalías.

A continuación se presentan medidas de tendencia central (promedio, mediana y moda) y medidas de dispersión de los datos.

Medidas de tendencia central

Promedio ($\bar{x}$)

Sea un conjunto de n observaciones x_1, x_2, ..., x_n para un atributo numérico X (como la edad o el sueldo), el valor promedio es:

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + ... + x_n}{n}$$

Sin embargo, el promedio es una medida muy sensible a los extremos u anomalías. Un número muy pequeño de observaciones pueden perturbar el valor promedio del atributo.

Como respuesta a este problema, se suele usar la Mediana.

Medidas de tendencia central

Mediana

Para datos asimetricos la mediana es una medida mas realista del centro de la distribución.

La mediana es el valor que parte al conjunto de datos (ordenado) en dos subconjuntos de igual tamaño.

Generalmente la media aplica para datos numéricos, sin embargo se puede extender a datos ordenados.

Si la cantidad de datos es par, la mediana corresponde al promedio entre los puntos extremos de ambos intervalos.

Medidas de tendencia central

Moda

La moda de un atributo es el valor con mayor frecuencia dentro de las observaciones.

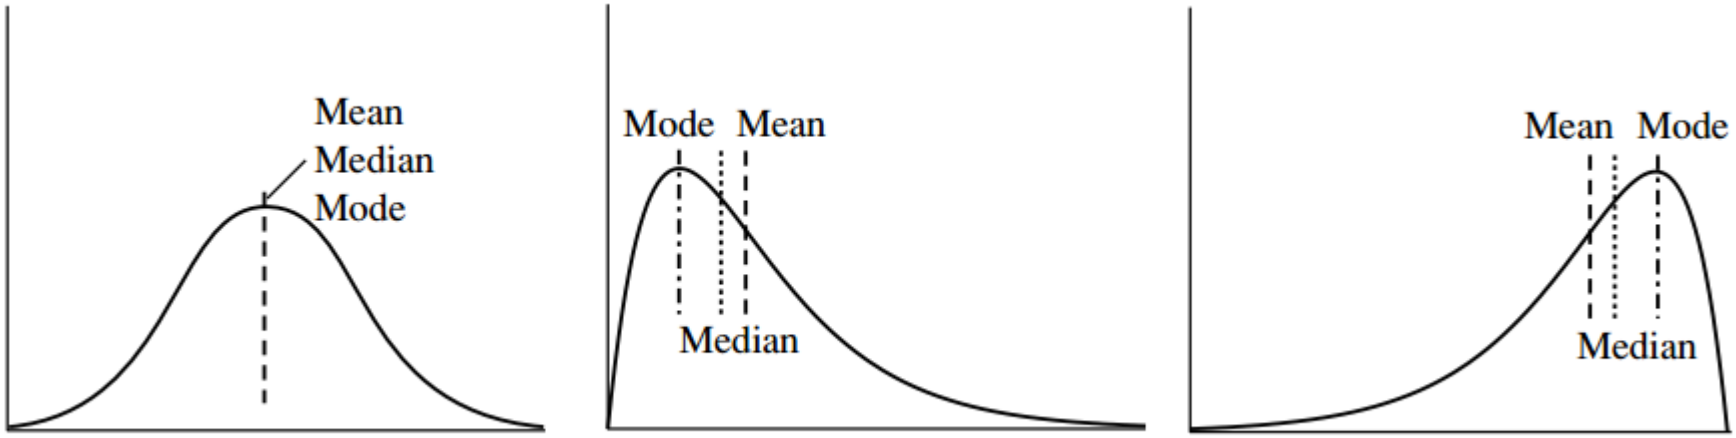
Puede calcularse tanto para datos cualitativos como cuantitativos.

Si la frecuencia coincide entre dos o mas atributos, se dice que el atributo es multimodal.

La moda puede no existir si todos los valores tienen la misma frecuencia.

Medidas de tendencia central

Utilizando estas medidas es posible determinar si las observaciones posee sesgos.



(a) Symmetric data **(b)** Positively skewed data **(c)** Negatively skewed data

Medidas de dispersión

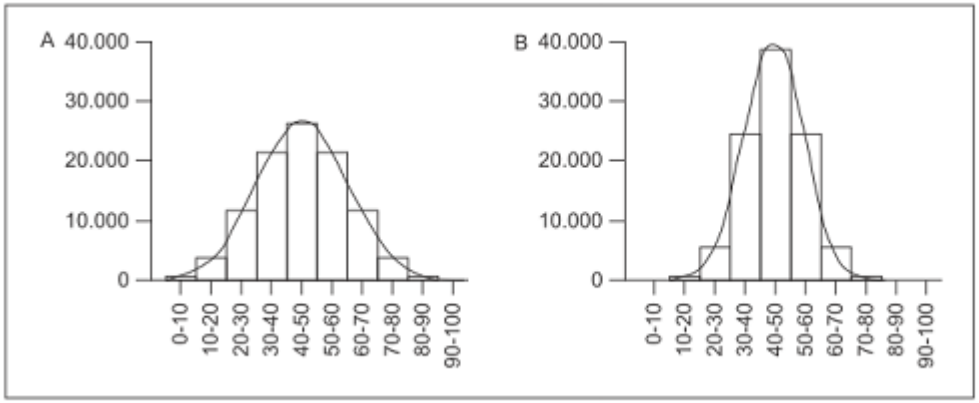
Además de determinar cuales son los valores de tendencia central, es necesario calcular que tan dispersos están los datos alrededor de estos valores centrales.

Entre estas medidas se incluyen:

> Rangos y cuartiles

> Varianza

> Desviación estándar



Medidas de dispersión

Varianza y desviación estándar

> Indican que tan esparcidos están los datos

> La varianza es una medida que muestra la distancia promedio (al cuadro) hacia la media general de las observaciones.

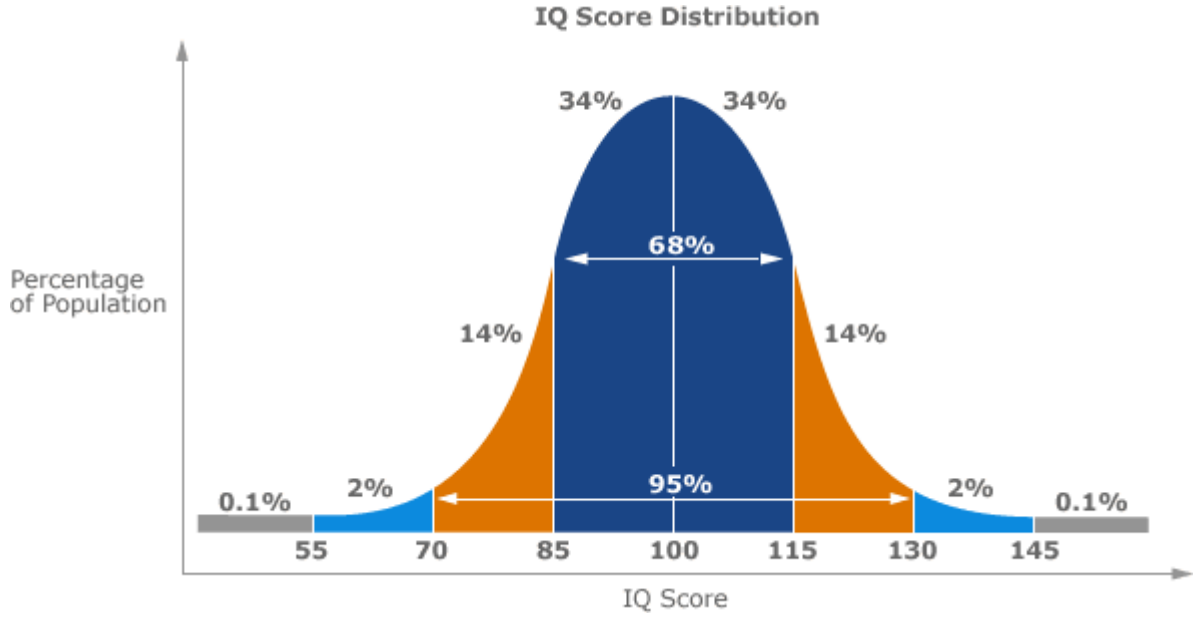
> La desviación estándar es la raíz cuadrada de la varianza.

$$\sigma^2 = \frac{1}{n} \sum_{1}^{n} \left(x_i - \bar{x} \right)^2$$

Medidas de dispersión

Varianza y desviación estándar

Utilizando la desviación estándar como criterio, es posible identificar OUTLIERS o valores atípicos en los datos.



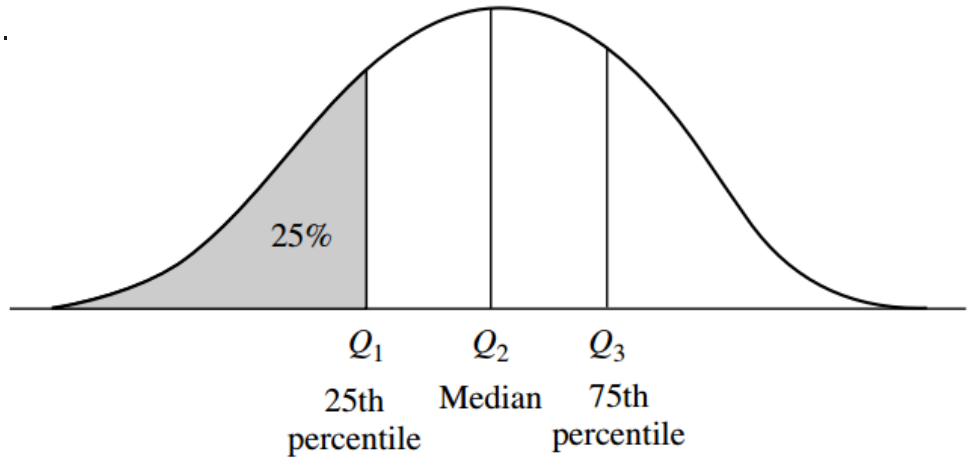
Medidas de dispersión

Rango y cuartiles

> Sea un conjunto de observaciones x_i , i = 1..n , el rango es la diferencia entre el valor máximo y el valor mínimo.

> Los cuartiles son aquellos datos que dividen el rango en 4 secciones de igual tamaño (25% de los datos en cada una).

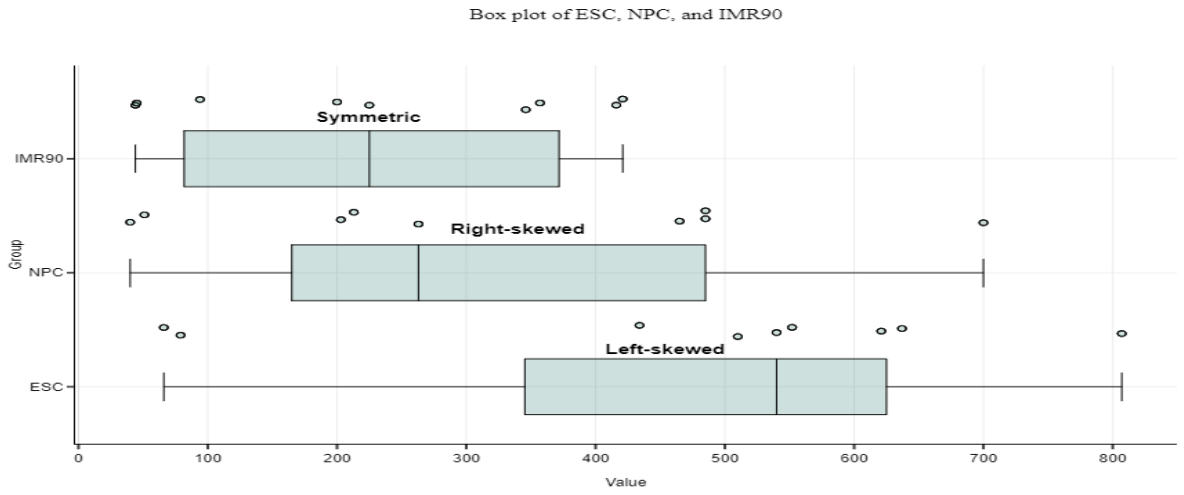
> Los cuartiles dan una medida del centro, la dispersión y la forma de una distribución.



Visualización

Estas medidas permiten conocer a los datos aislando cada uno de sus atributos.

Estas cuestiones son más sencillas de observar en gráficos especializados (Ej. boxplots).



Material de consulta

> Han et al. 2012. Data Mining: concepts and techniques. Capítulo 2.1, 2.2

> Aggarwal. 2015. Data Mining: The textbook. Capítulo 1.3