Unidad 2: Visualización de datos

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

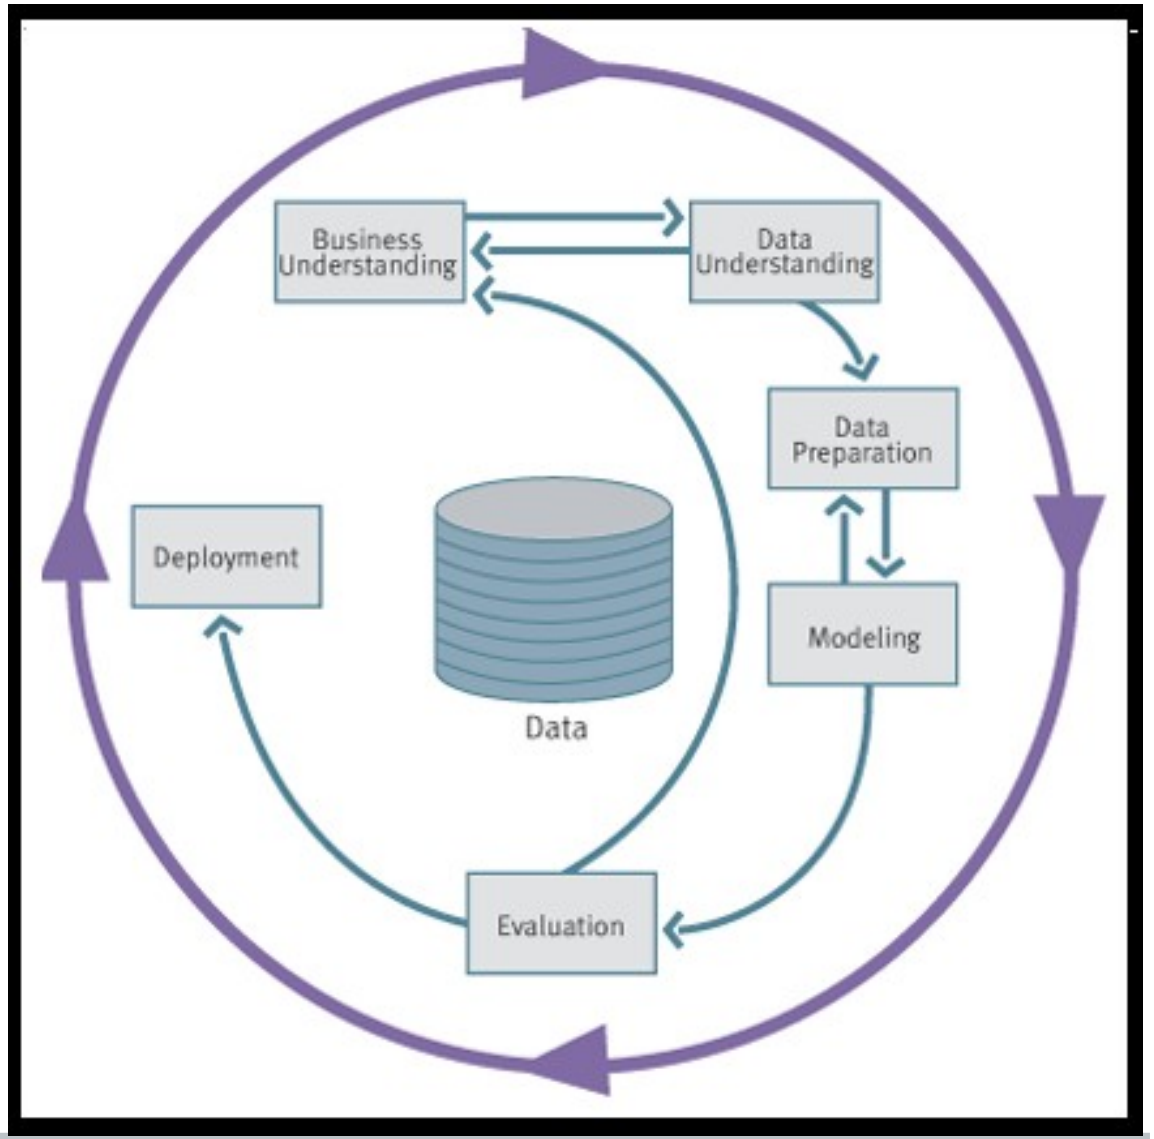
Recordando...

El conocimiento de los datos es un paso importante que se debe dar previo a cualquier actividad de procesado o minería de datos.

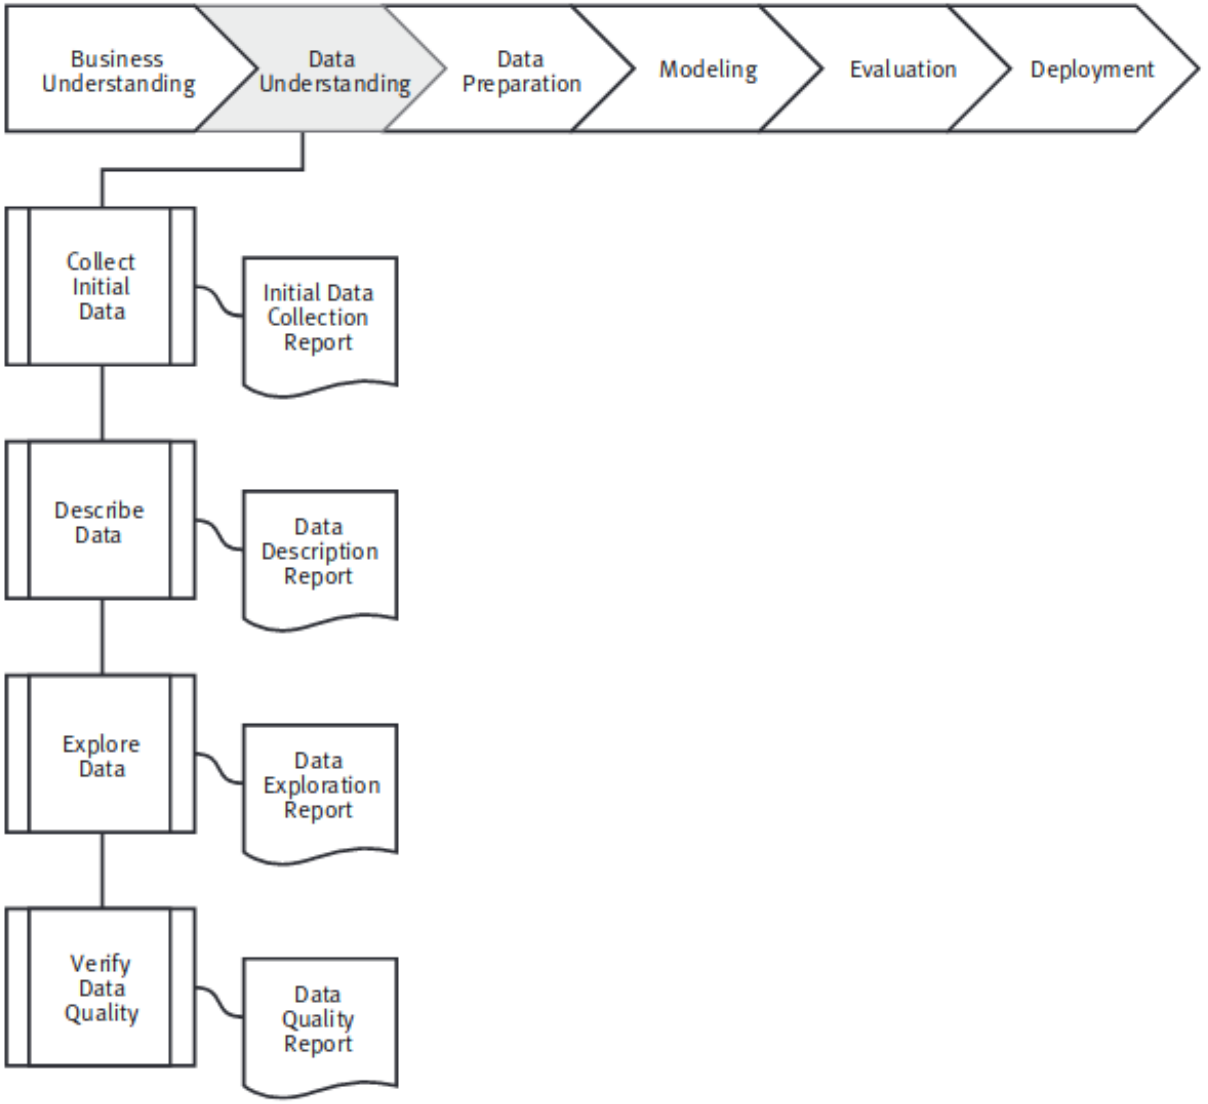
Esta fase de CRISP-DM nos permite tener en consideración las particularidades de cada uno de los atributos.

Sabemos con que estamos trabajando, que podemos esperar del conjunto de datos, y qué actividades serán necesarias para dejar los datos en condiciones de ser minados.

CRISP-DM


Business Understanding
Data Understanding
Data Preparation
Modeling
Evaluation
Deployment
Data

Data Understanding



Descripción de los datos

Los datos utilizados deben ser descriptos en su totalidad. Todos los intervinientes del proyecto deben saber la semántica detrás de cada uno de los atributos.

Desde la fuente de los datos y el mecanismo de obtención de los mismos, hasta las estadísticas de cada uno de sus atributos, debe constar para poner en conocimiento a cada parte interviniente de las características del dataset.

Para la descripción de los atributos se suele hacer uso de medidas de tendencia central y medidas de dispersión.

Descripción de los datos

Medidas de tendencia central

Descripción de los datos

Medidas de tendencia central

Las medidas de tendencia central nos permiten determinar cual es el comportamiento esperado de los datos. Esto es, si los valores se acumulan entorno a algún valor de referencia (media, mediana, moda).

Descripción de los datos

Medidas de tendencia central

Las medidas de tendencia central nos permiten determinar cual es el comportamiento esperado de los datos. Esto es, si los valores se acumulan entorno a algún valor de referencia (media, mediana, moda).

Medidas de dispersión

Descripción de los datos

Medidas de tendencia central

Las medidas de tendencia central nos permiten determinar cual es el comportamiento esperado de los datos. Esto es, si los valores se acumulan entorno a algún valor de referencia (media, mediana, moda).

Medidas de dispersión

Nos permiten conocer cual es la distancia promedio de los valores a la medida de tendencia central considerada.

(Varianza, desviación estándar, cuartiles)

Exploración de los datos

En el análisis exploratorio nos valdremos de las medidas obtenidas anteriormente para sacar conclusiones.

Sin embargo, muchas veces las tendencias que se dan entre los datos son difíciles de apreciar al ver números y resultados.

Por esto, la visualización de datos nos da una mano.

Visualización

¿Qué es?

La visualización es una herramienta para representar los datos de forma visual.

La visualización busca comunicar de forma clara y eficiente mediante gráficos estadísticos, imágenes, tablas, entre otros.

El presentar los datos mediante una herramienta gráfica es posible comprender más fácilmente como se comportan estos datos.

Visualizaciones básicas de Descriptores

Existen algunos gráficos que ayudan a representar visualmente las medidas estadísticas que describen los datos.

> Univariado:

- Histogramas
- Boxplots

> Multivariado

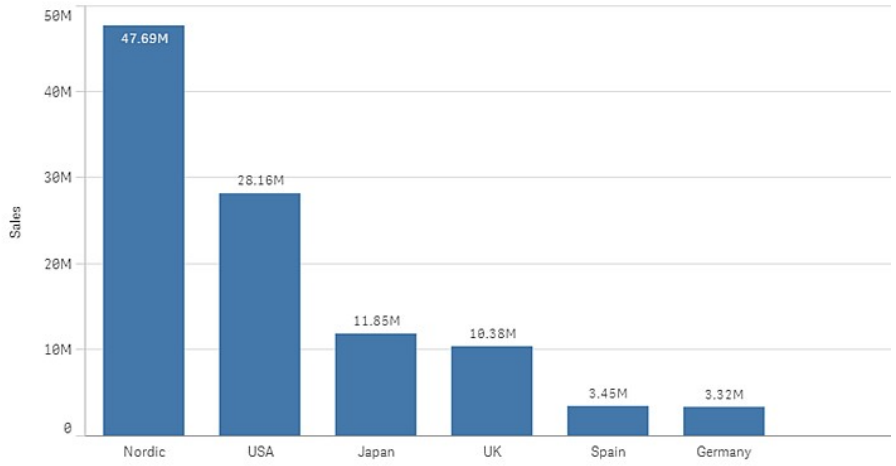
- Gráfico de Dispersión (Scatterplot)
- Matriz de Dispersión (Scatterplot Matrix)

Histogramas

Histo-grama (diagrama de postes)

Es un gráfico de muestra la distribución de frecuencia de un atributo determinado.

Si el atributo es nominal, la altura de la barra muestra la frecuencia de ocurrencia de cada uno de los valores del dominio.



Este gráfico también es conocido como Gráfico de Barras si hablamos de este tipo de atributo.

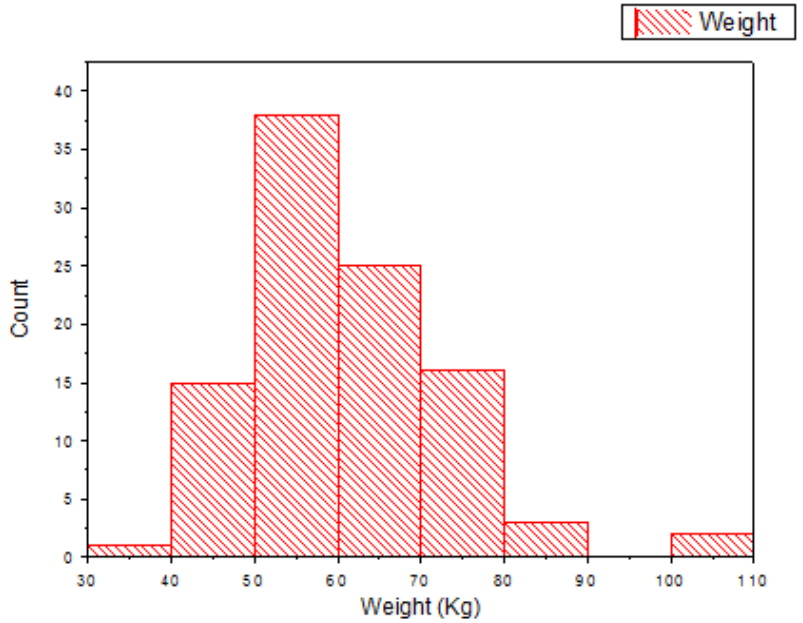
Histogramas

Si el atributo modelado es numérico, se prefiere el término Histograma.

El rango de valores que toma el atributo es discretizado en n subrangos (bins).

Típicamente, los subrangos

son de igual tamaño o ancho.



Boxplot

Box-plot (Diagama de cajas)

También es llamado gráfico de bigotes.

Debido a que los cuartiles no muestran información sobre los puntos extremos de la distribución, se utiliza un resumen de 5 números para describir los datos:

Mediana (Q2), Q1, Q3, Máximo, Mínimo.

Los box-plots muestran estos valores de la siguiente forma:

Boxplot

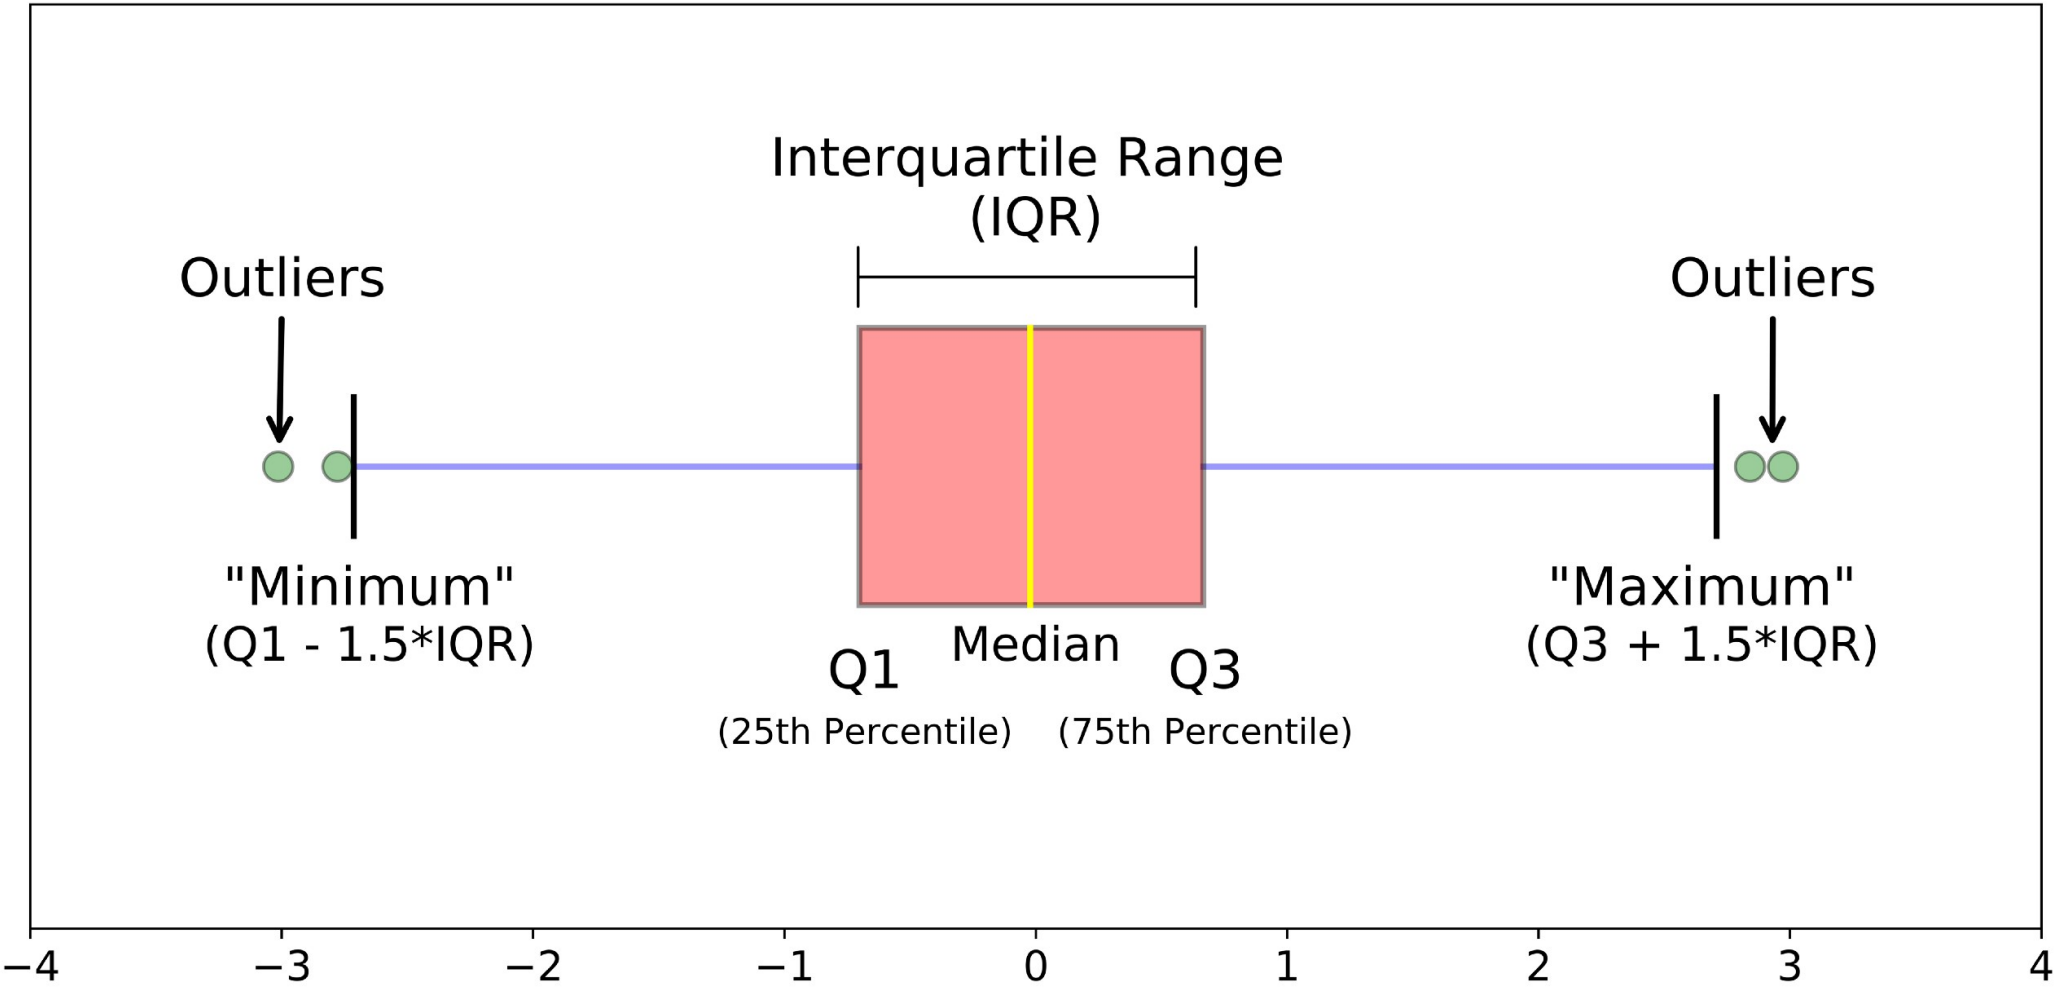
> Generalmente, los extremos de la caja están dados por los cuartiles **Q1** y **Q3**, por lo que la caja representa el rango intercuartil.

> La **mediana** (Q2) está representada dentro de la caja.

> Dos líneas o bigotes fuera de la caja se extienden hacia los valores **máximo** y **mínimo** de la distribución, si estos valores no superan 1.5 del rango intercuartil.

> Los valores que quedan fuera de los bigotes son **outliers**.

¿Cómo se lee?


Interquartile Range
(IQR)
Outliers
Outliers
"Minimum"
(Q1 - 1.5*IQR)
"Maximum"
(Q3 + 1.5*IQR)
Q1
Median
Q3
(25th Percentile)
(75th Percentile)
−4
−3
−2
−1
0
1
2
3
4

Boxplot: ejemplo

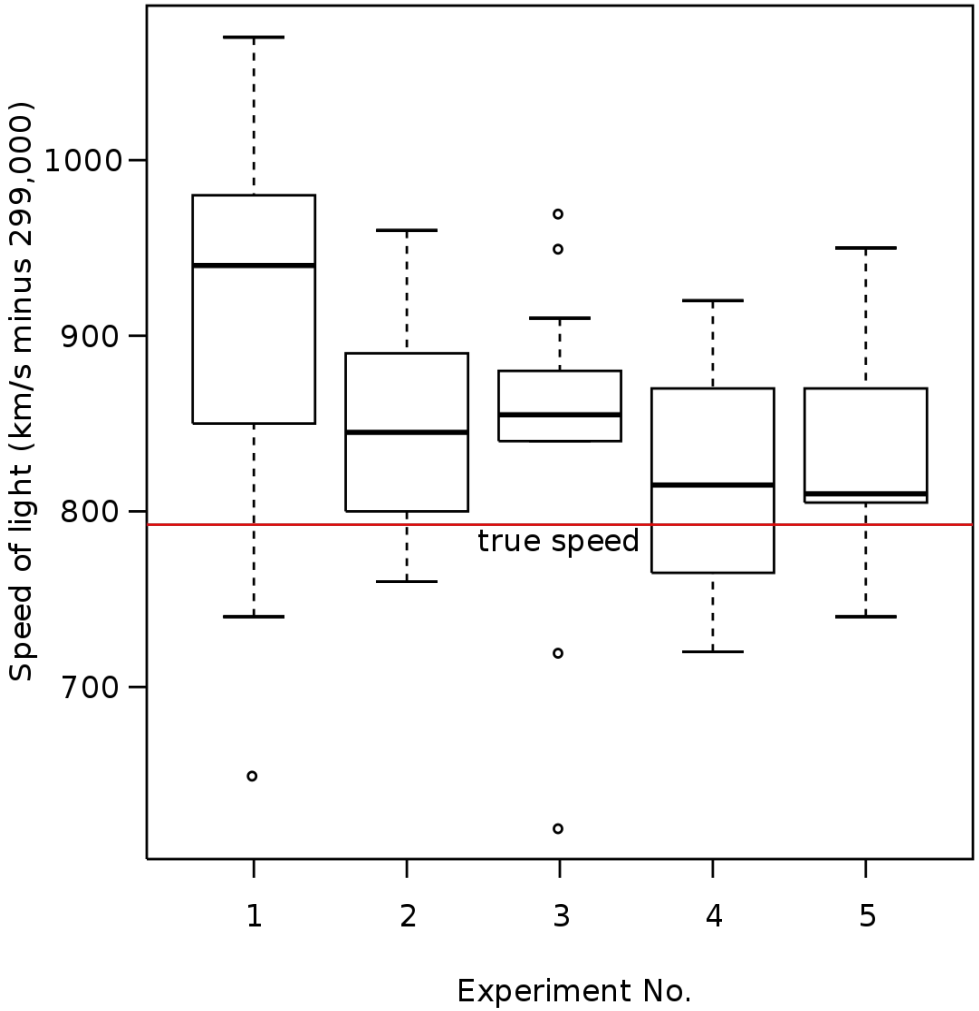


Gráfico de dispersión

Scatterplot

Es utilizado para observar si existe una correlación o patrón entre dos atributos numéricos dados.

Cada par de valores es tratado básicamente como un par de coordenadas y representado en un plano.

Los scatterplot además pueden mostrar si existen grupos o clusters de puntos u anomalías.

Grafico de dispersión

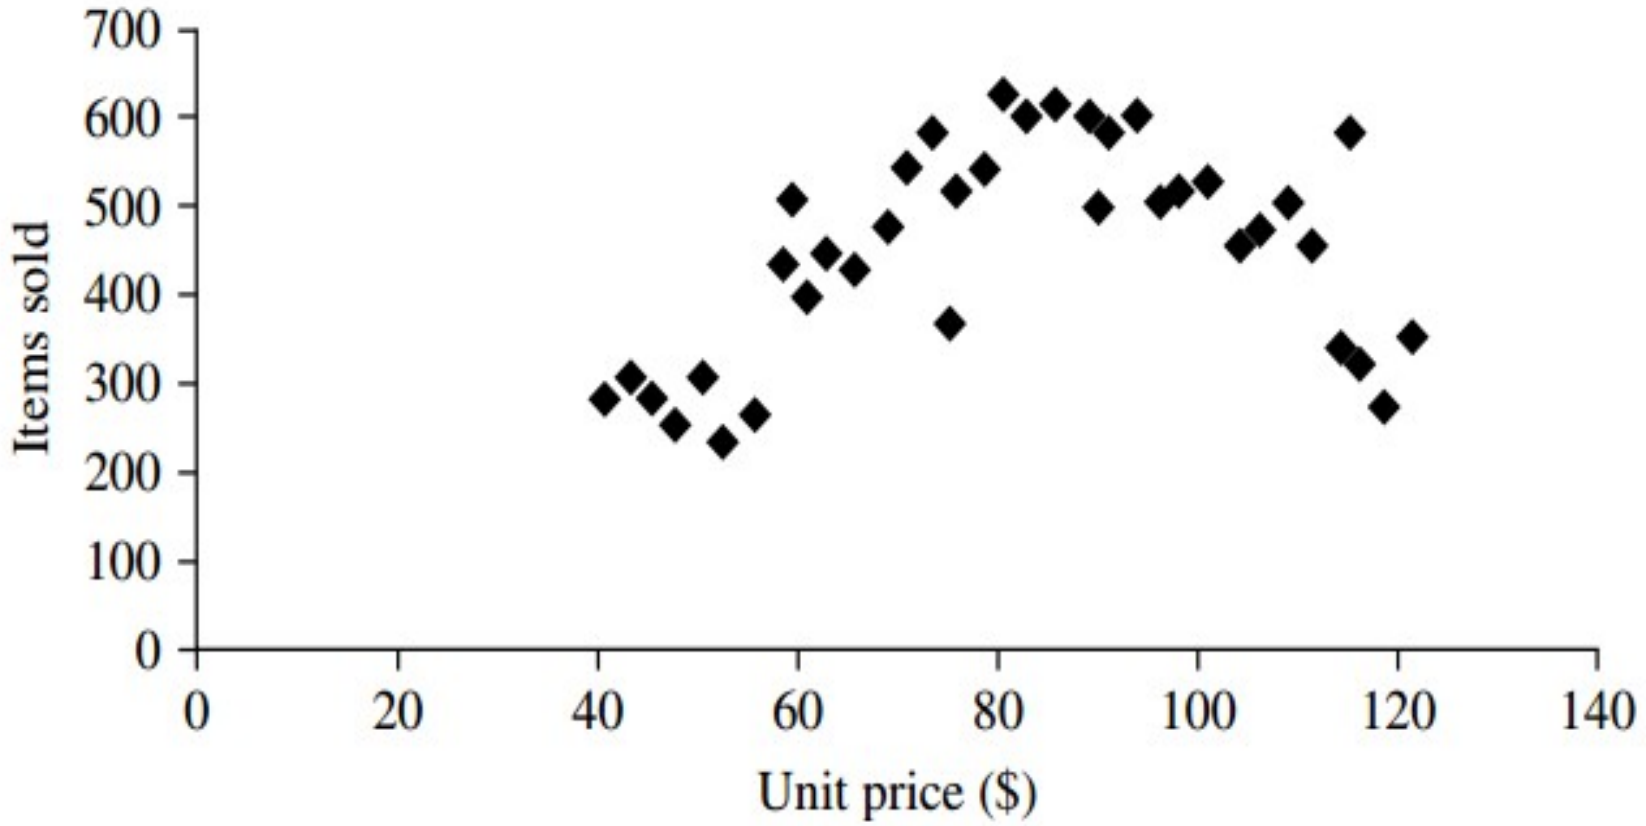
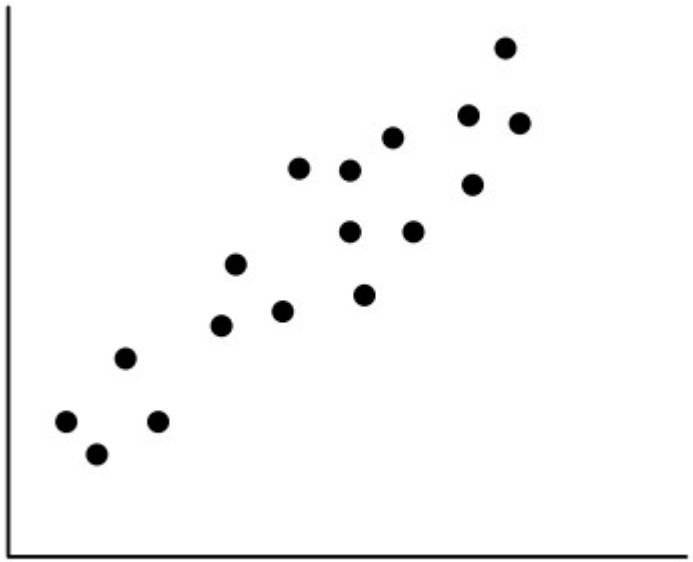
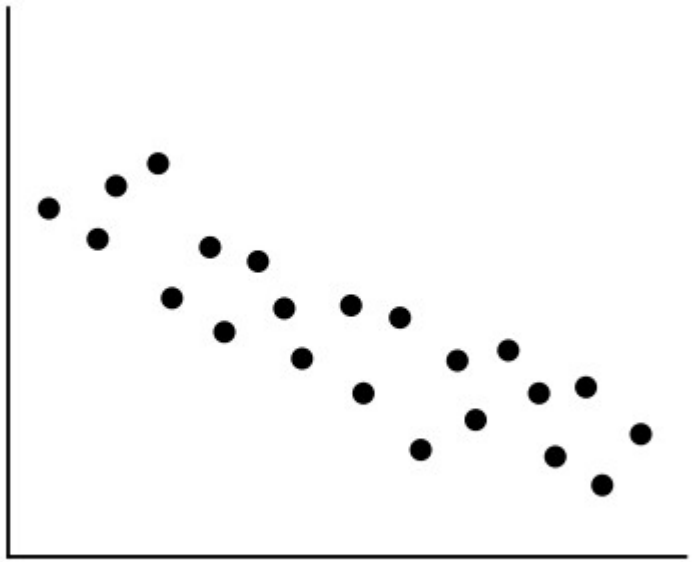


Gráfico de dispersión



(a)



(b)

Gráfico de dispersión

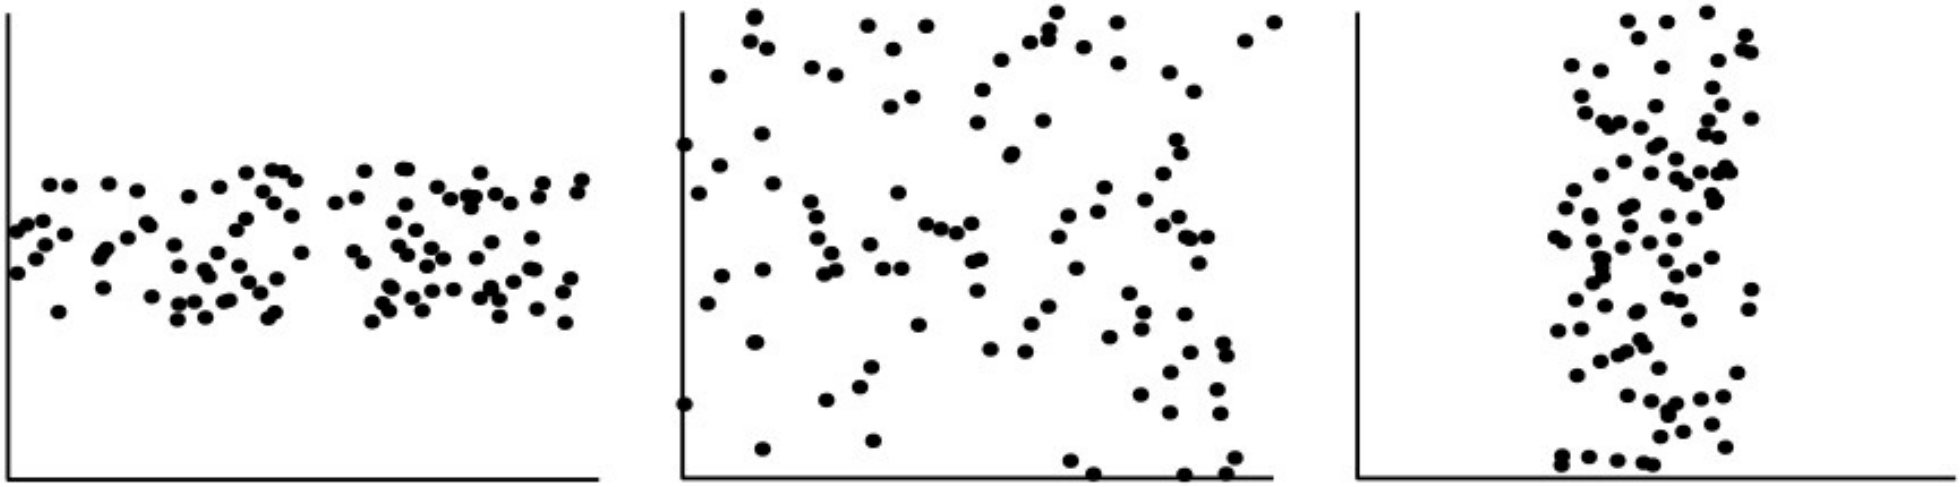


Gráfico de dispersión

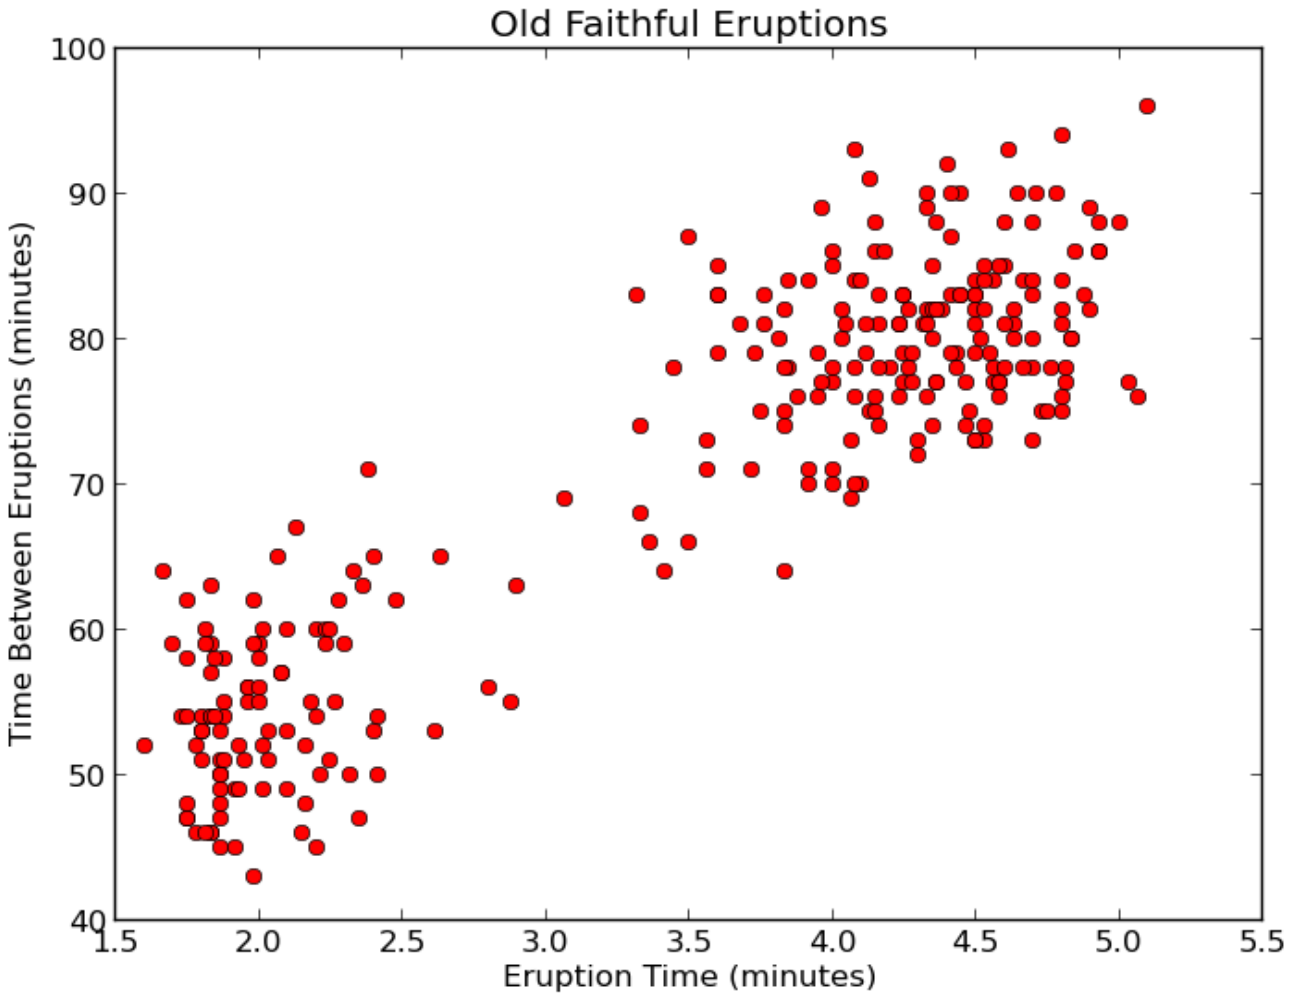
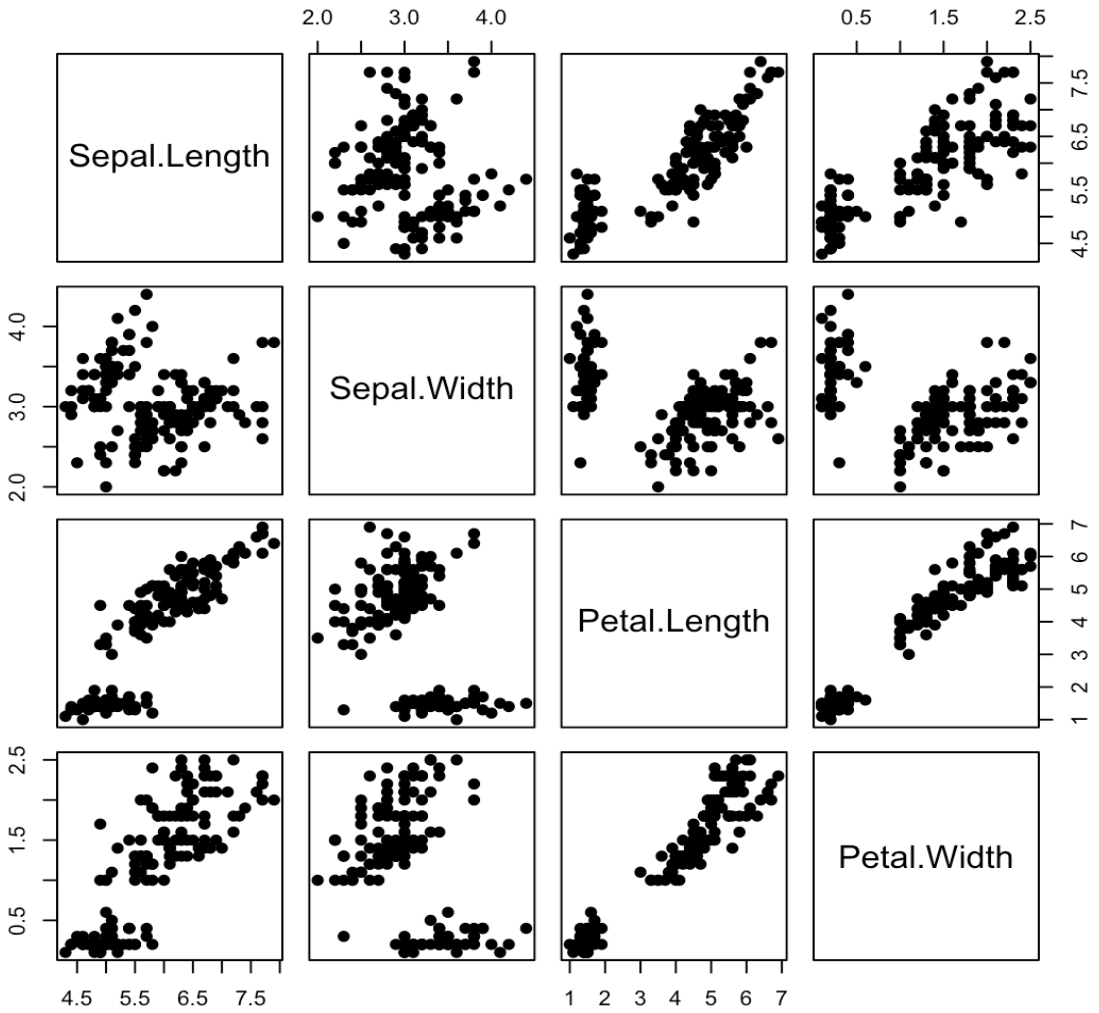


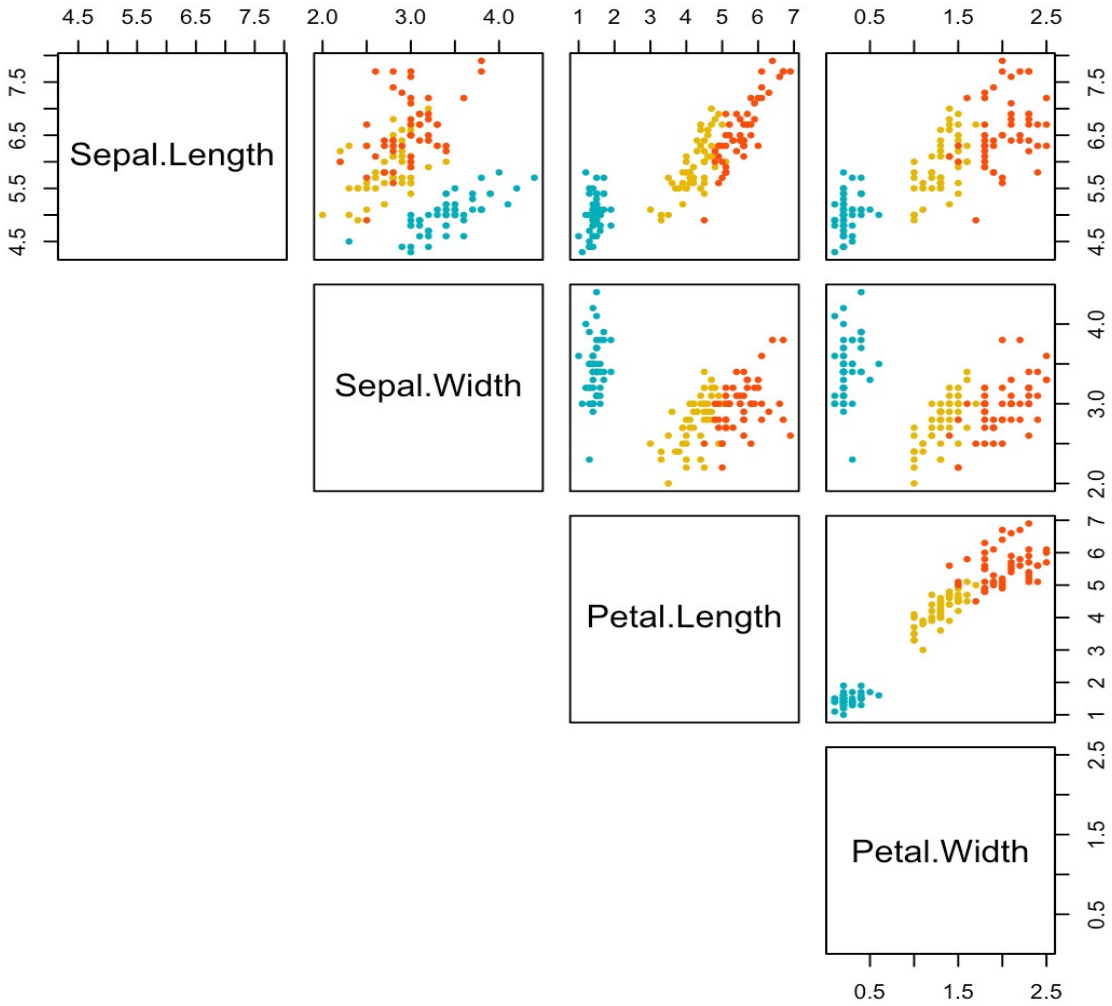
Gráfico de dispersión

¿Y si tenemos más de dos variables?

Scatterplot matrix



Scatterplot matrix



Dimensiones extra

Es posible agregar información a los gráficos codificada como color, forma, tamaño, entre otros.

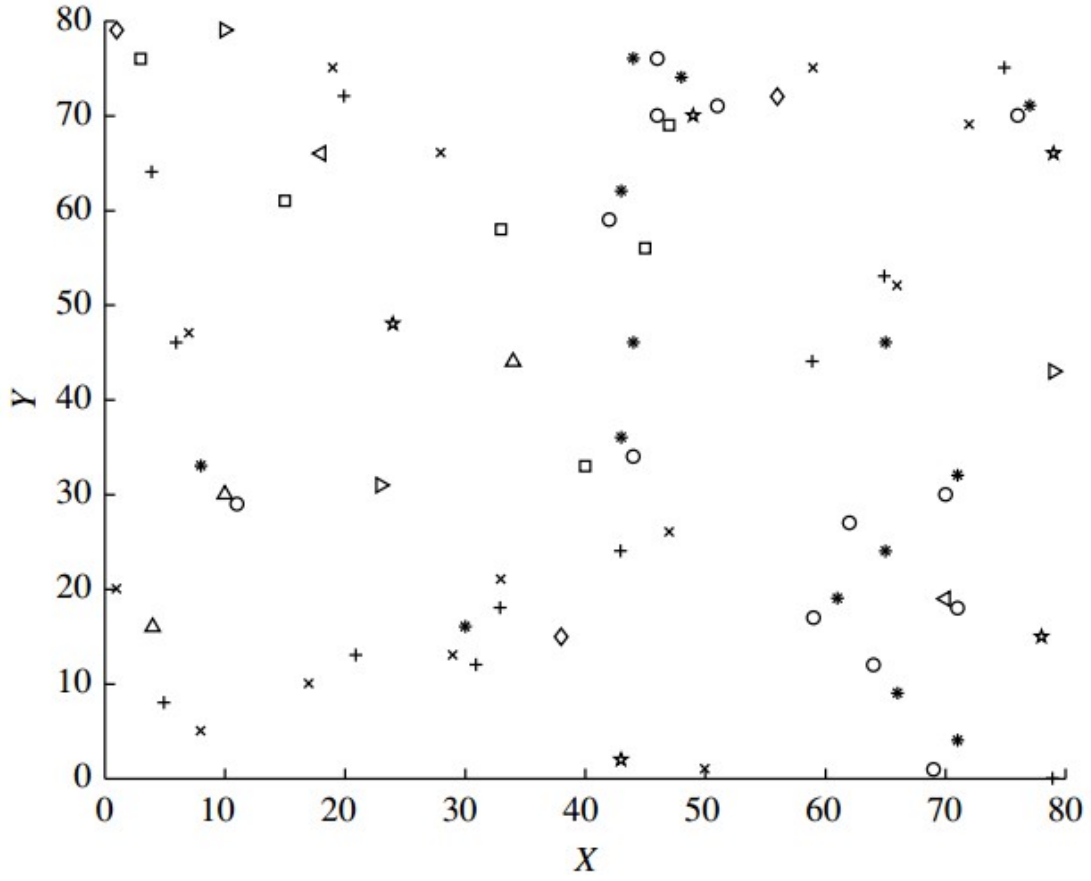
Ej.

Dimensiones extra

Es posible agregar información a los gráficos codificada como color, forma, tamaño, entre otros.

Ej.

Se agrega una dimensión extra utilizando distinta forma para cada valor de la misma.

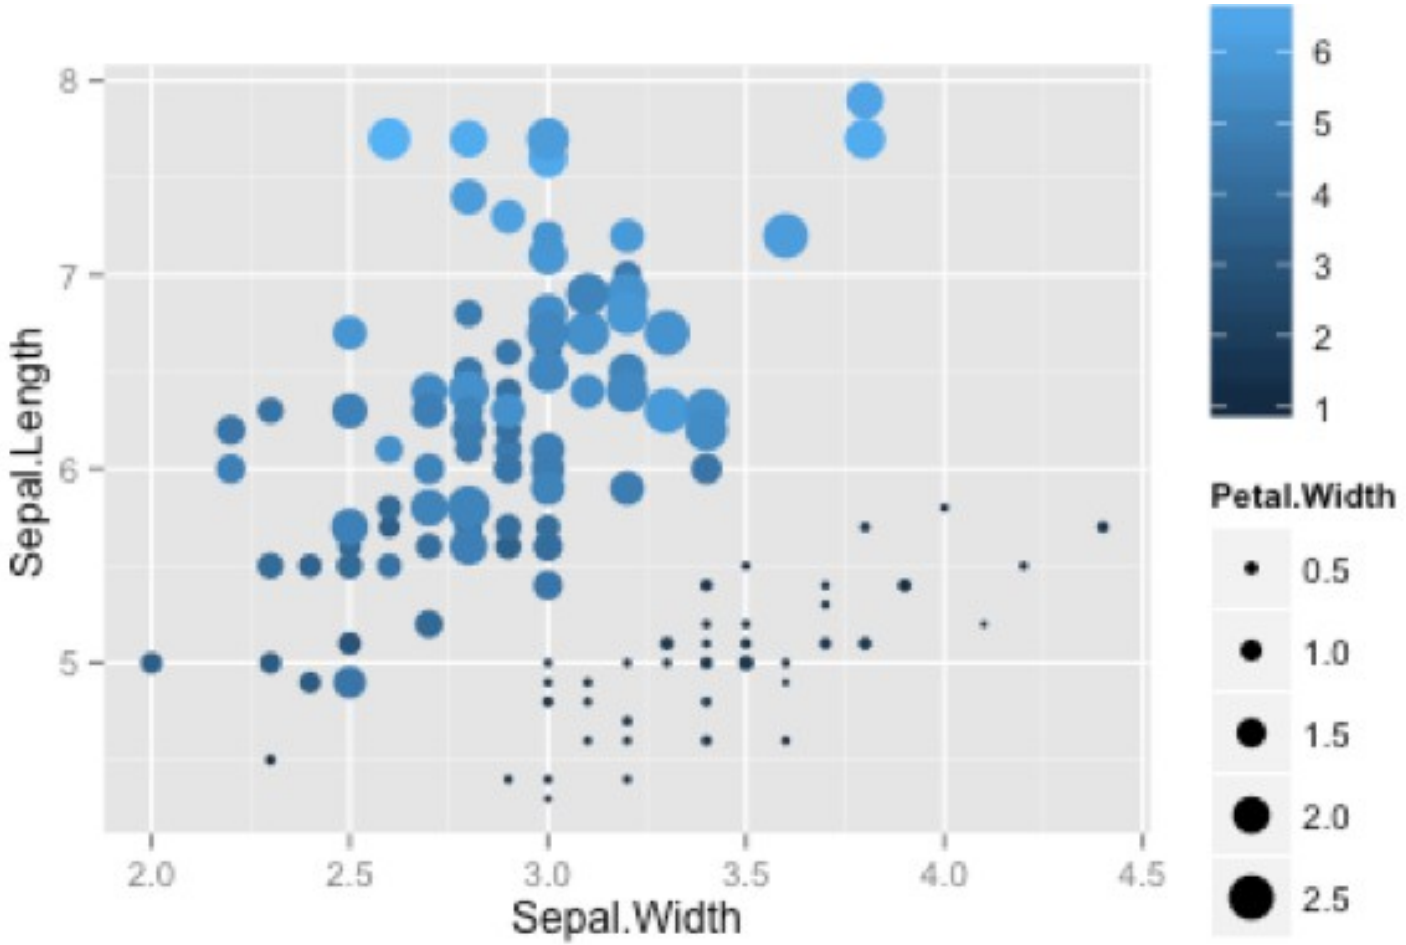


Dimensiones extra

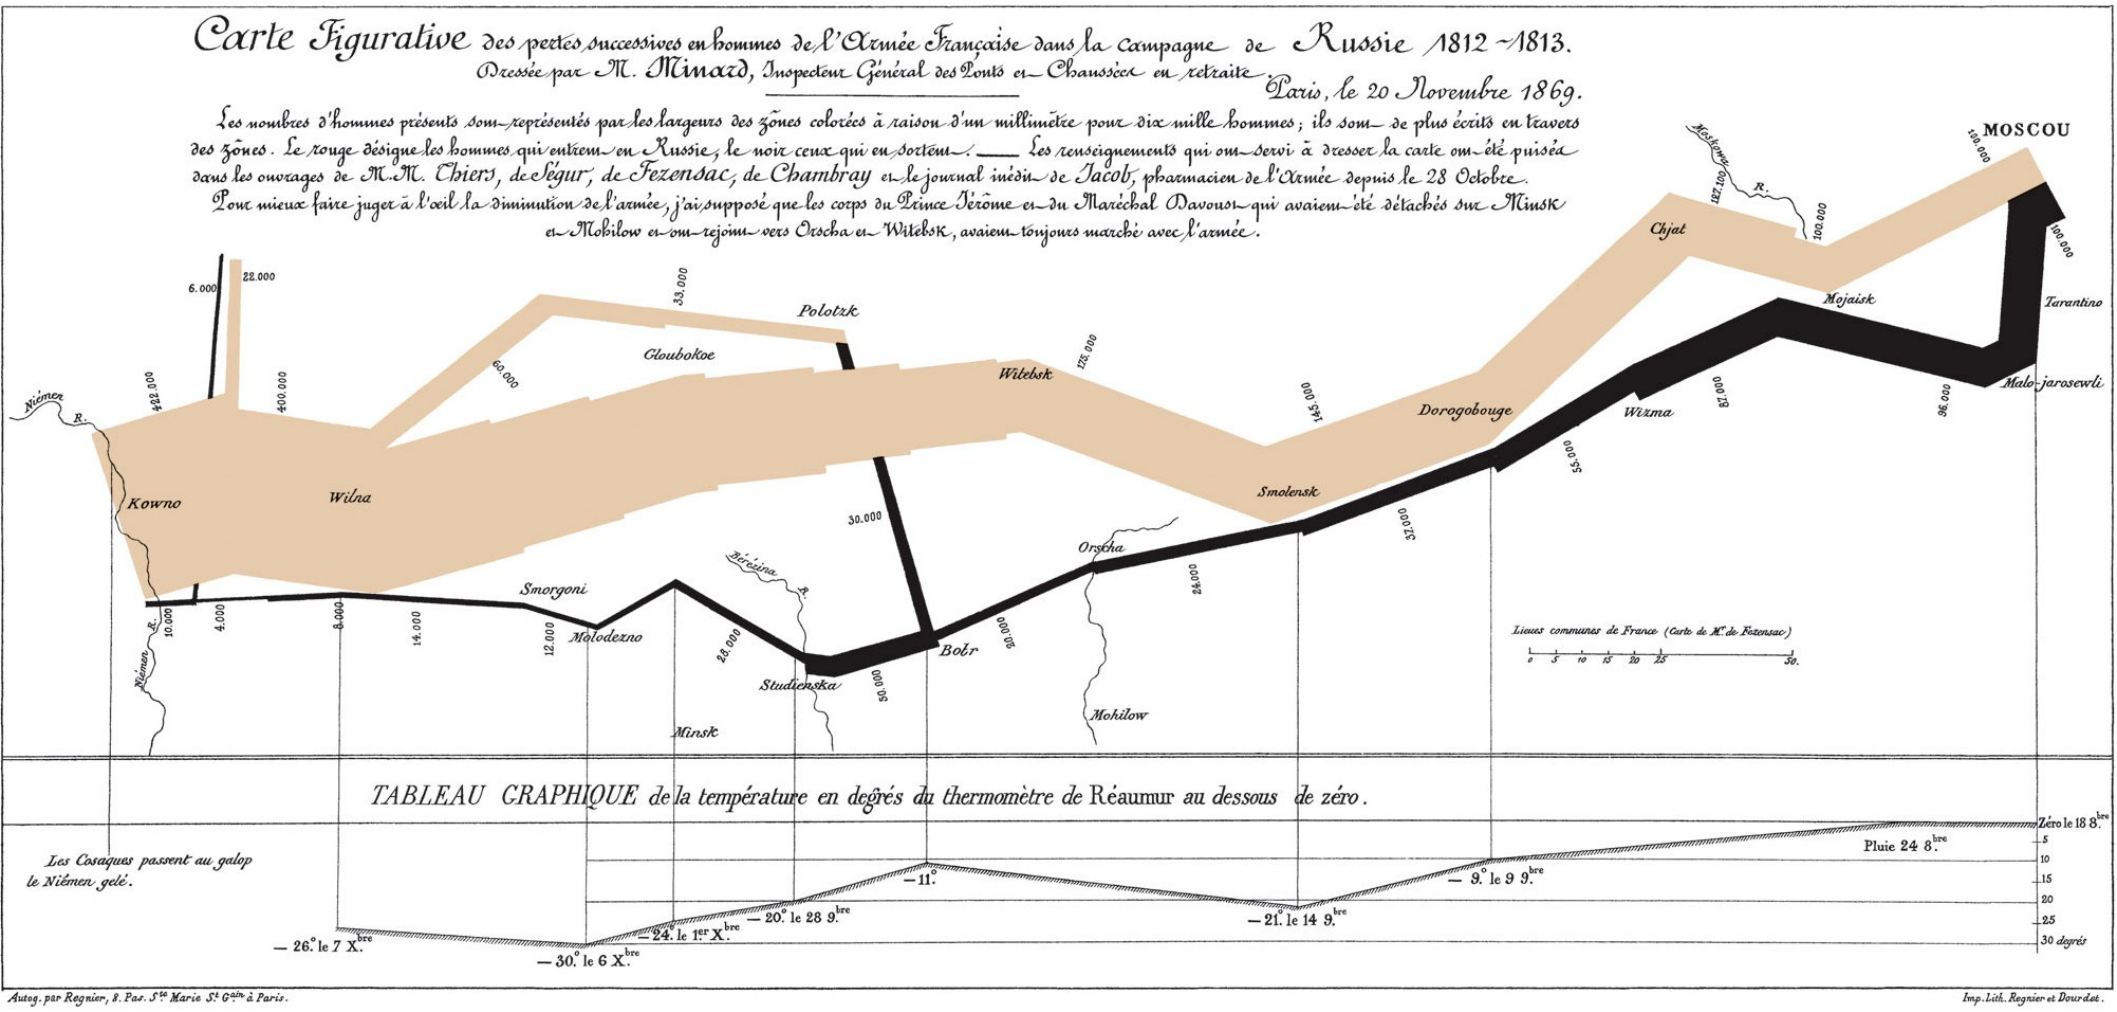
Heatmaps

	Monday	Tuesday	Wednesday	Thursday	Friday	Saturday	Sunday
0	6.00	7.35	11.79	9.82	13.93	7.60	9.10
1	3.73	7.29	7.88	6.62	8.73	5.58	5.63
2	3.44	7.31	5.29	4.23	3.98	3.70	3.06
3	3.67	7.02	3.69	3.12	1.27	2.77	1.94
4	3.81	5.50	1.92	2.65	1.42	3.55	2.29
5	4.54	3.67	1.29	2.48	2.63	5.40	3.58
6	5.52	3.46	3.46	3.67	3.68	6.53	4.33
7	5.75	6.15	7.33	6.23	5.70	6.58	4.85
8	7.94	10.46	10.79	10.40	8.92	6.10	6.25
9	13.58	14.08	14.29	14.13	11.97	7.10	7.38
10	18.77	16.27	18.83	15.70	15.02	10.10	8.23
11	21.00	17.52	24.77	15.25	18.60	12.68	10.10
12	21.13	18.38	31.77	15.27	22.12	13.88	12.60
13	22.54	20.38	36.85	18.55	23.77	14.35	12.81
14	27.02	24.02	37.40	24.62	23.70	14.28	10.15
15	30.52	26.58	33.00	30.13	23.13	13.20	8.15
16	29.42	25.77	25.56	29.78	20.40	11.62	9.46
17	23.67	22.81	19.04	23.28	15.42	11.65	12.63
18	17.88	19.79	15.23	17.08	11.15	13.13	13.92
19	16.38	16.69	14.06	16.17	9.93	13.78	12.04
20	16.04	13.21	14.75	18.90	10.08	13.25	9.58
21	13.77	11.92	14.96	20.88	9.62	12.92	9.69
22	10.48	13.98	14.38	20.17	8.92	12.66	10.98
23	8.00	14.69	13.27	17.85	8.48	11.43	9.58

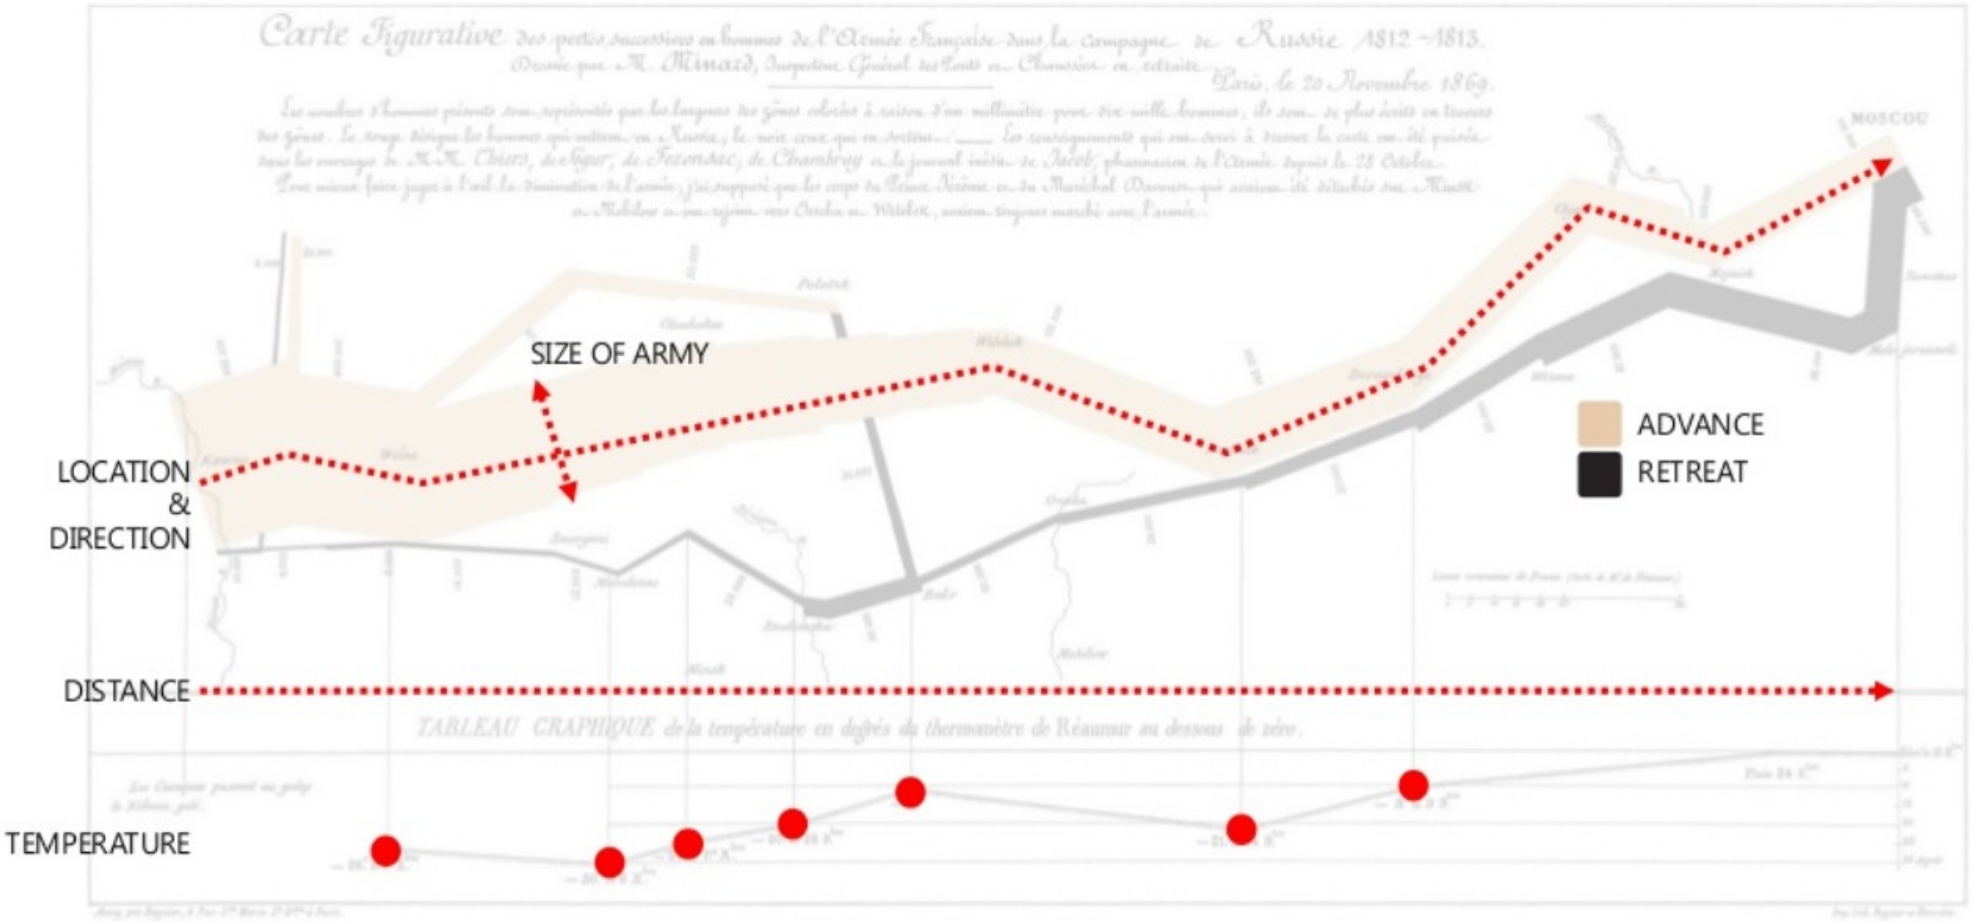
Dimensiones extra



Dimensiones extra

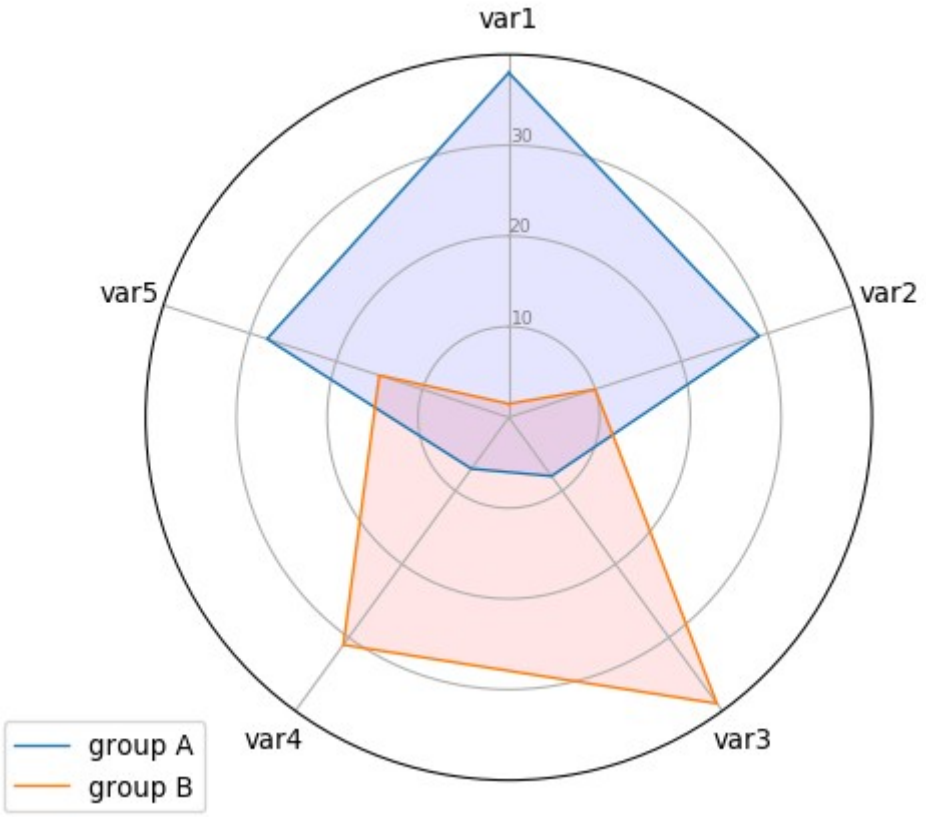


Dimensiones extra



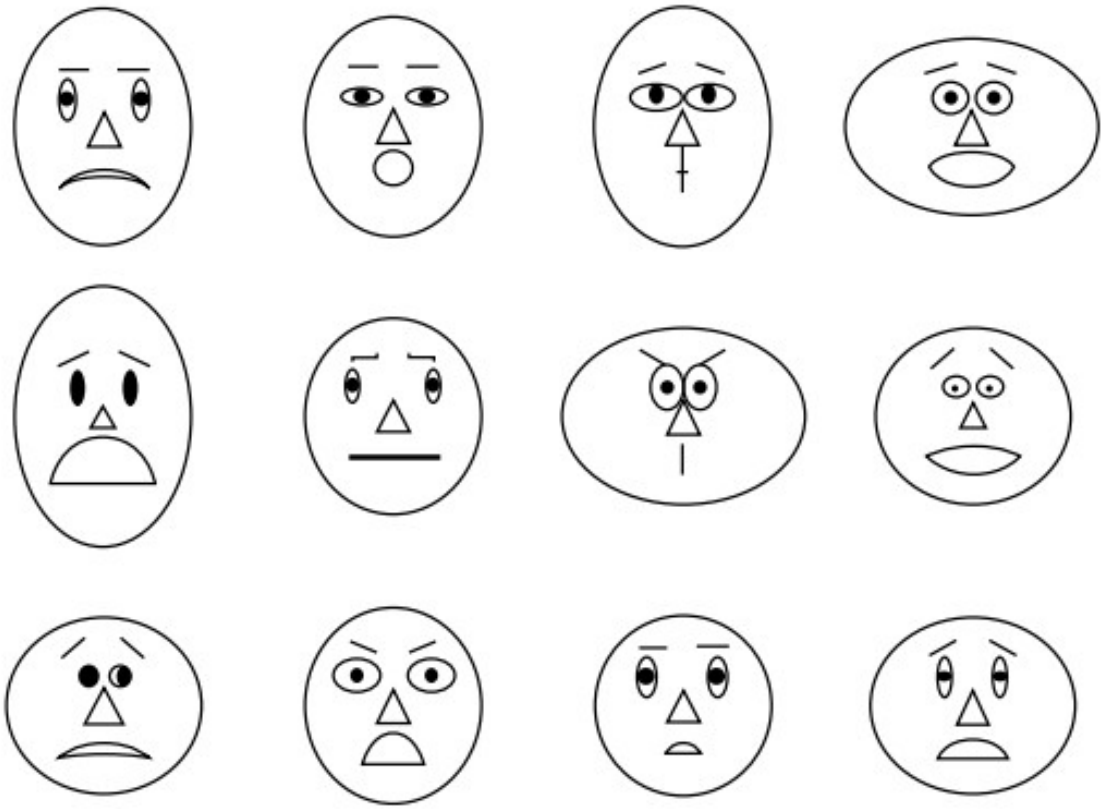
Dimensiones extra

Gráfico radial



Dimensiones extra

Caras de Chernoff (n<19)



Gráficos interactivos

Nombres de bebés

http://www.babynamewizard.com/voyager

Ediciones de Orígenes de las Especies

http://benfry.com/traces/

Coronavirus COVID-19 Global Cases by the Center for Systems Science and Engineering

https://gisanddata.maps.arcgis.com/apps/opsdashboard/index.html#/bda7594740fd40299423467b48e9ecf6

Material de consulta

Han et al. (2012). Data mining: concepts and techniques. Capítulo 2.2, 2.3