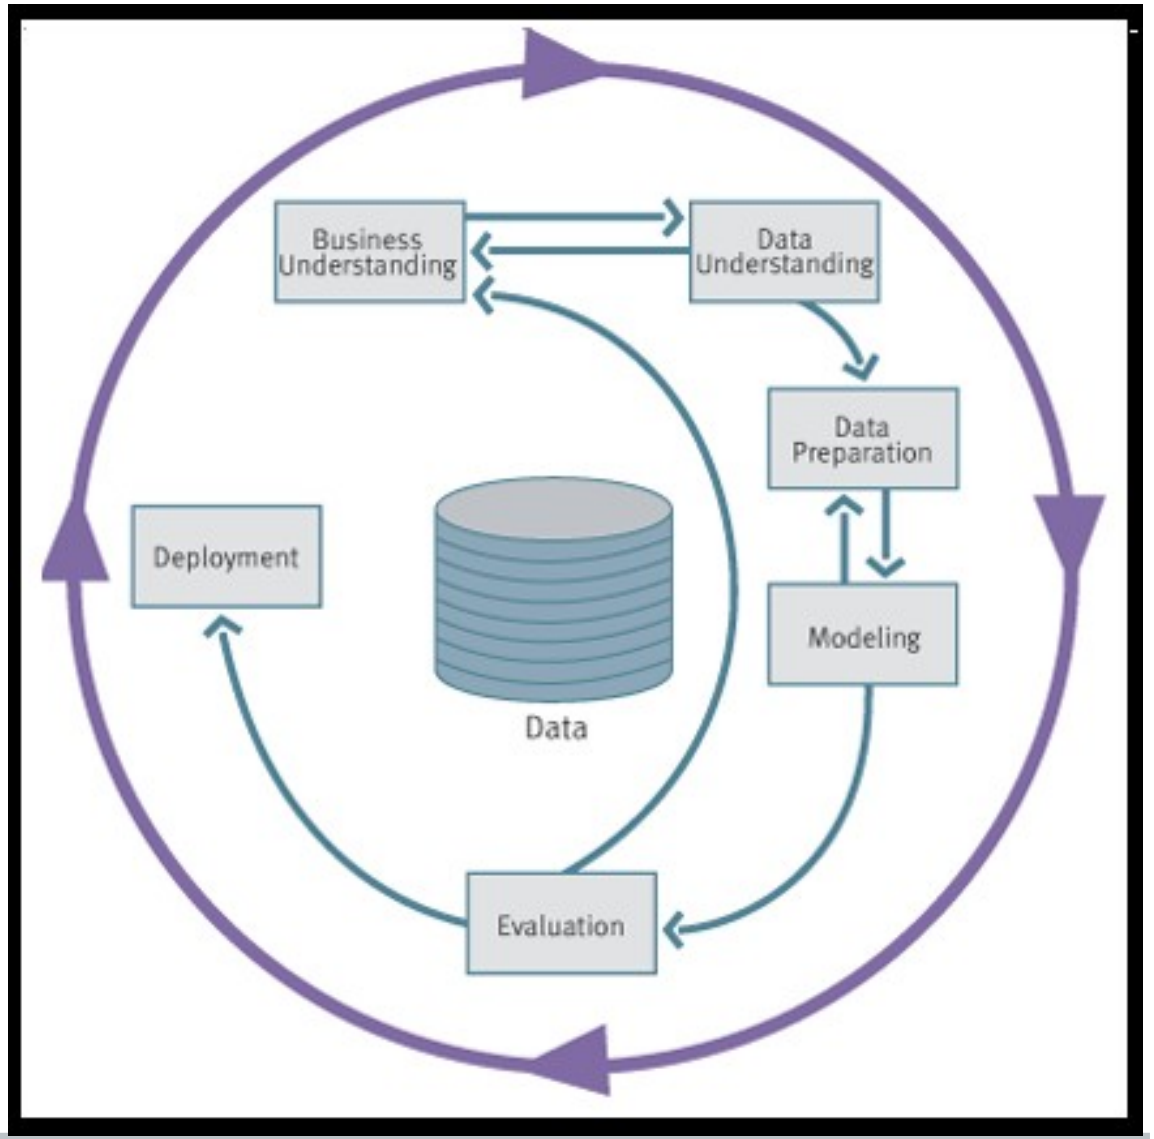
Unidad 2: Preparación de los Datos

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Recordando...


Business Understanding
Data Understanding
Data Preparation
Modeling
Evaluation
Deployment
Data

Recordando...

El conocimiento de los datos permite identificar las características de los repositorios de la organización para determinar su calidad.

Ante la identificación de datos erróneos y faltantes, de tipos de datos inconsistentes o incompatibles con las herramientas disponibles, de valores de datos desproporcionados, entre otros, se hace uso de técnicas de preparación de datos en la etapa posterior de CRIPS-DM.

La baja calidad de los datos se traslada a los resultados obtenidos del proceso de explotación de información.

Recordando...

Calidad de los datos

Existen varios factores que hacen a la calidad de los datos:

> **Precisión:** ruidos o errores

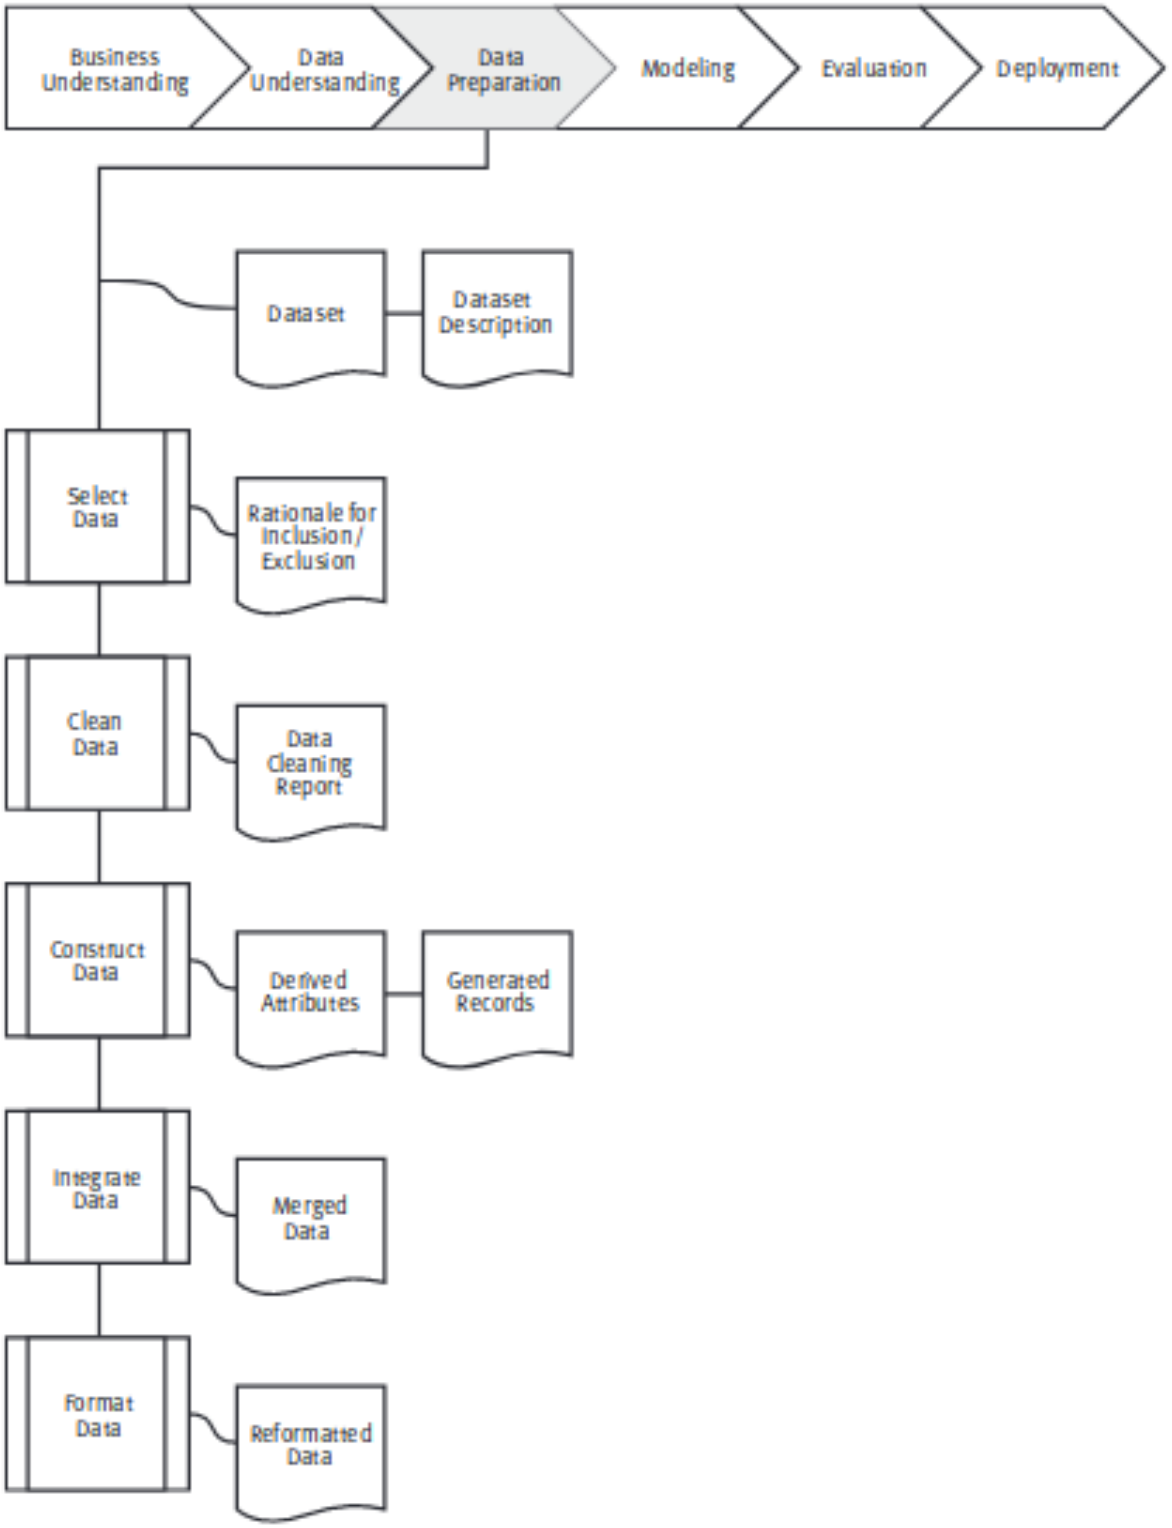
> **Completitud:** atributos, filas o valores perdidos

> **Consistencia:** valores inesperados

> **Credibilidad:** datos que parecen no ser reales

> **Interpretatibilidad:** valores codificados sin interpretación

Preparación de los datos



Actividades Principales

Selección de los datos

En esta primera actividad se decide que datos van a ser utilizados para el análisis.

Los criterios de selección incluyen la relevancia de los mismos para cumplir con los objetivos de minería de datos, de calidad y las restricciones técnicas (como límites en el volumen de los datos) que se plantearon al inicio del proyecto.

Aquí también se seleccionan los atributos y las filas que serán utilizadas.

Actividades Principales

Limpieza de los datos

Los datos necesitan ser despojados de los valores perdidos, el ruido, las anomalías y las inconsistencias.

Los datos “sucios” afectan directamente a los resultados de los modelos de minería de datos, provocando desconfianza a los stakeholders.

Aunque muchos algoritmos de minería de datos manejan internamente algunas cuestiones como datos incompletos o ruido, estos métodos no suelen ser robustos.

Estas razones justifican la utilización de métodos de limpieza de datos.

Actividades Principales

Integración de los datos

La información disponible en las tablas de datos puede no ser suficiente para responder a las preguntas formuladas en el inicio del proyecto, o bien esta información se encuentra disponible en varios repositorios distintos.

En algunos casos es factible unificar las bases de datos mediante tareas de integración de datos, de forma tal que los algoritmos puedan ser provistos de una única entrada.

Actividades Principales

Reducción de los datos

Ante ciertos escenarios como los provistos por restricciones técnicas varias, puede ser necesario utilizar una representación reducida de los datos que produzca los mismos resultados (o muy similares).

Reducción de la dimensionalidad

Se obtiene una versión “comprimida” de los datos utilizando esquemas especiales. Se incluyen técnicas de compresión de datos, selección de atributos relevantes, y construcción de nuevos atributos derivados.

Reducción de la numerosidad.

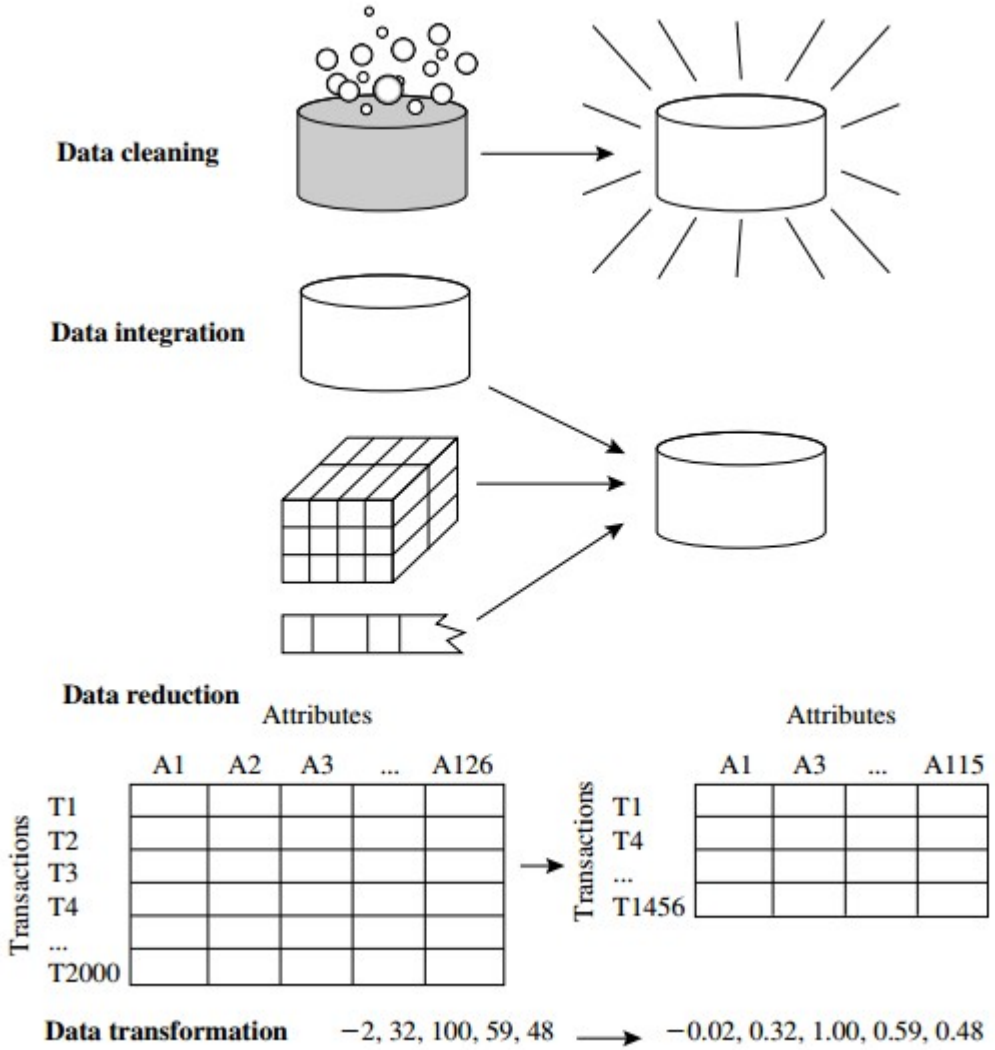
Las filas de los datos se reemplazan por datos generados por métodos paramétricos (regresiones lineales, por ejemplo) o no paramétricos (clusters, muestreo).

Actividades principales

Transformación de los datos

La **normalización** de ciertos atributos para que no influyan de forma desproporcionad en los resultados, o la **construcción de atributos derivados**, por ejemplo mediante **discretización**, son tareas que pueden ser necesarias para obtener los patrones de conocimiento de interés para la inteligencia de negocio.

Actividades principales



Limpieza de los datos

Como ya hemos mencionado, los datos reales suelen estar incompletos, con ruido e inconsistencia.

Distintas estrategias son utilizadas según el caso para solucionar estos problemas.

Limpieza de los datos

Valores perdidos o ausentes

Si en un dataset encuentras tuplas con los valores ausentes para un atributo dado...¿qué haces?

Limpieza de los datos

Valores perdidos o ausentes

Si en un dataset encuentras tuplas con los valores ausentes para un atributo dado...¿qué haces?

> Ignorar las tuplas:

Se realiza generalmente cuando el atributo CLASE si además otros atributos de dichas tuplas tampoco tienen valor asignado.

Se debe tener en cuenta que la cantidad de tuplas ignoradas no debe ser grande pues el dataset puede quedar inutilizable.

Limpieza de los datos

Valores perdidos o ausentes

Si en un dataset encuentras tuplas con los valores ausentes para un atributo dado...¿qué haces?

> Ignorar las tuplas:

Se realiza generalmente cuando el atributo CLASE si además otros atributos de dichas tuplas tampoco tienen valor asignado.

Se debe tener en cuenta que la cantidad de tuplas ignoradas no debe ser grande pues el dataset puede quedar inutilizable.

> Completar los valores a mano:

Esto es una actividad que demanda demasiado tiempo y recursos, por lo que no es factible si la cantidad de valores perdidos es considerable.

Limpieza de los datos

Valores perdidos o ausentes

Si en un dataset encuentras tuplas con los valores ausentes para un atributo dado...¿qué haces?

> Utilizar una constante global:

Reemplazar los valores ausentes por una única constante como la etiqueta “unknown”. Los algoritmos interpretarán erróneamente que esto es un valor normal y será utilizado al igual que el resto. Por esto, si bien el método es simple, puede no ser útil.

> Usar una medida de tendencia central:

Es factible utilizar en algunos escenarios una medida de tendencia central como el promedio o la media. Este valor debe ser calculado por cada CLASE, por lo que no es factible de aplicar si este valor está perdido.

Limpieza de los datos

Valores perdidos o ausentes

Si en un dataset encuentras tuplas con los valores ausentes para un atributo dado...¿qué haces?

> Utilizar el valor más probable:

Este valor puede ser obtenido mediante otras técnicas de minería de datos que predigan el valor de este atributo con base en los demás atributos. Se justifica si esos valores son altamente necesarios para satisfacer los objetivos de minería de datos.

Limpieza de los datos

Valores perdidos o ausentes

Si en un dataset encuentras tuplas con los valores ausentes para un atributo dado...¿qué haces?

> Utilizar el valor más probable:

Este valor puede ser obtenido mediante otras técnicas de minería de datos que predigan el valor de este atributo con base en los demás atributos. Se justifica si esos valores son altamente necesarios para satisfacer los objetivos de minería de datos.

Muchas veces los datos perdidos no son errores, sino que tienen asociada una semántica. Esto debe estar especificado en la descripción de los datos realizada previamente.

Limpieza de los datos

Ruido

El ruido es un error aleatorio en la medición de una variable.

Como observamos anteriormente, el ruido puede verse con técnicas de visualización como scatterplots, boxplots o histogramas.

Dado un atributo numérico (precio, por ejemplo), se pueden “difuminar” el ruido mediante técnicas especiales.

Limpieza de los datos: ruido

Binning:

Los métodos de binning (de bin - contenedor), “difuminan” el conjunto de datos ordenado para reducir el ruido consultando los “vecindarios” de valores

Los atributos ordenados se dividen en “contenedores”, y sus valores son reemplazados por la media, mediana, o sus valores frontera.

Por ejemplo.

Limpieza de los datos: ruido

{4. 8. 15. 21. 21. 24. 25. 28. 34}

Partition into (equal-frequency) bins:

Bin 1: 4, 8, 15
Bin 2: 21, 21, 24
Bin 3: 25, 28, 34

Smoothing by bin means:

Bin 1: 9, 9, 9
Bin 2: 22, 22, 22
Bin 3: 29, 29, 29

Smoothing by bin boundaries:

Bin 1: 4, 4, 15
Bin 2: 21, 21, 24
Bin 3: 25, 25, 34

Limpieza de los datos: ruido

Regresión

Se puede difuminar los datos mediante técnicas de regresión.

La regresión permite aproximar los valores mediante una función que se ajuste mejor a los datos.

Los valores reales, entonces se reemplazan por el valor que da la función, reduciendo así el ruido.

Si el ajuste no es bueno se pierde demasiada información.

Limpieza de los datos: ruido

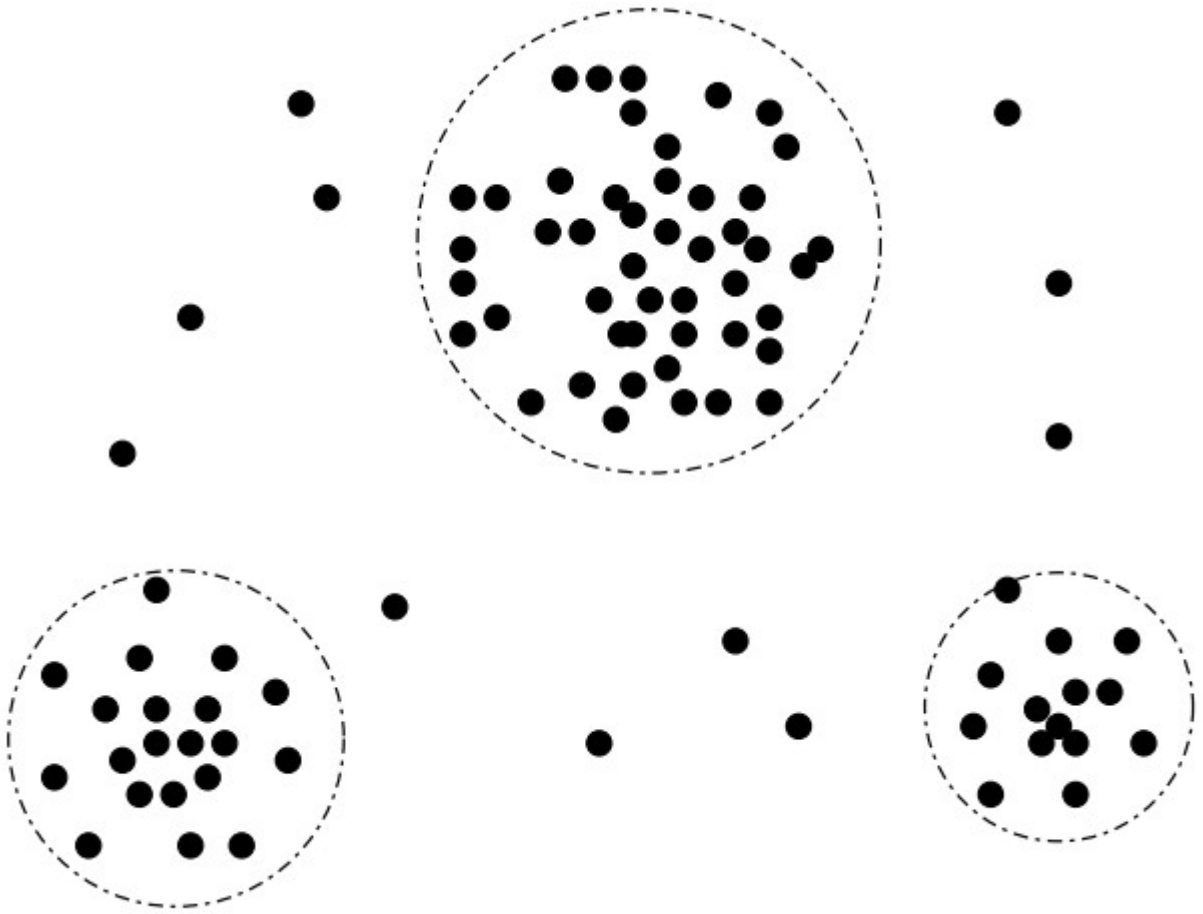
Detección de anomalías:

Utilizando métodos de agrupamiento, por ejemplo, se pueden “agrupar” juntos los valores que siguen cierta lógica.

Los valores con ruido que no se ajustan al comportamiento normal de los datos quedarán excluidos de dichos grupos.

Sus valores pueden ser reemplazados por el promedio o mediana de su cluster más cercano, o eliminados.

Limpieza de los datos: ruido



Limpieza de los datos

Integración

La integración de los datos es necesaria cuando la información a utilizar se encuentra en diferentes fuentes (y posiblemente en diferentes formatos)

La integración debe realizarse con cuidado para evitar redundancia e inconsistencia.

¿Cómo se hace para hacer coincidir esquemas y objetos de diferentes fuentes?

Esto se conoce como el **problema de la identificación de entidades** (Entity identification problem)

Limpieza de los datos: integración

Entity identification problem

La integración de esquemas y la coincidencia de objetos puede ser desafiante.

Se deben determinar atributos compartidos por las diferentes fuentes que posean los mismos valores y semántica, por ejemplo: ID y DNI

Esto se obtiene de la descripción de los datos.

Las múltiples fuentes pueden tener distinta semántica y formatos para los atributos.

¿En ambos recursos un campo en blanco significa lo mismo? ¿cómo hacer que coincidan?

Limpieza de los datos: integración

Entity identification problem

Se debe tener cuidado con los atributos dependientes unos de otros.

Por ejemplo, los descuentos pueden aplicarse a una factura completa en un sistema, mientras que en otro sistema este descuento se aplica sobre cada línea de la factura.

Limpieza de los datos: integración

Redundancia y correlación

Un atributo puede ser redundante si puede derivarse de algún otro valor.

Por ejemplo, la edad es redundante si se posee la fecha de nacimiento del individuo.

Inconsistencias en la nomenclatura de los atributos también pueden esconder redundancias.

Se pueden detectar utilizando técnicas de correlación, para determinar si el valor de un atributo implica el valor de otro atributo.

Limpieza de los datos: integración

Filas duplicadas

El uso de tablas denormalizadas es otra fuente de redundancia de datos a nivel de filas.

Las inconsistencias pueden aparecer entre estas filas, al refereirse a la misma entidad pero poseer valores distintos en sus atributos (problemas de actualización de los datos, por ejemplo).

Es importante detectar estas filas y solucionar los errores que allí se detecten, manteniendo solo una fila por entidad.

Limpieza de los datos: integración

Detección y resolución de conflictos

Para dos fuentes distintas, los valores para un mismo atributo pueden diferir.

Puede haber diferencias en la representación, escala de los valores, o la codificación de los mismos (Ej. Altura medida en pies y medida en metros, o medida cm y en kilometros)

Limpieza de los datos

Reducción de los datos

Estas técnicas se aplican para reducir la dimensión del conjunto de datos y mantener su consistencia e integridad.

La reducción de la dimensionalidad se utiliza por motivos técnicos (limitaciones, eficiencia) y aún así obtener resultados similares.

Limpieza de los datos: reducción

Reducción de la dimensionalidad:

Se trata de reducir la cantidad de atributos o variables del conjunto de datos. Técnicas para esto son:

> Wavelet Transform (Transformada ondícula)

> Principal Components Analysis (Analisis de componentes principales)

> Attribute subset selection (mediante clasificación bayesiana o TDIDT)

Los dos primeros proyectan el conjunto de datos en un espacio de menor dimensiones.

El último elimina las dimensiones redundantes o irrelevantes para cierto objetivo.

Limpieza de los datos: reducción

Reducción de la Numerosidad:

Se reemplaza el volumen de datos original por otras formas de representación de menor volumen.

> Métodos paramétricos:

> **Regresión**: se usa para estimar los datos, y solo se almacenan los parámetros de la función modelo, por lo que el volumen es menor.

> Métodos no paramétricos:

> **Muestreo**: utilizado para seleccionar aleatoriamente un subconjunto de los atributos. Generalmente se utilizan estrategias complejas para asegurar la validez de los modelos.

Limpieza de los datos

Transformación y discretización

Los datos son transformados para que los algoritmos trabajen de forma más eficiente o para entender mejor los resultados.

Estas técnicas incluyen:

> **Construcción de atributos:** a partir de otros atributos, para ayudar al proceso de minería.

> **Agregación de los datos:** valores diarios pueden ser agregados para construir valores semanales, mensuales o anuales.

> **Normalización:** Se escalan los atributos para que queden en un rango reducido o bien todos en el mismo rango.

Limpieza de los datos

Transformación y discretización

Los datos son transformados para que los algoritmos trabajen de forma más eficiente o para entender mejor los resultados.

Estas técnicas incluyen:

> **Discretización:** a partir de valores numéricos, se reemplazan por etiquetas para intervalos determinados. Pueden resultar jerarquías de conceptos. Se pueden generar varios atributos a partir de distintas discretizaciones de una misma variable.

> **Jerarquías conceptuales:** para datos nominales, es posible agruparlos en categorías más ámplias que los contengan. Por ejemplo, calles pueden ser agrupadas en ciudades, y estas a su vez en provincias.

Investigar

> Técnicas de discretización

> Técnicas de normalización

Material de consulta:

Han et al. (2012) Data Mining: Concepts and techniques. Capítulo 3

Aggrawal (2015) Data Mining: The textbook. Capítulo 2.