Unidad 3:
Modelado – Aprendizaje Automático

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Modelado

Supón que un cliente requiere mejorar las ventas de un determinado producto.

Se tiene una base de datos de las ventas del producto en 200 mercados, junto con la cantidad de dinero invertido en distintos tipos de publicidad: en radio, televisión y periódicos.

No se puede incrementar directamente la cantidad de ventas, sino que se debe incentivar la demanda indirectamente mediante publicidad.

Modelado

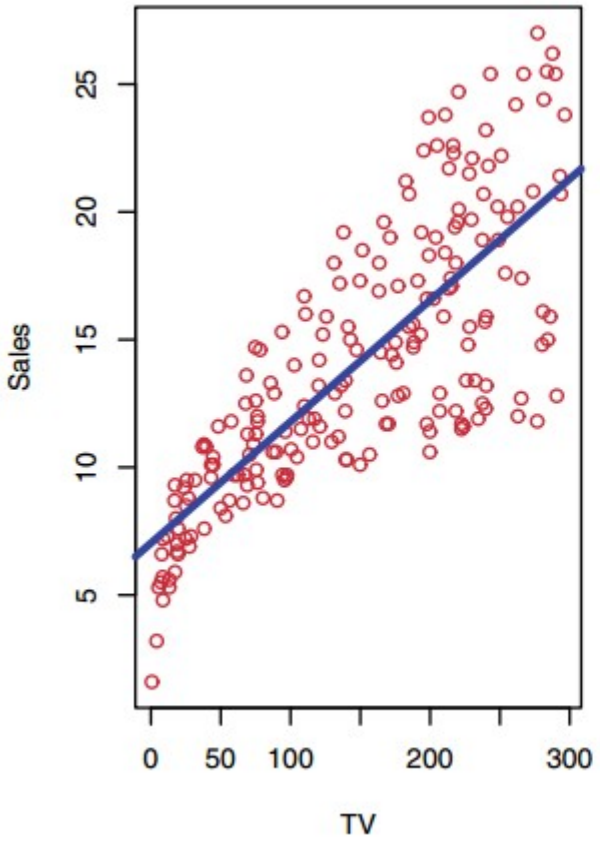
Supón que un cliente requiere mejorar las ventas de un determinado producto.

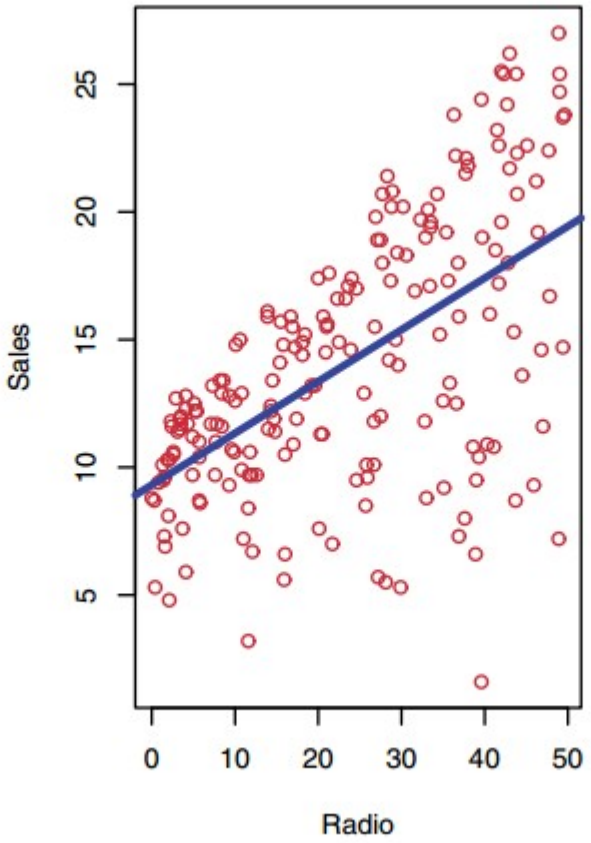
Se tiene una base de datos de las ventas del producto en 200 mercados, junto con la cantidad de dinero invertido en distintos tipos de publicidad: en radio, televisión y periódicos.

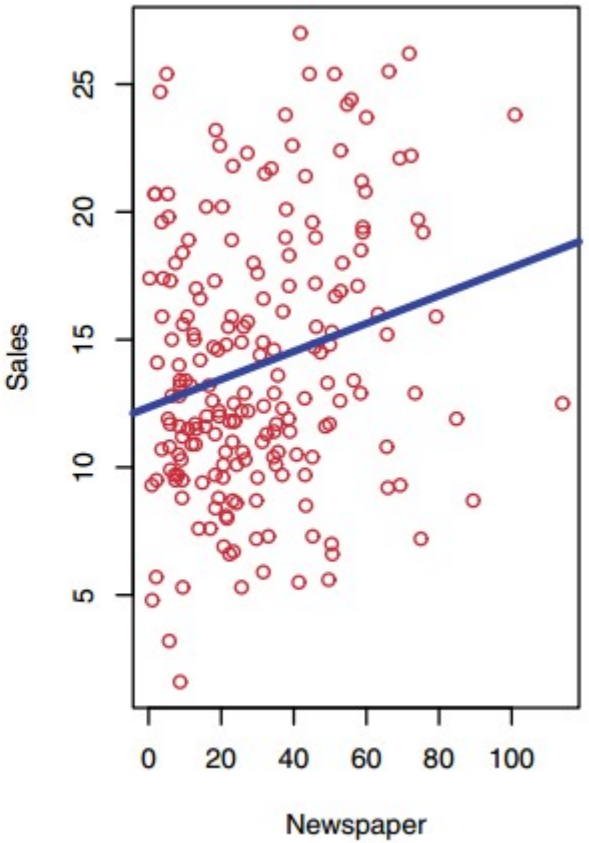
No se puede incrementar directamente la cantidad de ventas, sino que se debe incentivar la demanda indirectamente mediante publicidad.

> ¿En qué tipo de publicidad conviene invertir?

Modelado


Sales
5
10
15
20
25
0
50
100
200
300
TV


Sales
5
10
15
20
25
0
10
20
30
40
50
Radio


Sales
5
10
15
20
25
0
20
40
60
80
100
Newspaper

Modelado

De forma general, lo que se busca es ESTIMAR el valor de una respuesta Y a partir de distintos estimadores $X_1, X_2, \ldots, X_p$, asumiendo que existe una relación entre las variables independientes y la variable dependiente:

Modelado

De forma general, lo que se busca es ESTIMAR el valor de una respuesta Y a partir de distintos estimadores $X_1, X_2, \ldots, X_p$, asumiendo que existe una relación entre las variables independientes y la variable dependiente:

$$Y = f\left(\vec{x}\right) + \varepsilon$$

Modelado

De forma general, lo que se busca es ESTIMAR el valor de una respuesta Y a partir de distintos estimadores $X_1, X_2, \ldots, X_p$, asumiendo que existe una relación entre las variables independientes y la variable dependiente:

$$Y = f\left(\vec{x}\right) + \varepsilon$$

Los métodos de aprendizaje, entonces, se refieren a distintos acercamientos para estimar la función, o la relación que subyace a los datos.

¿Por qué se estima f?

Predicción:

En algunas situaciones, los valores de las variables independientes o estimadores son fácilmente obtenibles, pero el valor de Y no puede ser obtenido fácilmente.

Supón que $X_1, X_2, \ldots, X_p$ son características de la sangre de un paciente que pueden ser fácilmente obtenidas mediante un análisis de laboratorio, e Y es el riesgo de que un paciente sufra una reacción adversa a un medicamento.

Es interesante conocer el riesgo a partir de los estimadores antes de administrar la droga.

¿Por qué se estima f?

Predicción:

Lo que se busca en la predicción es una función

$$\hat{Y} = \hat{f}(\vec{x})$$

que estime el valor real de Y.

No nos interesa la forma de la función en si, sino la respuesta obtenida y su precisión.

La función es una caja negra y puede ser tan compleja como sea necesaria para asegurar la calidad de la respuesta.

¿Por qué se estima f?

Predicción:

Como es de esperar, el estimador de f no será perfecto.

La precisión de $\hat{Y}$ depende de dos cantidades:

Error reducible:

Dado por los métodos seleccionados para el modelado, los cuales no son perfectos.

Error irreducible:

Dado por que Y no es solo una función de X, sino que también es función del error. Existen innumerables factores que puede que no estemos considerando en el modelado, por lo que nunca será un estimador perfecto.

$$Y = f\left(\vec{x}\right) + \varepsilon$$

¿Por qué se estima f?

Predicción:

Las técnicas de modelado buscan reducir el error reducible, o lo que es lo mismo, la diferencia entre el valor real y el valor de la función estimada.

El error irreducible supone una cota superior de la capacidad del modelo.

¿Por qué se estima f?

Inferencia:

En otras oportunidades no nos interesa exactamente el valor de Y, sino la relación misma entre los estimadores y la respuesta.

> ¿Qué variables influyen más sobre la respuesta?

> ¿De qué forma influye cada variable?

> ¿Puede la relación ser resumida con una función simple?

Nos interesa la forma de la función.

¿Por qué se estima f?

Inferencia:

Un ejemplo es el visto al inicio de la presentación:

Nos interesa saber:

> ¿Cuál tipo de publicidad impacta más en las ventas?

> ¿De qué forma impacta un tipo particular de publicidad en las mismas?

> Etc.

Ante este escenario, nos suele interesar que la función estimada sea lo más simple posible.

Métodos para estimar f

Para generar una función que modele el conjunto de datos, se debe ENTRENAR dicha función.

Para esto es necesario un conjunto de datos u observaciones en el cual se conozca tanto los valores históricos de las variables independientes y de su respuesta asociada.

Este tipo de aprendizaje se denomina **supervisado** y el conjunto de observaciones se denomina **conjunto de entrenamiento**.

Existen dos tipos de métodos de aprendizaje para estimar f:

Métodos para estimar f

Métodos paramétricos:

Constan de dos pasos:

1. Se asume la forma de la función (lineal, cuadrática, etc) y se plantea un modelo genérico:

$$f(\vec{x}) = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \ldots + \beta_p \cdot x_p$$

2. Se entrena o ajusta el modelo estimando los parámetros o coeficiente de la función para que se aproximen al valor real.

$$Y \approx \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \ldots + \beta_p \cdot x_p$$

Métodos para estimar f

Métodos paramétricos:

Se reduce el problema de estimar una función a estimar un conjunto de p+1 coeficientes.

Sin embargo, al prefijar la forma de la función, estamos forzando al modelo a que siga dicha forma, lo cual reduce la precisión de las respuestas.

Además, cuanto más flexibles sean las formas propuestas, más difícil será estimar los coeficientes.

Métodos para estimar f

Métodos no paramétricos:

Estas técnicas no hacen suposiciones sobre la forma de la función.

Se busca construir una función que se aproxima a los puntos del conjunto de entrenamiento de una forma suave.

Esto produce que el ajuste de la función sea mejor que con los métodos paramétricos.

Sin embargo, se suele necesitar un número mayor de observaciones para el entrenamiento, las funciones resultantes suelen ser muy complejas, y pueden ser demasiado sensibles al ruido.

Precisión vs Comprensión

Generalmente al elegir un método de modelado se debe decidir entre estas dos características.

Los métodos más simples de interpretar suelen ser más imprecisos e inflexibles para adaptarse a los datos.

Los métodos flexibles suelen incorporar relaciones complejas entre los datos que resultan difícil de interpretar y analizar.

La selección de los distintos métodos suelen también estar condicionada por el tipo de objetivo que tengamos: predicción o inferencia.

Regresión Lineal

La regresión lineal es uno de los métodos de modelado más simples para el aprendizaje supervisado.

Es un método que busca relacionar de forma lineal un conjunto de predictores con una salida NUMÉRICA determinada.

Es un método que proviene de la estadística pero es ampliamente utilizado.

Como ya mencionamos, suele ser muy simple y fácil de interpretar, por lo que se suele usar para inferencia.

Regresión Lineal

Regresión Lineal Simple:

Se busca predecir el valor de una respuesta cuantitativa Y a partir de un único predictor x.

Matemáticamente:

$$Y \approx \beta_1 x + \beta_0$$

$$\hat{Y} = \hat{\beta}_1 x + \hat{\beta}_0$$

Regresión lineal

Estimación de los coeficientes:

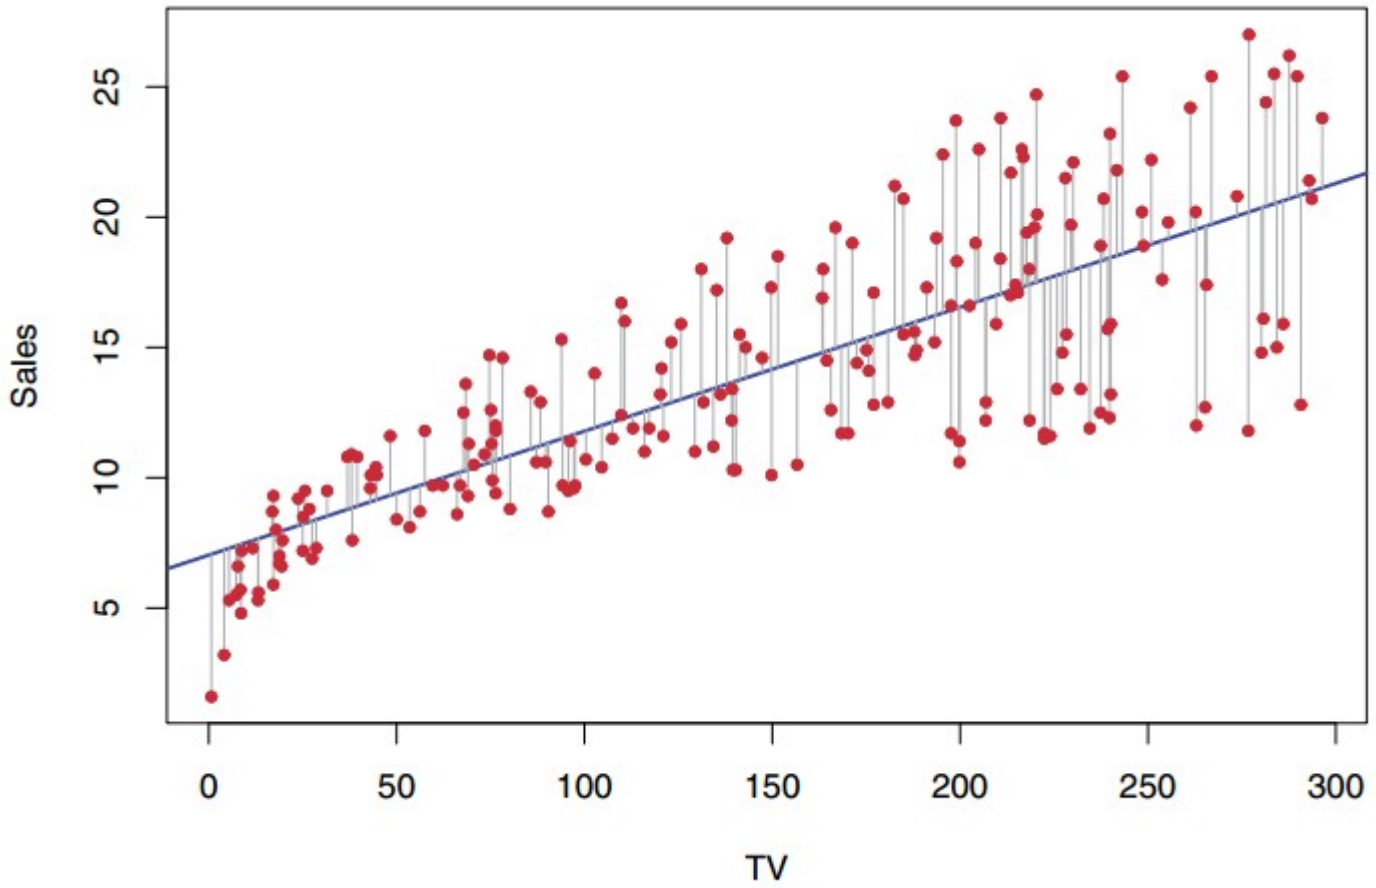
En la práctica, los coeficientes son desconocidos, por lo que deben ser estimados a partir de los datos.

El conjunto de entrenamiento se compone de un conjunto de n pares u observaciones

$$\{(x_i, y_i)\}, \quad i=1..n$$

Se buscan los coeficientes de la línea de regresión que más se aproxime a todos las observaciones o puntos.

Regresión lineal



Regresión lineal

Método de los mínimos cuadrados

Sea $\hat{y}_i = \hat{\beta}_1 x_i + \hat{\beta}_0$, entonces $e_i = y_i - \hat{y}_i$

Se dice que e es un residuo, la diferencia entre el valor observado y el valor estimado para un predictor dado.

El método de los mínimos cuadrados busca minimizar

$$RSS = e_1^2 + e_2^2 + \ldots + e_n^2$$

$$RSS = \sum_{i=1}^{n} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \right)^2$$

Regresión lineal

Se estima los coeficientes mediante el álgebra, resultando que aquellos que minimizan la función son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Regresión lineal

Regresión lineal múltiple:

El mundo no es tan sencillo, y generalmente se tienen más de un predictor para cada respuesta, de forma tal que:

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \varepsilon$$

De esta forma, para estimar los p parámetros es necesario minimizar:

$$RSS = \sum_{i=1}^{n} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \ldots - \hat{\beta}_p x_{ip} \right)^2$$

Material de consulta

> James et al. 2013. An introduction to statistical learning. Capítulos 2.1, 3.1.1, 3.2.1