Unidad 3:
Modelado - Clasificación

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Modelado

Regresión Lineal:

Método **paramétrico** que permite encontrar la dependencia existente entre un conjunto de **predictores** (o variables independientes) y una variable objetivo (respuesta, dependiente) **numérica** (cuantitativa).

Se trata de encontrar una función (lineal)

$$Y = f\left(\vec{x}\right) + \varepsilon$$

tal que

$$Y \approx \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \ldots + \beta_p \cdot x_p$$

Modelado

¿Y si la respuesta es cualitativa?

Modelado

¿Y si la respuesta es cualitativa?

Se puede codificar cada valor discreto mediante un número entero y utilizar regresión lineal.

Modelado

¿Y si la respuesta es cualitativa?

Se puede codificar cada valor discreto mediante un número entero y utilizar regresión lineal.

¿Problemas?

Modelado

¿Y si la respuesta es cualitativa?

Se puede codificar cada valor discreto mediante un número entero y utilizar regresión lineal.

¿Problemas?

> El orden importa:

Dependiendo de que números se utilicen para codificar y, particularmente, el orden de los mismos, la función será distinta, por lo que no se extraerá correctamente el modelo que subyace a los datos.

Modelado

¿Qué hacer entonces?

Utilizar técnicas de clásificación.

Modelado

¿Qué hacer entonces?

Utilizar técnicas de clásificación.

La clasificación es una actividad del aprendizaje supervisado en la cual, a partir de un conjunto de tuplas $\bar{X}$ donde

$$x_i \in \bar{X} = \left(x_{i1,} x_{i2,} \ldots, x_{i(p-1)}, clase \right)$$

se busca predecir el valor del atributo clase (cualitativo) a partir de los demás atributos de la tupla.

Clasificación

Clasificadores:

Existen distintas técnicas para realizar esta actividad:

> Regresión Logística

> Support Vector Machines (SVM)

> Algoritmos Top-Down Induction of Decision Trees

Clasificación

Clasificadores:

Existen distintas técnicas para realizar esta actividad:

> Regresión Logística

> Support Vector Machines (SVM)

> Algoritmos Top-Down Induction of Decision Trees

Árboles de inducción:

> ID3

> CART

> C4.5

> C5.0

Clasificación

Árboles de Decisión:

Son estructuras (árboles) en las que:

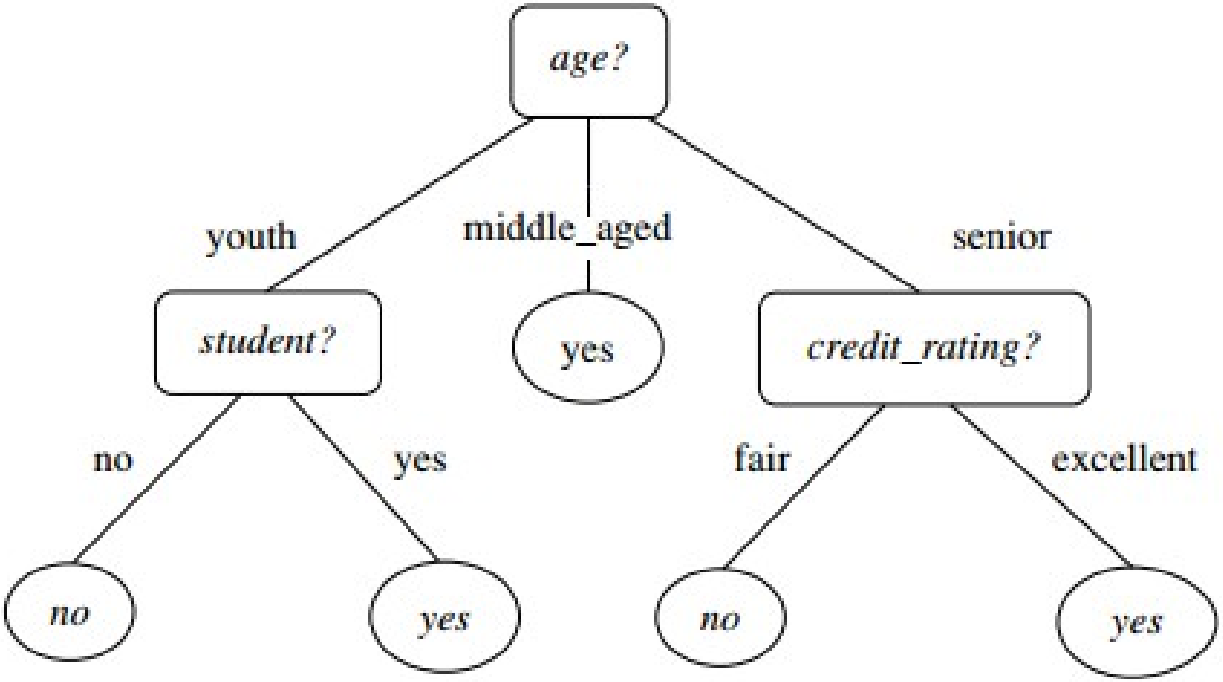
> cada nodo interno corresponde a una condición sobre el valor de una determinada variable o predictor.

> cada rama corresponde a la decisión de evaluar la condición en el nodo padre.

> cada hoja corresponde al valor del atributo clase.

Clasificación

¿Compra o no compra una computadora?



Clasificación

Reglas de decisión:

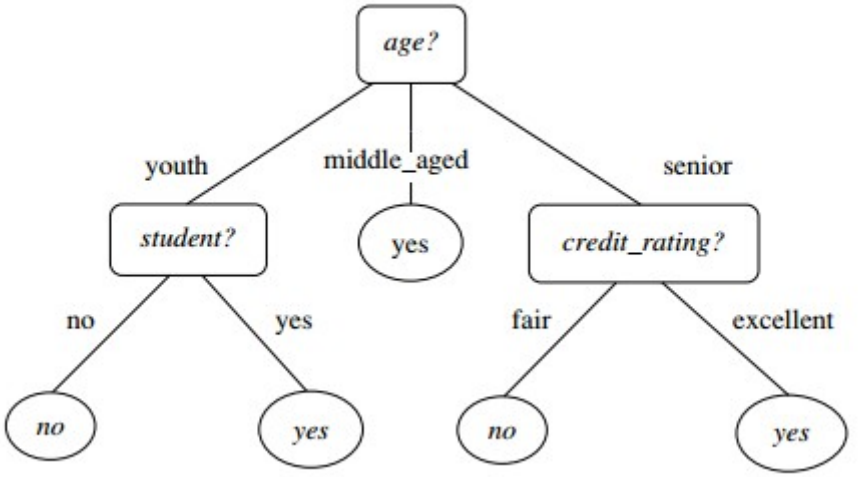
A partir del árbol se pueden extraer reglas mediante el recorrido del árbol:

IF Age = Youth AND Student = No → No

IF Age = Youth AND Student = Yes → Yes

IF Age = Middle_Aged → Yes

…



Clasificación

Reglas de decisión:

Estas reglas pueden ser utilizadas para:

> Describir el comportamiento de los datos (Inferencia).

> Predecir el atributo clase de nuevas tuplas no clasificadas.

En uno u otro caso, como siempre, se debe buscar un equilibrio entre precisión e interpretatibilidad, dependiendo de los objetivos planteados.

Árboles de Decisión

Algoritmo Básico

1. Si el conjunto de datos es vacío o si todos los elementos del conjunto inicial pertenecen a la misma clase → Fin
2. Seleccionar una variable.
3. Particionar el conjunto de datos según los valores de dicha variable.
4. Por cada partición, ejecutar el algoritmo.

Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
Soleado	Alta	Alta	No	No
Soleado	Alta	Alta	Si	No
Nublado	Alta	Alta	No	Si
Lluvioso	Media	Alta	No	Si
Lluvioso	Baja	Normal	No	Si
Lluvioso	Baja	Normal	Si	No
Nublado	Baja	Normal	Si	Si
Soleado	Media	Alta	No	No
Soleado	Baja	Normal	No	Si
Lluvioso	Media	Normal	No	Si
Soleado	Baja	Normal	Si	Si
Nublado	Baja	Alta	Si	Si
Nublado	Alta	Normal	No	Si
Lluvioso	Media	Alta	SI	No

Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
Soleado	Alta	Alta	No	No
Soleado	Alta	Alta	Si	No
Nublado	Alta	Alta	No	Si
Lluvioso	Media	Alta	No	Si
Lluvioso	Baja	Normal	No	Si
Lluvioso	Baja	Normal	Si	No
Nublado	Baja	Normal	Si	Si
Soleado	Media	Alta	No	No
Soleado	Baja	Normal	No	Si
Lluvioso	Media	Normal	No	Si
Soleado	Baja	Normal	Si	Si
Nublado	Baja	Alta	Si	Si
Nublado	Alta	Normal	No	Si
Lluvioso	Media	Alta	SI	No

Árboles de decisión

Ejecución



Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
Soleado	Alta	Alta	No	No
Soleado	Alta	Alta	Si	No
Soleado	Media	Alta	No	No
Soleado	Baja	Normal	No	Si
Soleado	Baja	Normal	Si	Si

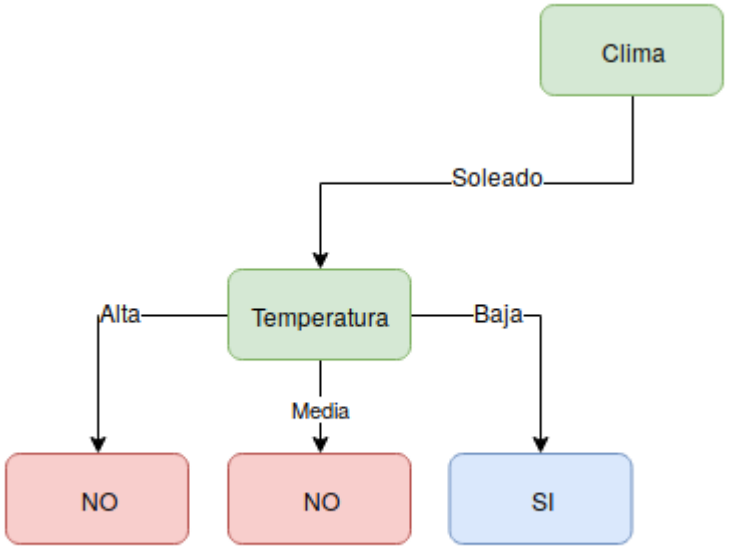
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
	Alta	Alta	No	No
	Alta	Alta	Si	No
	Media	Alta	No	No
	Baja	Normal	No	Si
	Baja	Normal	Si	Si

Árboles de decisión

Ejecución



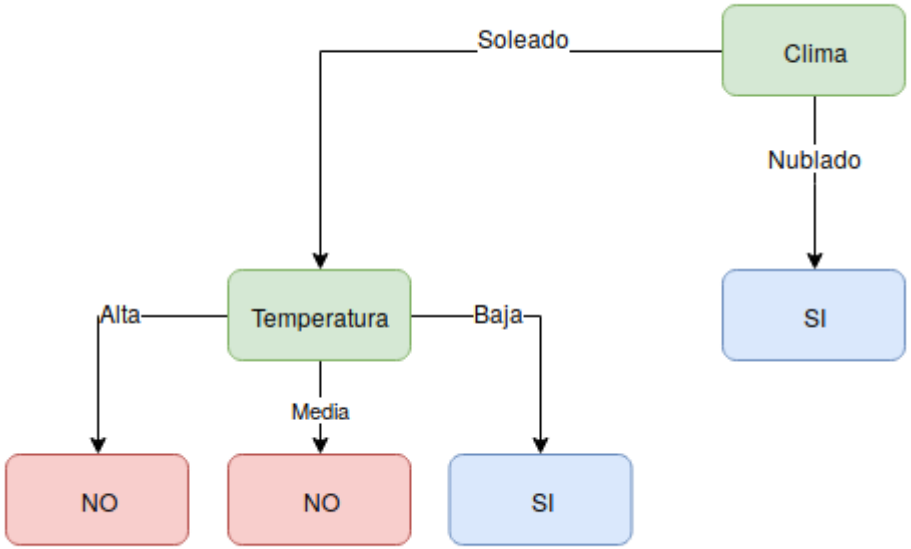
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
Nublado	Alta	Alta	No	Si
Nublado	Baja	Normal	Si	Si
Nublado	Baja	Alta	Si	Si
Nublado	Alta	Normal	No	Si

Árboles de decisión

Ejecución



Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
Lluvioso	Media	Alta	No	Si
Lluvioso	Baja	Normal	No	Si
Lluvioso	Baja	Normal	Si	No
Lluvioso	Media	Normal	No	Si
Lluvioso	Media	Alta	SI	No

Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
	Media	Alta	No	Si
	Baja	Normal	No	Si
	Baja	Normal	Si	No
	Media	Normal	No	Si
	Media	Alta	SI	No

Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
	Baja	Normal	No	Si
	Baja	Normal	Si	No

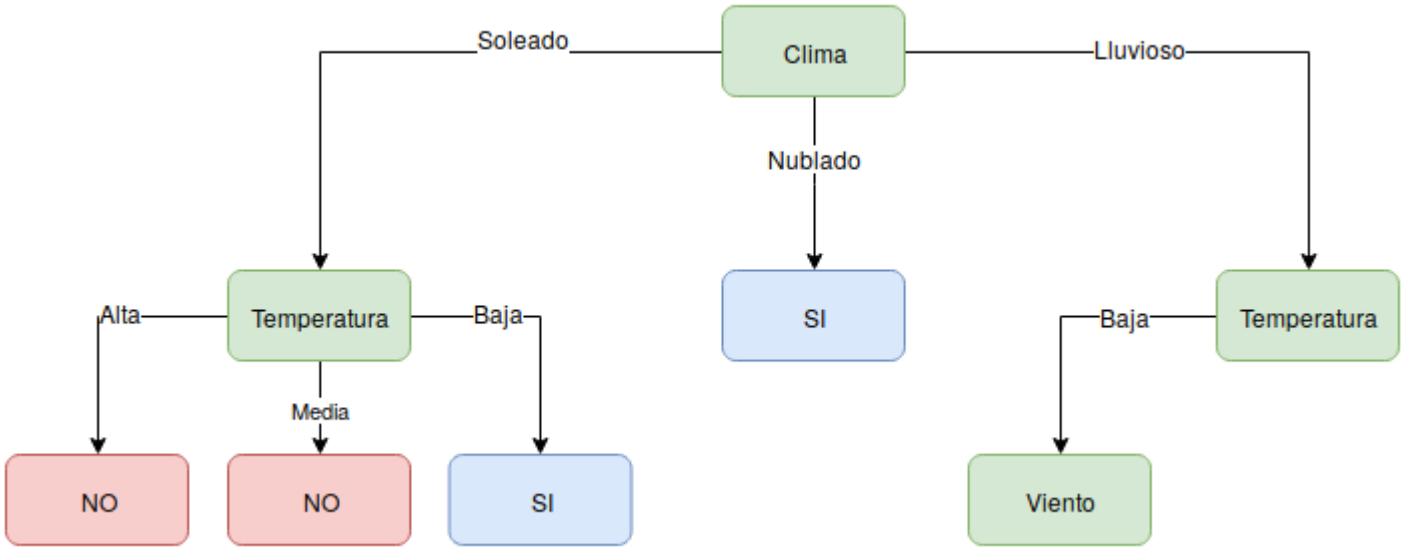
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
		Normal	No	Si
		Normal	Si	No

Árboles de decisión

Ejecución



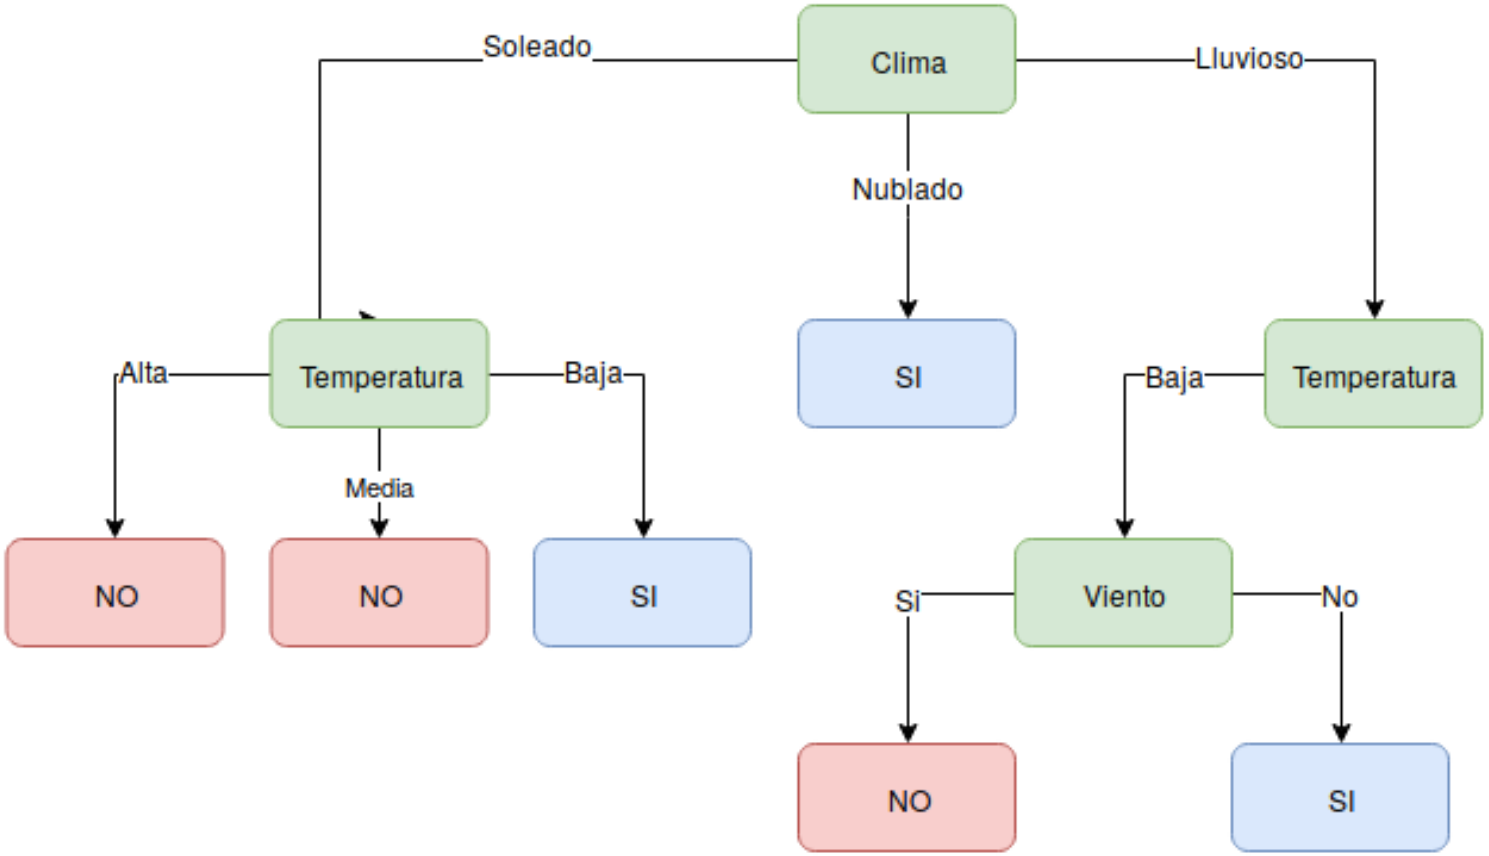
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
			No	Si
			Si	No

Árboles de decisión

Ejecución



Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
	Media	Alta	No	Si
	Baja	Normal	No	Si
	Baja	Normal	Si	No
	Media	Normal	No	Si
	Media	Alta	SI	No

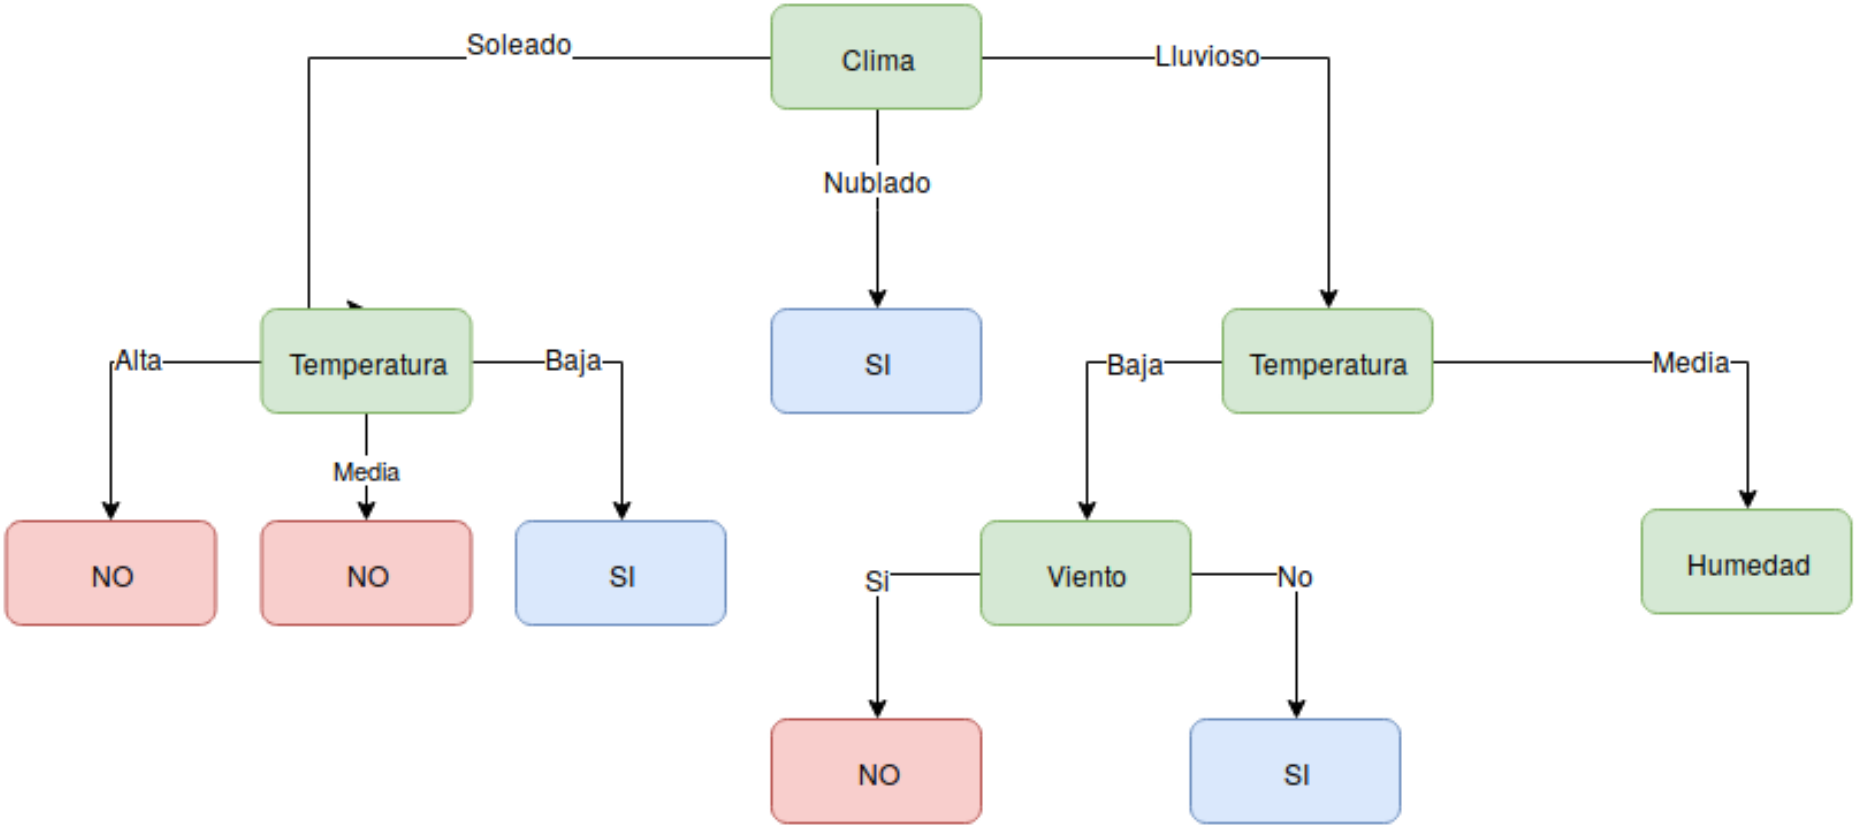
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
	Media	Alta	No	Si
	Media	Normal	No	Si
	Media	Alta	SI	No

Árboles de decisión

Ejecución



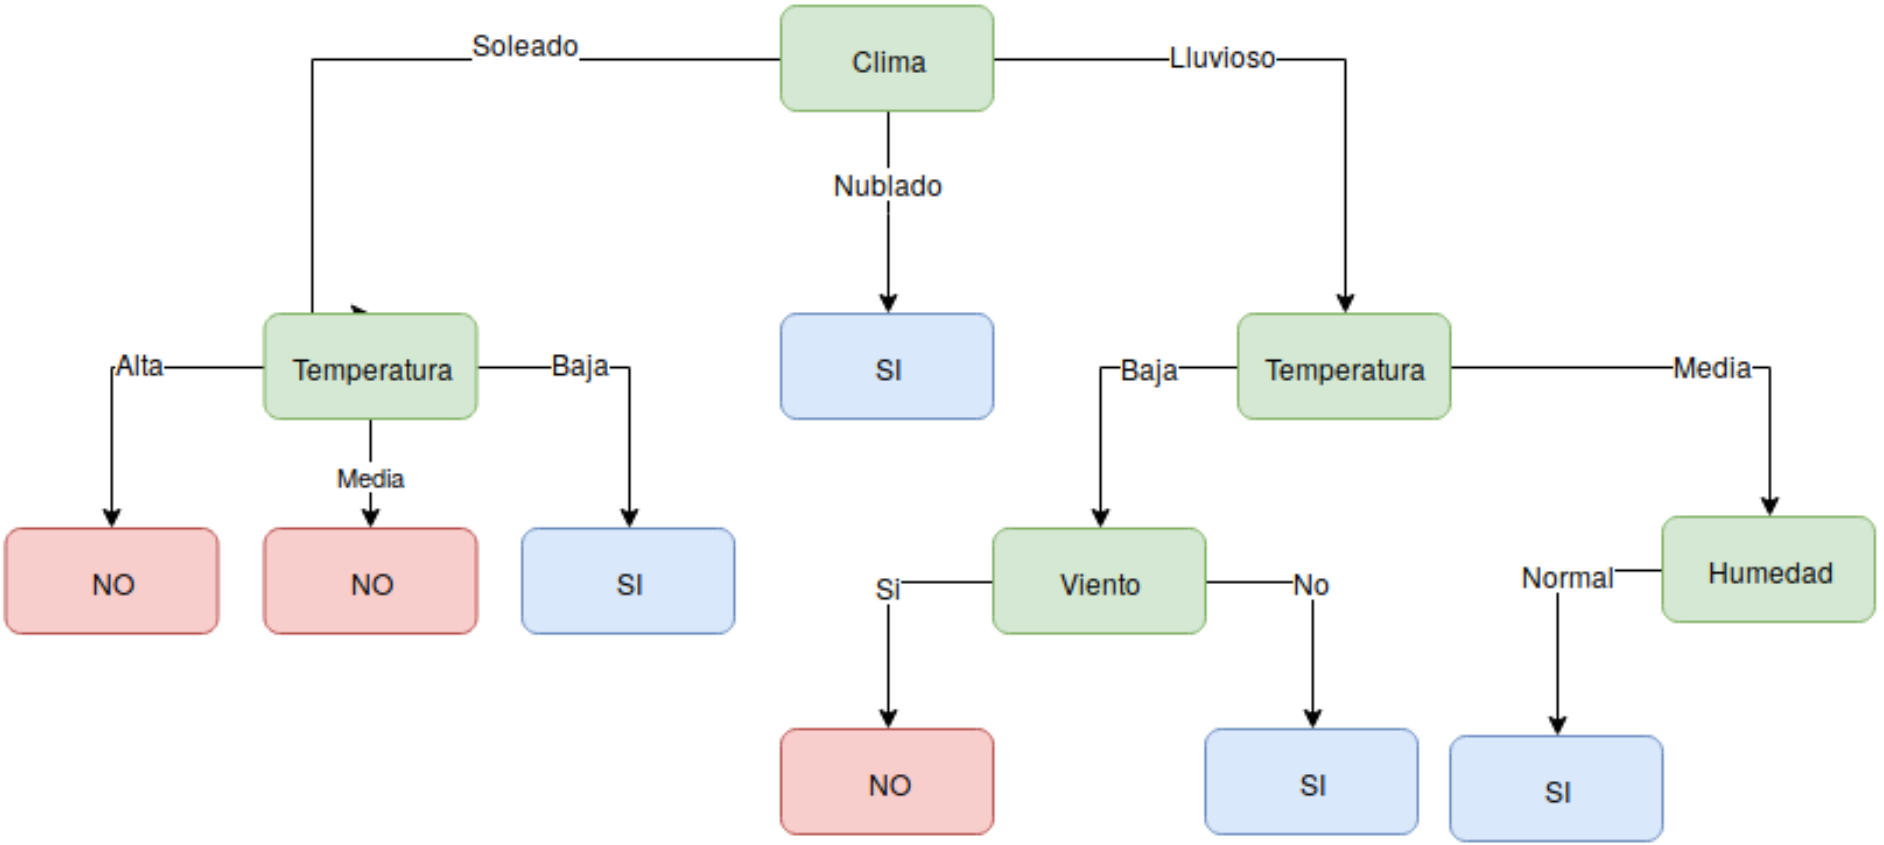
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
		Alta	No	Si
		Normal	No	Si
		Alta	SI	No

Árboles de decisión

Ejecución



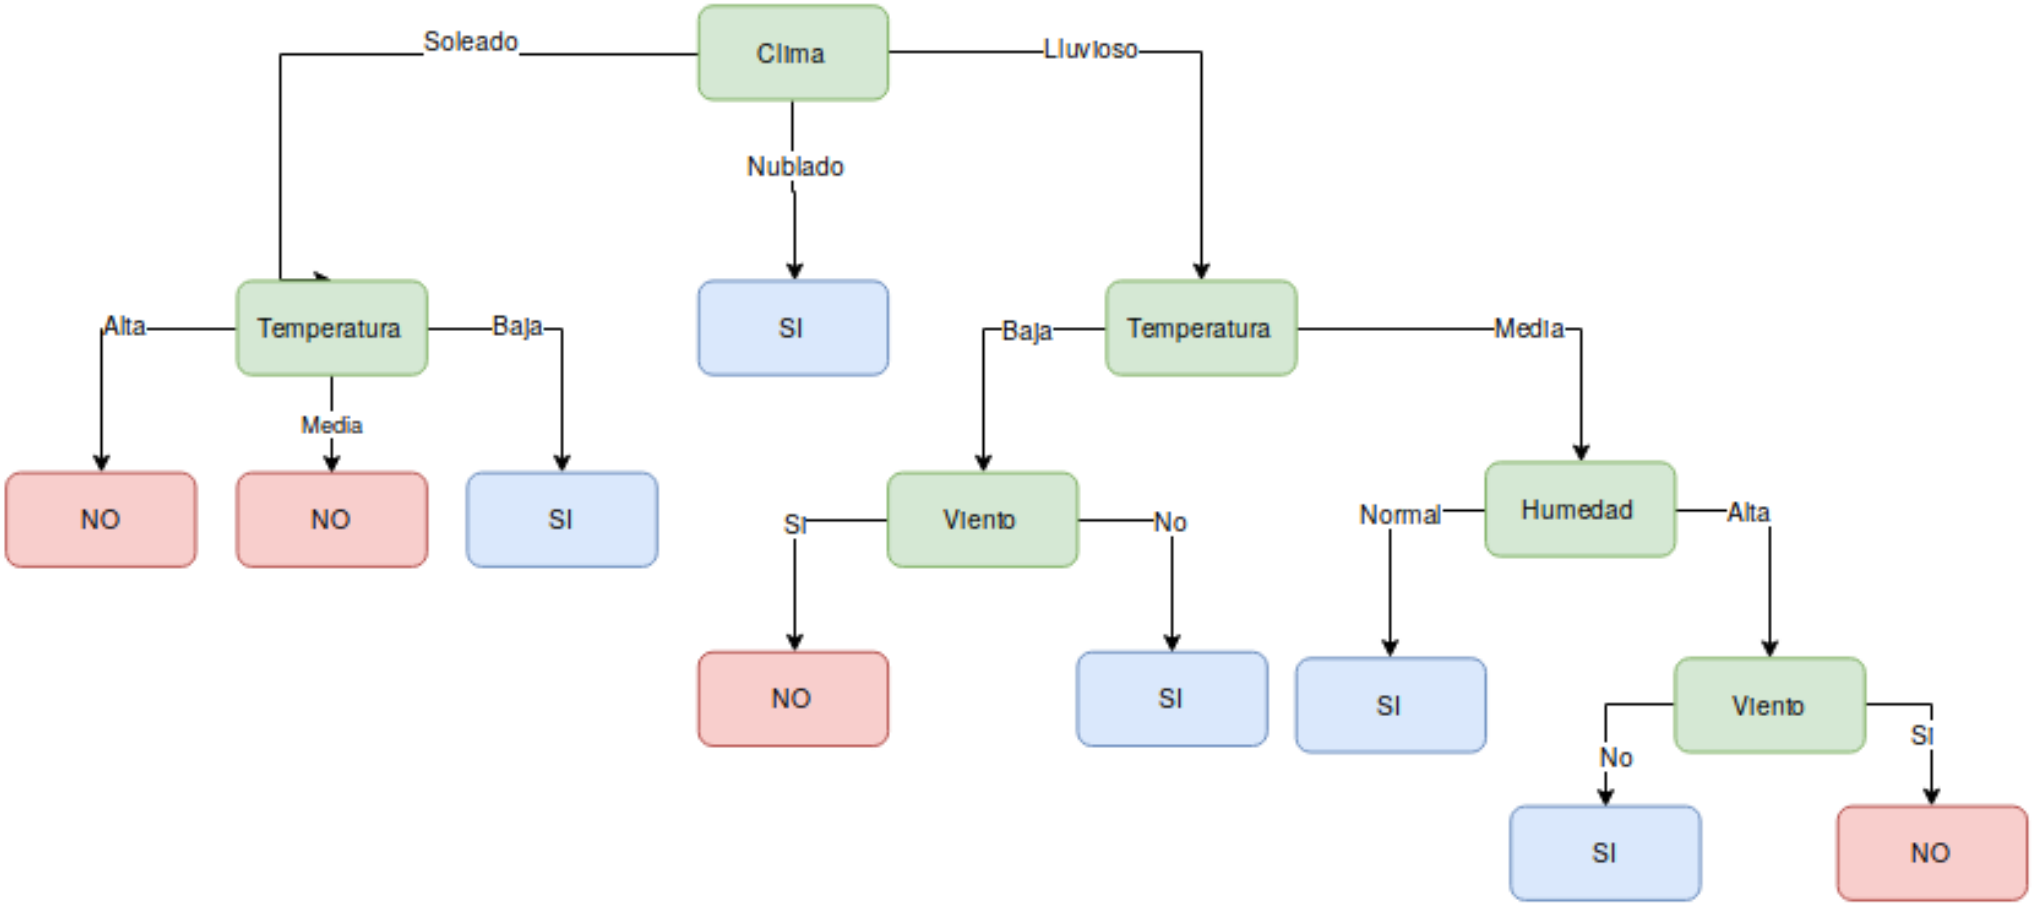
Árboles de decisión

Ejecución

Clima	Temperatura	Humedad	Viento	Juega?
			No	Si

Árboles de decisión

Eiecución



¿Qué atributos seleccionar?

Métricas:

Las métricas son criterios que determinan cuál es el mejor atributo para particionar los datos.

La idea es que el árbol resulte lo más pequeño posible, con pocos nodos y ramas.

¿Qué atributos seleccionar?

Métricas:

Las métricas son criterios que determinan cuál es el mejor atributo para particionar los datos.

La idea es que el árbol resulte lo más pequeño posible, con pocos nodos y ramas.

> ID3 → Ganancia de la información (Shannon):

Se busca minimizar la información necesaria para clasificar las tuplas, de forma tal que las particiones sean lo más “puras” posibles, en relación a las clases.

$$Info(D) = -\sum_{i=1}^{m} p_i \log_2(p_i)$$

¿Qué atributos seleccionar?

Métricas:

Las métricas son criterios que determinan cuál es el mejor atributo para particionar los datos.

La idea es que el árbol resulte lo más pequeño posible, con pocos nodos y ramas.

> CART → Gini Index:

El índice Gini busca representar el nivel de impureza de cada partición

$$Gini(D) = 1 - \sum_{i=1}^{m} p_i^2$$

Bondad del modelo

Medidas de eficiencia o performance del modelo

Para evaluar si realmente el método aprendió el patrón implícito, se puede realizar una herramienta llamada **Matriz de Confusión**, construida contando los aciertos y errores del proceso de clasificación con el modelo generado.

Cuestiones de cuantificación

	1 Real	0 Real	Total
1 Pred	V Positivos	F Positivos	Positivos Pred
0 Pred	F Negativos	V Negativos	Negativos Pred
Total	Positivos Reales	Negativos Reales	

> **Verdaderos Positivos**: Se predice 1 y se espera 1

> **Verdaderos Negativos**: Se predice 0 y se espera 0

> **Falsos Positivos**: Se predice 1 y se espera 0

> **Falsos Negativos**: Se predice 0 y se espera 1

Cuestiones de cuantificación

A partir de la Matriz de Confusión se pueden obtener medidas para evaluar la calidad del modelo. Estas medidas son:

Precisión o Accuracy

Determina que tan acertado es el modelo.

Sensitividad, Sensitivity o Recall

Determina si los positivos son correctamente detectados.

Especificidad o Specificity

Determina si los negativos son correctamente detectados.

Cuestiones de cuantificación

	1 Real	0 Real	Total
1 Pred	V Positivos	F Positivos	Positivos Pred
0 Pred	F Negativos	V Negativos	Negativos Pred
Total	Positivos Reales	Negativos Reales	

$$Accuracy = \frac{(V_P + V_N)}{V_P + V_N + F_P + F_N}$$

$$Sensitivity = \frac{V_P}{V_P + F_N}$$

$$Specificity = \frac{V_N}{V_N + F_P}$$

Cuestiones de cuantificación

Ejemplo

Estudio sobre un modelo que predice si un paciente muere o no al tomar una droga. Para la prueba se usaron 5000 ejemplos, 500 pacientes mueren y 4500 no:

Predicho	Muere	No Muere	Total Pred.
Muere	150	500	650
No Muere	350	4000	4350
Total Real	500	4500	

Cuestiones de cuantificación

Ejemplo

Estudio sobre un modelo que predice si un paciente muere o no al tomar una droga. Para la prueba se usaron 5000 ejemplos, 500 pacientes mueren y 4500 no:

Predicho	Muere	No Muere	Total Pred.
Muere	150	500	650
No Muere	350	4000	4350
Total Real	500	4500	

$$A = \frac{(150 + 4000)}{5000} = 0.83$$

Cuestiones de cuantificación

Ejemplo

Estudio sobre un modelo que predice si un paciente muere o no al tomar una droga. Para la prueba se usaron 5000 ejemplos, 500 pacientes mueren y 4500 no:

Predicho	Muere	No Muere	Total Pred.
Muere	150	500	650
No Muere	350	4000	4350
Total Real	500	4500	

$$A = \frac{(150 + 4000)}{5000} = 0.83$$

$$Specificicty = \frac{4000}{4500} = 0.888$$

Cuestiones de cuantificación

Ejemplo

Estudio sobre un modelo que predice si un paciente muere o no al tomar una droga. Para la prueba se usaron 5000 ejemplos, 500 pacientes mueren y 4500 no:

Predicho	Muere	No Muere	Total Pred.
Muere	150	500	650
No Muere	350	4000	4350
Total Real	500	4500	

$$A = \frac{(150 + 4000)}{5000} = 0.83$$

$$Specificicty = \frac{4000}{4500} = 0.888$$

$$Sensitivity = \frac{150}{500} = 0.3$$

Cuestiones de cuantificación

El modelo detecta muy bien los casos en los que los pacientes no mueren, lo cual no es crÍtico para el negocio, pero no detecta bien las tuplas en las cuales los pacientes mueren.

Cuestiones de cuantificación

El modelo detecta muy bien los casos en los que los pacientes no mueren, lo cual no es crÍtico para el negocio, pero no detecta bien las tuplas en las cuales los pacientes mueren.

El 70% de pacientes que morirían al tomar la droga, no son detectados.

Cuestiones de cuantificación

El modelo detecta muy bien los casos en los que los pacientes no mueren, lo cual no es crítico para el negocio, pero no detecta bien las tuplas en las cuales los pacientes mueren.

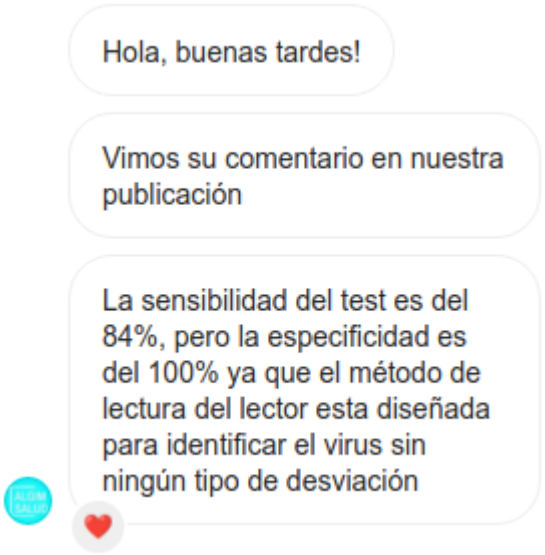
El 70% de pacientes que morirían al tomar la droga, no son detectados.

Por esta razón, es necesario evaluar no solo la precisión del modelo, sino el comportamiento del mismo frente a cada clase.

Hay un mundo real ahí afuera!



Saber diferenciar entre especificidad y sensitividad puede ayudarte en tu campaña de marketing!



Material de Lectura

Han et al. 2012. Data Mining: Concepts and Techniques. Capítulo 8.

James et al. 2013. An introduction to Statistical Learning.

Capítulo 8.