Unidad 3:
Validación de Modelos

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Recordemos...

Modelos

Los modelos buscan representar el conjunto de datos mediante distintas herramientas tales como funciones o árboles.

Recordemos...

Modelos

Los modelos buscan representar el conjunto de datos mediante distintas herramientas tales como funciones o árboles.

Los algoritmos “aprenden” el patrón o la tendencia implícita entre los datos. Para eso se utilizan algoritmos que provienen de la estadística, del aprendizaje automático, de la inteligencia artificial, entre otros.

Recordemos...

Modelos

Los modelos buscan representar el conjunto de datos mediante distintas herramientas tales como funciones o árboles.

Los algoritmos “aprenden” el patrón o la tendencia implícita entre los datos. Para eso se utilizan algoritmos que provienen de la estadística, del aprendizaje automático, de la inteligencia artificial, entre otros.

Una de las actividades de la minería de datos es poder “relacionar” los valores de una serie de atributos de entrada con los valores que toma un atributo de salida o target.

Recordemos...

Modelos

Este tipo de aprendizaje se denomina "**supervisado**", debido a que poseemos un conjunto de datos en donde constan estos valores de entrada y el valor asociado del atributo objetivo.

Recordemos...

Modelos

Este tipo de aprendizaje se denomina "**supervisado**", debido a que poseemos un conjunto de datos en donde constan estos valores de entrada y el valor asociado del atributo objetivo.

Se pueden obtener este tipo de modelos para **predecir** el valor de la variable de salida o para determinar cual es la relación implícita entre los atributos (**inferencia**).

Recordemos...

Modelos

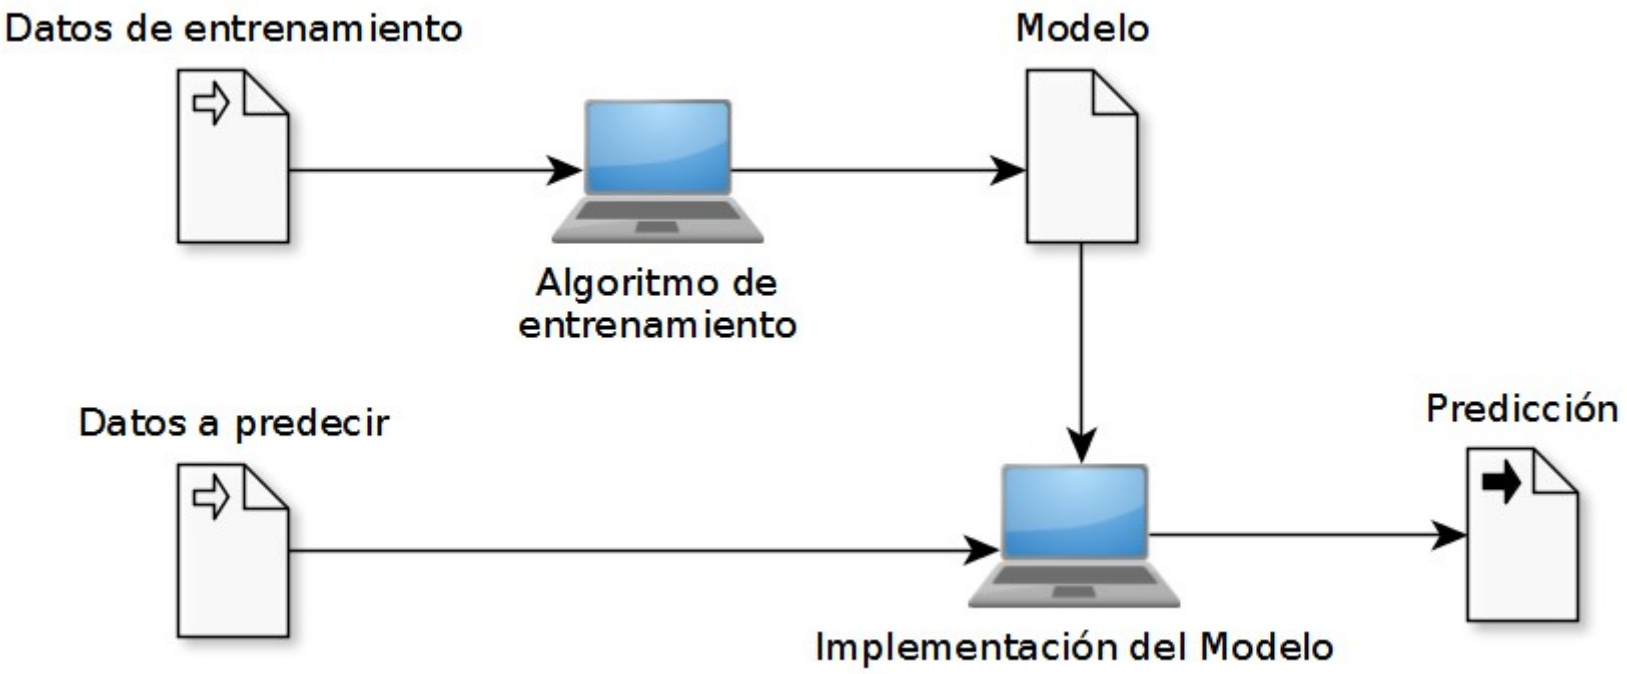
Este tipo de aprendizaje se denomina "**supervisado**", debido a que poseemos un conjunto de datos en donde constan estos valores de entrada y el valor asociado del atributo objetivo.

Se pueden obtener este tipo de modelos para **predecir** el valor de la variable de salida o para determinar cual es la relación implícita entre los atributos (**inferencia**).

En caso de que el atributo objetivo sea cuantitativo, esta actividad se llama **regresión**. En caso de ser cualitativo se denomina **clasificación**.

Recordemos...

Modelos



Validación

¿Qué tan bien el conjunto de datos es representado por el modelo?

Una vez generado el modelo, debemos determinar si el modelo realmente ha encontrado el patrón oculto entre los datos.

Validación

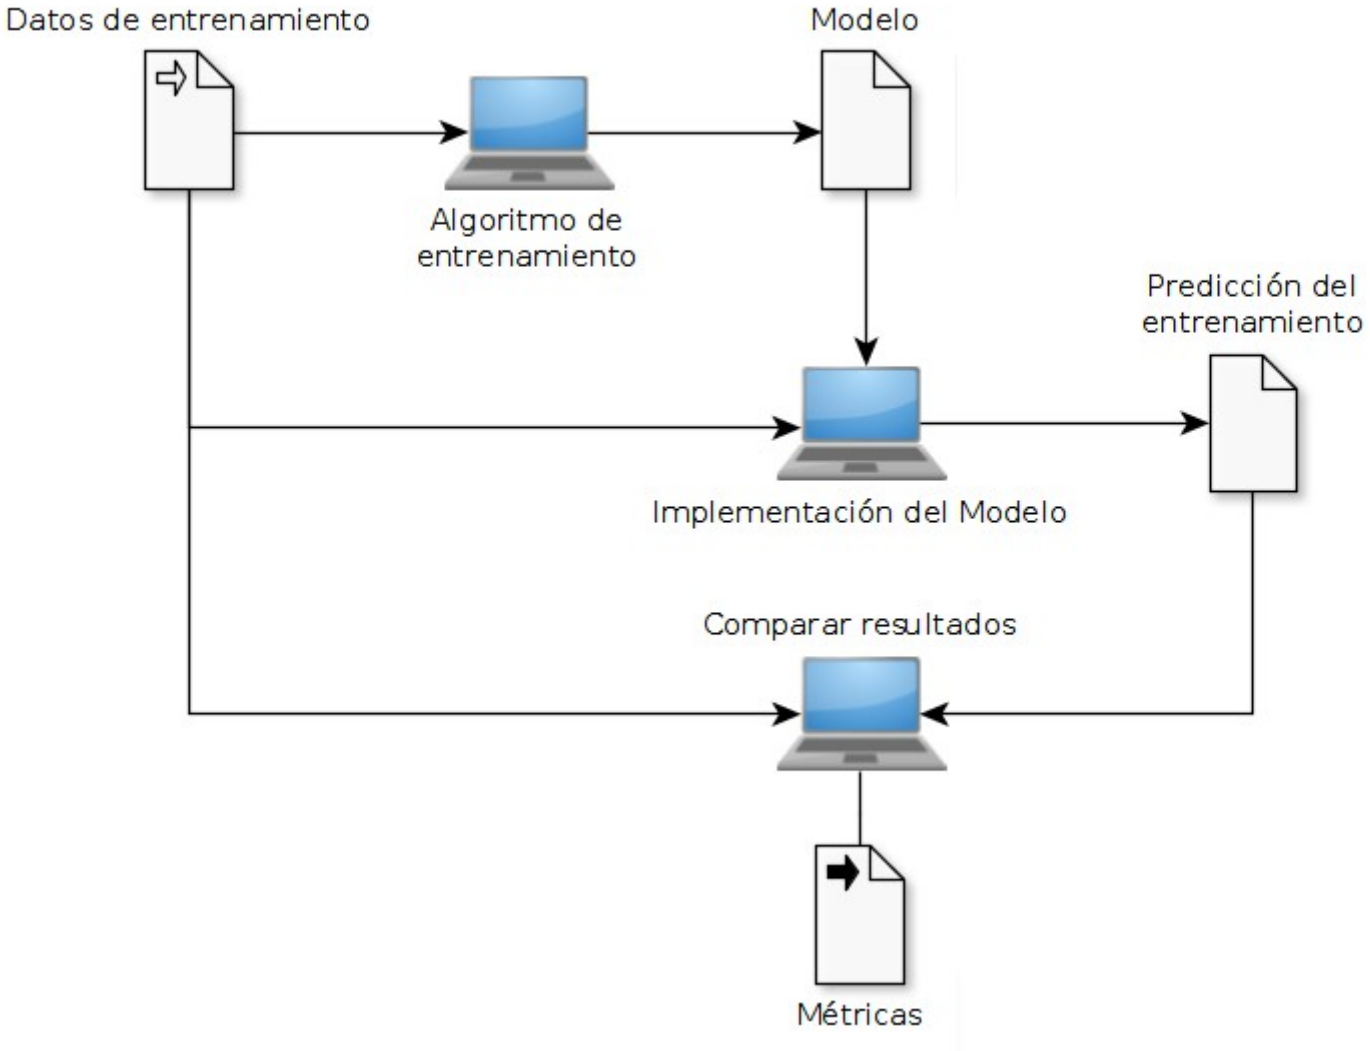
¿Qué tan bien el conjunto de datos es representado por el modelo?

Una vez generado el modelo, debemos determinar si el modelo realmente ha encontrado el patrón oculto entre los datos.

Para esto, lo primero que hemos hecho es someter el conjunto de datos utilizado para entrenar el modelo al modelo mismo y determinar que tantos “aciertos” tiene.

Esta es una primera medida de precisión o “accuracy” que podemos calcular.

Validación


Datos de entrenamiento
Modelo
Algoritmo de entrenamiento
Predicción del entrenamiento
Implementación del Modelo
Comparar resultados
Métricas

Validación

Sin embargo….

Si el modelo ajusta con un 100% de precisión ¿significa que es un buen modelo?

Validación

Sin embargo….

Si el modelo ajusta con un 100% de precisión ¿significa que es un buen modelo?

¿Qué nos asegura que al ingresar nuevos datos de entrada vamos a tener los resultados correctos?

Validación

Sin embargo….

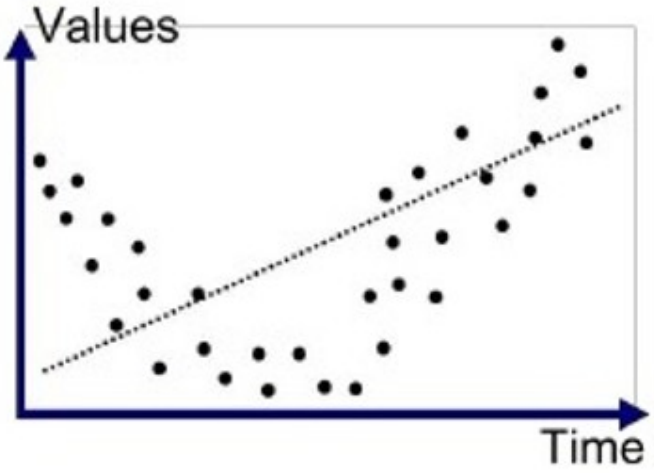
Si el modelo ajusta con un 100% de precisión ¿significa que es un buen modelo?

¿Qué nos asegura que al ingresar nuevos datos de entrada vamos a tener los resultados correctos?

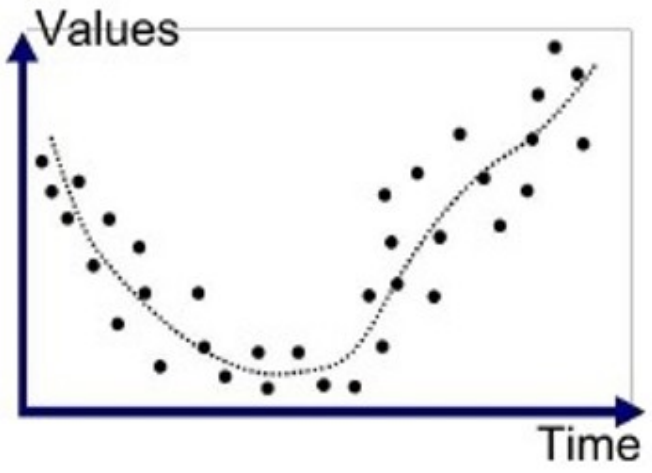
En algunas oportunidades, el modelo generado “sobre-ajusta” (overfitting), esto es, aprende a “copiar” los datos de entrenamiento, pero no el patrón detrás de los mismos.

Validación

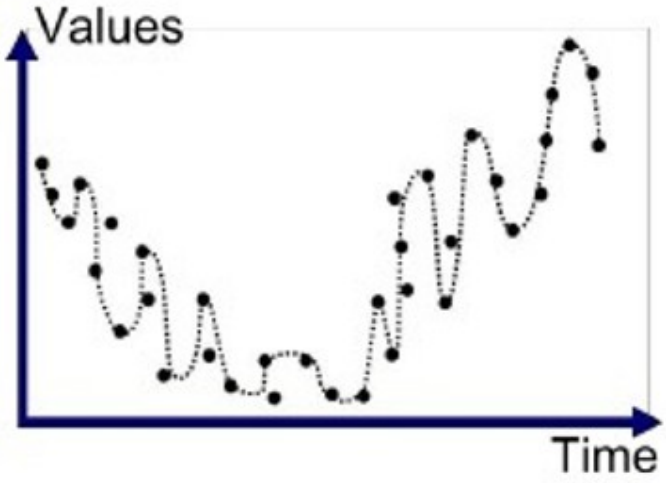
Ajuste



Underfitted



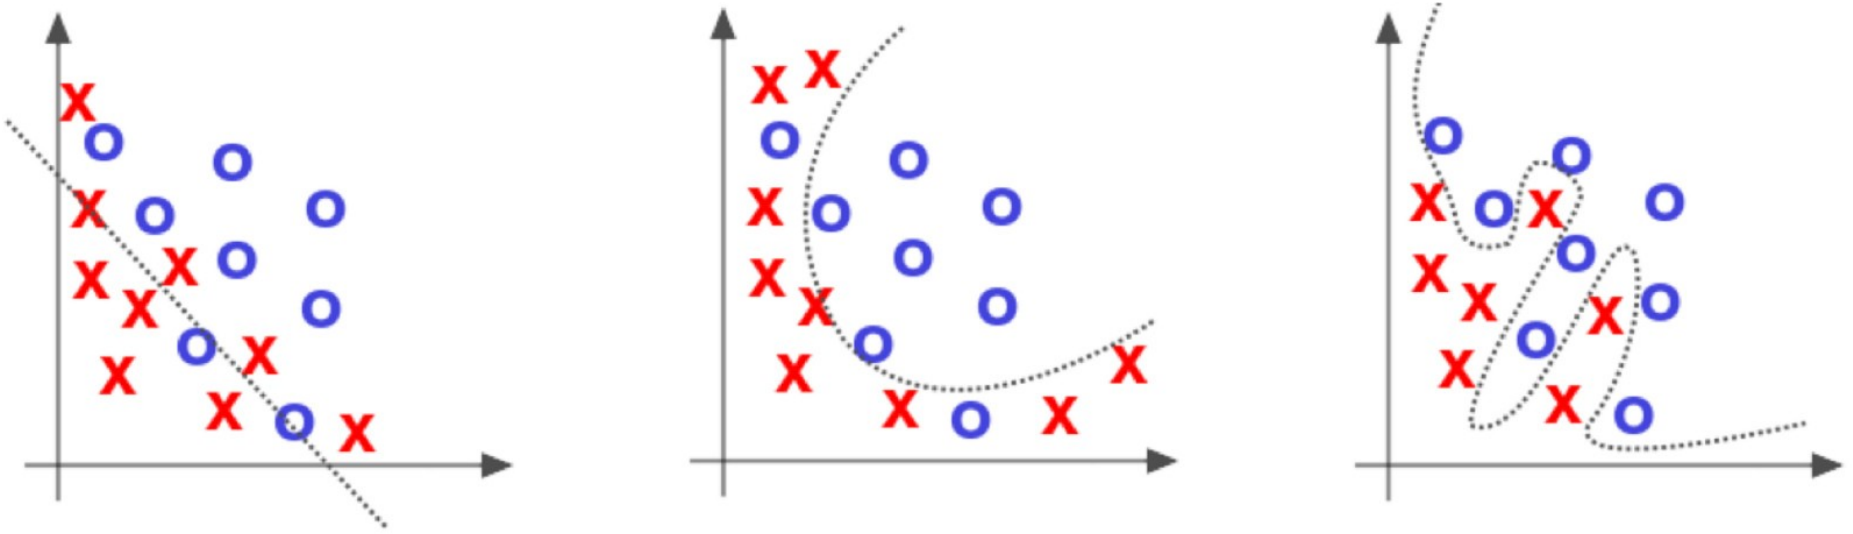
Good Fit/Robust



Overfitted

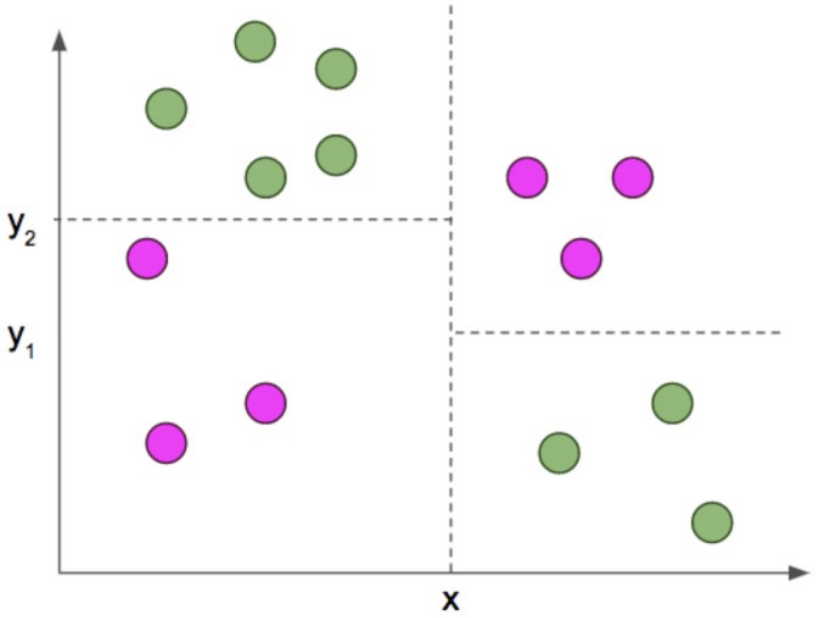
Validación

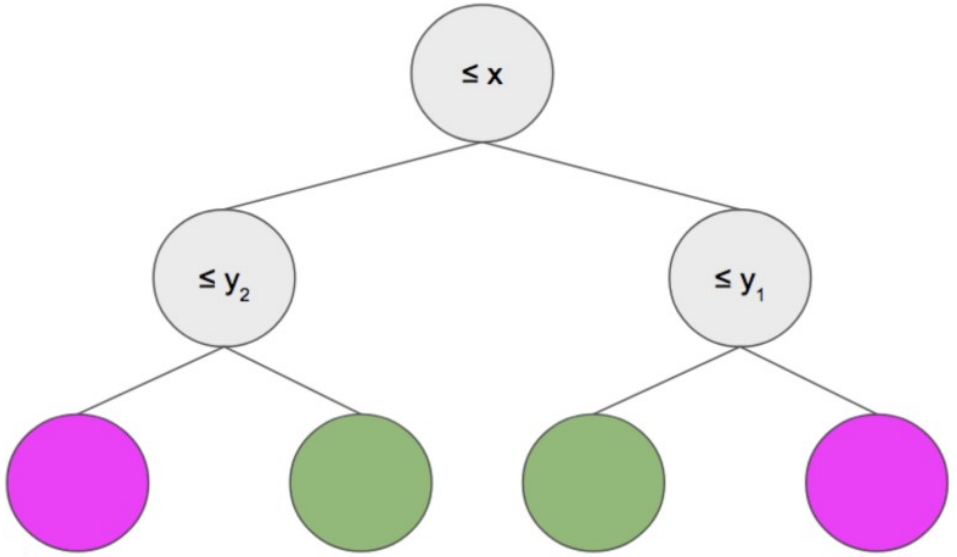
Ajuste



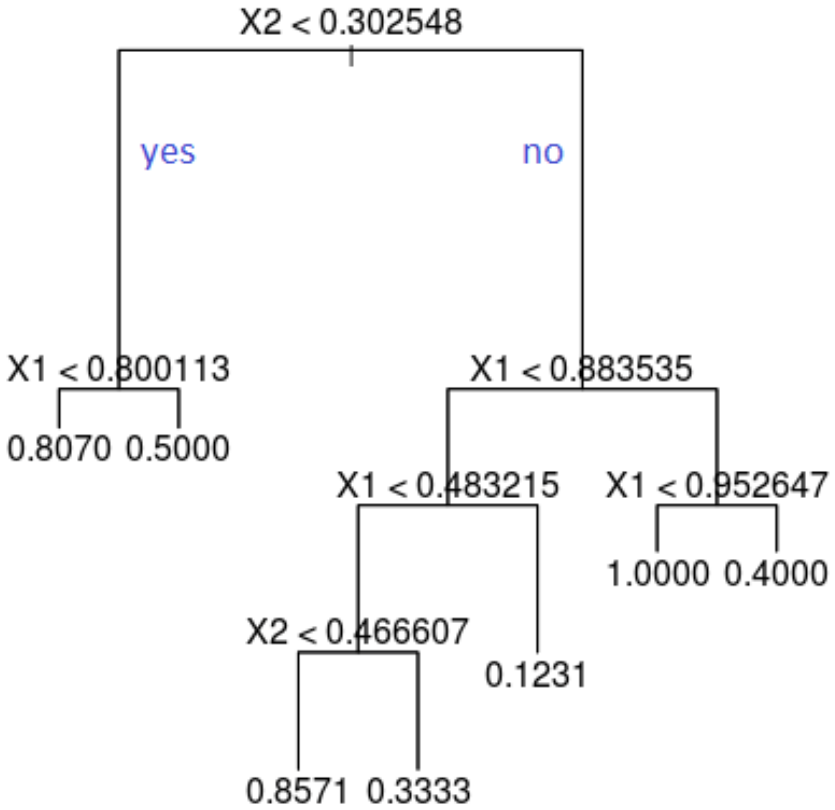
Validación

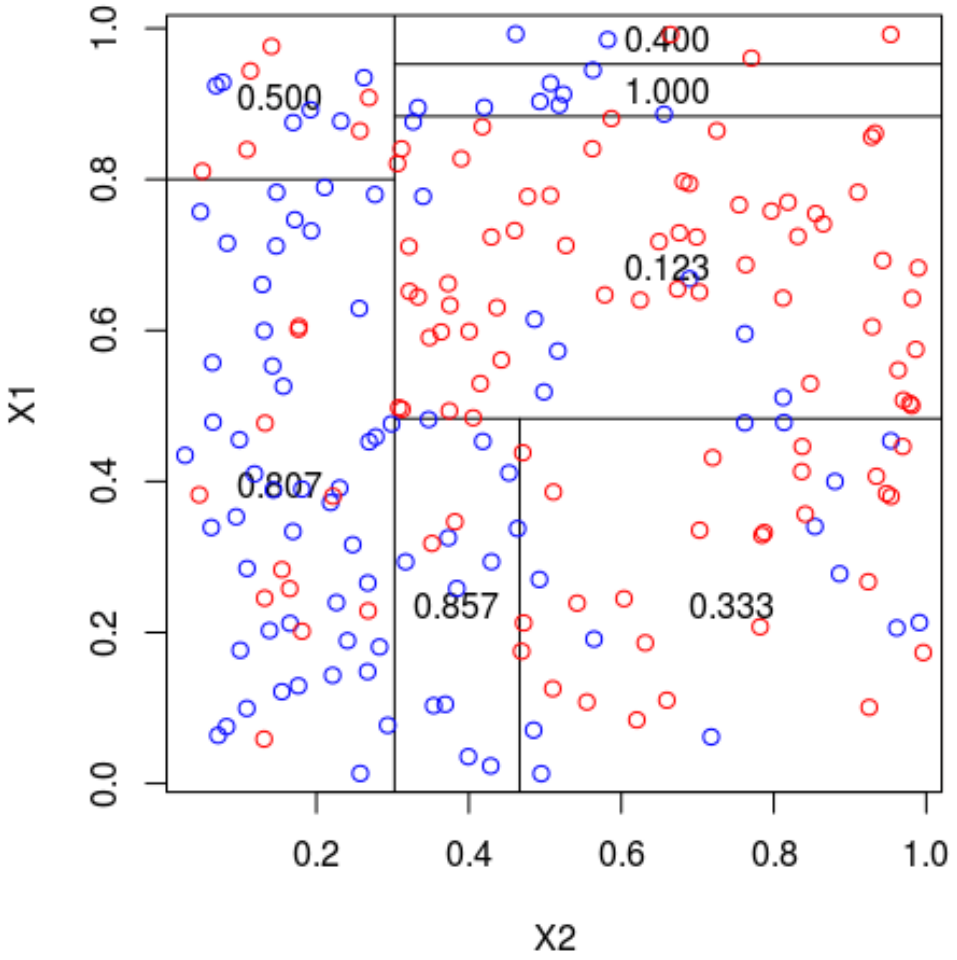
Ajuste





Validación


X2 < 0.302548
yes
no
X1 < 0.800113
X1 < 0.883535
0.8070 0.5000
X1 < 0.483215
X1 < 0.952647
1.0000 0.4000
X2 < 0.466607
0.1231
0.8571 0.3333


0.500
0.400
1.000
0.123
0.807
0.857
0.333
X1
X2
0.0
0.2
0.4
0.6
0.8
1.0

Bias y Varianza

Bias (sesgo): Indica que tan lejos está el modelo de capturar la naturaleza del fenómeno. Un sesgo alto indica underfitting, ya que no se capturan los patrones ocultos en los datos.

Varianza: Indica qué tanto cambia el modelo si se lo entrena con distintos datos. Si el modelo cambia mucho, entonces está copiando a los datos y no se está capturando la naturaleza del fenómeno. Alta varianza indica Overfitting.

Bias y Varianza

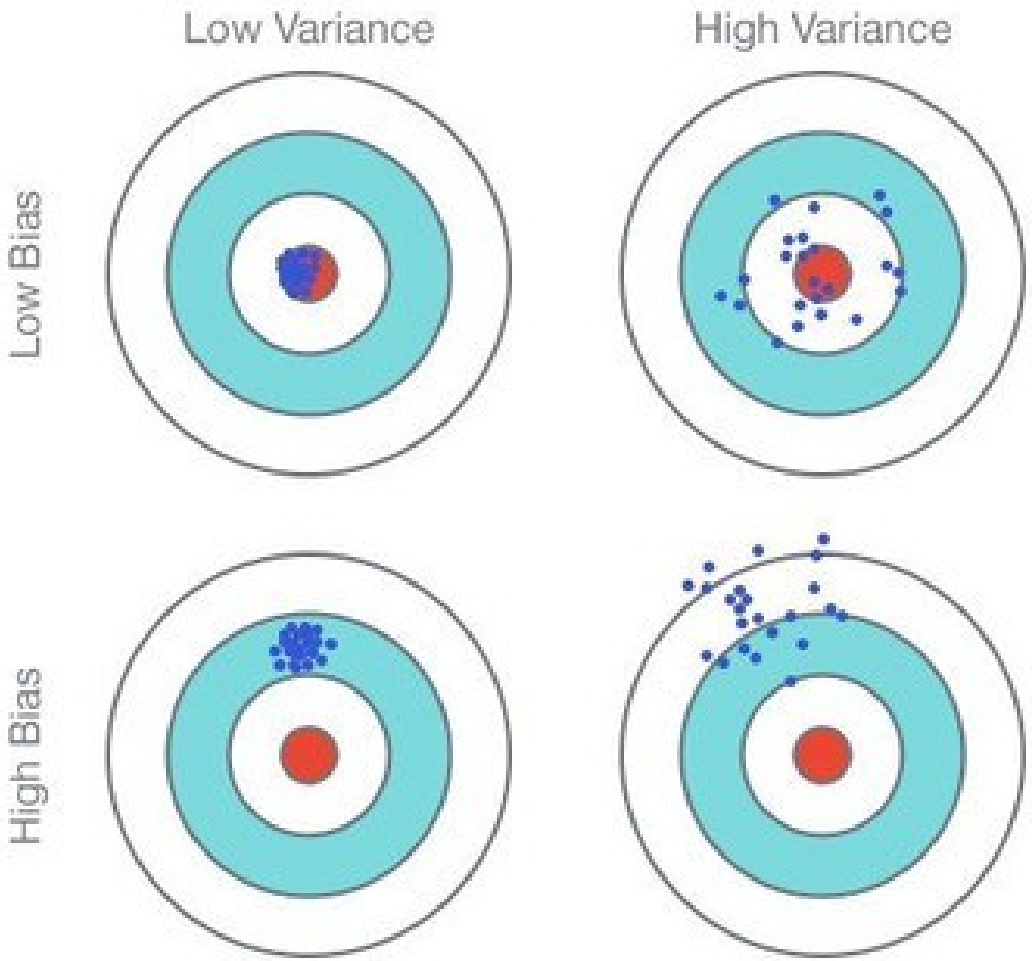
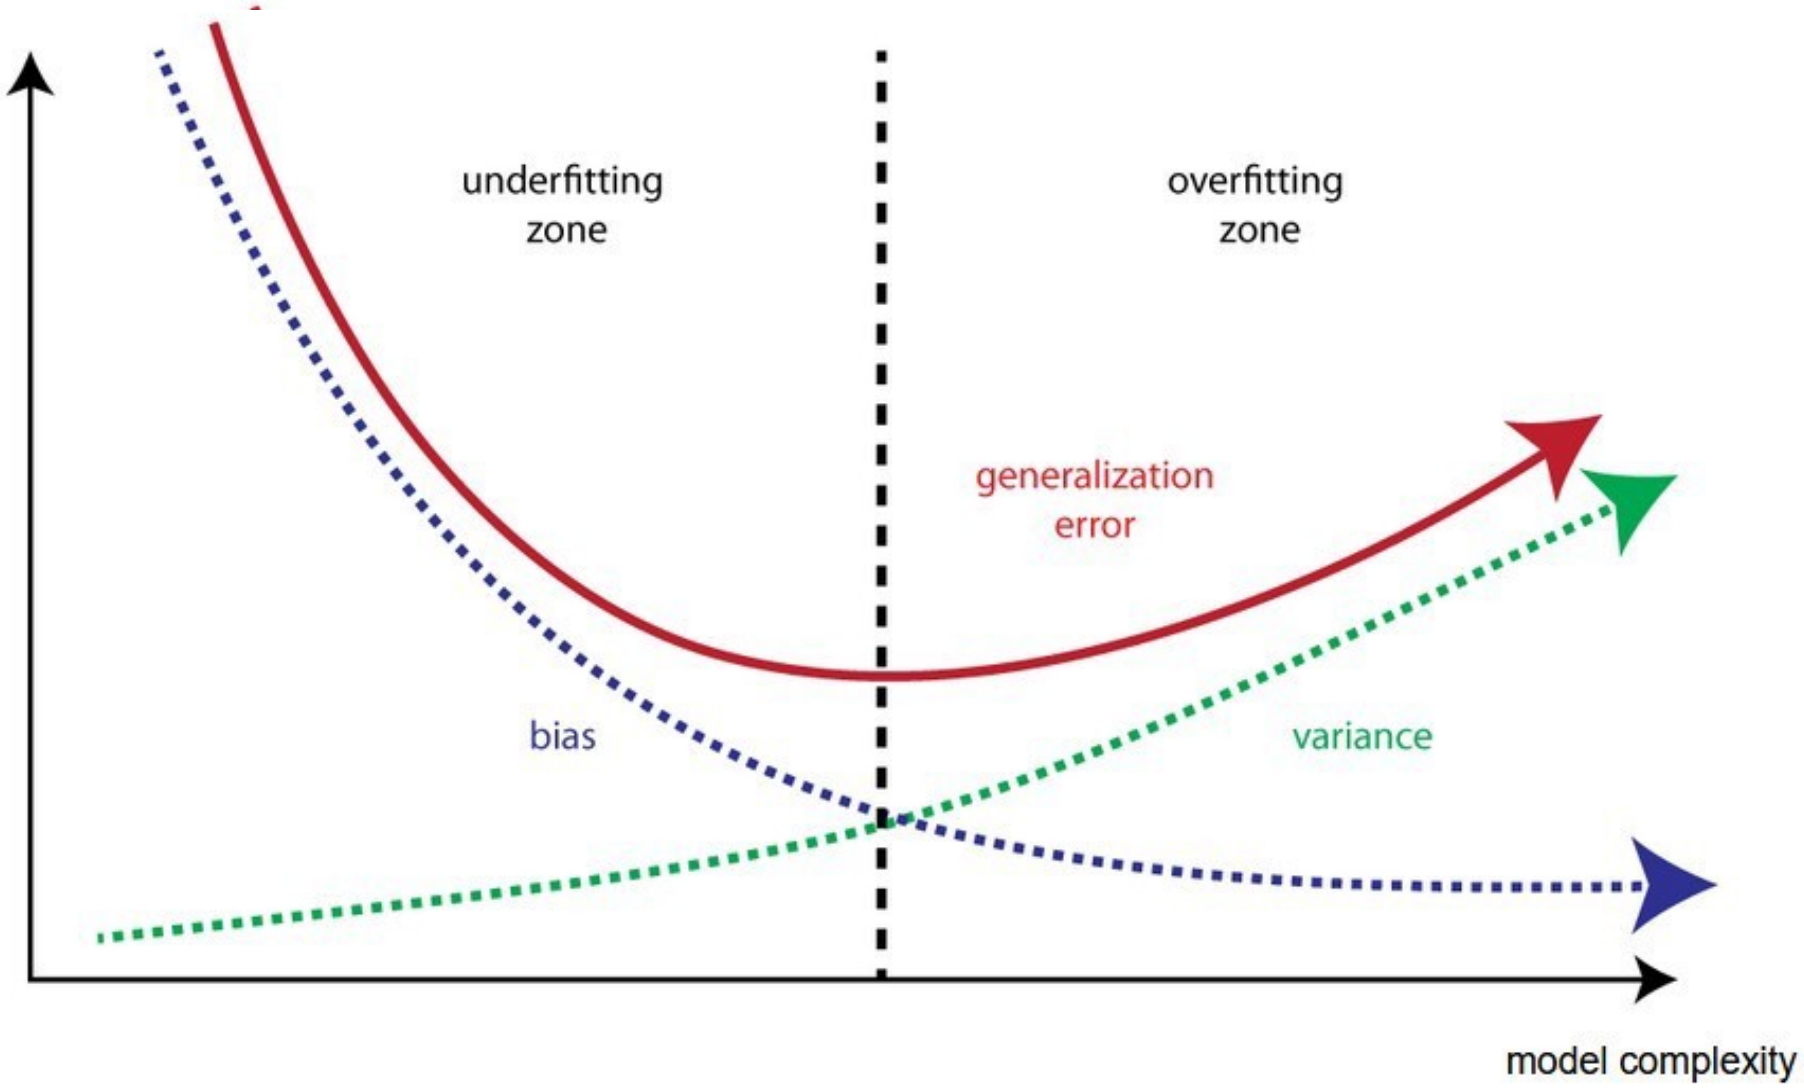


Fig. 1: Graphical Illustration of bias-variance trade-off , Source: Scott Fortmann-Roe., Understanding Bias-Variance Trade-off

Bias-variance Tradeoff



Cómo elegir un modelo correctamente

Generalmente en un problema de aprendizaje supervisado se tiene:

> Un conjunto de datos con los valores de los atributos objetivo (datos de entrenamiento).

> Un conjunto de datos sin los valores de los atributos objetivo (estos se quieren predecir)

Cuestiones Metodológicas

Generalmente en un problema de aprendizaje supervisado se tiene:

> Un conjunto de datos con los valores de los atributos objetivo (datos de entrenamiento).

> Un conjunto de datos sin los valores de los atributos objetivo (estos se quieren predecir)

Sin embargo, el proceso de evaluación necesita de un tercer conjunto de datos: el conjunto de testing.

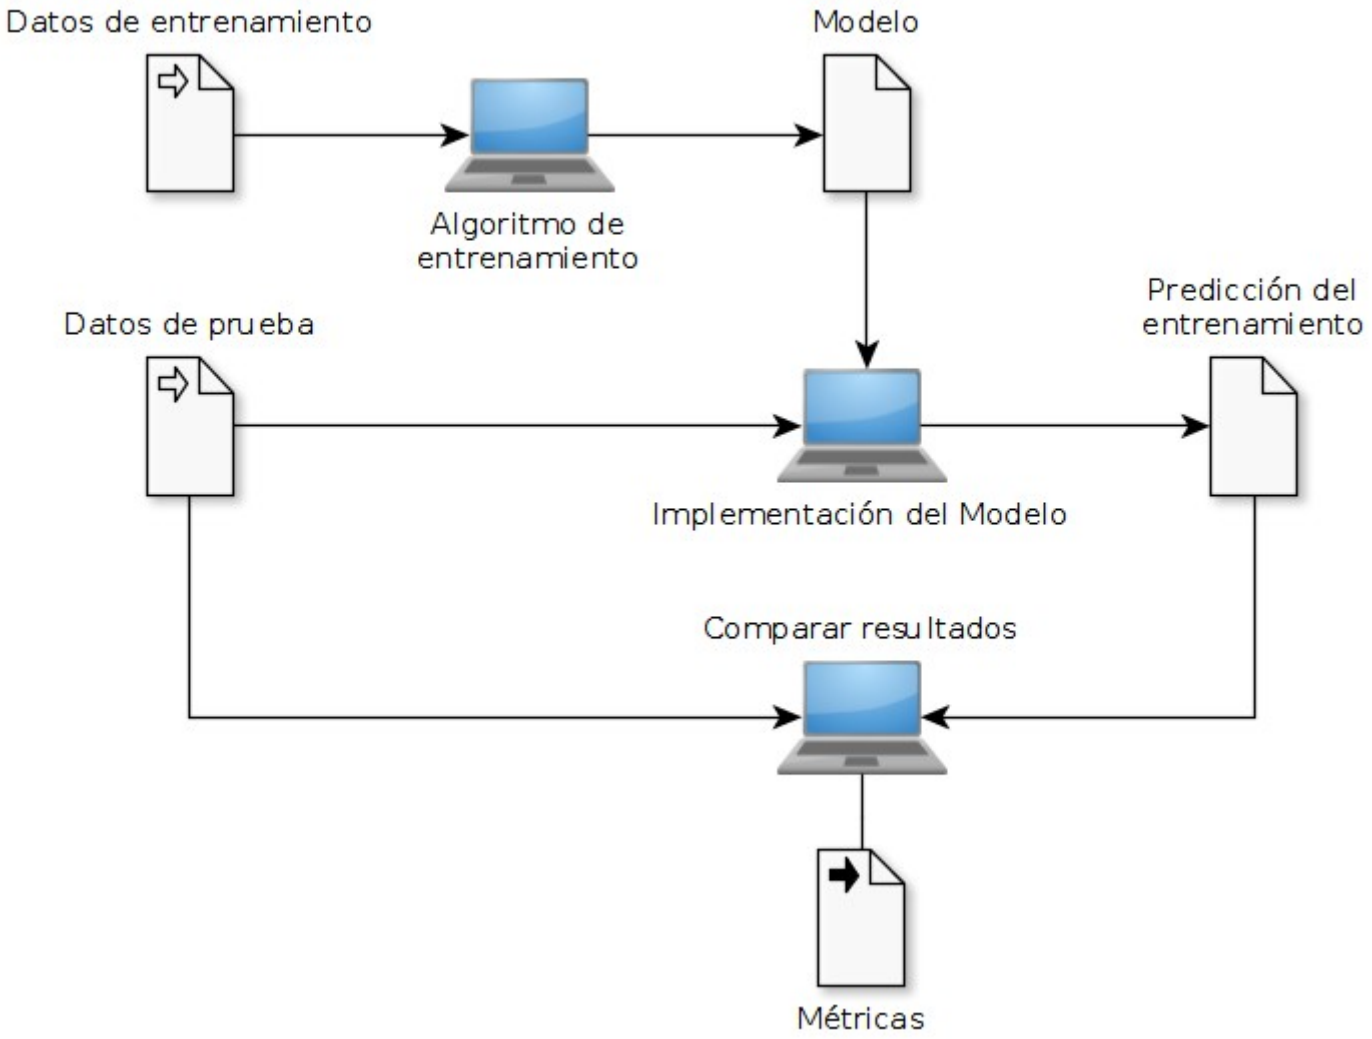
Cuestiones Metodológicas

Los datos de testing

Este conjunto de datos debe ser etiquetado.

De esta forma es posible determinar si los valores predichos se corresponden con los valores esperados.

Cuestiones Metodológicas



Cuestiones Metodológicas

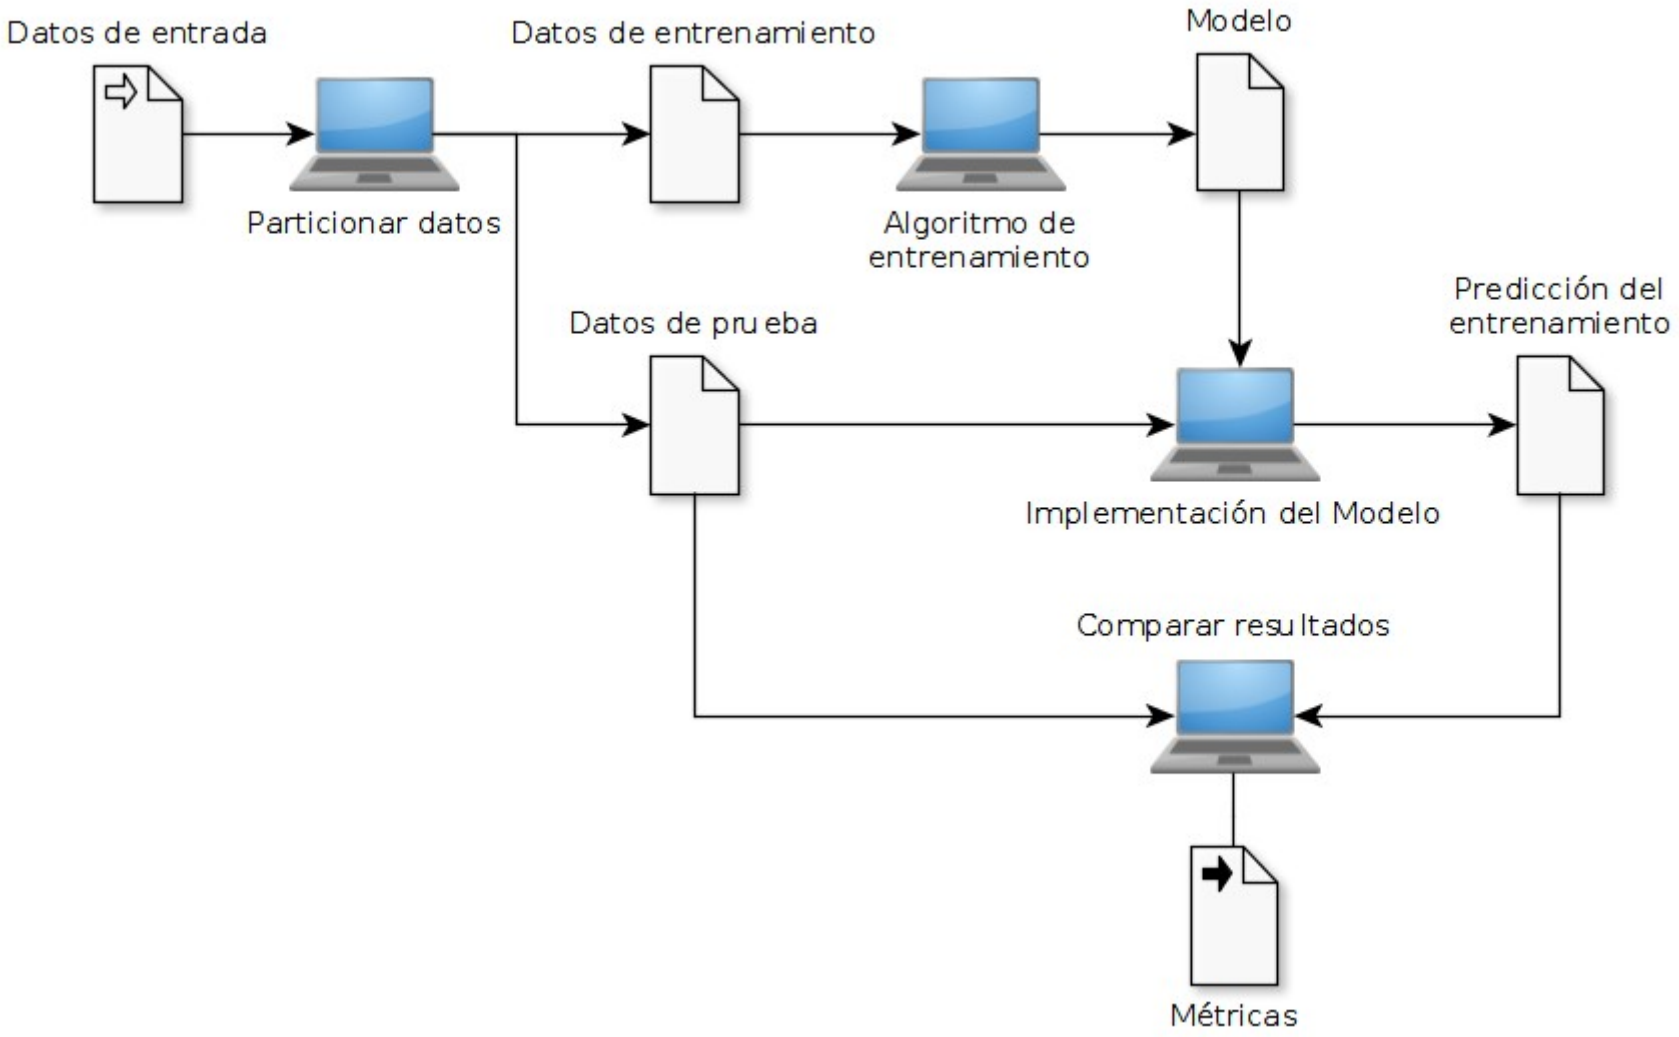
Los datos de testing

Sin embargo, en la práctica no se posee un conjunto de datos a ser utilizado con este propósito.

El procedimiento común consiste en particionar el conjunto de datos etiquetado en un conjunto de entrenamiento y un conjunto de testing.

$$\{Train, Test\} \Big/ Train \cup Test = D \wedge Train \cap Test = \emptyset$$

Cuestiones Metodológicas



Cuestiones Metodológicas

Tamaño

No existe ninguna regla sobre la proporción a ser utilizada.

Las más comunes son:

> Regla de pareto: 80% - 20%

> ⅔ – ⅓

Es importante que en ambos conjuntos haya la misma proporción de valores para el atributo objetivo

Cuestiones Metodológicas

Muestreo aleatorio simple:

Se generan números aleatorios para seleccionar n elementos de la base de datos.

Esto no nos asegura que haya la misma representatividad de clases.

Cuestiones Metodológicas

Muestreo aleatorio simple:

Se generan números aleatorios para seleccionar n elementos de la base de datos.

Esto no nos asegura que haya la misma representatividad de clases.

Muestreo estratificado:

Se divide al conjunto de datos de acuerdo a los valores del atributo objetivo.

Por cada subconjunto se selecciona aleatoriamente un porcentaje de datos para testing.

Las proporciones por cada clase puede ser o no las mismas.

Cuestiones Metodológicas

Muestreo por cuotas

Similar al estratificado pero no aleatorio.

Se pueden elegir los individuos por conveniencia.

Muestreo sistemático:

Se elige un elemento de forma aleatoria, y a partir de el se eligen los siguientes siguiendo una función dada. Por ejemplo:

$$pos_i = pos_{i-1} + 3$$

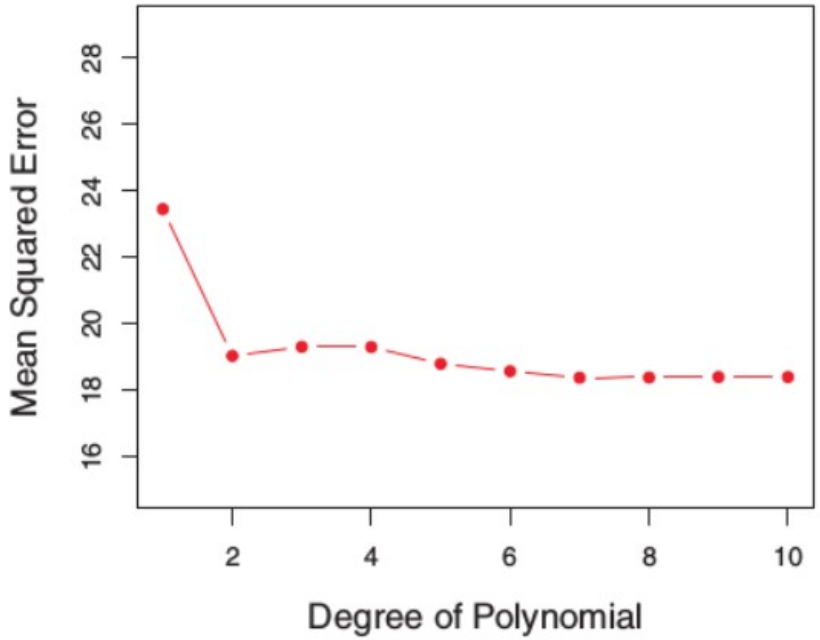
Otros...

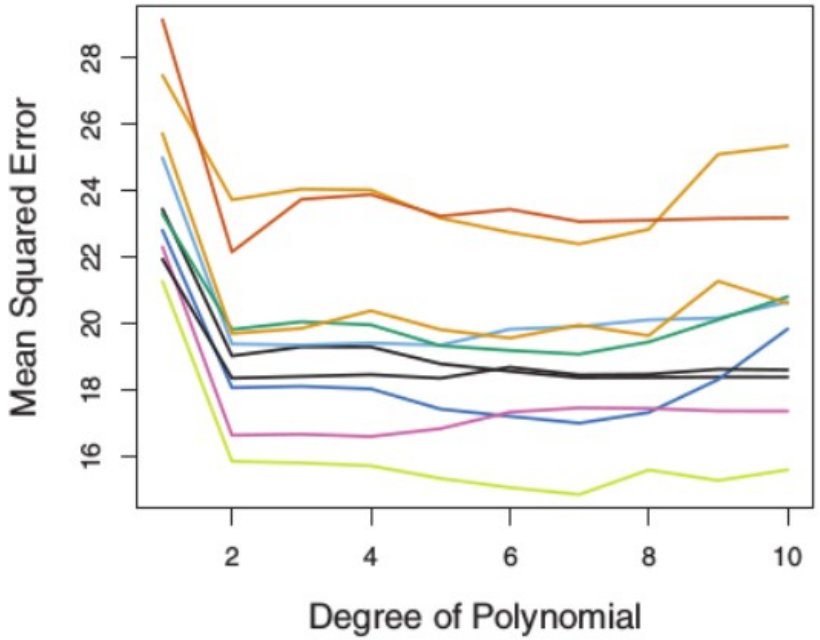
Cuestiones Metodológicas

Pero...

¿Cómo aseguramos que las muestras elegidas son las mejores opciones para generar y evaluar los modelos?

¿Cómo sabemos que los resultados obtenidos son independientes de la partición generada?





Cuestiones Metodológicas

Para solucionar estas cuestiones se utiliza lo que se denomina Validación Cruzada, Cross Validation o X-Validation

Esta estrategia utilizan sucesivos muestreos del conjunto de datos obteniendo en cada iteración conjuntos distintos de entrenamiento y de prueba.

Al finalizar el proceso se suelen promediar los resultados de todas las iteraciones.

Cuestiones Metodológicas

Cross-Validation

Existen dos variantes principales:

> Cross validation dejando uno fuera (LOOCV)

> Cross validation por grupos (k-folds CV)

Cuestiones Metodológicas

Leave One Out Cross Validation (LOOCV)

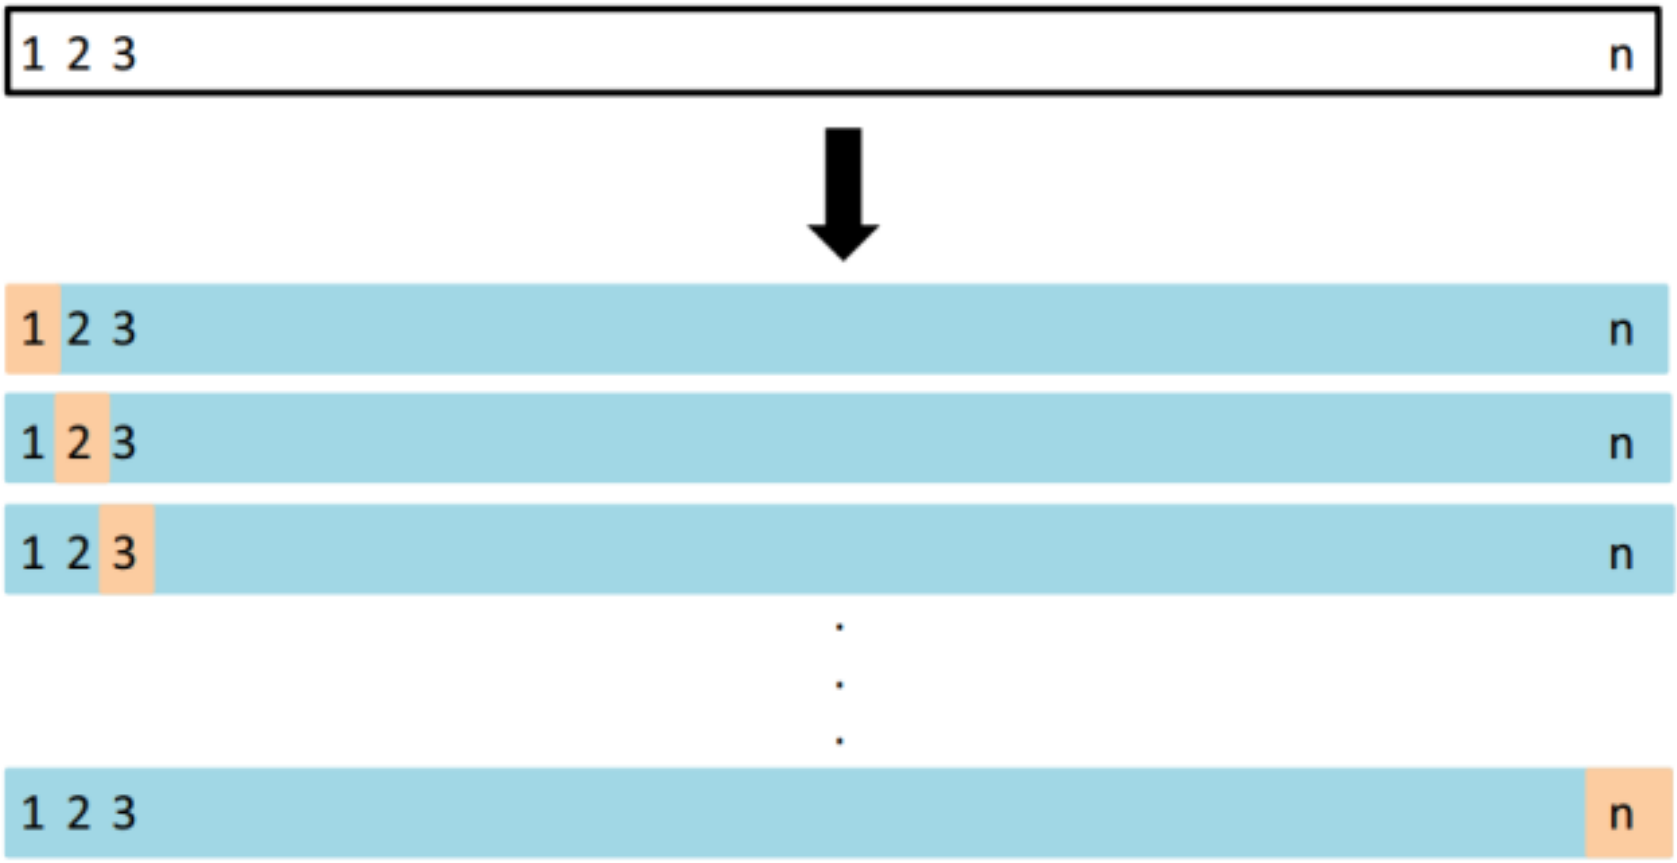
Se busca aumentar la cantidad de datos de entrenamiento para reducir el error del modelo.

Sea n el tamaño de la base de datos, se toman n-1 elementos para entrenamiento y se deja 1 tupla para validación.

Se realizan n entrenamientos variando en cada oportunidad el elemento apartado.

El error total del modelo es el promedio de los errores de cada entrenamiento (error cuadrático medio).

Cuestiones Metodológicas



Cuestiones Metodológicas

Ventajas

> Se usan todos los elementos para el entrenamiento, pero no se incorporan todos los errores individuales.

> No se considera solo el error de un conjunto de datos de pruebas.

> El error es único para el conjunto de datos, no difiere en función de la partición realizada

Desventajas

> Muy costoso de implementar (n iteraciones)

Cuestiones Metodológicas

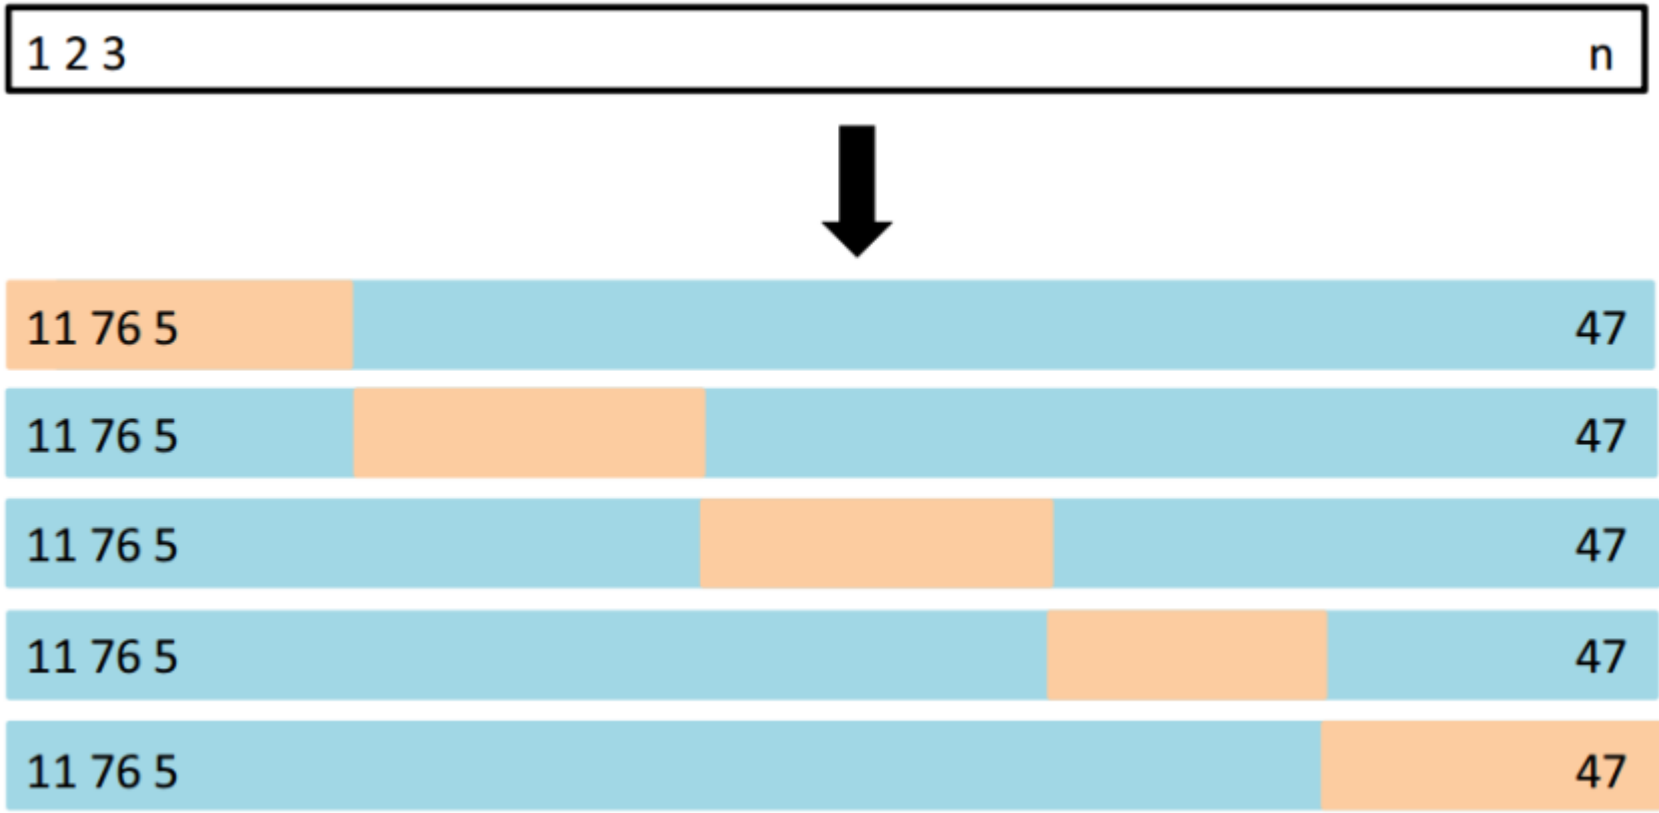
K-Folds Cross Validation

En esta alternativa de LOOCV se divide el conjunto de datos de manera aleatoria en k grupos de aproximadamente el mismo tamaño.

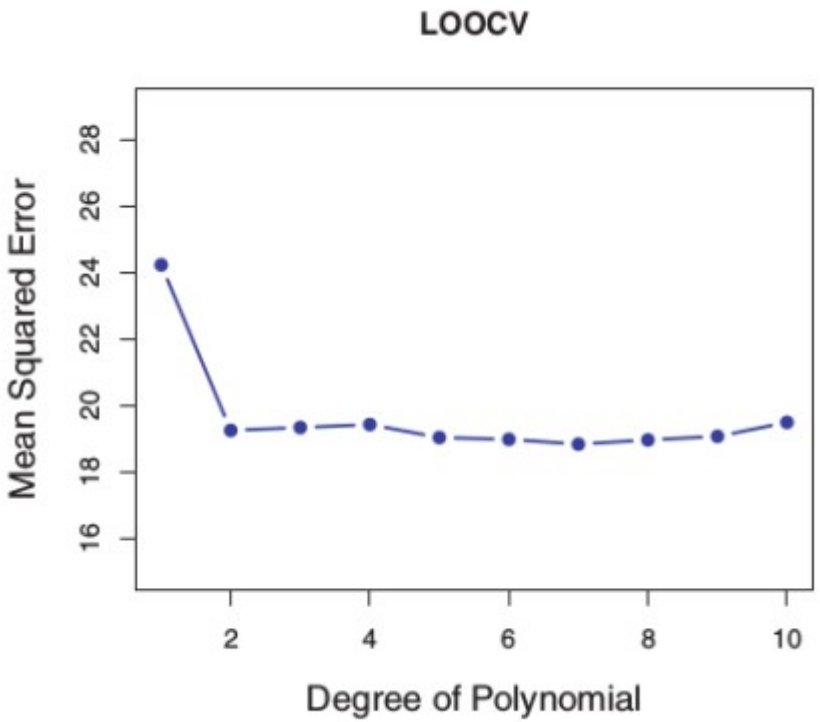
Es más eficiente que LOOCV, debido a que se realizan menos ajustes del modelo, a expensas de incorporar mayores errores al mismo.

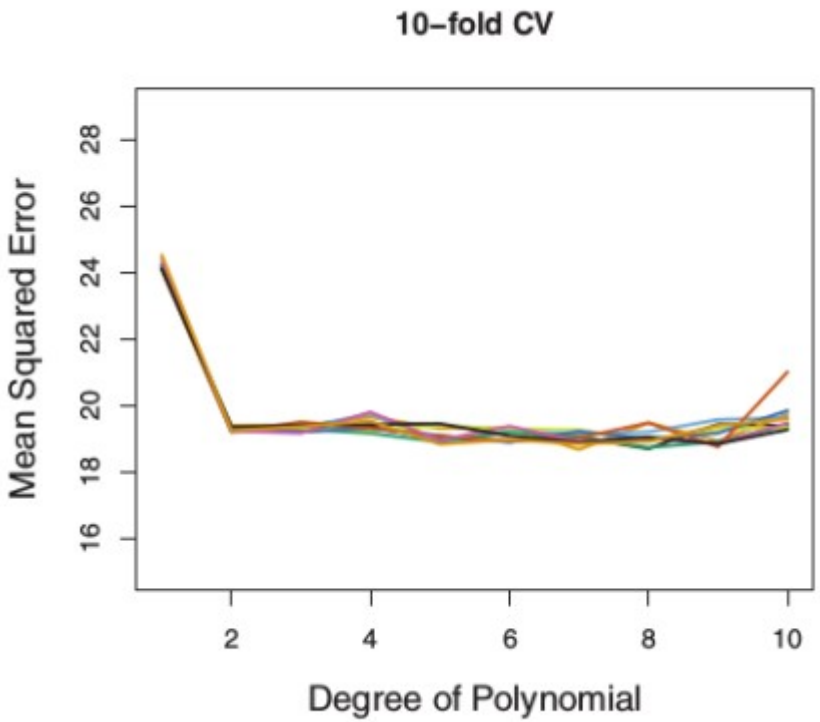
Es necesario determinar una buena configuración del tamaño de K en función del tiempo disponible para la creación del modelo.

Cuestiones Metodológicas



Cuestiones Metodológicas





¿Cómo reducimos el bias y la varianza?

Bias alto es sinónimo de **underfitting**.

Esto es, el modelo no es suficientemente potente para comprender el patrón de fondo. Puede darse si utilizamos, por ejemplo, una función lineal para aproximar una cuadrática.

Para solucionar esto se puede:

- Usar modelos más complejos, o no paramétricos.
- Asegurarse de que los datos son representativos
- Configuración correcta de praámetros

¿Cómo reducimos el bias y la varianza?

La **varianza alta** está generalmente asociada con el **overfitting**

Esto es, el modelo copia los datos de entrenamiento tan bien que pierde poder de generalización. Esto suele suceder con modelos muy complejos o modelos no paramétricos.

Para solucionar esto se puede:

- Usar modelos más simples, o paramétricos
- Usar más datos (data aungmentation)
- Métodos ensamblados (varios modelos combinados)

¿Cómo reducimos el bias y la varianza?



Hay que encontrar el balance entre el bias y la varianza seleccionando métodos apropiados.

Recordemos además que la interpretabilidad del modelo es otro factor que puede ayudarnos a decantarnos por uno u otro modelo.

Material de Lectura

James, Gareth, et al. An introduction to statistical learning. Vol. 112. New York: springer, 2013.

Aggarwal. 2015. Data Mining: The textbook. **Sección 10.9**

Berthold et al. (2020). Guide to Intelligent Data Science: How to Intelligently Make Use of Real Data. **Chapters 5.4, 5.5 and 5.6**. Second Edition. Springer. https://doi.org/10.1007/978-3-030-45574-3