Unidad 3:
Agrupamiento - DBSCAN

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Agrupamiento

¿Qué es?

Agrupamiento

¿Qué es?

Es una actividad de la minería de datos que busca particionar o clasificar el conjunto de datos en grupos o clases, de forma tal que cada grupo esté conformado por elementos similares entre si, y distintos considerablemente a los elementos de otros grupos.

Agrupamiento

¿Qué es?

Es una actividad de la minería de datos que busca particionar o clasificar el conjunto de datos en grupos o clases, de forma tal que cada grupo esté conformado por elementos similares entre si, y distintos considerablemente a los elementos de otros grupos.

¿Tipos de algoritmos?

Agrupamiento

¿Qué es?

Es una actividad de la minería de datos que busca particionar o clasificar el conjunto de datos en grupos o clases, de forma tal que cada grupo esté conformado por elementos similares entre si, y distintos considerablemente a los elementos de otros grupos.

¿Tipos de algoritmos?

- Particionamiento (K-means)
- Jerárquicos
- Basados en Grillas
- Basados en Densidad

Método de particionamiento

K-Means

Método de particionamiento

K-Means

- Se busca particionar el conjunto de datos.
- Está basado en centroides
- Es iterativo, en cada iteración se re-calculan los centroides
- La asignación se realiza utilizando la distancia euclideana.

Método de particionamiento

K-Means

- Se busca particionar el conjunto de datos.
- Está basado en centroides
- Es iterativo, en cada iteración se re-calculan los centroides
- La asignación se realiza utilizando la distancia euclideana.

Inconvenientes

Método de particionamiento

K-Means

- Se busca particionar el conjunto de datos.
- Está basado en centroides
- Es iterativo, en cada iteración se re-calculan los centroides
- La asignación se realiza utilizando la distancia euclideana.

Inconvenientes

- Costoso si la cantidad de datos es grande
- Muchas evaluaciones de la función de distancia
- Clusters esféricos

Método de particionamiento

K-Means

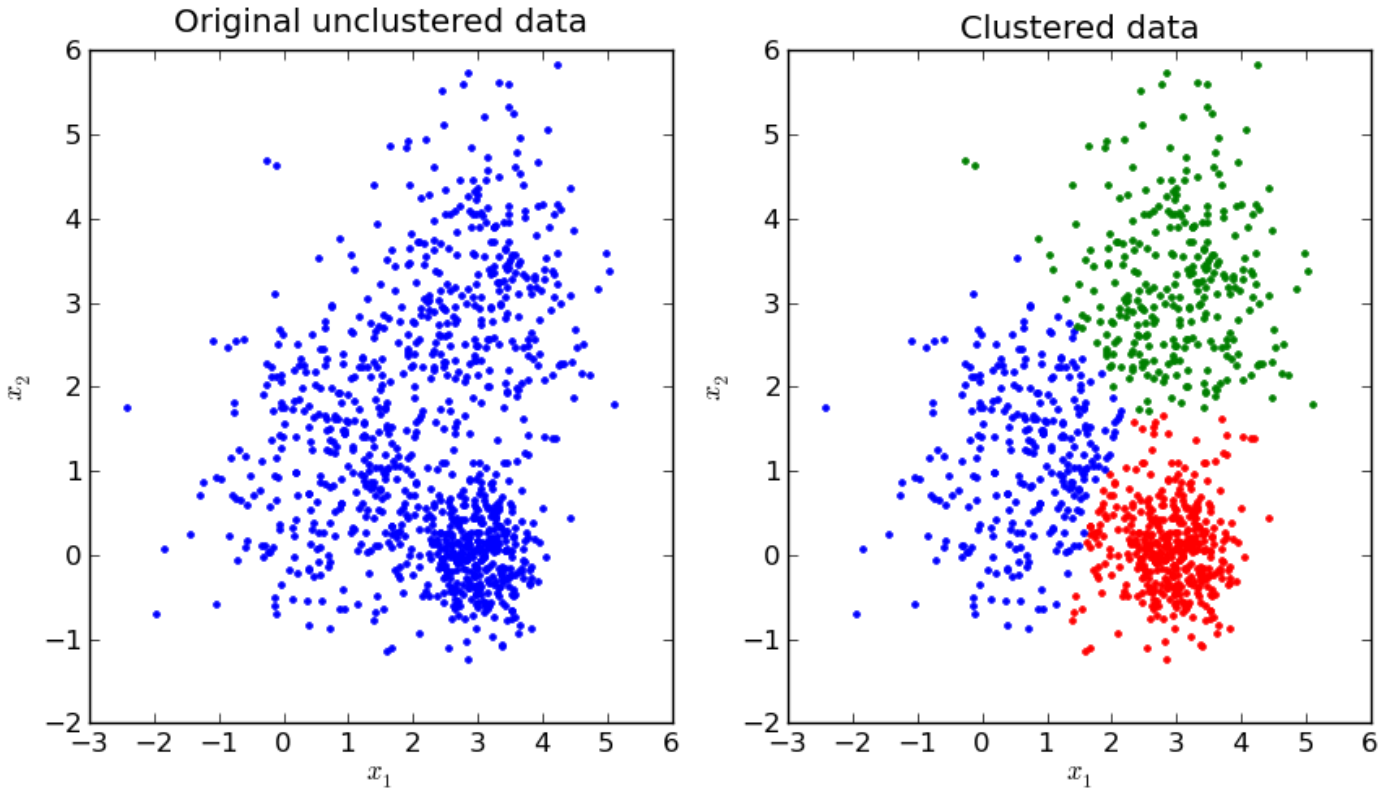
- Se busca particionar el conjunto de datos.
- Está basado en centroides
- Es iterativo, en cada iteración se re-calculan los centroides
- La asignación se realiza utilizando la distancia euclideana.

Inconvenientes

- Costoso si la cantidad de datos es grande
- Muchas evaluaciones de la función de distancia
- Clusters esféricos

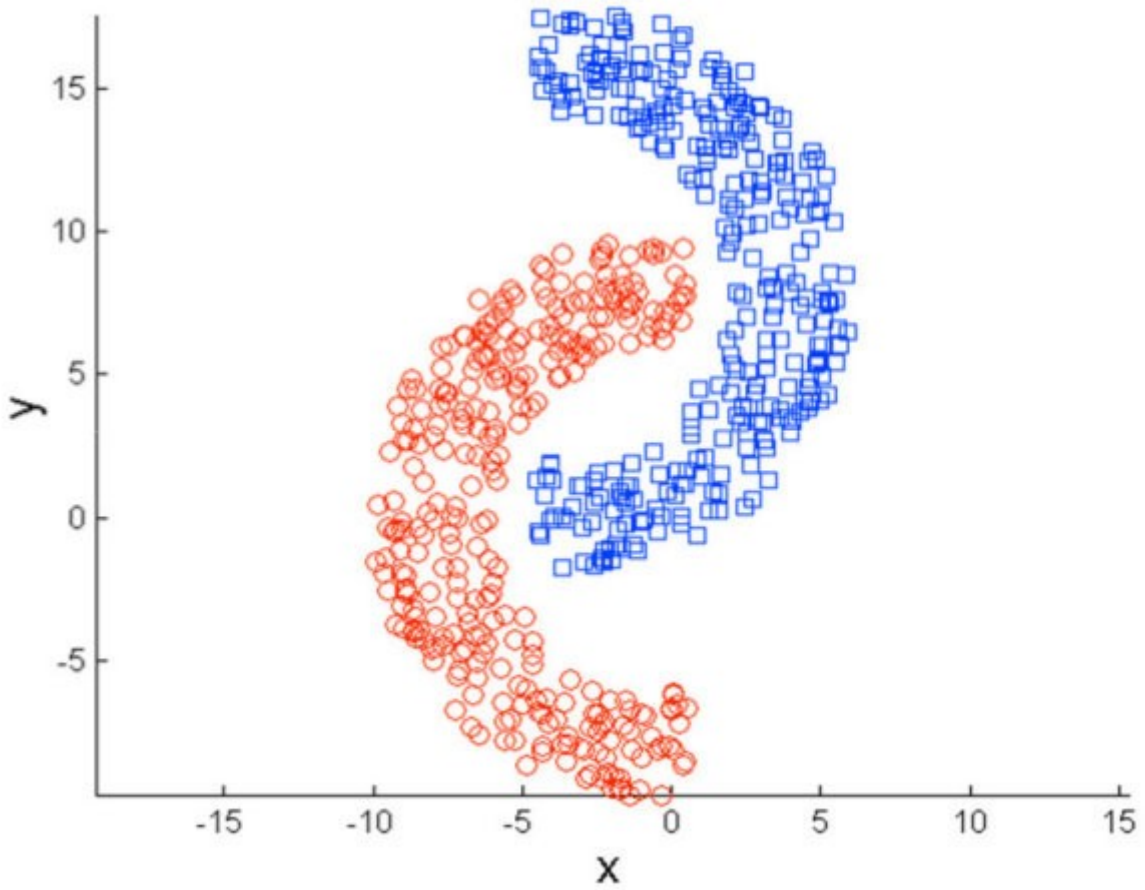
Método de particionamiento

K-Means



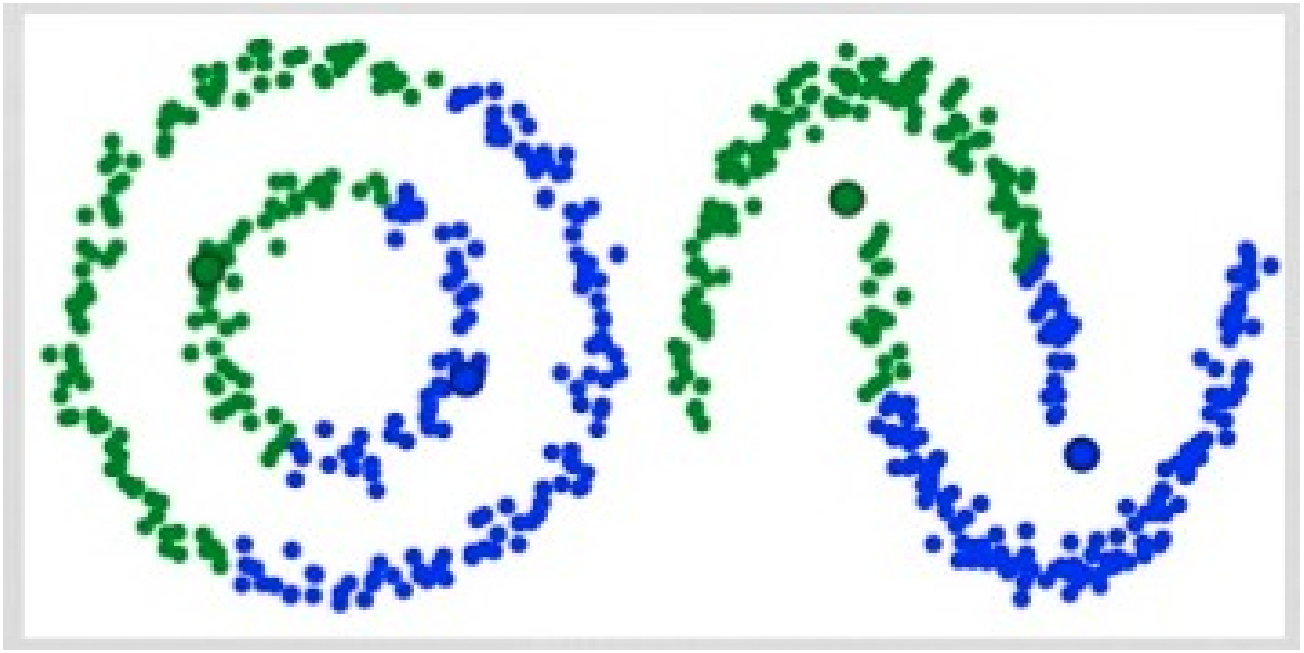
Método de particionamiento

¿K-Means?



Método de particionamiento

¿K-Means?



Métodos basados en densidad

¿Qué caracterizan a estos clusters?

- Evidentemente los clusters no están “juntos” en el espacio.
- Los clusters están formados por regiones densas de puntos.
- La densidad está dada por la cantidad de puntos en una región del espacio.

- Tiene sentido en estos casos detectar estos grupos basándonos en este criterio.

Métodos basados en densidad

DBSCAN (1996)

(Density Based Spatial Clustering of Applications with Noise)

Es un algoritmo de agrupamiento que utiliza el concepto de densidad mediante la incorporación de dos parámetros de entrada.

Es uno de los algoritmos más utilizados en la historia de la minería de datos, junto con K-Means.

DBSCAN

Idea básica

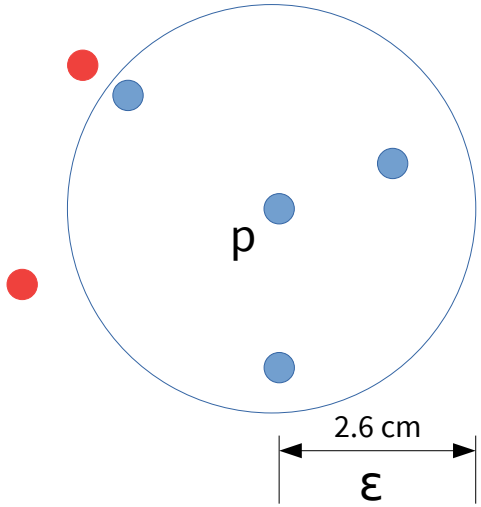
- Si un objeto q está densamente conectado a otro objeto p, entonces q y p pertenecen al mismo cluster.

- Si q no está densamente conectad a ningún objeto, entonces q es clasificado como ruido.

DBSCAN – Conceptos iniciales

ε-neighborhood | ε-vecindario

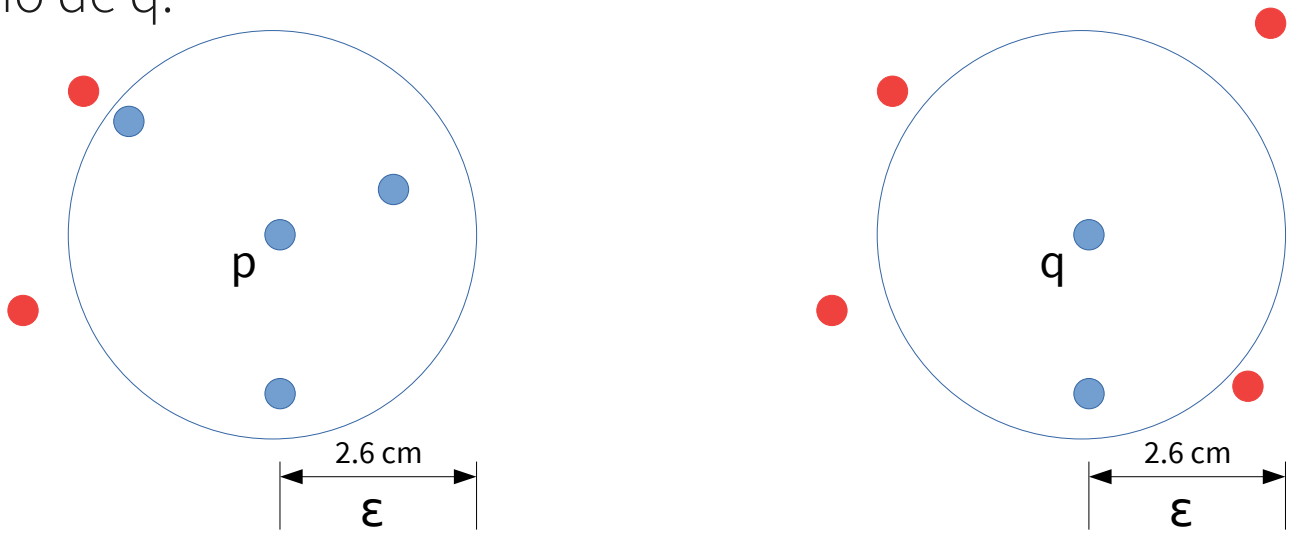
El ε-vecindario de un objeto p es el conjunto de todos los objetos que se encuentran a distancia ε de p.



DBSCAN – Conceptos iniciales

Core Object | Objeto central

q es un objeto central (co) sii hay por lo menos MinPts objetos en el ε-vecindario de q.

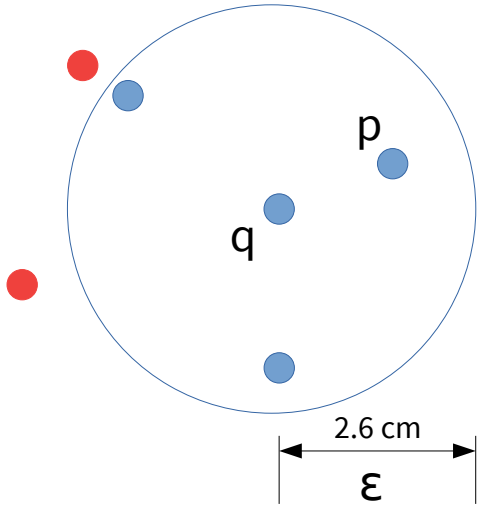


DBSCAN – Conceptos iniciales

Directamente alcanzable por densidad

Directly density reachable (ddr)

Un objeto p es directamente alcanzable por densidad (ddr) sii q es un objeto central (co) y p pertenece al ε-vecindario de q



DBSCAN – Conceptos iniciales

Alcanzable por densidad

Density reachable (dr)

Un objeto p es alcanzable por densidad (dr) desde q sii existe una cadena de objetos tal que: $q_1, q_2, \ldots, q_n$

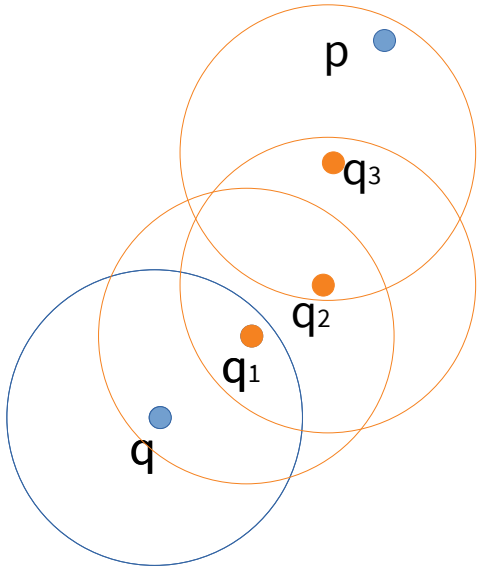
q_1 es directamente alcanzable desde q

q_2 es directamente alcanzable desde q_1

q_3 es directamente alcanzable desde q_2

…

p es directamente alcanzable desde q_n



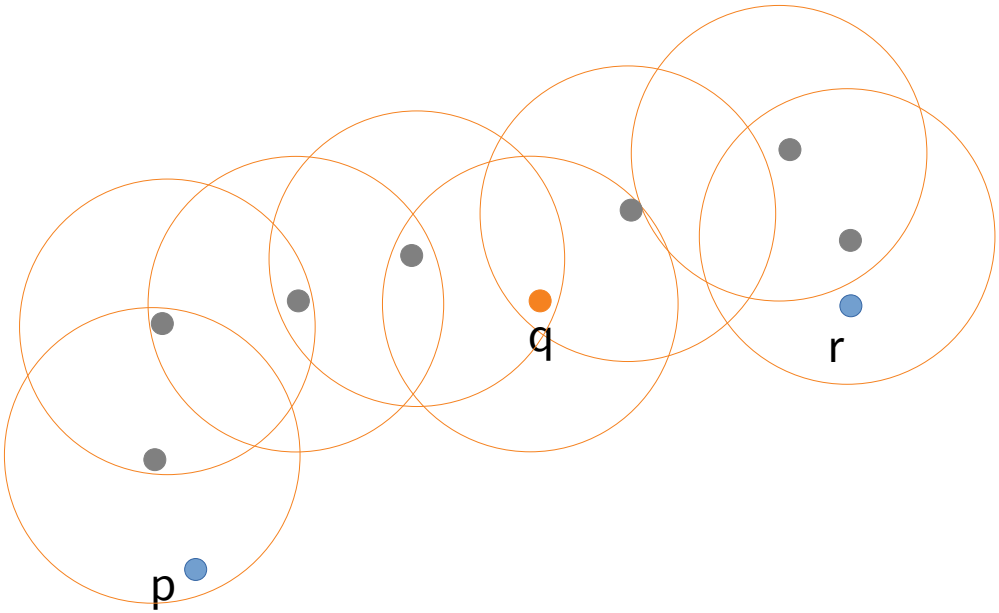
DBSCAN – Conceptos iniciales

Densamente conectado

Density connected (dc)

Un objeto p está densamente conectado (dc) a un objeto r sii existe un objeto q que:

- es alcanzable desde p
- es alcanzable desde r



Algoritmo

Input:

- MinPts
- ε

Output:

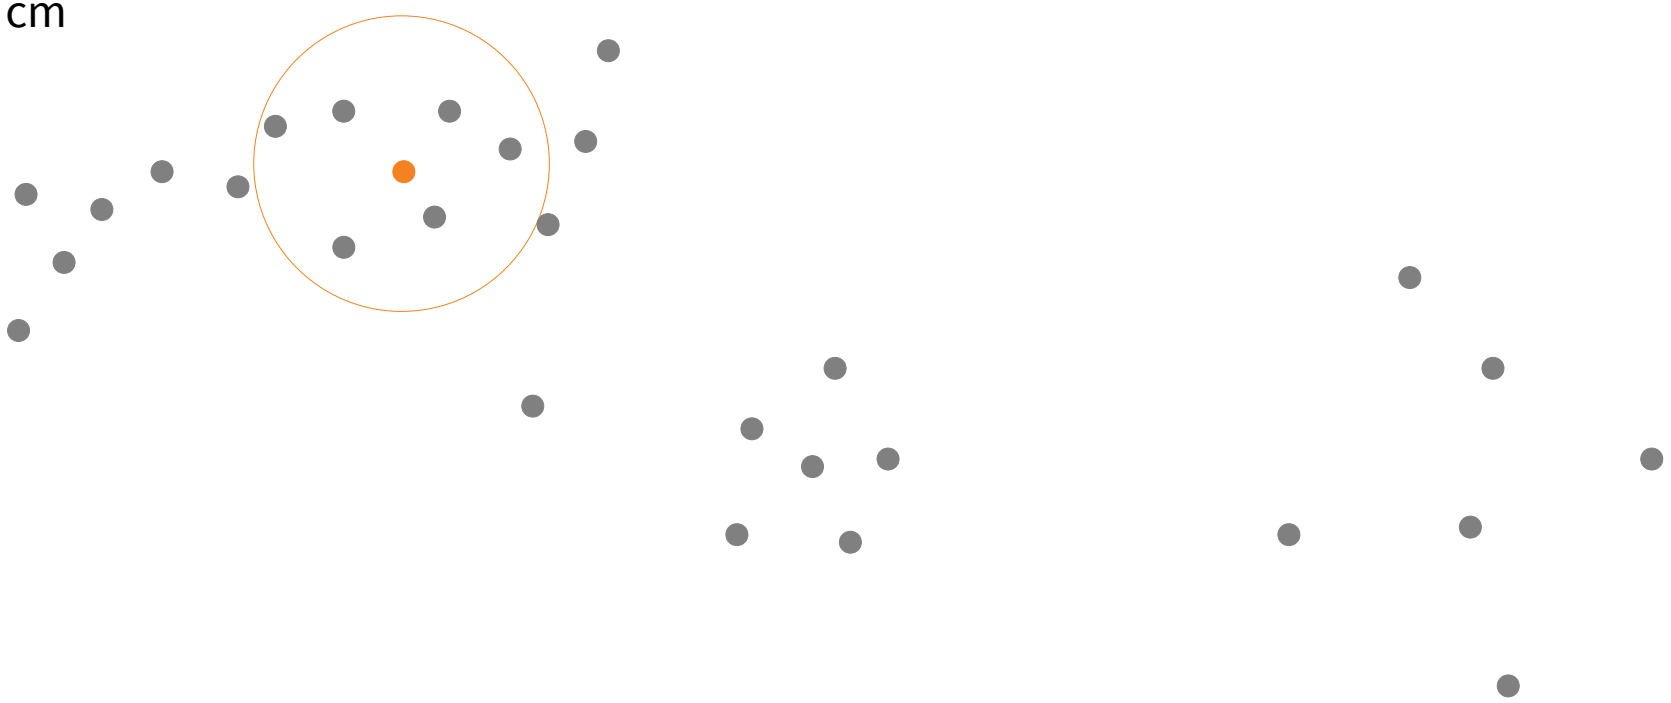
- Conjuntos de datos clasificados en grupos

Procedimiento:

- Para cada objeto x de D:
  - Si x no está clasificado:
    - Si x es un objeto central:
      - Recolectar todos los objetos que son densamente alcanzables desde x
    - Si x no es un objeto central:
      -Clasificar x como ruido.

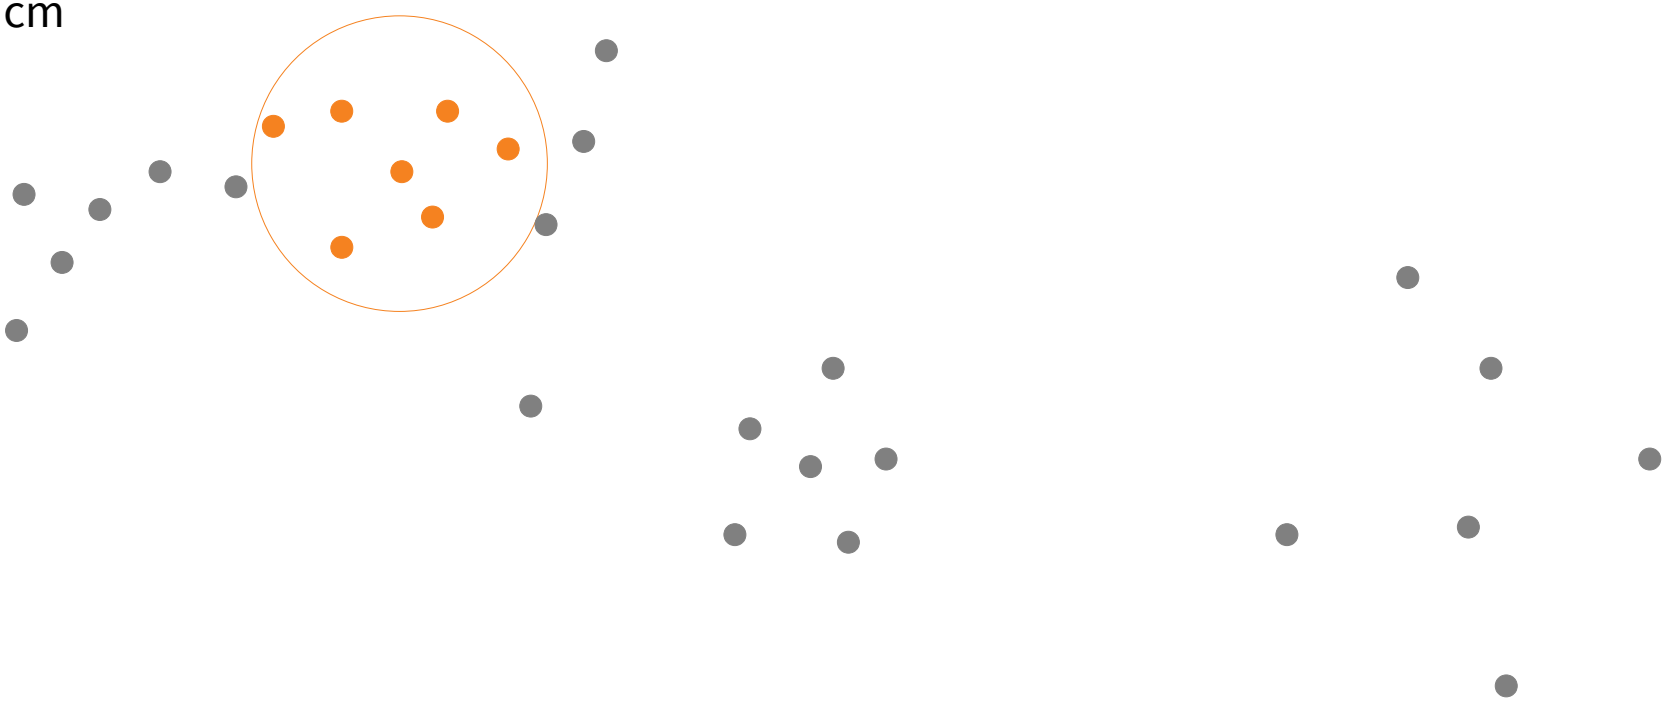
Ejemplo

MinPts = 3
Eps = 2 cm



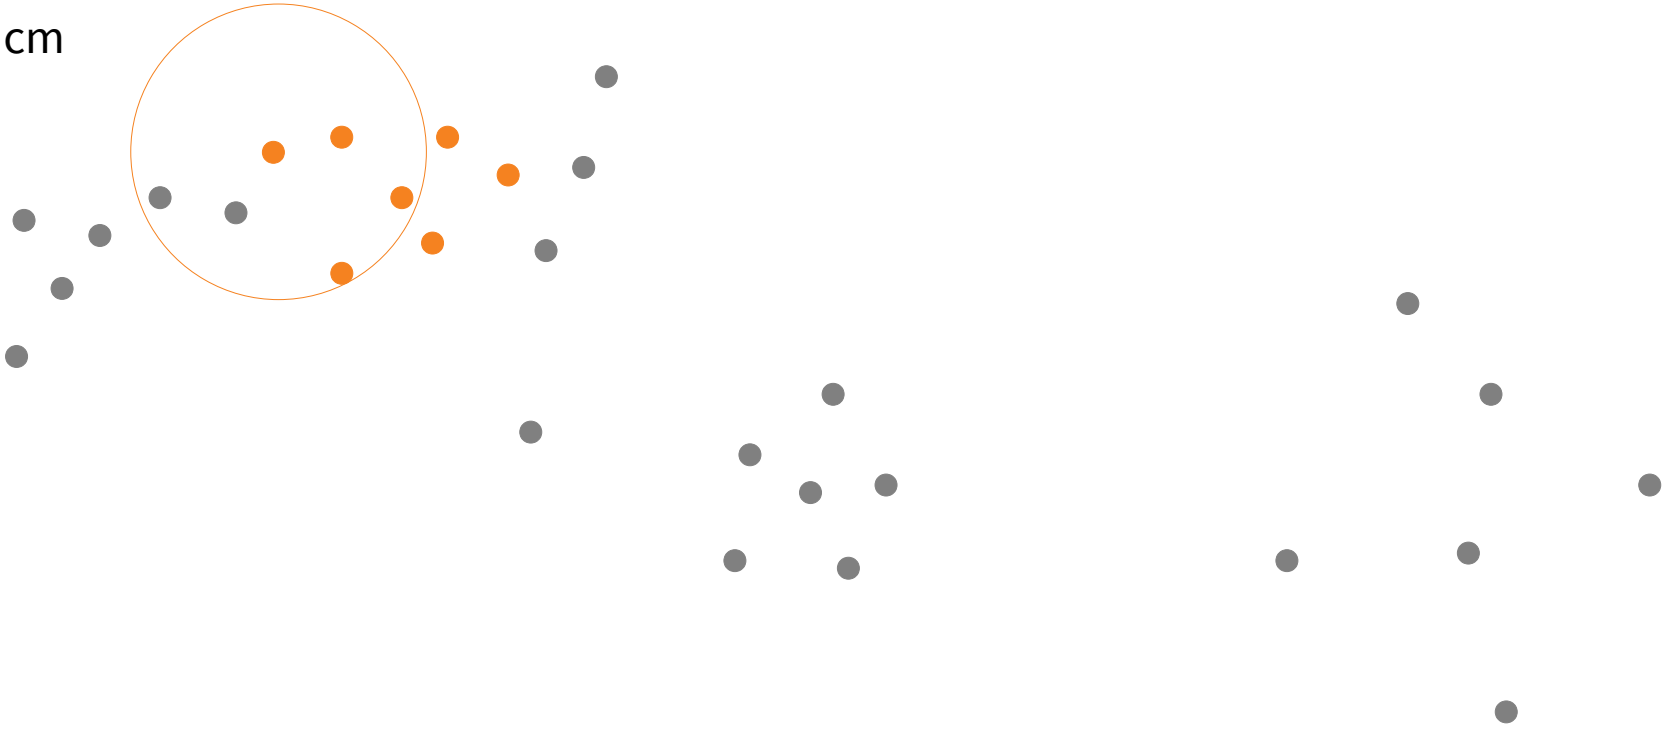
Ejemplo

MinPts = 3
Eps = 2 cm



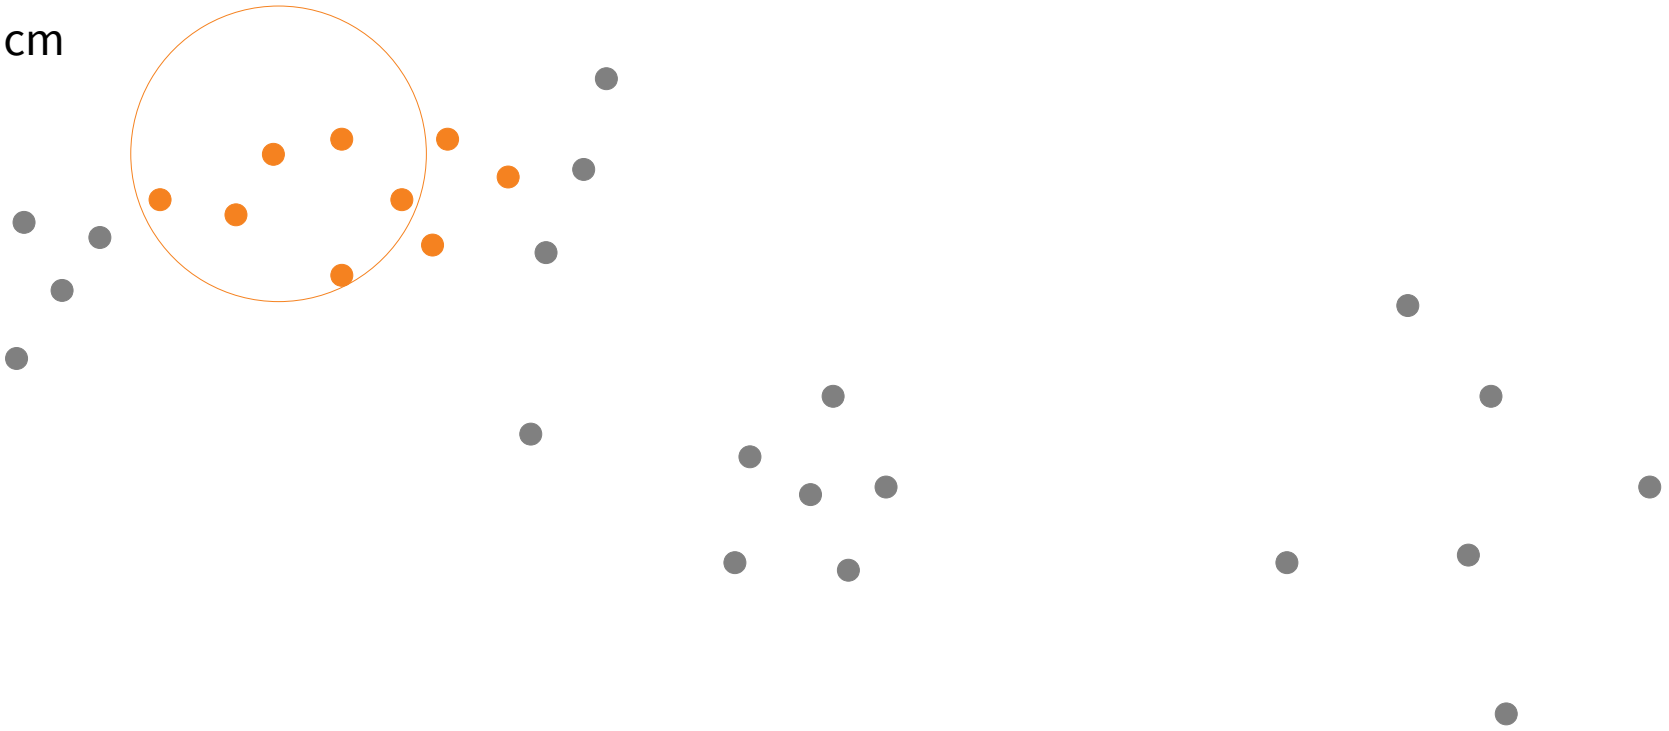
Ejemplo

MinPts = 3
Eps = 2 cm



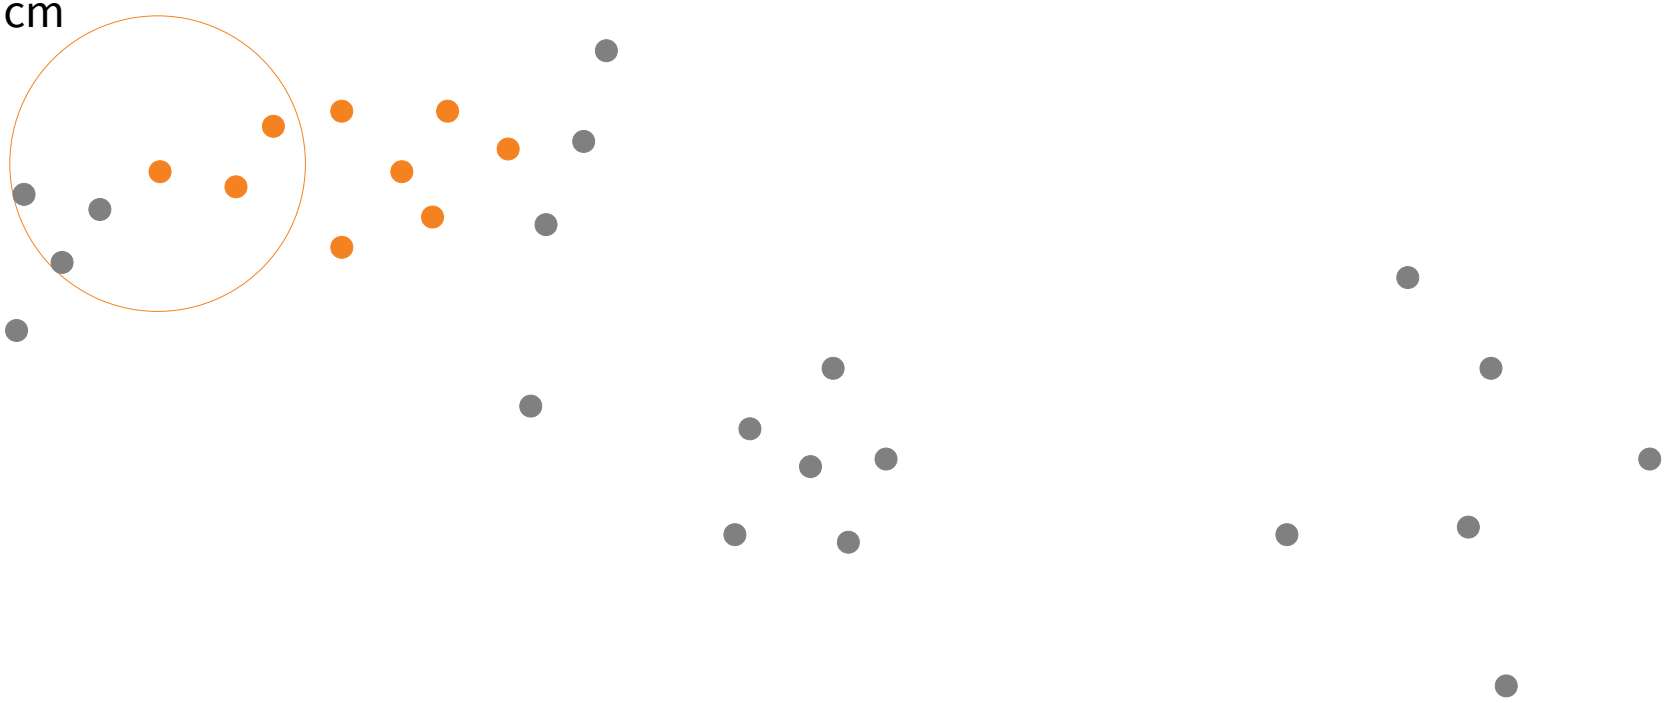
Ejemplo

MinPts = 3
Eps = 2 cm



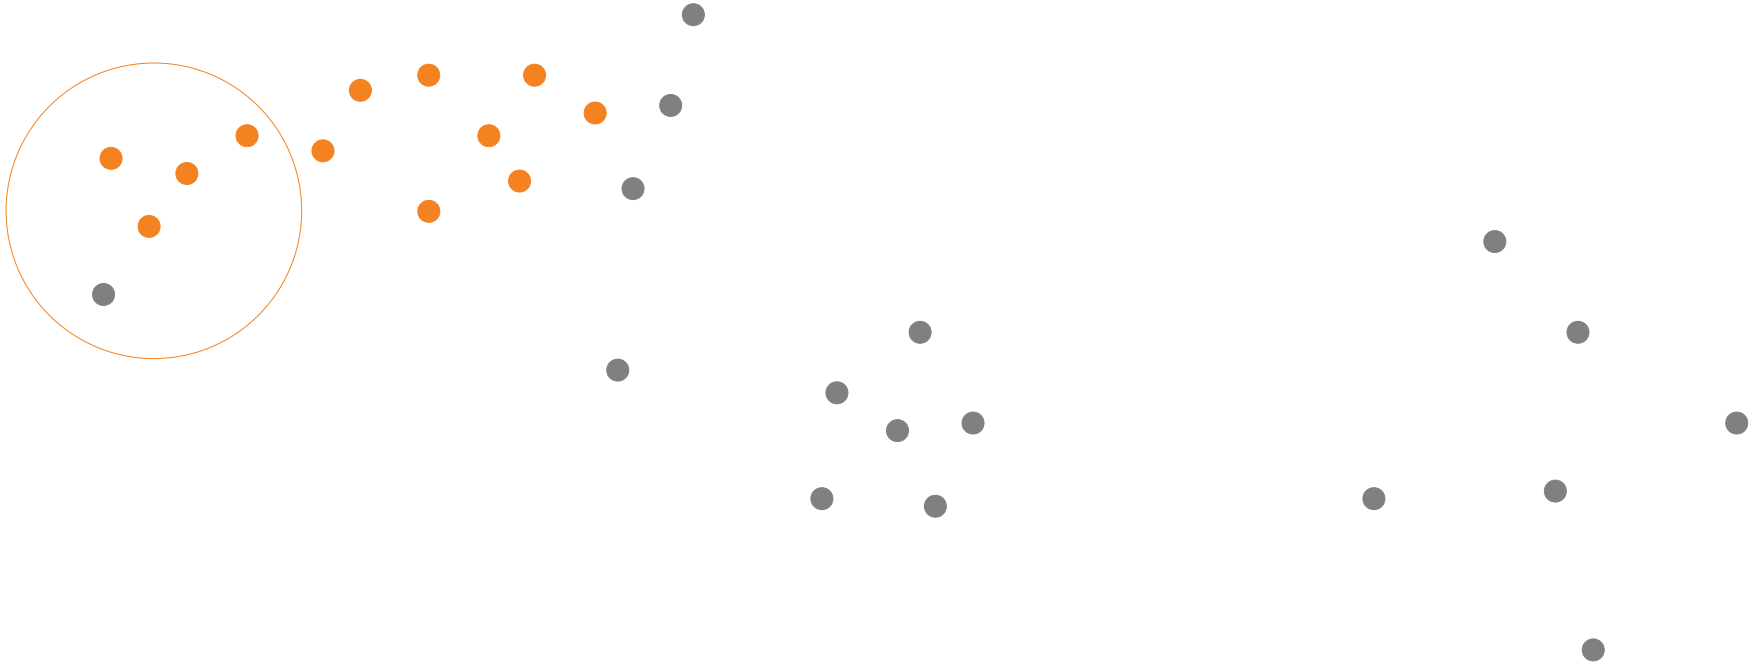
Ejemplo

MinPts = 3
Eps = 2 cm



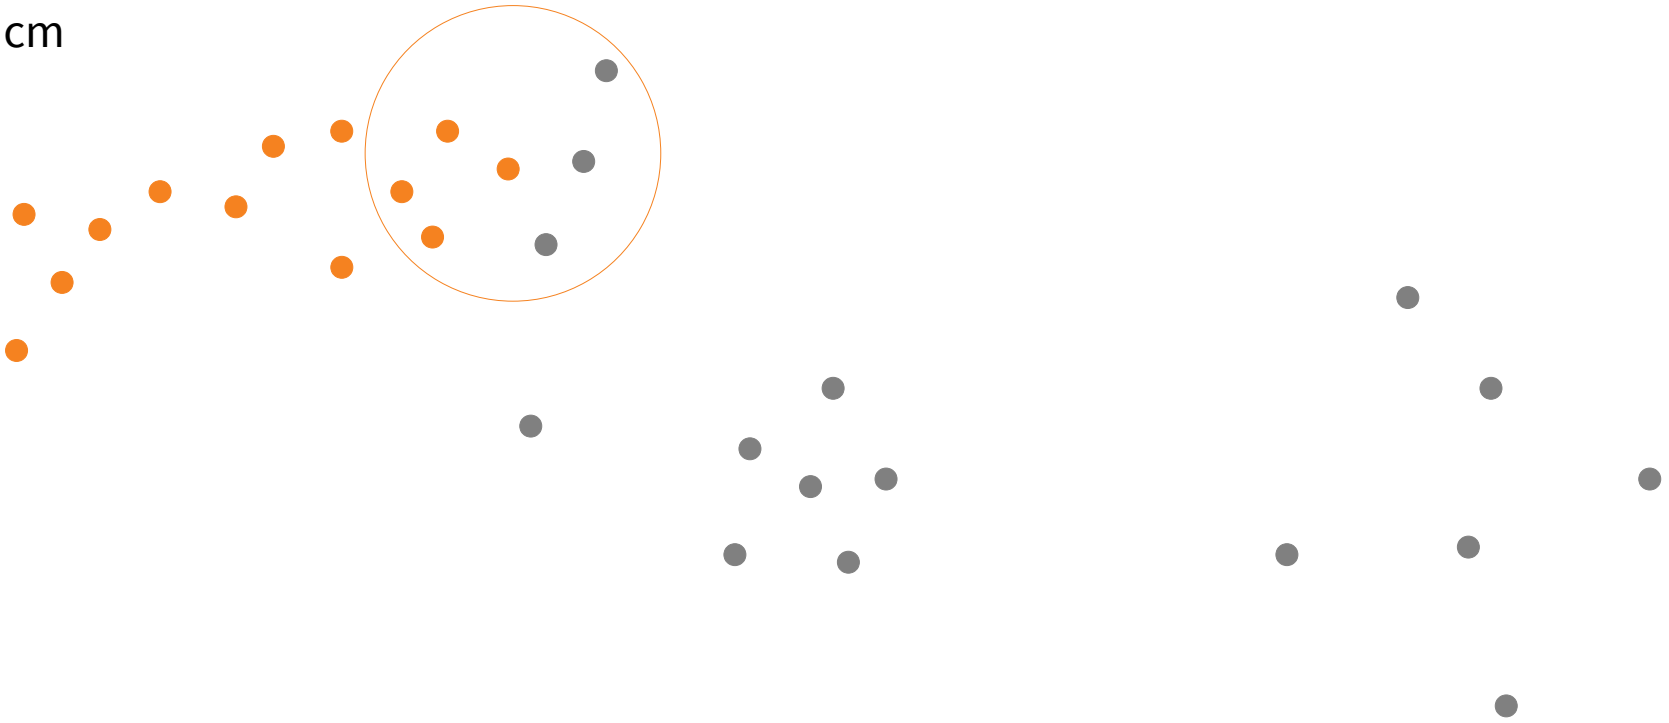
Ejemplo

MinPts = 3
Eps = 2 cm



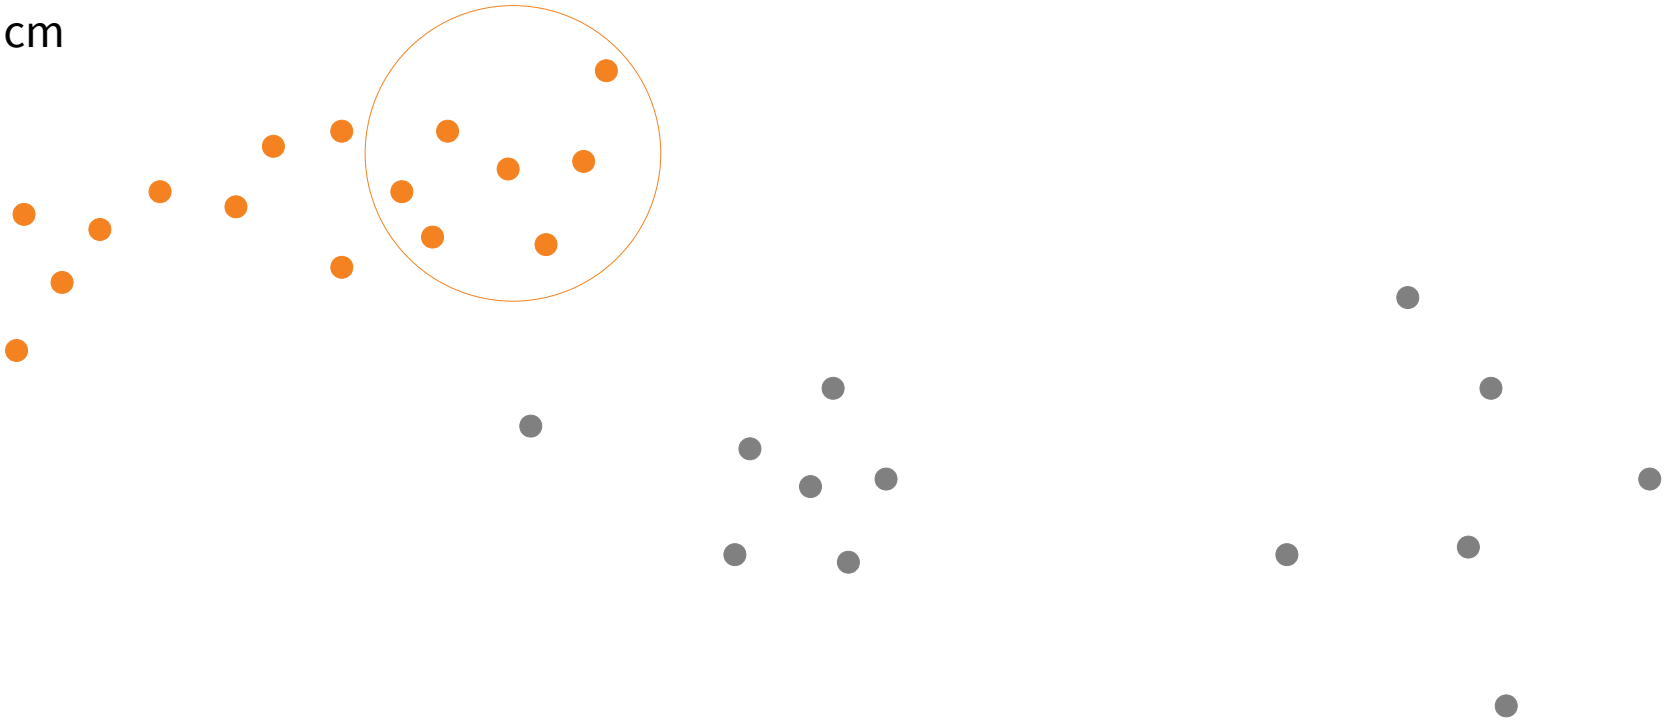
Ejemplo

MinPts = 3
Eps = 2 cm



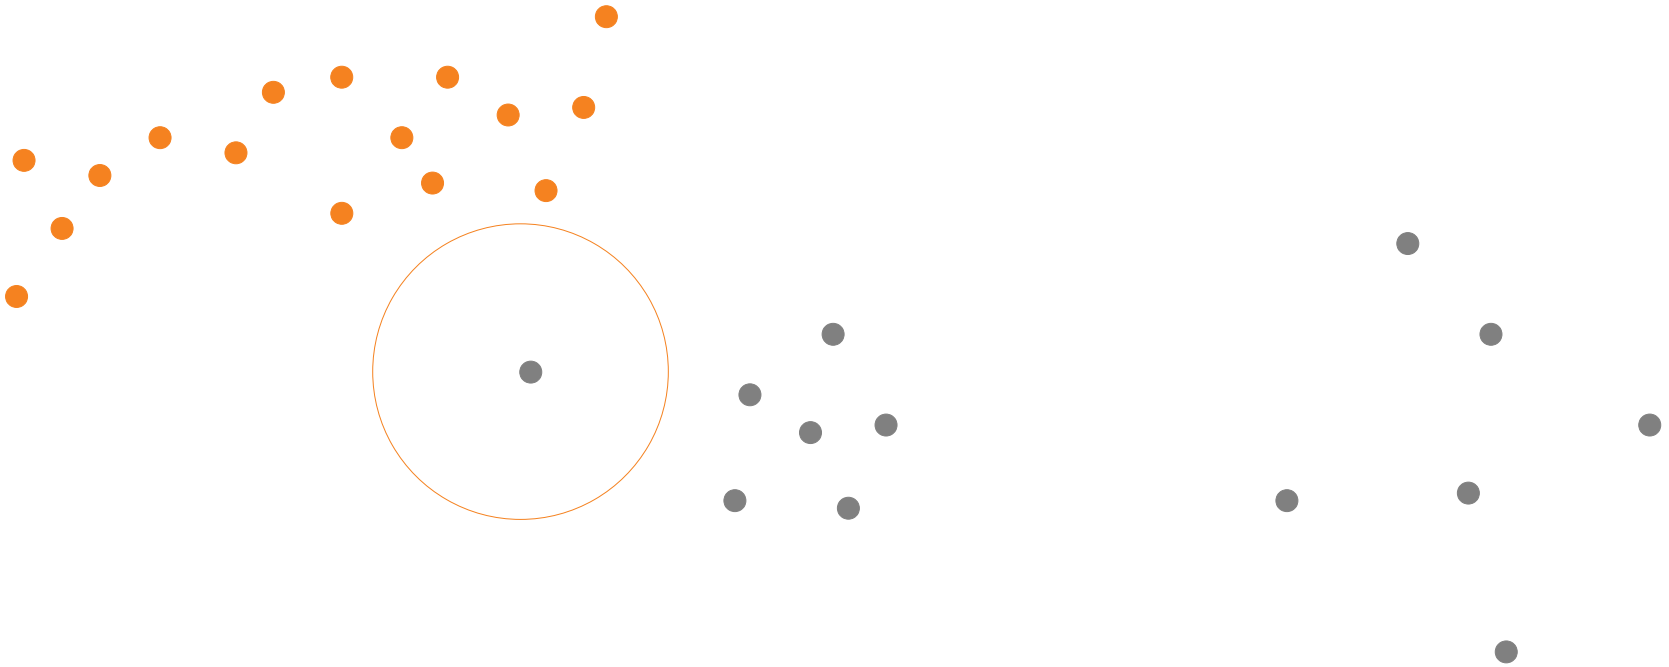
Ejemplo

MinPts = 3
Eps = 2 cm



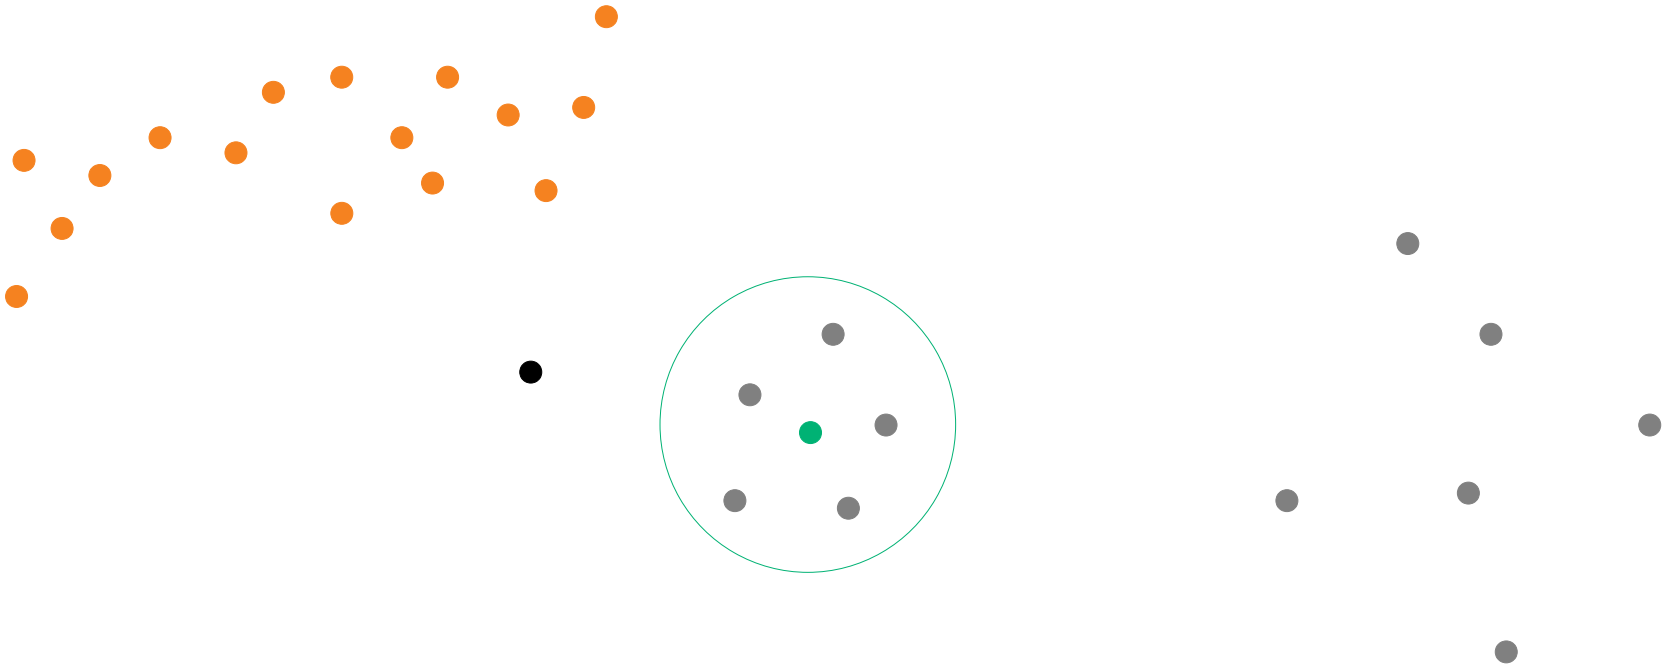
Ejemplo

MinPts = 3
Eps = 2 cm



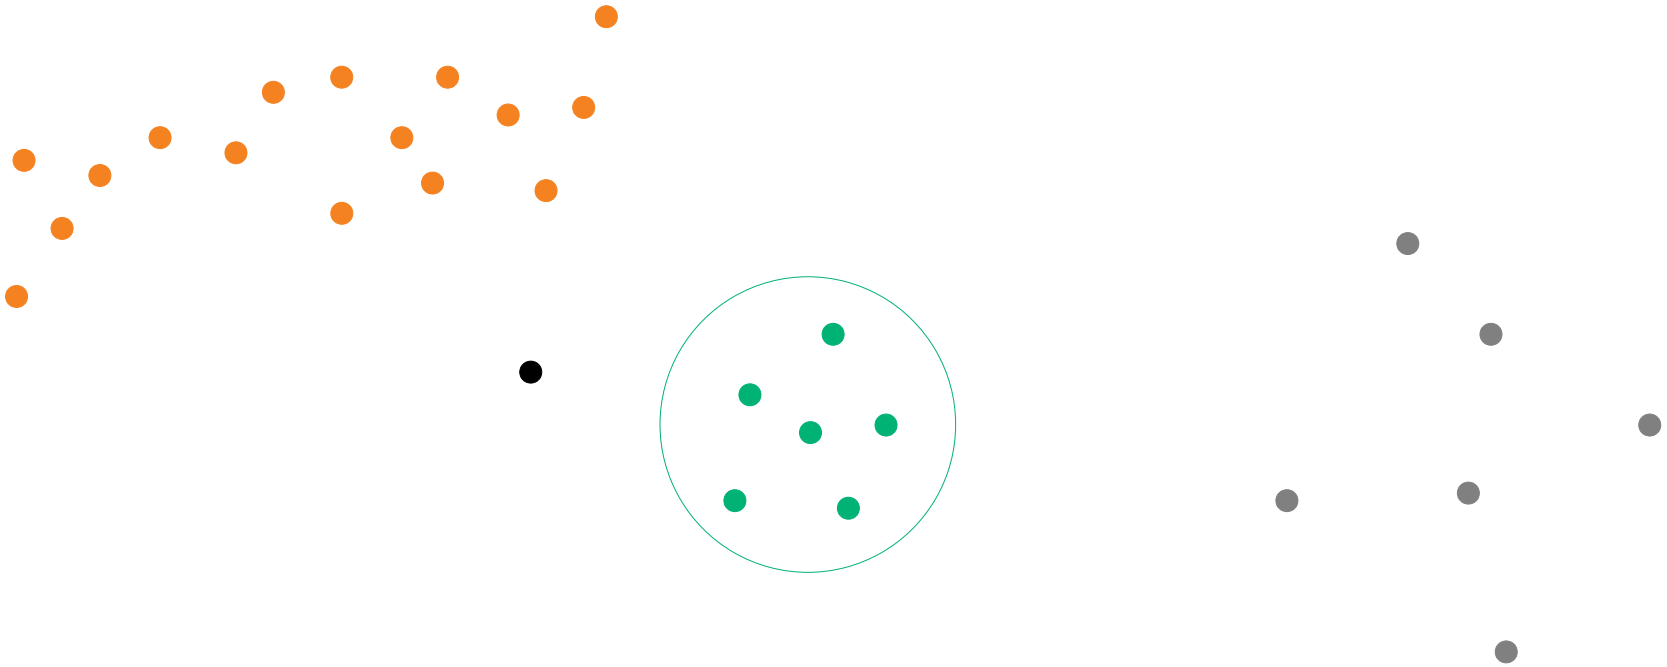
Ejemplo

MinPts = 3
Eps = 2 cm



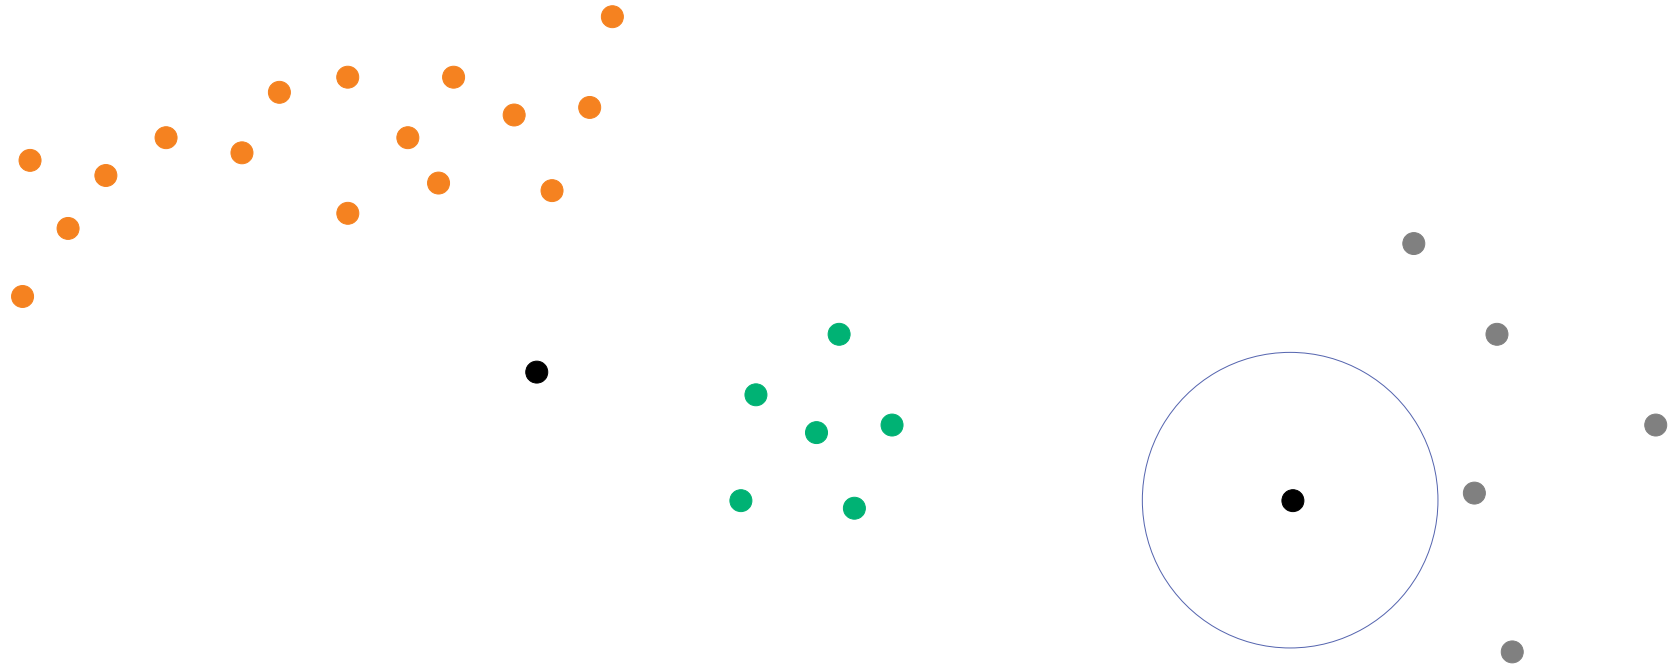
Ejemplo

MinPts = 3
Eps = 2 cm



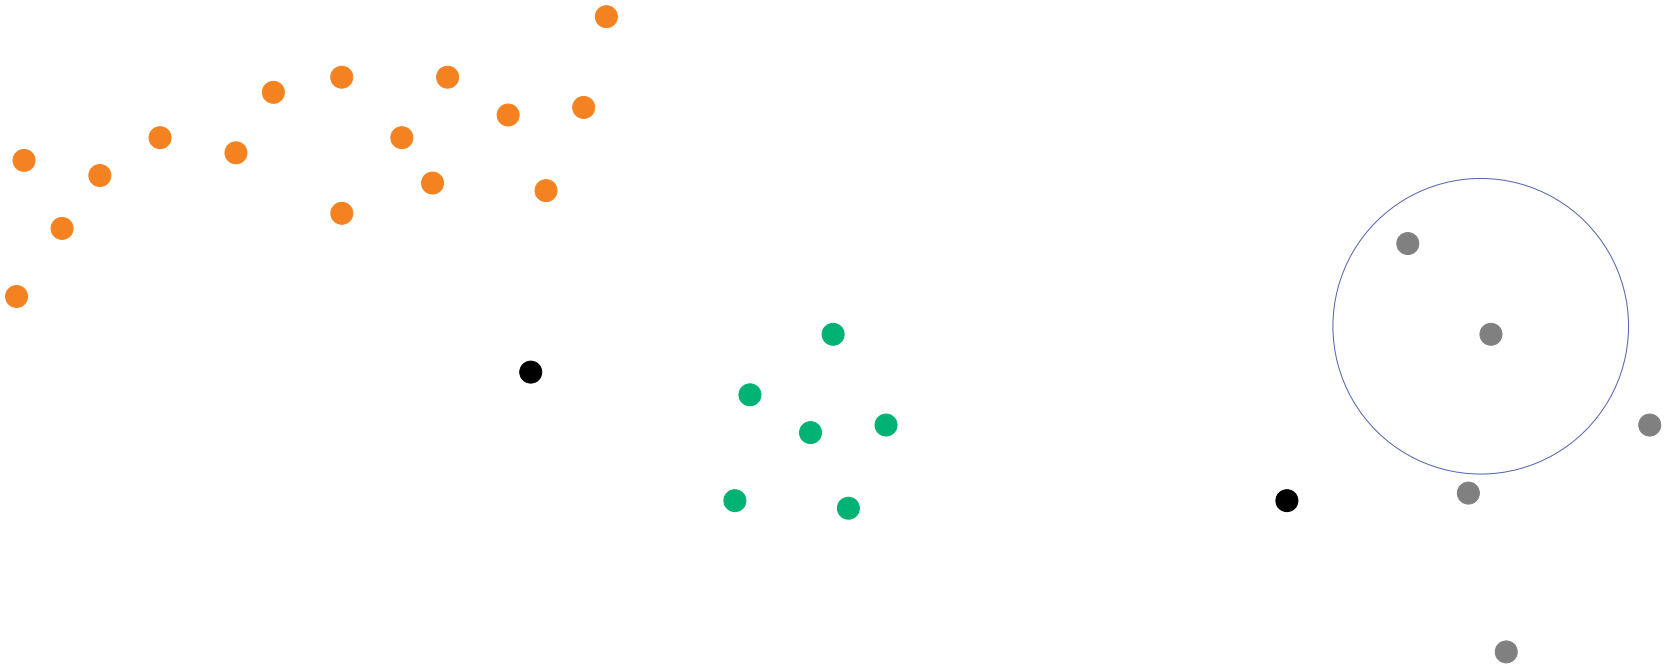
Ejemplo

MinPts = 3
Eps = 2 cm



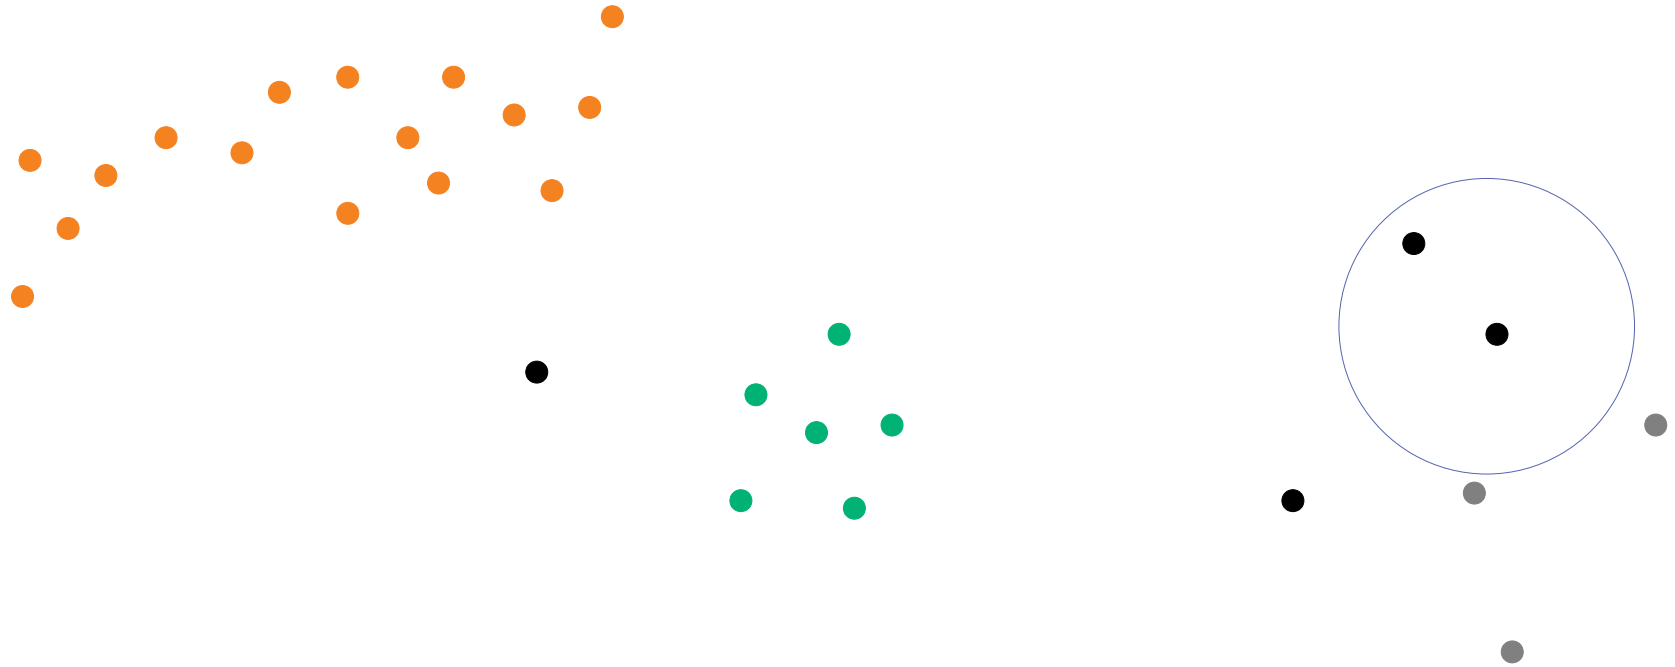
Ejemplo

MinPts = 3
Eps = 2 cm



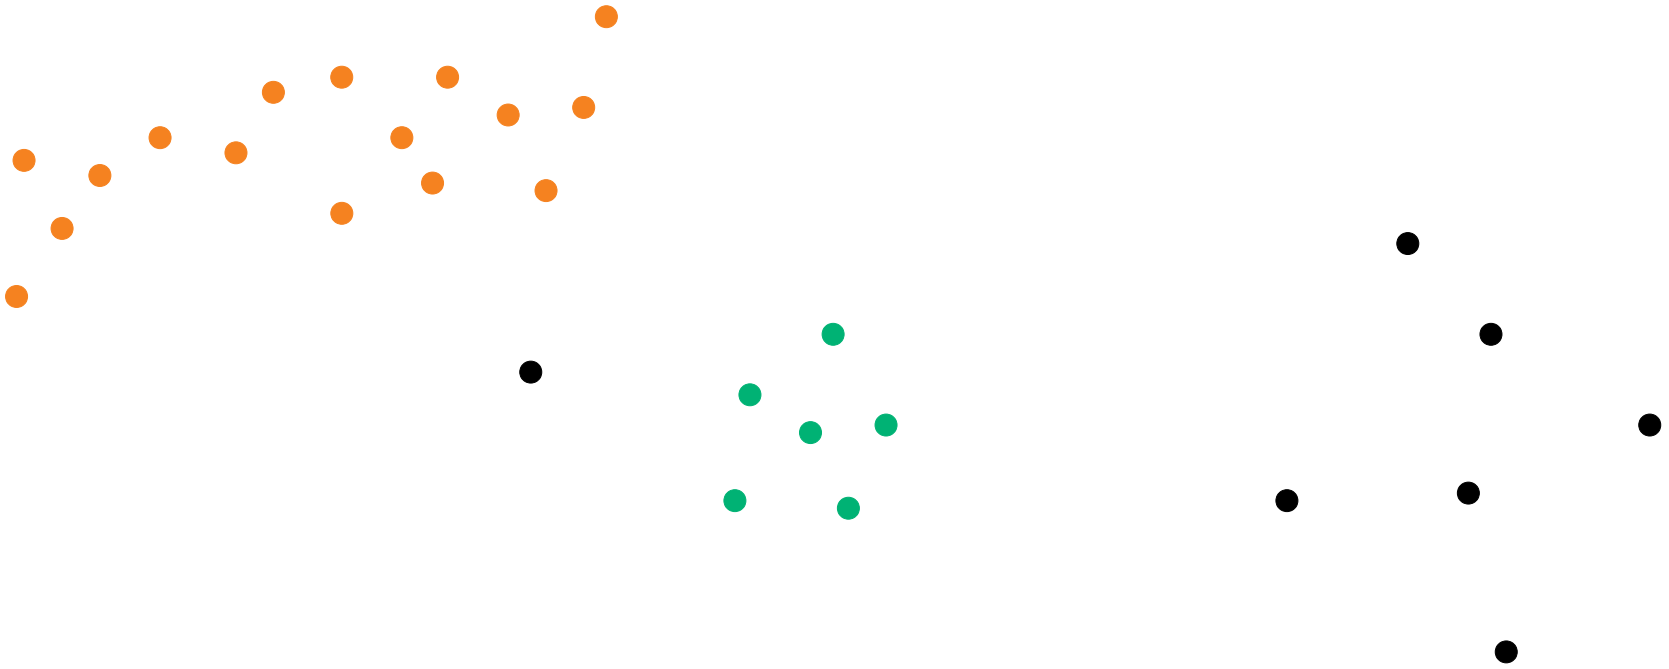
Ejemplo

MinPts = 3
Eps = 2 cm



Ejemplo

MinPts = 3
Eps = 2 cm



¿Clusters de distinta densidad?

Problema de DBSCAN

- Si los clusters poseen distintas densidades, los que no cumplan con las condiciones de Minpts y Eps serán detectados como ruido.

- Existen variantes que permiten explorar dinámicamente distintos rangos de densidades.

Material de Consulta

Han et al. 2012. Data Mining: Concepts and Techniques. Capítulo 10.4