Unidad 3:
Patrones de asociación

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Escenario

Suponga que son contratados por un gerente de ventas de un supermercado que desea aumentar las ventas de productos en el mismo.

Las bases de datos del supermercado consiste en un conjunto de transacciones o compras de cada cliente en cada oportunidad.

Cada transacción es una lista no ordenada de productos con largo variable.

Escenario

T1 → {Leche, Pan, Cereales}

T2 → {Leche, Azúcar, Pan, Huevos}

T3 → {Manteca, Pan, Leche}

T4 → {Huevos, Azúcar}

Su objetivo de minería de datos es encontrar relaciones entre los productos comprados para que el gerente pueda generar promociones a partir de ellas.

Conceptos

Base de datos transaccional

Sea un conjunto de ítems $I = \{I_1, I_2, \ldots, I_m\}$

Una base de datos transaccional D está formada por un conjunto m de tuplas, siendo cada tupla un subconjunto de ítems.

$$D = \left\{ T_j \Big/ T_j \subseteq I \wedge T \neq \emptyset \right\}, j = 1..n$$

Conceptos

Conjunto de Items Frecuentes

(Frequent Itemsets)

Un conjunto de ítems frecuentes es un subconjunto de ítems que se encuentra o repite de forma frecuente en las transacciones de la base de datos.

Interesa encontrar los subconjuntos frecuentes máximos, i.e. aquellos del máximo tamaño posible.

Conceptos

Reglas de asociación

Sea $I=\{I_1, I_2, \ldots, I_m\}$ un conjunto de ítems y de una base de datos transaccional tal como se detalló anteriormente.

Sea A un conjunto de ítems tal que $A \subseteq I$ se dice que una transacción T contiene a A si $A \subseteq T$

Una regla de asociación, entonces, es una implicación de la forma

$$A \Rightarrow B$$

Donde

$$A \subset I, B \subset I, A \neq \emptyset, B \neq \emptyset, A \cap B = \emptyset$$

Conceptos

Regla de asociación

Una regla $A \Rightarrow B$ tiene dos valores asociados: el soporte y la confianza.

El soporte del patrón $A \cup B$ es el porcentaje de las transacciones de la base de datos que contienen al mismo.

La confianza de la regla, por otro lado, es el porcentaje de las transacciones que contienen a A que también contienen a B.

Esto se traduce como las probabilidades:

$$support\left(A \Rightarrow B\right) = P\left(A \cup B\right)$$

$$confidence\left(A \Rightarrow B\right) = P\left(B \mid A\right) = \frac{support\left(A \cup B\right)}{support\left(A\right)}$$

Conceptos

Las reglas cuyo soporte y confianza superan un umbral mínimo se llaman reglas fuertes.

Ejemplo:

I = {Leche, Pan, Cereales, Huevos, Manteca, Azúcar}

T1 → {Leche, Pan, Cereales}

T2 → {Leche, Azúcar, Pan, Huevos}

T3 → {Manteca, Pan, Leche}

T4 → {Huevos, Azúcar}

$$Supp(\{Leche\} \Rightarrow \{Pan\})$$

$$Conf(\{Leche\} \Rightarrow \{Pan\})$$

Conceptos

Las reglas cuyo soporte y confianza superan un umbral mínimo se llaman reglas fuertes.

Ejemplo:

I = {Leche, Pan, Cereales, Huevos, Manteca, Azúcar}

T1 → {Leche, Pan, Cereales}

T2 → {Leche, Azúcar, Pan, Huevos}

T3 → {Manteca, Pan, Leche}

T4 → {Huevos, Azúcar}

$$Supp(\{Leche\} \Rightarrow \{Pan\}) = P(\{Leche, Pan\}) = 3/4 = 0.75$$

$$Conf(\{Leche\} \Rightarrow \{Pan\}) = P(\{Pan\} | \{Leche\}) = \frac{P(\{Leche \cup Pan\})}{P(\{Leche\})} = \frac{0.75}{0.75} = 1$$

Conceptos

Las reglas cuyo soporte y confianza superan un umbral mínimo se llaman reglas fuertes.

Ejemplo:

I = {Leche, Pan, Cereales, Huevos, Manteca, Azúcar}

T1 → {Leche, Pan, Cereales}

T2 → {Leche, Azúcar, Pan, Huevos}

T3 → {Manteca, Pan, Leche}

T4 → {Huevos, Azúcar}

$$Supp(\{Leche\} \Rightarrow \{Cereales\})$$

$$Conf(\{Leche\} \Rightarrow \{Cereales\})$$

Conceptos

Las reglas cuyo soporte y confianza superan un umbral mínimo se llaman reglas fuertes.

Ejemplo:

I = {Leche, Pan, Cereales, Huevos, Manteca, Azúcar}

T1 → {Leche, Pan, Cereales}

T2 → {Leche, Azúcar, Pan, Huevos}

T3 → {Manteca, Pan, Leche}

T4 → {Huevos, Azúcar}

$$Supp(\{Leche\} \Rightarrow \{Cereales\}) = P(\{Leche, Cereales\}) = 1/4 = 0.25$$

$$Conf(\{Leche\} \Rightarrow \{Cereales\}) = P(\{Cereales\} | \{Leche\}) = \frac{Supp(\{Leche, Cereales\})}{Supp(\{Leche\})} = \frac{0.25}{0.75} = 0.333$$

Algoritmo

Algoritmo Genérico

El algoritmo básico para encontrar reglas de asociación consta de 2 etapas:

1. Encontrar todos los patrones frecuentes (soporte > min_sup)
2. Generar reglas fuertes a partir de los patrones frecuentes (conf > min_conf)

Distintos algoritmos utilizan este método, pero haciendo uso de distintas estrategias para mejorar la eficiencia.

Algoritmo A-priori (Agrawal y Srikant, 1994)

Se realiza un procedimiento iterativo por niveles.

En cada nivel k se generan conjuntos de items frecuentes de tamaño k utilizando los conjuntos de items frecuentes de tamaño k-1.

El tamaño de k sigue aumentando mientras k-1 tenga itemsets frecuentes.

Posteriormente, se generan reglas a partir de cada itemset

Algoritmo A-priori (Agrawal y Srikant, 1994)

Se realiza un procedimiento iterativo por niveles.

En cada nivel k se generan conjuntos de ítems frecuentes de tamaño k utilizando los conjuntos de ítems frecuentes de tamaño k-1.

El tamaño de k sigue aumentando mientras k-1 tenga ítemsets frecuentes.

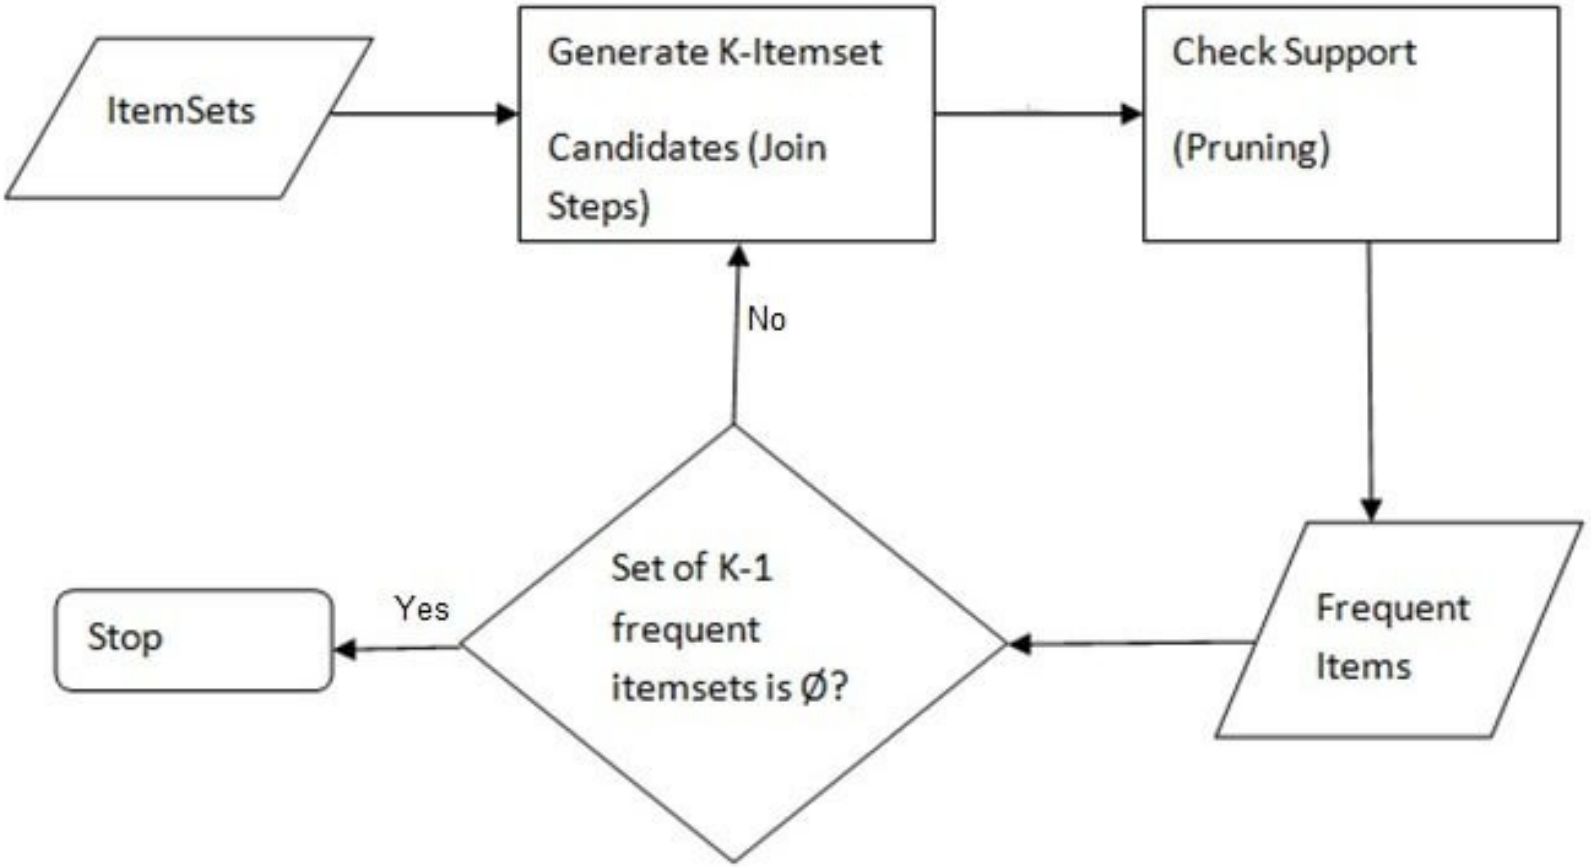
Posteriormente, se generan reglas a partir de cada ítemset

Propiedad A-priori o antimonótona:

Todos los subconjuntos de un conjunto de ítems frecuentes, también son frecuentes.

Algoritmo a-priori

Generación de patrones frecuentes



Algoritmo A-priori

Una vez que se obtienen los ítems frecuentes F, se deben encontrar las reglas fuertes.

Por cada subconjunto A de F, se prueba la confianza de las reglas A → F-A

Si estas reglas superan el umbral mínimo, entonces son reglas fuertes, y podemos saber cual conjunto de ítems condiciona la compra de otro subconjunto de ítems.

Ejemplo

ID	Itemsets
1	{Pan, Manteca, Leche}
2	{Huevos, Leche, Yogurt}
3	{Pan, Queso, Huevos, Leche}
4	{Huevos, Leche, Yogurt}
5	{Queso, Leche, Yogurt}

Representaciones

Representación booleana

Consiste en una matriz con una fila por transacción y una columna por cada item, siendo el valor de la celda intersección 1 si la transacción contiene el item en cuestión, o 0 si no.

ID	Item 1	Item 2	Item 3
T1	1	1	1
T2	1	0	1
T3	0	1	1

Representaciones

Representación por listas

Se invierte la representación usual.

En esta estructura solo tendremos una fila por cada item, en la cual constará su nombre o ID y la lista de transacciones que lo contienen.

Item	Transacciones
Item 1	{T1, T2}
Item 2	{T1,T3}
Item 3	{T1,T2,T3}

Material de lectura

> Han et al. 2012. Data Mining: Concepts and techniques. Capítulo 6.

> Aggrawal. 2015. Data Mining, the textbook. Capítulo 4.2

> Agrawal, Rakesh, and Ramakrishnan Srikant. "Fast algorithms for mining association rules." Proc. 20th int. conf. very large data bases, VLDB. Vol. 1215. 1994.