Unidad 3:
Descubrimiento de Anomalías

Ing. Giovanni Daián Rottoli
Ing. Lía Aguirre

Licencia Creative Commons
Atribución 4.0 Internacional

Outlier Detection

Caso práctico

Imaginen que son un auditor en un banco.

Para proteger a sus clientes de fraudes y robos, su trabajo es determinar si se han realizado compras extrañas con su tarjeta de crédito.

Por ejemplo, si se compra por un monto mucho mayor al habitual, o la compra fue realizada lejos de los lugares donde se compra usualmente, es probable que esa compra no haya sido realizada por el dueño de la tarjeta.

Ante esta situación, se contacta al cliente para certificar que haya sido él el que realizó la operación.

Outlier Detection

Caso práctico

La mayoría de las transacciones realizadas suelen ser normales.

Un cambio significativo en los hábitos del usuario puede indicar que haya sido otro el que la usó.

La idea principal es detectar aquellas transacciones que desvien considerablemente de la norma.

Outlier Detection

¿Qué son las anomalías? (Outlier, Anomaly)

Una anomalía (outlier, anomaly) es un objeto de la base de datos con valores de sus atributos que desvían significatívamente de los valores normales de los mismos, como si fuesen generados por otro mecanismo.

Outlier Detection

Anomalía vs Ruido

El ruido, si bien no sigue un comportamiento normal, es diferente de las anomalías.

El ruido, es un error aleatorio o varianza en una variable.

Por ejemplo, un cliente puede comprar un día una prenda de ropa más cara de lo habitual. Si esto fuese tomado como un outlier, estaríamos molestando al cliente por falsas alarmas.

El ruido debería ser eliminado en la etapa de preparación de los datos.

Outlier Detection

Anomalías vs Ruido

Las anomalías son interesantes porque son generados por un mecanismo que es distinto al que generó el resto de los datos.

Este mecanismo induce un patrón en los datos anómalos.

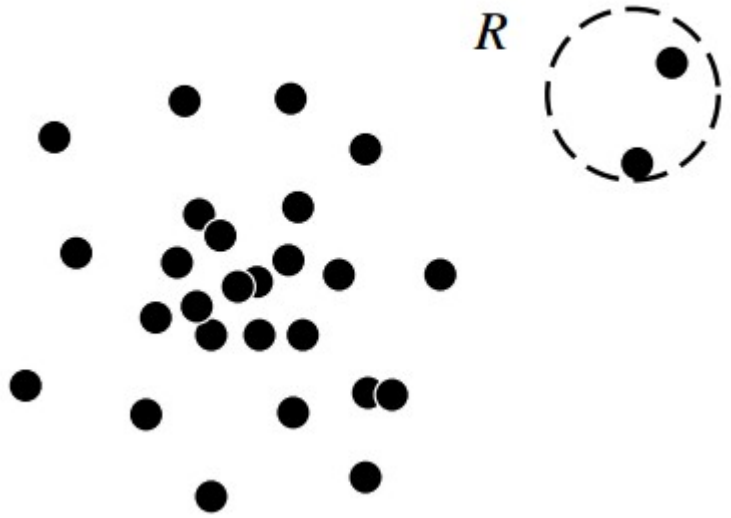
Es este mecanismo o justificación la que realmente interesa, más allá del dato individual que resulta anómalo.

Tipos de Anomalías

Anomalías Globales

Las anomalías globales son puntos que desvian de la totalidad de los puntos de la base de datos.

La detección de esta clase de anomalías es importante en ámbitos como la detección de intruciones en una red.



Tipos de Anomalías

Anomalías Contextuales

"La temperatura de hoy es de 28°C"

Tipos de Anomalías

Anomalías Contextuales

"La temperatura de hoy es de 28°C"

Como "hoy" es otoño, la temperatura resulta excepcional.

Si la medida fuese tomada en primavera, este valor no sería extraño.

En una base de datos, un objeto es una anomalía contextual si desvia respecto a los valores normales en un contexto específico.

Tipos de Anomalías

Anomalias Locales

Son un tipo particular de anomalías contextuales.

Estas anomalías se dan en los contextos en que la densidad es utilizada como medida de normalidad.

Esto significa que un punto es una anomalía local si la densidad de su vecindario desvia considerablemente de la densidad de su entorno.

Tipos de Anomalías

Anomalías colectivas

Supón que Mercadolibre tiene que entregar un conjunto de paquetes.

Si un paquete se demora en llegar a su destino, no resultaría extraño, puesto que es normal que haya demoras por algún motivo.

Sin embargo, si más de 100 paquetes se demoran el mismo día, esto significaría que existe un mecanismo que está sistemáticamente retrasando la entrega de paquetes.

Una anomalía colectiva es un subconjunto de datos que, juntos, desvían del comportamiento normal del dataset.

Métodos

Existen múltiples métodos en la bibliografía para detectar anomalías.

Estos se clasifican en:

> Supervisados

> Semi-supervisados

> No supervisados

Métodos

Supervisados

Los métodos supervisados modelan cada dato como normal o anormal.

Expertos del dominio clasifican el dataset en estas dos categorías.

Posteriormente, un modelo de clasificación es generado a partir de los datos etiquetados para poder clasificar los nuevos datos que ingresen.

Estos modelos deben ser actualizados cada cierto tiempo pues el comportamiento normal puede cambiar.

Métodos

No supervisados

Ya que muchas veces no podemos etiquetar los datos a mano, es necesario recurrir al aprendizaje no supervisado.

Al utilizar métodos de clustering, los puntos normales (o que siguen un comportamiento similar) son agrupados, quedando alejados de los puntos anormales.

Sin embargo, este alejamiento puede no suceder. Por ej. en caso de que los datos normales no sigan un patrón marcado (uniformemente distribuidos) siendo los datos anormales los que siguen un patrón.

Métodos

Semi-supervisados

Se usa en bases de datos donde es posible conseguir que una pequeña porción de los datos estén etiquetadas.

Estos datos son usados para encontrar los vecindarios o grupos de datos normales, y entrenar un modelo que describa dicha normalidad.

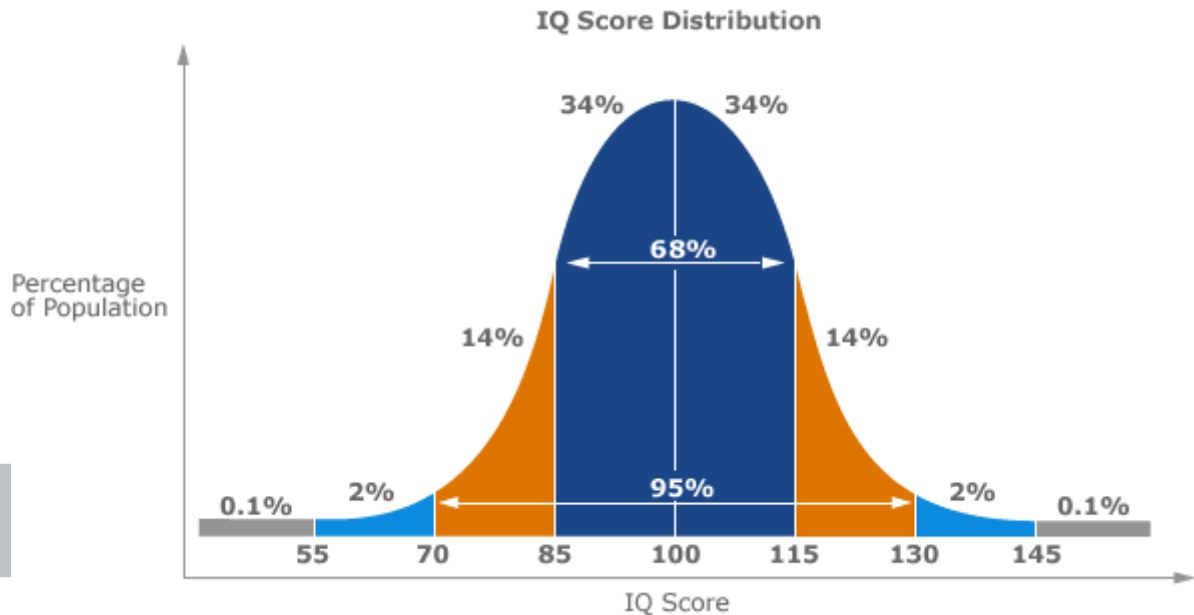
Posteriormente, este modelo es utilizado para detectar los outliers.

Algoritmos y técnicas

Métodos estadísticos

Los métodos estadísticos asumen cual es la normalidad de los datos.

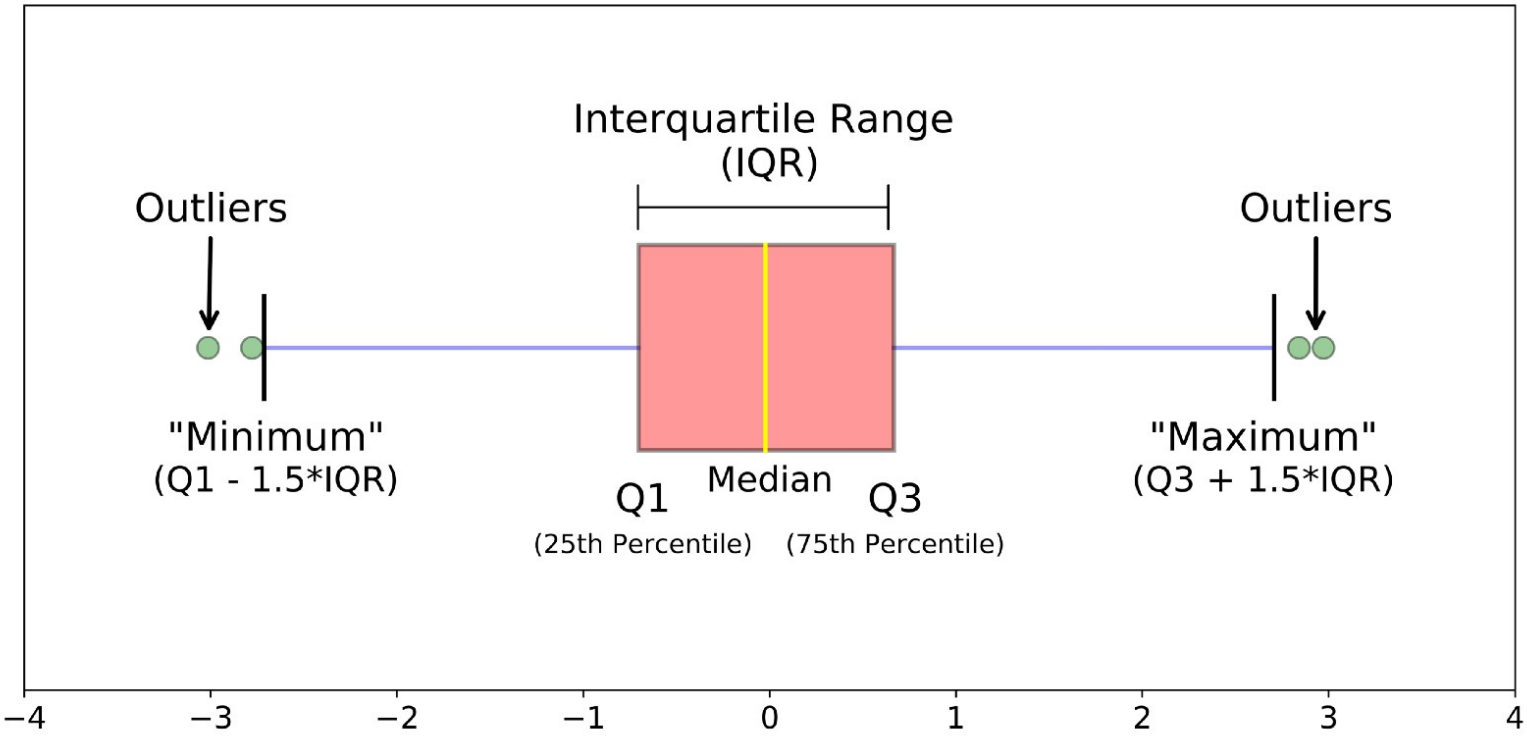
Cómo los datos son generados por cierto proceso estocástico, los datos normales son aquellos que se ubican en una región de alta probabilidad, mientras que las anomalías son aquellos ubicados en regiones de baja probabilidad.



Métodos estadísticos

Método del boxplot

Método paramétrico para distribuciones univariada.



Entre el mínimo Y el máximo se Encuentra el 99,3% de los Datos.

Métodos estadísticos

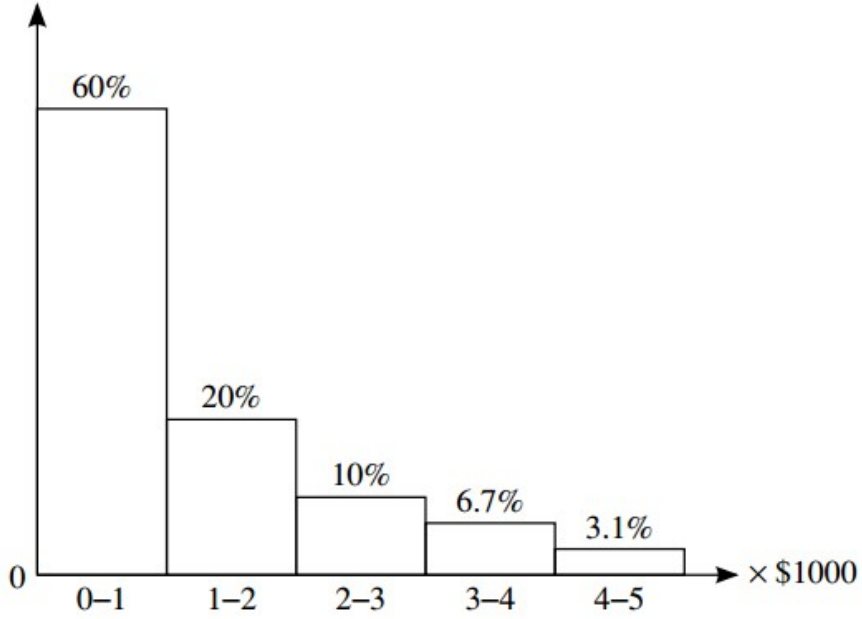
Método del histograma

Es un método no-paramétrico, pues no asume una distribución previa de los datos, sino que la aprende a partir del modelado.

Si un dato cae en un bin con alta frecuencia, indica que el comportamiento es normal.

Si, por el contrario, un dato cae en un bin con baja frecuencia, el comportamiento es anómalo.

Depende del tamaño del bin.



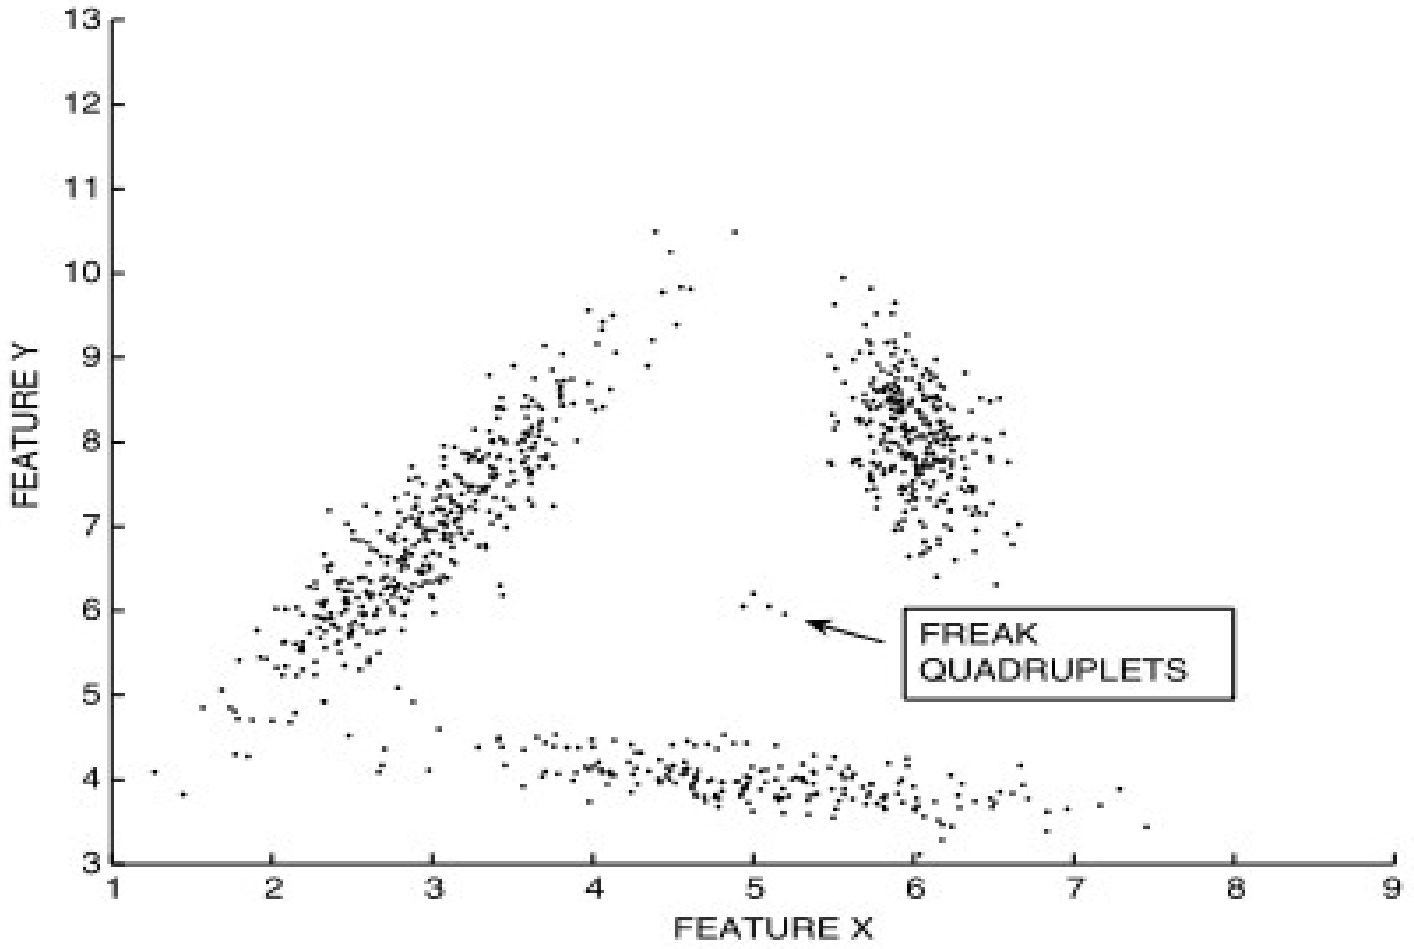
Métodos basados en clustering

Mientras que el clustering busca conjuntos de datos similares entre sí, la detección de anomalías se trata de encontrar los datos que se encuentran lejos de estos grupos.

Estas dos actividades suelen verse como actividades complementarias.

La utilización de algoritmos de clustering puede ser además beneficiosa, puesto que muchas veces los datos anómalos se encuentran agrupados, al haber sido generados por otro mecanismo.

Métodos basados en clustering



Métodos basados en clustering

Estrategia

Dado un punto cualquiera de la base de datos.

1. ¿El objeto pertenece a algún cluster? Si no, Outlier.
2. ¿Hay una gran distancia entre el objeto y su cluster más cercano? Si si, Outlier.
3. ¿El objeto pertenece a algún cluster disperso y aislado? Si si, todos los objetos del cluster son outliers.

Métodos pendientes

Métodos basados en distancia

Métodos basados en densidad

Material de consulta

Han et al. 2012. Data Mining: Concept and Techniques. Capítulo 12.

Aggrawal. 2015. Data mining: the textbook. Capítulo 8.