Minería de Texto

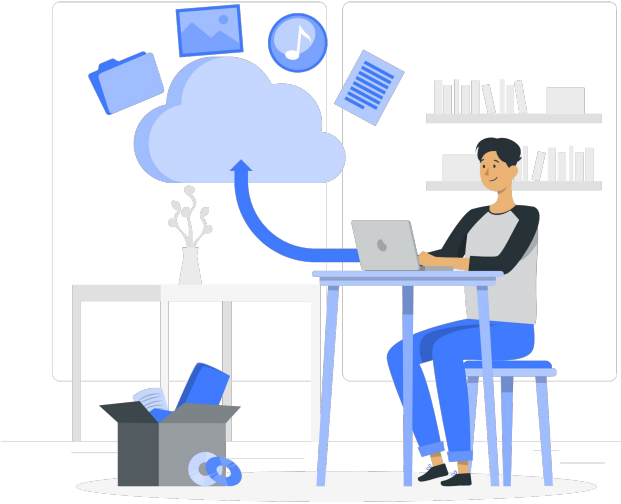
Ciencia de Datos

Contexto

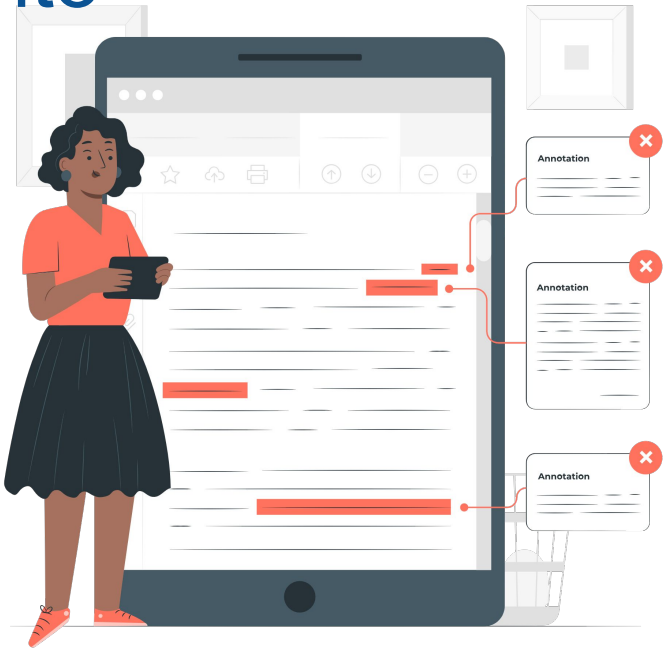
- Big Data (V V V)
- Gran proporción de datos no estructurados.
- Un gran porcentaje son textos.

  (Documentos, Artículos de Blogs, Tweets, entre otros).

- Necesitamos técnicas específicamente diseñadas para tratar con esta clase de datos.



Text mining o Minería de Textos es el proceso de extraer conocimiento a partir de datos textuales no estructurados.



Aplicaciones



- **Análisis de sentimientos:** Analizar el feedback de usuarios de un servicio o producto.
- **Investigación de mercado:** Determinar tendencias y modas.
- **Detección de fraudes:** Por ejemplo, identificando reclamos como fraudulentos.
- **Investigación científica:** Identificar patrones y relaciones en comunicaciones científicas (papers, charlas, etc.).

Terminología

Corpus

Es una colección de documentos de texto.

- Único o múltiples idiomas.
- Estático o Dinámico
- Etiquetados o No etiquetados.



Terminología

Documento

Es una unidad discreta de información textual dentro de una colección.

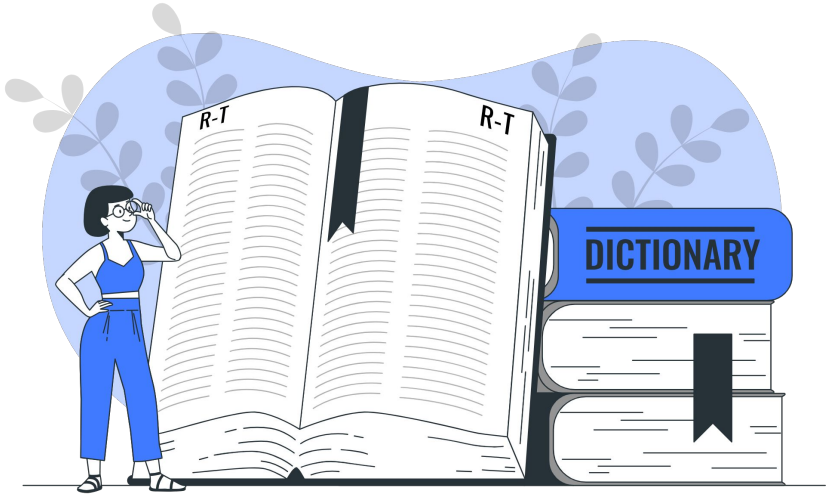
- Relación muchos a muchos.
- Puede tener o no relación con documentos físicos.
- Puede ser semi-estructurados o no estructurados.



Terminología

Características o atributos

- **Caracteres**: letras, números, símbolos.
  - Bolsa de caracteres.
  - n-gramas
- **Palabras**
- **Términos:** palabras o frases con carga semántica.
- **Conceptos**: categorización

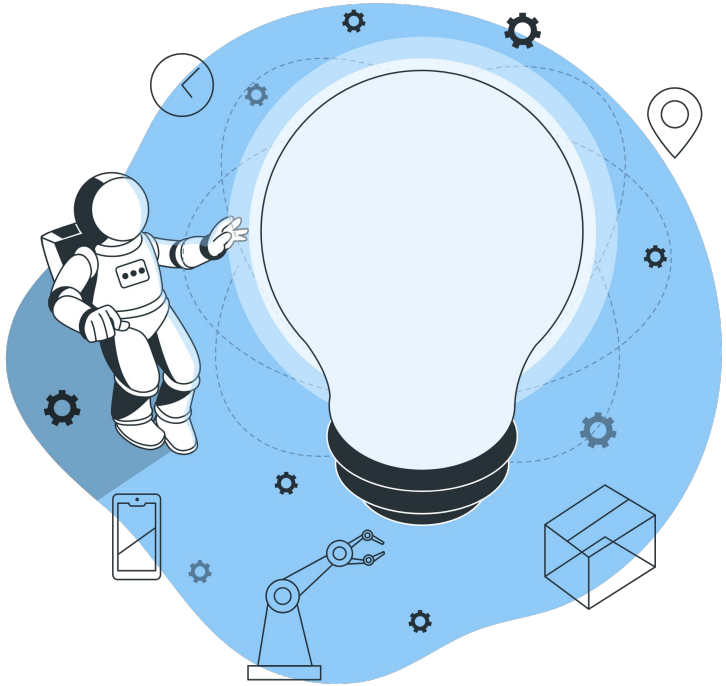


Messi emprendió un viaje profesional hasta convertirse en el jugador más importante el mundo.

Preparación de textos

Preparación

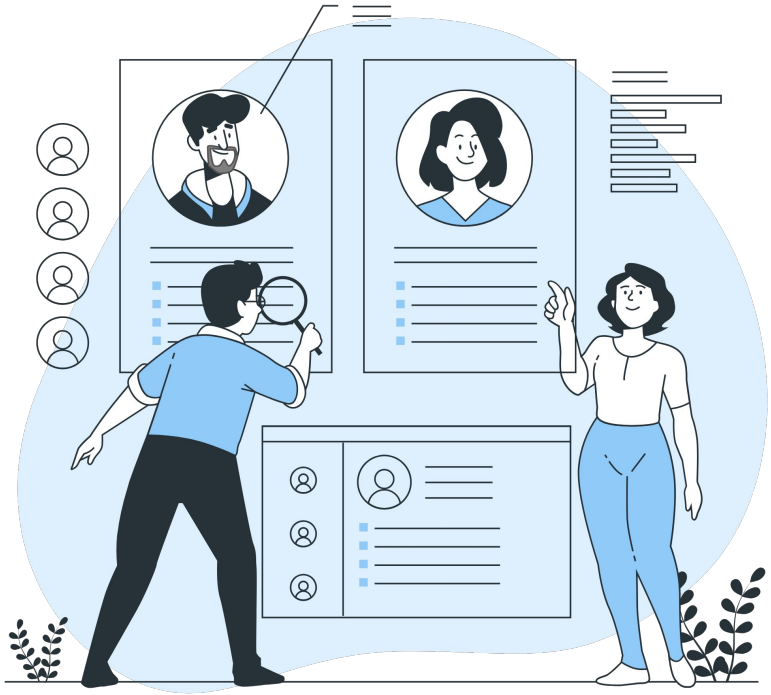
- La minería de textos es altamente dependiente de la preparación de los documentos.
- Objetivo: Crear representaciones estructuradas de los documentos.



Estas representaciones buscan “exponer” el significado de los textos para que sea accedido por los algoritmos de minería.

Preprocesamiento

Preparatorio



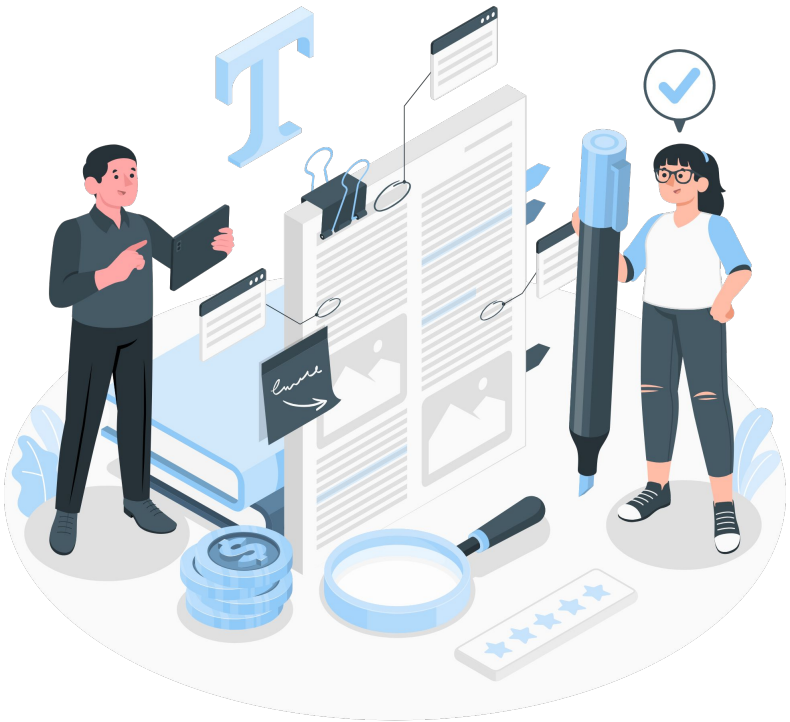
Permite convertir un documento “crudo” en un formato adecuado para realizar más procesamiento – Secuencia de caracteres.

- Obtener el texto de un PDF, una imagen, o un audio.
- Identificar partes de su estructura (párrafos, columnas, conclusiones, etc.)
- Identificar metadatos (título, autores, etc.)

Depende de la representación del texto.

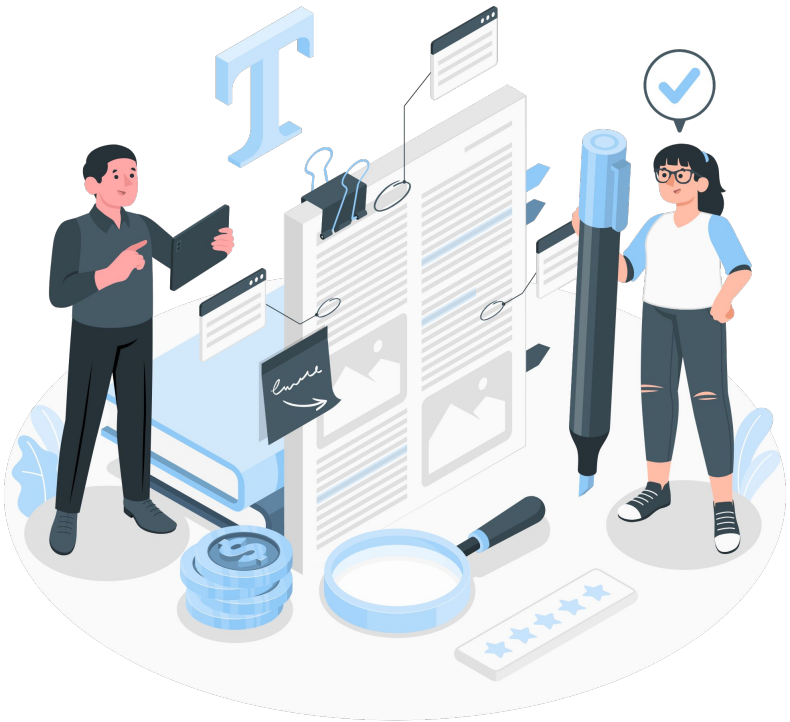
Preparación

Procesamiento de Lenguaje Natural



Procesamientos generales independientes del problema y dependen de las características del lenguaje.

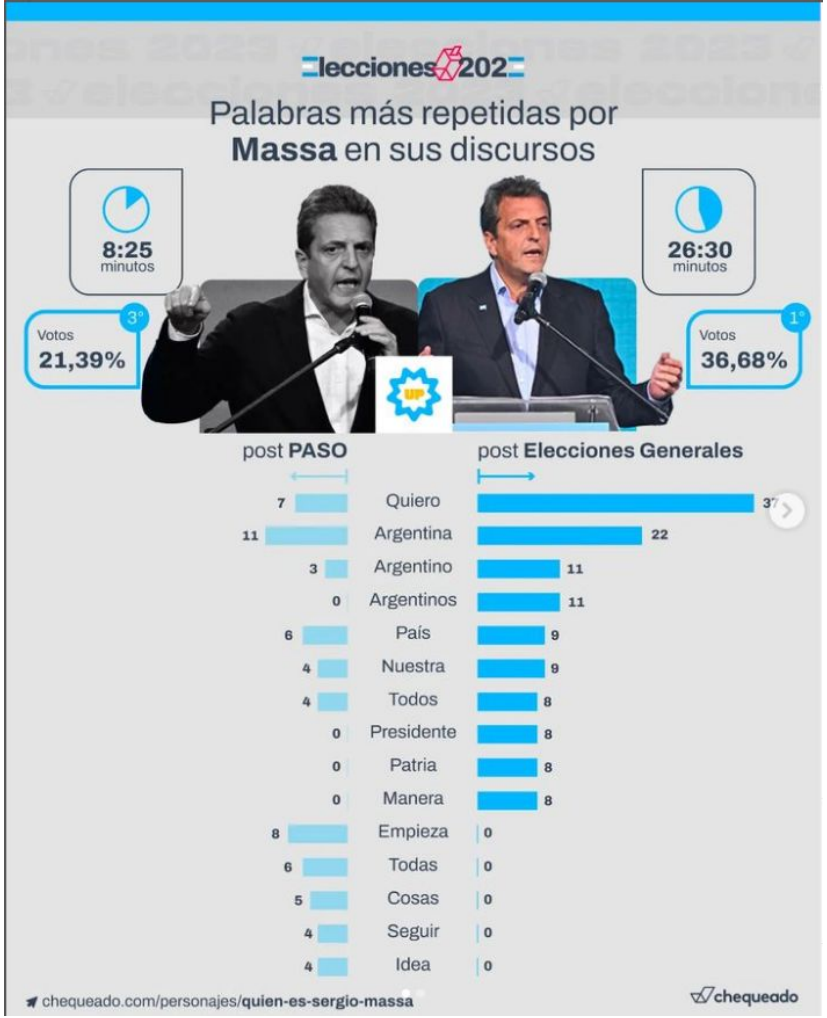
Preparación



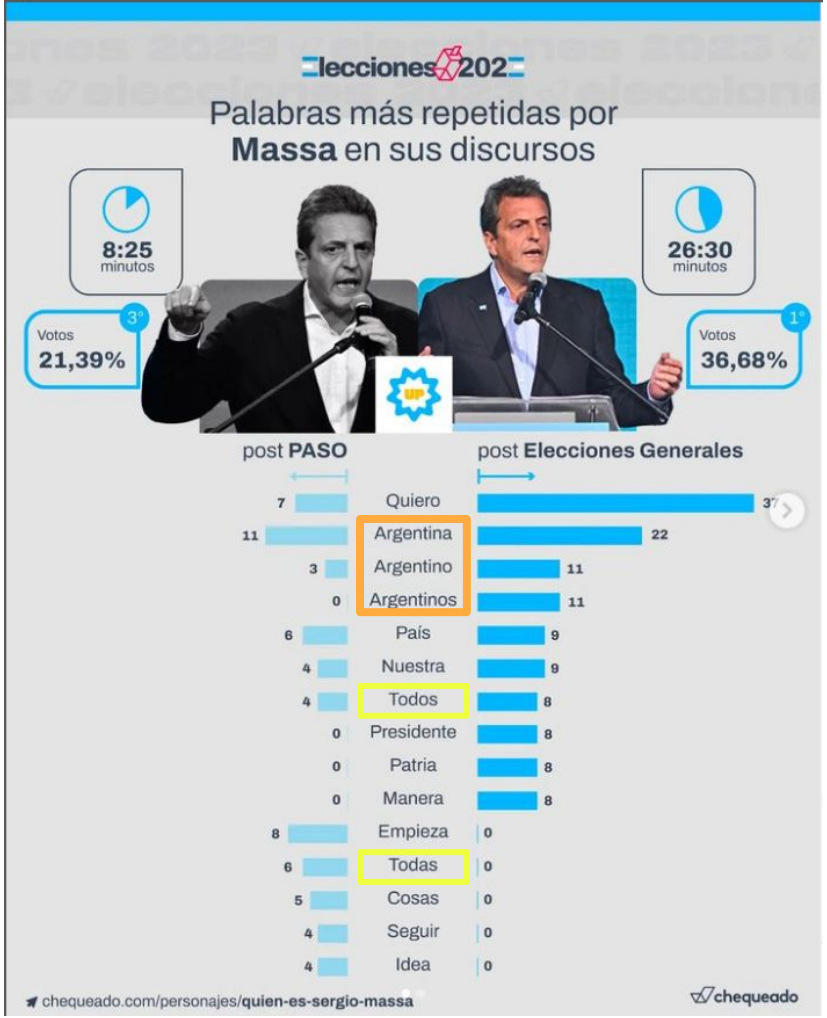
Tokenización: Dividir texto en palabras o términos.

Lematización: Hallar el lema o forma no flexionada de una palabra (por género, número, conjugación, etc.), para estandarizarla.

Huida, Huirá, Huiremos, Huyó: Huir


Elecciones 2023
Palabras más repetidas por
Massa en sus discursos
8:25
minutos
26:30
minutos
Votos
21,39%
3°
Votos
36,68%
1°
post PASO
post Elecciones Generales
7 Quiero 37
11 Argentina 22
3 Argentino 11
0 Argentinos 11
6 País 9
4 Nuestra 9
4 Todos 8
0 Presidente 8
0 Patria 8
0 Manera 8
8 Empieza 0
6 Todas 0
5 Cosas 0
4 Seguir 0
4 Idea 0
chequeado.com/personajes/quien-es-sergio-massa
chequeado


Elecciones 2023
Palabras más repetidas por
Milei en sus discursos
18:39
minutos
8:25
minutos
Votos
30,04%
1°
Votos
29,98%
2°
post PASO
post Elecciones Generales
15 Libertad 13
0 Queremos 11
8 Todos 10
0 Kirchnerismo 9
0 Juntos 8
6 Ideas 7
5 País 7
5 Gracias 7
6 Años 6
5 Cambio 6
12 Argentina 4
9 Hoy 4
6 Quiero 4
10 Son 0
7 Modelo 0
6 Robo 0
chequeado.com/personajes/quien-es-javier-milei
chequeado


Elecciones 2023
Palabras más repetidas por
Massa en sus discursos
8:25
minutos
26:30
minutos
Votos
21,39%
3°
Votos
36,68%
1°
post PASO
post Elecciones Generales
7 Quiero 37
11 Argentina 22
3 Argentino 11
0 Argentinos 11
6 País 9
4 Nuestra 9
4 Todos 8
0 Presidente 8
0 Patria 8
0 Manera 8
8 Empieza 0
6 Todas 0
5 Cosas 0
4 Seguir 0
4 Idea 0
chequeado.com/personajes/quien-es-sergio-massa
chequeado


Elecciones 2023
Palabras más repetidas por
Milei en sus discursos
18:39
minutos
8:25
minutos
Votos
30,04%
1°
Votos
29,98%
2°
post PASO
post Elecciones Generales
15 Libertad 13
0 Queremos 11
8 Todos 10
0 Kirchnerismo 9
0 Juntos 8
6 Ideas 7
5 País 7
5 Gracias 7
6 Años 6
5 Cambio 6
12 Argentina 4
9 Hoy 4
6 Quiero 4
10 Son 0
7 Modelo 0
6 Robo 0
chequeado.com/personajes/quien-es-javier-milei
chequeado

Preparación

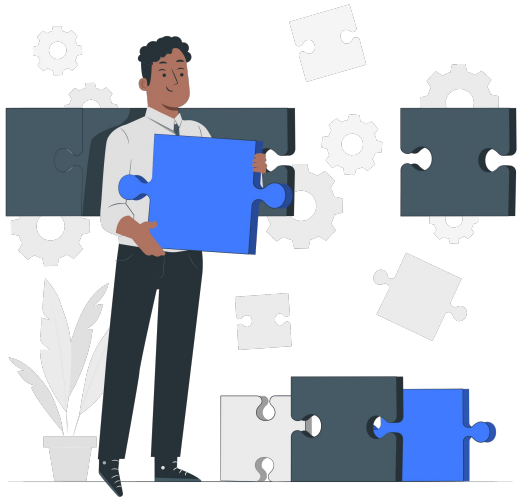
- **Etiquetado de partes del discurso:**
  - **Categorías básicas:** Verbo, Sustantivo, Preposición, Adjetivo, etc.
  - **Categorías más complejas:** corpus de categorías especializadas.
- **Análisis Sintáctico:**
  - Identificación de sujeto, predicado, modificadores, objetos, oraciones subordinadas, etc.



Preparación

Representación numérica

- Bolsa de palabras (Bag of words)
  - Conjunto (Set)
  - One-hot Encoding
  - Vector de frecuencia
- TF-IDF (term frequency–inverse document frequency)
  - Indica la importancia de una palabra en un documento.
  - TF: Frecuencia relativa de un término de un documento.
  - IDF: Indica que tanta información brinda ese término, en función de si es un término común o raro.



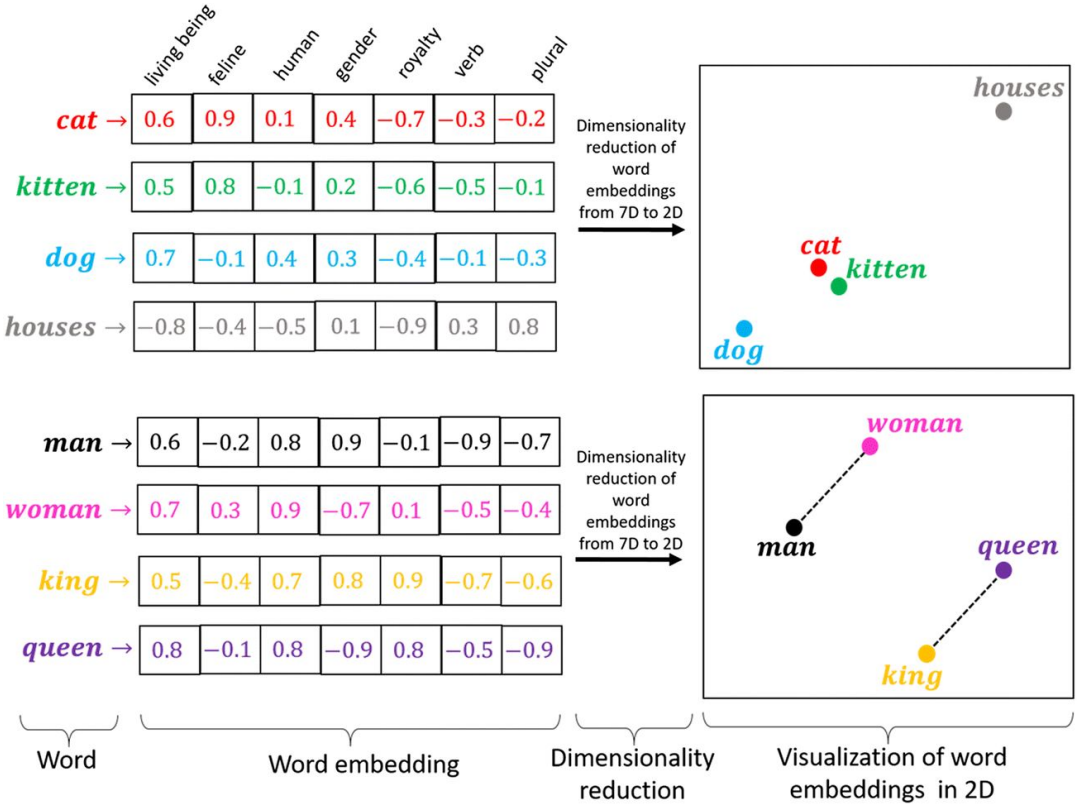
Preparación

Embeddings:

- Representación vectorial de una frase, término, palabra, concepto, etc. en un espacio métrico.
- Queremos algunas propiedades como que:
  - Si dos palabras son similares, deben ser vecinas.
  - Si estas dos palabras poseen opuesto, las distancias a sus respectivos opuestos deben ser similares.

(Word2Vec)

Representación numérica



Actividades de Minería de Datos

Actividades



Objetivo: Particionar la colección de documentos según su similitud.

- Los algoritmos de agrupamiento “clásicos” pueden ser usados sobre la representación vectorial de los documentos. (K-means, por ej.)
- Algunas modificacione:
  - **Función de distancia:** similitud coseno
  - **Cálculo del centroide:** se excluyen las palabras poco frecuentes.

Actividades

Objetivo: Construir un modelo predictivo de la clase de una colección de documentos.

Algunos algoritmos tradicionales pueden ser usados.

Se debe tener en cuenta que los espacios vectoriales son dispersos: la presencia de un término es más informativa que su ausencia.

- K-NN
- Clasificador de Bayes.
- SVM para espacios dispersos.



Actividades



Más…

- Descubrimiento de Novedades
- Modelado de temas
- Búsqueda de asociaciones
- Búsquedas de anomalías.

Entre otros…

Próximas clases

¡Recuerden leer el material!!

Profundizaremos en:

- Representación de documentos. Comparación.
- Técnicas de clasificación.
- Técnicas de agrupamiento.

Rapidminer

- Instalar extensión para el procesamiento de texto
- Descargar el archivo “Lord of the Rings.pdf”
- Realizar preprocesamiento básico y un análisis exploratorio.



Tarea

- Investigar más (3) actividades de procesamiento de lenguaje natural.
- Busquen por lo menos un ejemplo real del uso de análisis de texto.

- Leer el siguiente material:
  - Aggarwal. (2015). Data Mining: The textbook. Chaper 13: Text Mining.
  - Aggarwal. (2015). Data Mining: The textbook. Section 3.3: Text Similarity Measures.

Les dejo la consigna en el campus.

Preguntas guía: https://forms.gle/VcRwJkrtpSqsRPpe9

Bibliografía

- Feldman, R., & Sanger, J. (2007). The text mining handbook: advanced approaches in analyzing unstructured data. Cambridge university press.
- Aggarwal, C. C. (2015). Data mining: the textbook (Vol. 1). New York: springer.