Correo electrónico *

santiagociaponi3@gmail.com

Se está buscando determinar qué conceptos importantes suelen aparecer juntos en papers de ciencia de datos, utilizando el algoritmo a-priori.
¿Qué actividades se podrían realizar en la etapa de preparación de datos para lograr este objetivo?

- [ ] Vectorización TF-IDF
- [x] Stop-word removal
- [ ] Vectorización One-hot encoding
- [x] Vectorización por frecuencia
- [x] Tokenización
- [x] Lematización
- [ ] Otros:

Por qué resulta relevante el planteo metodológico de objetivos de negocio y objetivos de minería de datos, para llevar adelante un proyecto de ciencia de datos.

La principal ventaja que nos brinda este enfoque es la de alinear el trabajo técnico (es decir, todas las actividades que realizamos desde un punto de vista técnico para conseguir los resultados) con las necesidades reales de la organización (dadas por los objetivos de negocio).

Este planteo implica varias cuestiones además de la ya nombrada, como poder garantizar mayor trazabilidad de las actividades a realizar (sabemos para que hacemos las cosas, que queremos obtener) y principalmente garantizar calidad y utilidad de los resultados.

Explique cuál es la diferencia entre la evaluación realizada en la fase de modelado de CRISP-DM y la fase de Evaluación propiamente dicha.

la etapa de evaluación que se encuentra en la fase de modelado evalua la calidad tecnica del modelo, su objetivo principal es el de medir el rendimiento del modelo y ajustar parámetros. Se podría decír que responde la pregunta: ¿El modelo está aprendiendo bien?

por otro lado, la FASE de evaluación realiza una evaluación global de todo el proyecto. No analiza solo el rendimiento técnico, sino que también si el modelo cumple los objetivos de negocio definidos en la primer fase.

podemos notar que una gran diferencia esta en sus objetivos y alcance:

mientras la evaluación dentro del modelado mide la eficacia técnica de un modelo, la fase de evaluacion busca un análisis global, con revisión con los stackeholders y validación de la utilidad del modelo.

a su vez, la fase de evaluación puede llegar a derivar en una revisión de alguna fase previa, si se detecta algún error o no se llegan a los objetivos requeridos.

Un grupo de científicos busca asociar un conjunto de genes con patologías específicas.
La base de datos de entrada posee 10 atributos de entrada Ti, y un atributo de salida. Los atributos de entrada toman valores enteros {1,2,3,4} según la base nitrogenada que se encuentra en la posición i de la secuencia (1: Timina, 2: Guanina, 3: Adenina, 4: Citosina).

El atributo de salida, también entero, corresponde con cuatro tipos de cancer: (1: cancer de higado, 2: cancer de pulmón, 3: cancer de pancreas, 4: cancer de piel).

Indique que actividad de la minería de datos utilizaría? Explique.

Inicialmente podemos definir que va a ser un problema de aprendizaje supervisado, puesto que tenemos una variable objetivo.

Las variables son categóricas (por más que estén representadas con números) por lo que buscamos resolver es un problema de clasificación.

En este caso, queremos predecir el tipo de cancer (1 a 4) a partir de 10 atributos de entrada (T1, 12, ... , T10).

Podríamos aplicar clasificadores como árboles de decisión.

Describa un problema de negocio que pueda ser resuelto con regresión, sobre datos textuales. Explique indicando datos de entrada y de salida.

Datos de entrada: opiniones de mercado libre en texto.
ej: "muy bueno el producto, compra satisfactoria", "muy malo, llego roto".

La salida, van a ser las estrellas asignadas por el cliente.

Se debería plantear TF-IDF para formar vectores numéricos (luego de una preparación que dejara solo las palabras más importantes), los cuales podemos usar como entrada para una regresión, con su rating correspondiente como salida.

¿Por qué resulta necesaria una etapa de conocimiento de los datos antes de la preparación de los mismos? ¿Por qué no hacer la exploración y la preparación a la vez?

Esta etapa es importante porque nos permite conocer el contenido, calidad y limitaciones de los datos antes de transformarlos. En sí su objetivo principal es el de conocer en su totalidad los datos, tanto su significado como sus tipos, semántica, visualizaciones, etc.

Trabajarlas por separado nos da la ventaja de conocer en su totalidad todos los datos antes de realizar una actividad de la preparación (como borrar ciertos datos que quizas sean relevantes en realidad)

---

relevantes en realidad)

Explique por qué la estructura jerárquica de crisp-dm representa una mejora frente al uso del modelo KDD para llevar adelante proyectos de ciencia de datos.

KDD tenía una estructura secuencial, las etapas en este caso se ejecutan una después de la otra. Esto es algo muy importante (para mal) ya que no nos permite realizar retroalimentaciones ni contempla jerarquías. Está centrada en lo técnico, en los pasos necesarios para llevar a cabo la minería.

CRISP-DM plantea una estructura jerarquica la cuál tiene una sólida división de responsabilidades entre FASES, la cuál se planteo no solo pensando en la división de las actividades, sino que también en la retroalimentación de las mismas.

Su estructura jerarquica nos permite ir de lo general a lo particular, contextualizando las actividades y brindando un mejor seguimiento de las mismas.

A su vez esta estructura nos facilita la estandarización y trazabilidad, lo cuál es bastante deseable para hacer el proyecto reproducible.