Trabajo Práctico II

Funciones de Distancia - continuación

Objetivo: representar situaciones reales y resolver búsquedas por similitud con funciones adecuadas para conjuntos, vectores, histogramas, distribuciones y series temporales.

Indicaciones generales. En cada ejercicio, explicitar la representación, mostrar al menos un cálculo completo y justificar la elección de la función en el contexto. Redondear los resultados finales a cuatro decimales y ordenar de menor a mayor distancia. Las consultas de rango incluyen el límite. En k-NN, resolver empates por identificador alfabético. Junto con la resolución, entregar el código desarrollado para realizar los cálculos (en Python).

Ejercicio 1 Jaccard y hábitos de compra

Un supermercado busca clientes con hábitos parecidos para sugerir productos. Solo interesa qué categorías compraron durante el mes; las cantidades y las categorías que ninguno compró no deben influir.

Cliente	Categorías compradas
Q	pan, leche, fruta, café
A	pan, leche, fruta, té
B	pan, leche
C	carne, arroz, aceite
D	pan, leche, fruta, café, yogur

$$dJ(A,B) = 1 - |A \cap B| / |A \cup B|$$

a) Calcular las distancias de Q a A, B, C y D, indicando cada intersección y unión.

b) Obtener los 2 vecinos más cercanos de Q y la consulta de rango con radio 0,5.

c) ¿Cambian las distancias si se agregan al catálogo 100 categorías que nadie compró? ¿Y si Q compra diez veces más unidades de las mismas categorías?

d) Proponer una convención para comparar dos historiales vacíos y otra para comparar uno vacío con uno no vacío. Justificarla.

Ejercicio 2 Hamming y detección de imágenes duplicadas

Una galería representa cada imagen mediante un hash perceptual de 8 bits. Los bits ocupan posiciones fijas y todos tienen el mismo peso. Se busca detectar posibles duplicados de Q = 10110110.

A = 10110111; B = 10000110; C = 01001001; D = 10100110.

$$dH(x,y) = cantidad\ de\ posiciones\ en\ las\ que\ x\ e\ y\ difieren$$

a) Calcular las cuatro distancias e identificar los candidatos con distancia menor o igual que 1.

b) Si una imagen llega con un hash de 7 bits, ¿puede compararse directamente? Explicar qué debe uniformarse y por qué no corresponde alinear los bits como si fueran palabras.

c) ¿Un hash cercano garantiza que dos imágenes sean iguales? Explicar cómo usar el resultado como filtro de candidatos.

Ejercicio 3 Mahalanobis y perfiles de funcionamiento

Una fábrica registra temperatura y presión de una máquina. Ambas suelen aumentar juntas. Se buscan registros históricos cercanos al funcionamiento de referencia q = (0; 0), expresado como desviaciones respecto de los valores habituales. Las variables ya fueron estandarizadas.

La covarianza histórica es Σ = [[1; 0,8], [0,8; 1]]. Utilizar su inversa $\Sigma^{-1} = (1/0{,}36) \cdot [[1; -0{,}8], [-0{,}8; 1]]$, sin volver a estimarla con los candidatos.

Registro	Temperatura estandarizada	Presión estandarizada
A	1	1
B	1	−1
C	0,5	0

$$dM(x, q) = \sqrt{((x - q)^{\mathrm{T}} \Sigma^{-1} (x - q))}$$

a) Calcular las distancias de Mahalanobis y recuperar los 2 registros más cercanos a q.

b) Calcular, como contraste, las distancias euclidianas. Comparar especialmente A y B e interpretar el efecto de la correlación.

c) Recuperar los registros con dM ≤ 1,5. Explicar por qué una desviación conjunta puede resultar más habitual que una variación en sentidos opuestos.

d) ¿Qué condición debe cumplir Σ para aplicar esta fórmula y obtener una métrica? ¿Qué problema aparece si dos variables son copias exactas?

Ejercicio 4 Chi cuadrado y búsqueda por textura

Un catálogo de telas usa histogramas de tres patrones locales de textura. Las categorías son diferentes tipos de patrón, sin una distancia espacial definida entre ellas. Cada imagen aporta 10 observaciones, obtenidas con el mismo procedimiento.

Imagen	Patrón 1	Patrón 2	Patrón 3
Q	4	0	6
A	2	2	6
B	4	1	5
C	0	0	10

$$d\chi^2(x, y) = \Sigma_{\mathrm{i}} ((x_{\mathrm{i}} - y_{\mathrm{i}})^2 / (x_{\mathrm{i}} + y_{\mathrm{i}}))$$

Usar la convención sin factor 1/2. Una casilla con ambos valores iguales a cero aporta 0.

a) Calcular las distancias de Q a las tres imágenes y determinar la más parecida.

b) Explicar por qué esta función resulta adecuada para comparar frecuencias de patrones y cómo pondera las diferencias entre casillas.

c) Una nueva imagen aporta 100 observaciones, diez veces las frecuencias de Q. ¿Qué ocurriría al usar los recuentos crudos? Indicar cómo normalizar todos los histogramas para comparar proporciones.

d) ¿Se puede aplicar automáticamente una poda basada en desigualdad triangular con esta disimilitud? Justificar.

Ejercicio 5 Wasserstein y distribución de intensidades

Un buscador de imágenes en escala de grises debe considerar pequeño un cambio hacia un nivel de intensidad vecino, y mayor un desplazamiento hacia un nivel lejano. Las imágenes se representan con histogramas normalizados sobre cuatro niveles igualmente espaciados: 0, 1, 2 y 3.

Imagen	Nivel 0	Nivel 1	Nivel 2	Nivel 3
Q	0	1	0	0
A	1	0	0	0
B	0	0	0	1
C	0	0,5	0,5	0

Utilizar Wasserstein de orden 1 en una dimensión. Cada unidad de masa transportada tiene costo igual a la distancia absoluta entre niveles. Todos los histogramas tienen masa total 1.

$$W_1(P, Q) = \Sigma_{i=0}{}^{2} |F_p(i) - FQ(i)|$$

$F_p(i)$ es la masa acumulada desde el nivel 0 hasta el nivel i. El espaciado unitario ya está incorporado en la fórmula.

a) Calcular W_1 desde Q hacia A, B y C, y ordenar las imágenes por similitud.

b) Describir un transporte de masa de costo mínimo para cada comparación. Relacionar ese costo con el cálculo por acumuladas.

c) Calcular la distancia Manhattan de Q a A y de Q a B. Explicar qué información sobre los niveles pierde esa comparación.

d) Si los niveles se ubican en 0, 10, 20 y 30, ¿cómo cambian las distancias Wasserstein? Indicar las unidades del resultado.

Ejercicio 6 Canberra y componentes poco abundantes

Un laboratorio busca muestras con perfiles de concentración similares. Dos componentes abundantes y dos trazas se miden con el mismo protocolo. Las diferencias relativas en las trazas también importan; no se desea que las concentraciones grandes dominen toda la comparación.

Muestra	Componente 1	Componente 2	Traza 1	Traza 2
Q	100	100	1	0
A	110	100	1	0
B	100	100	0	0
C	100	100	1	1

$$dC(x, y) = \Sigma_i |x_i - y_i| / (|x_i| + |y_i|)$$

Los valores están en mg/L. Si ambos valores de una coordenada son cero, su aporte es 0.

a) Calcular las distancias a Q y recuperar todas las muestras con dC ≤ 0,1.

b) Comparar el aporte de pasar de 100 a 110 con el de pasar de 1 a 0. Interpretar por qué Canberra es pertinente para el objetivo del laboratorio.

c) Calcular el aporte de comparar 0 con 0,001. ¿Qué problema puede causar el ruido cercano al límite de detección? Proponer un criterio de preprocesamiento sin cambiar los datos de los incisos anteriores.

Ejercicio 7 Bray Curtis y comunidades de aves

Un equipo de ecología compara sitios muestreados durante el mismo tiempo y sobre la misma superficie. Busca comunidades con abundancias semejantes, dando mayor influencia a las especies abundantes. Las ausencias compartidas no deben aumentar artificialmente la similitud.

Sitio	Gorriones	Tordos	Horneros	Calandrias
Q	8	2	0	0
A	6	4	0	0
B	0	0	8	2
C	16	4	0	0

$$dBC(x,y) = \Sigma_i |x_i - y_i| / \Sigma_i (x_i + y_i)$$

a) Calcular las disimilitudes a Q y obtener los 2 sitios más similares.

b) Q y C tienen las mismas proporciones. Explicar por qué su disimilitud sobre recuentos no es cero.

c) Normalizar cada sitio para que sus abundancias sumen 1 y recalcular Q contra C. Explicar cuándo conviene comparar composición relativa y cuándo abundancias absolutas.

d) ¿Qué cambia si se añade una especie ausente en todos los sitios? ¿Qué decisión sería necesaria si ambas muestras estuvieran vacías?

Ejercicio 8 KL y Jensen Shannon en perfiles de noticias

Un portal representa la distribución de lecturas por dos temas: tecnología y deportes. P = (0,5; 0,5) es el perfil de un lector. Los perfiles candidatos son A = (0,9; 0,1), B = (0,6; 0,4) y C = (1; 0). Se desea comparar perfiles probabilísticos, teniendo en cuenta el sentido de la comparación cuando corresponda.

$$DKL(P \,\|\, Q) = \Sigma_i P_i \, ln(P_i / Q_i)$$

$$M = (P + Q)/2; \quad JS(P,Q) = [DKL(P \,\|\, M) + DKL(Q \,\|\, M)]/2$$

$$dJS(P,Q) = \sqrt{JS(P,Q)}$$

Usar logaritmos naturales. Un término con $P_i = 0$ aporta 0. Si $P_i > 0$ y $Q_i = 0$, KL es infinita. JS denota la divergencia; dJS, su raíz cuadrada.

a) Calcular DKL(P ‖ A) y DKL(A ‖ P). Interpretar por qué no son intercambiables cuando un perfil se usa para aproximar al otro.

b) Calcular JS(P, Q) y dJS(P, Q) para cada candidato Q ∈{A, B, C}. Ordenarlos por cercanía al lector P.

c) Explicar por qué DKL(P ‖ C) es infinita y JS(P, C) es finita. Mostrar el promedio M utilizado para el candidato C.

d) Para recuperar perfiles similares sin privilegiar una dirección, ¿cuál de estas medidas elegiría? Si además se exige una métrica, precisar cuál corresponde y por qué.

Ejercicio 9 Hausdorff y comparación de contornos

Un sistema de inspección compara contornos simplificados de piezas, previamente alineados y expresados en milímetros. Cada contorno es un conjunto de puntos sin orden. Se busca controlar la peor separación entre el contorno observado y el de referencia.

Referencia Q = {(0; 0), (2; 0), (2; 2)}. Pieza A = {(0; 0), (2; 0), (2; 3)}. Pieza B = {(0; 0), (2; 0), (2; 2), (8; 8)}.

$$h(A,B) = max_{\mathrm{a}} \in A\, min_{\beta} \in B\, \|a - b\|_2$$

$$dH(A,B) = max\{h(A,B), h(B,A)\}$$

a) Para Q y A, mostrar la distancia mínima desde cada punto al otro conjunto. Calcular ambas distancias dirigidas y la distancia de Hausdorff.

b) Repetir el procedimiento para Q y B. Explicar por qué no alcanza con calcular solamente h(Q, B).

c) Recuperar las piezas a distancia de Hausdorff menor o igual que 1 mm de Q.

d) Si (8; 8) fuera ruido del sensor, ¿cómo afectaría la decisión? Proponer un tratamiento o una variante robusta, e indicar qué se pierde si ese punto fuera un defecto real.

Ejercicio 10 DTW y gestos realizados a distinto ritmo

Una pulsera registra una característica de movimiento ya normalizada. Se buscan gestos parecidos aunque duren distinta cantidad de muestras. Q = (0, 1, 2, 1, 0) es la referencia; A = (0, 1, 1, 2, 1, 0) contiene una fase más lenta; B = (0, 1, 0, 1, 0) describe otro movimiento.

Usar costo local $|x_i - y_j|$ y costo acumulado sin normalizar por la longitud del camino. Se permiten pasos horizontal, vertical y diagonal, sin ventana de restricción.

$$D(i,j) = |x_{\mathrm{i}} - y_{\mathrm{j}}| + min\{D(i-1,j), D(i,j-1), D(i-1,j-1)\}$$

Inicializar D(0, 0) = 0, D(i, 0) = ∞ para i > 0 y D(0, j) = ∞ para j > 0. DTW(x, y) = D(n, m).

a) Construir las matrices acumuladas para Q contra A y Q contra B. Obtener las distancias y elegir el gesto más parecido.

b) Reconstruir un camino óptimo para Q contra A e indicar qué muestras se repiten en el alineamiento.

c) Explicar por qué la comparación punto a punto no resuelve directamente la diferencia de duración. Si dos series distintas tienen DTW igual a cero, ¿qué propiedad métrica se incumple?

d) Si la duración fuera relevante para distinguir gestos, ¿qué restricción o información adicional incorporaría?

Actividad complementaria Coseno en búsqueda de documentos

Esta función ya se trabajó en el TP I. La siguiente actividad permite revisarla en un contexto donde interesa comparar el tema de documentos de distinta extensión.

Una biblioteca representa documentos mediante frecuencias de tres términos, en este orden: algoritmo, datos, red. Se ignoran el orden de las palabras y los demás términos. La consulta es q = (1, 1, 0).

Documento	algoritmo	datos	red
A	1	1	0
B	10	10	0
C	1	0	1
D	0	0	5

$$dcos(x, y) = 1 - (x \cdot y)/(\|x\|_2 \, \|y\|_2)$$

a) Calcular las cuatro distancias y devolver los 2 documentos más cercanos.

b) Interpretar el resultado de A y B. Explicar por qué es útil que la longitud del vector no determine por sí sola la similitud temática.

c) Un documento E queda representado como (0, 0, 0). Explicar por qué la fórmula no está definida y proponer cómo tratarlo en el sistema.

d) ¿Una distancia coseno igual a cero implica que dos documentos son idénticos? ¿Puede utilizarse sin más en un índice que exige una métrica? Fundamentar ambas respuestas.

Cierre integrador

Elegir tres ejercicios correspondientes a distintos tipos de datos. Para cada uno, redactar una respuesta que conecte las siguientes decisiones:

a) Qué objeto real se busca y qué información conserva o descarta su representación.

b) Qué significa que dos objetos sean parecidos y por qué la función elegida refleja esa noción.

c) Qué función alternativa de la presentación podría producir un resultado poco útil, y por qué.

d) Qué consulta necesita la aplicación: vecino más cercano, k vecinos o rango. Precisar qué representa el umbral si se elige rango.