Trabajo Práctico II

Funciones de distancia, continuación

MATERIA	Gestión Avanzada de Datos
CARRERA	Ingeniería en Sistemas de Información
FACULTAD	UTN Facultad Regional Concepción del Uruguay
ALUMNO	Manuel Riedel
FECHA	3 de noviembre de 2026

El código de todos los cálculos está en el notebook TP5-Funciones-de-distancia-continuacion.ipynb, en la misma carpeta que este informe. Los resultados están redondeados a cuatro decimales, sin redondear los pasos intermedios, y ordenados de menor a mayor distancia. Las consultas de rango incluyen el límite y los empates en k-NN se resuelven por identificador alfabético. Uso punto decimal y coma para separar coordenadas, igual que en la salida de Python.

Ejercicio 1. Jaccard y hábitos de compra

Cada cliente se representa como el conjunto de categorías que compró en el mes. Se pierden las cantidades y el orden de compra. Uso Jaccard porque al supermercado solo le interesa qué categorías compró cada uno, y Jaccard compara lo que tienen en común contra todo lo que compraron entre los dos, sin contar lo que ninguno compró.

a) Cálculo completo para A: Q ∩ A = {pan, leche, fruta}, que tiene 3 elementos. Q ∪ A = {pan, leche, fruta, café, té}, que tiene 5. Entonces dJ(Q, A) = 1 − 3/5 = 0.4000.

Cliente	Intersección con Q	Unión con Q	dJ
D	café, fruta, leche, pan (4)	café, fruta, leche, pan, yogur (5)	0.2000
A	fruta, leche, pan (3)	café, fruta, leche, pan, té (5)	0.4000
B	leche, pan (2)	café, fruta, leche, pan (4)	0.5000
C	vacía (0)	aceite, arroz, café, carne, fruta, leche, pan (7)	1.0000

b) Los 2 vecinos más cercanos de Q son D y A. La consulta de rango con radio 0.5 devuelve D, A y B. B está justo en el límite y el límite se incluye.

c) No cambian en ninguno de los dos casos. Las categorías que nadie compró no entran ni en la intersección ni en la unión. Y como el conjunto solo registra si una categoría se compró o no, comprar diez veces más de las mismas categorías deja a Q con el mismo conjunto.

d) Dos historiales vacíos dan 0/0, así que la fórmula no está definida. Propongo tomar d = 0, porque los dos conjuntos son iguales y así se mantiene que la distancia de un objeto consigo mismo es 0. De todos modos no los usaría para recomendar, porque un cliente sin compras no dice nada sobre sus hábitos. Uno vacío con uno no vacío da d = 1, que es lo que ya sale de la fórmula (intersección 0 y unión mayor que 0): no tienen nada en común.

Ejercicio 2. Hamming y detección de imágenes duplicadas

Cada imagen se representa con un hash de 8 bits, donde cada posición siempre significa lo mismo y todas pesan igual. Uso Hamming porque compara posición por posición y cuenta cuántos bits cambian, que es lo que importa cuando las posiciones son fijas y tienen el mismo peso.

a) Cálculo completo para B: Q = 10110110 y B = 10000110 difieren en las posiciones 3 y 4, entonces dH(Q, B) = 2. Como la distancia es una cantidad de posiciones, sale entera. Los candidatos con distancia menor o igual que 1 son A y D. C es el complemento de Q, difiere en los 8 bits.

Imagen	Hash	Posiciones distintas de Q	dH
A	10110111	8	1
D	10100110	4	1
B	10000110	3, 4	2
C	01001001	1, 2, 3, 4, 5, 6, 7, 8	8

b) No se puede comparar directo, porque Hamming necesita cadenas del mismo largo. Hay que uniformar el método: calcular el hash de esa imagen con el mismo algoritmo y los mismos 8 bits que el resto de la galería. No corresponde alinear los bits como si fueran palabras (insertar o correr bits, como en Levenshtein), porque cada posición tiene un significado fijo. Si se corre un bit, se compara una característica de la imagen con otra distinta.

c) No. El hash resume la imagen en 8 bits, así que hay solo 256 valores posibles e imágenes distintas pueden tener el mismo hash o uno muy parecido. Por eso lo uso como filtro: primero me quedo con las imágenes a distancia menor o igual que 1 (acá A y D), que es barato de calcular, y después a esos candidatos los verifico con una comparación más precisa, como comparar las imágenes completas o revisarlas a mano. B y C se descartan sin gastar esa comparación.

Ejercicio 3. Mahalanobis y perfiles de funcionamiento

Cada registro se representa como un vector (temperatura, presión) estandarizado. Uso Mahalanobis porque las dos variables están correlacionadas y esta distancia tiene en cuenta la covarianza: mide qué tan raro es un registro según cómo se comportan juntas las variables, no solo qué tan lejos está.

a) Cálculo completo para A: $x - q = (1, 1)$. Multiplicando por la inversa, $(1/0.36) \times (1 - 0.8, -0.8 + 1) = (1/0.36) \times (0.2, 0.2)$. Multiplicando por $(x - q)$ queda $(0.2 + 0.2) / 0.36 = 1.1111$, y $dM(A, q) = \sqrt{1.1111} = 1.0541$. Los 2 registros más cercanos a q son C y A.

Registro	Vector	dM	Euclidiana
C	(0.5, 0)	0.8333	0.5000
A	(1, 1)	1.0541	1.4142
B	(1, −1)	3.1623	1.4142

b) Con la euclidiana A y B empatan en 1.4142. Con Mahalanobis B queda tres veces más lejos que A (3.1623 contra 1.0541). En A las dos variables suben juntas, que es lo habitual porque la correlación es 0.8. En B una sube y la otra baja, que casi nunca pasa. La euclidiana no ve esa diferencia porque trata a las variables como si no tuvieran relación.

c) Con dM menor o igual que 1.5 se recuperan C y A. Una desviación conjunta es más habitual porque, con correlación positiva, los datos históricos se reparten sobre una elipse alargada en la dirección (1, 1). En esa dirección la varianza es $1 + 0.8 = 1.8$ y en la dirección (1, −1) es $1 - 0.8 = 0.2$. Por eso moverse en sentidos opuestos cuesta mucho más, aunque el desplazamiento sea igual de largo: el cuadrado de la distancia de A es $2 / 1.8 = 1.1111$ y el de B es $2 / 0.2 = 10$.

d) Σ tiene que ser simétrica y definida positiva, es decir, con todos sus autovalores mayores que cero. Así tiene inversa y la distancia es una métrica. Si dos variables son copias exactas, la correlación es 1, Σ = [[1, 1], [1, 1]] tiene determinante 0 y no tiene inversa, así que no se puede aplicar la fórmula. Habría que sacar una de las dos copias.

Ejercicio 4. Chi cuadrado y búsqueda por textura

Cada imagen se representa con un histograma de 3 casillas, con la cantidad de observaciones de cada patrón de textura. Se pierde dónde aparece cada patrón en la imagen. Uso chi cuadrado porque compara frecuencias casilla por casilla, y acá los patrones son categorías distintas sin una distancia entre ellas, así que no tiene sentido comparar una casilla con otra.

a) Cálculo completo para A: $(4 - 2)^2 / (4 + 2) + (0 - 2)^2 / (0 + 2) + (6 - 6)^2 / (6 + 6) = 4/6 + 4/2 + 0 = 2.6667$. La imagen más parecida a Q es B.

Aporte de cada casilla a la distancia con Q

Imagen	Patrón 1	Patrón 2	Patrón 3	Distancia
B	0.0000	1.0000	0.0909	1.0909
A	0.6667	2.0000	0.0000	2.6667
C	4.0000	0.0000	1.0000	5.0000

b) Sirve para frecuencias porque divide cada diferencia por el tamaño de la casilla. Una misma diferencia pesa más en una casilla con pocas observaciones que en una con muchas, porque en proporción es un cambio más grande. Se ve en A: la diferencia de 2 en el patrón 2 (0 contra 2) aporta 2.0000 y la misma diferencia de 2 en el patrón 1 (4 contra 2) aporta 0.6667. Así las casillas grandes no dominan la comparación.

c) Con los recuentos crudos, la imagen nueva E = (40, 0, 60) tiene las mismas proporciones que Q pero queda a distancia 73.6364, más lejos que todas las demás. La diferencia es solo la cantidad de observaciones. Para comparar proporciones hay que dividir cada histograma por su total de observaciones, de modo que sume 1. Q y E quedan los dos en (0.4, 0, 0.6) y su distancia es 0.0000. Todos los histogramas tienen que normalizarse igual. Las imágenes de 10 observaciones quedan a un décimo de su distancia: B 0.1091, A 0.2667 y C 0.5000, con el mismo orden.

d) No. Esta fórmula sin raíz no cumple la desigualdad triangular. Con los datos del ejercicio: $d(Q, A) = 2.6667$, pero $d(Q, B) + d(B, A) = 1.0909 + 1.0909 = 2.1818$. Una poda basada en esa desigualdad podría descartar objetos que sí están cerca. Habría que usar su raíz cuadrada, que sí es métrica, o no podar.

Ejercicio 5. Wasserstein y distribución de intensidades

Cada imagen se representa con un histograma normalizado sobre cuatro niveles de intensidad. Se pierde dónde está cada píxel. Uso Wasserstein porque los niveles tienen un orden y una distancia entre ellos, y esta función tiene en cuenta cuán lejos hay que mover la masa. Eso es lo que pide el buscador: que un cambio a un nivel vecino cueste poco y a uno lejano cueste más.

a) Cálculo completo para C: las acumuladas son FQ = (0, 1, 1) y FC = (0, 0.5, 1), entonces $W1(Q, C) = |0 - 0| + |1 - 0.5| + |1 - 1| = 0.5000$. Por similitud el orden es C, A y B.

Masa acumulada

Imagen	F(0)	F(1)	F(2)	W1 con Q
Q	0	1	1	
C	0	0.5	1	0.5000
A	1	1	1	1.0000
B	0	0	0	2.0000

b) Un transporte de costo mínimo para cada comparación es:

Imagen	Transporte desde Q	Costo	W1
C	quedan 0.5 en el nivel 1 y pasan 0.5 al nivel 2	0.5 x 1 = 0.5000	0.5000
A	pasa 1 del nivel 1 al nivel 0	1 x 1 = 1.0000	1.0000
B	pasa 1 del nivel 1 al nivel 3	1 x 2 = 2.0000	2.0000

|FP(i) − FQ(i)| es la masa que tiene que cruzar la frontera entre el nivel i y el i + 1. Cada cruce cuesta 1 por unidad de masa, así que sumar esas diferencias da el mismo costo que el transporte. Por ejemplo, de Q a B la masa cruza dos fronteras (entre 1 y 2, y entre 2 y 3), y por eso las acumuladas difieren en 1 para i = 1 y para i = 2.

c) Manhattan da 2.0000 para Q contra A y 2.0000 para Q contra B. Da lo mismo porque solo ve que la masa está en otra casilla, no cuán lejos. Pierde el orden de los niveles y la distancia entre ellos: pasar al nivel vecino o a uno más lejano es igual.

d) Se multiplican por 10, porque cada frontera entre niveles ahora cuesta 10: C 5.0000, A 10.0000 y B 20.0000. El orden no cambia. El resultado está en las mismas unidades que los niveles de intensidad, ya que la masa es una proporción y no tiene unidades. Se puede leer como cuánto hay que mover en promedio la intensidad de la imagen.

Ejercicio 6. Canberra y componentes poco abundantes

Cada muestra se representa con un vector de 4 concentraciones en mg/L. Uso Canberra porque divide cada diferencia por la suma de los dos valores, así cuenta la diferencia relativa en cada coordenada. Entonces las trazas pesan igual que los componentes abundantes, que es lo que pide el laboratorio.

a) Cálculo completo para A: |100 − 110| / (100 + 110) + 0/200 + 0/2 + 0 = 10/210 = 0.0476. La última coordenada aporta 0 porque los dos valores son cero. B y C empatan en 1.0000 y van en orden alfabético. Con dC menor o igual que 0.1 se recupera solo A.

Aporte de cada coordenada a la distancia con Q

Muestra	Comp. 1	Comp. 2	Traza 1	Traza 2	dC
A	0.0476	0.0000	0.0000	0.0000	0.0476
B	0.0000	0.0000	1.0000	0.0000	1.0000
C	0.0000	0.0000	0.0000	1.0000	1.0000

b) Pasar de 100 a 110 aporta 10/210 = 0.0476. Pasar de 1 a 0 aporta 1/1 = 1.0000, que es lo máximo que puede aportar una coordenada. La diferencia absoluta del primer caso es diez veces mayor, pero en proporción es mucho menor. Por eso Canberra es pertinente: se nota si desaparece una traza, y 10 mg/L más sobre 100 casi no cambia el perfil. Con Manhattan sería al revés: A quedaría a 10 y B a 1.

c) Comparar 0 con 0.001 aporta 0.001/0.001 = 1.0000, lo mismo que perder una traza entera. Si 0.001 es ruido cerca del límite de detección, una medición casi nula le suma 1 a la distancia y la muestra queda lejos sin ninguna razón química. Como criterio propongo definir un límite de detección según el protocolo del laboratorio (por ejemplo 0.01 mg/L) y tomar como 0 todo valor por debajo de ese límite en todas las muestras antes de calcular. Los datos de los incisos anteriores no cambian porque ningún valor distinto de cero está por debajo del límite, y 0 contra 0.001 pasa a aportar 0.

Ejercicio 7. Bray Curtis y comunidades de aves

Cada sitio se representa con un vector de abundancias, la cantidad de individuos de cada especie. Se pueden comparar recuentos directamente porque el muestreo fue en el mismo tiempo y superficie. Uso Bray-Curtis porque mide cuánta abundancia no coincide sobre el total: las especies abundantes influyen más y las ausencias compartidas no cuentan, porque suman 0 arriba y abajo.

a) Cálculo completo para A: (|8 − 6| + |2 − 4| + 0 + 0) / (14 + 6 + 0 + 0) = 4/20 = 0.2000. Los 2 sitios más similares a Q son A y C.

Sitio	Suma de diferencias	Suma total	dBC
A	4	20	0.2000
C	10	30	0.3333
B	20	20	1.0000

b) Sobre recuentos la disimilitud también mide la cantidad total, no solo las proporciones. C tiene el doble de individuos que Q, y esos 10 individuos de más son la diferencia: 10/30 = 0.3333. No es cero porque en C hay más aves.

c) Normalizados, Q y C quedan los dos en (0.8, 0.2, 0, 0), así que su disimilitud es 0/2 = 0.0000. Conviene comparar composición relativa cuando interesa qué especies dominan y la cantidad total depende del esfuerzo de muestreo, por ejemplo con muestreos de distinto tiempo o superficie. Conviene comparar abundancias absolutas cuando el muestreo es el mismo y la cantidad de individuos también es información, como acá, donde C tiene el doble de aves.

d) Si se agrega una especie ausente en todos los sitios no cambia nada: suma 0 en el numerador y en el denominador. Si dos muestras estuvieran vacías queda 0/0 y hay que decidir qué hacer, porque la fórmula no está definida. Decidiría no compararlas y marcarlas como sin datos, porque no hay ninguna comunidad que comparar. Si el sistema necesitara un número, tomaría d = 0 porque son iguales.

Ejercicio 8. KL y Jensen Shannon en perfiles de noticias

Cada lector o perfil se representa con una distribución de probabilidad sobre dos temas. Se pierde cuánto lee en total y queda solo la proporción. Uso KL cuando importa el sentido (un perfil que aproxima a otro) y JS cuando se quiere comparar sin dirección.

a) $D_{KL}(P \| A) = 0.5 \ln(0.5/0.9) + 0.5 \ln(0.5/0.1) = -0.2939 + 0.8047 = 0.5108$. $D_{KL}(A \| P) = 0.9 \ln(0.9/0.5) + 0.1 \ln(0.1/0.5) = 0.5290 - 0.1609 = 0.3681$. No son intercambiables porque KL mide lo que se pierde al usar el segundo perfil para aproximar al primero, y pesa cada término según el primero. En $D_{KL}(P \| A)$ se usa A para aproximar al lector: el lector lee deportes la mitad del tiempo y A le da solo 0.1, y eso se penaliza. En $D_{KL}(A \| P)$ los pesos los pone A, que casi no tiene deportes, y ese término pesa poco.

b) Cálculo completo para A: M = (0.7, 0.3). $D_{KL}(P \| M) = 0.0872$ y $D_{KL}(A \| M) = 0.1163$, entonces $JS(P, A) = (0.0872 + 0.1163) / 2 = 0.1017$ y $dJS(P, A) = \sqrt{0.1017} = 0.3190$. Por cercanía al lector el orden es B, A y C.

Candidato	M	$D_{KL}(P \| M)$	$D_{KL}(Q \| M)$	JS	dJS
B	(0.55, 0.45)	0.0050	0.0051	0.0051	0.0711
A	(0.7, 0.3)	0.0872	0.1163	0.1017	0.3190
C	(0.75, 0.25)	0.1438	0.2877	0.2158	0.4645

c) $D_{KL}(P \| C)$ es infinita porque P tiene 0.5 en deportes y C tiene 0, y el término $0.5 \ln(0.5/0)$ no está acotado: C no puede explicar algo que el lector sí lee. JS no tiene ese problema porque cada perfil se compara con el promedio M, y M tiene masa donde al menos uno de los dos la tiene. Para C, M = (0.75, 0.25). $D_{KL}(P \| M) = 0.1438$ y $D_{KL}(C \| M) = 0.2877$, porque el término con C = 0 aporta 0. Entonces $JS(P, C) = 0.2158$.

d) Elegiría JS, porque es simétrica y siempre finita. Si además se exige una métrica, corresponde dJS, la raíz cuadrada de JS, que sí cumple la desigualdad triangular. JS sola no la cumple: JS(P, C) = 0.2158, pero JS(P, B) + JS(B, C) = 0.0051 + 0.1639 = 0.1690. Con la raíz sí se cumple: dJS(P, C) = 0.4645 es menor que dJS(P, B) + dJS(B, C) = 0.4760. KL tampoco es una métrica y además no es simétrica.

Ejercicio 9. Hausdorff y comparación de contornos

Cada contorno se representa como un conjunto de puntos en milímetros, sin orden. Uso Hausdorff porque toma la peor separación entre los dos contornos, que es lo que se quiere controlar en la inspección.

a) Cálculo completo para el punto (2, 2) de Q: a (0, 0) hay $\sqrt{8} = 2.8284$, a (2, 0) hay 2 y a (2, 3) hay 1, así que su mínimo es 1. Entonces h(Q, A) = 1.0000, h(A, Q) = 1.0000 y dH(Q, A) = 1.0000.

Punto de Q	Mínimo hacia A
(0, 0)	0.0000
(2, 0)	0.0000
(2, 2)	1.0000

Punto de A	Mínimo hacia Q
(0, 0)	0.0000
(2, 0)	0.0000
(2, 3)	1.0000

b) Para Q y B, h(Q, B) = 0.0000, h(B, Q) = 8.4853 y dH(Q, B) = 8.4853. El valor sale de (8, 8) contra (2, 2): $\sqrt{(6^2 + 6^2)} = \sqrt{72}$. No alcanza con h(Q, B) porque la distancia dirigida solo mira si cada punto de Q tiene uno cerca en B. Da 0 aunque B tenga un punto de más muy lejos. Hay que mirar los dos sentidos.

Punto de Q	Mínimo hacia B
(0, 0)	0.0000
(2, 0)	0.0000
(2, 2)	0.0000

Punto de B	Mínimo hacia Q
(0, 0)	0.0000
(2, 0)	0.0000
(2, 2)	0.0000
(8, 8)	8.4853

c) Con distancia menor o igual que 1 mm se recupera solo A, que está justo en el límite.

d) Si (8, 8) fuera ruido, B se rechazaría aunque sus otros tres puntos coinciden exactamente con Q, porque Hausdorff toma el máximo y depende de un solo punto. Propongo repetir la medición o filtrar puntos aislados antes de calcular. Otra opción es la Hausdorff parcial, que en lugar del máximo toma un percentil de las distancias mínimas: con el percentil 75, h(B, Q) pasa a 0, porque las distancias son 0, 0, 0 y 8.4853 y se toma la tercera. Lo que se pierde es que, si (8, 8) fuera un defecto real, como una rebaba, la variante robusta no lo detecta y la pieza pasa el control. Eso va en contra de controlar la peor separación, por eso repetiría la medición antes de descartar el punto.

Ejercicio 10. DTW y gestos realizados a distinto ritmo

Cada gesto se representa con una serie temporal, la secuencia de valores de la característica de movimiento. Se conservan la forma y el orden, y al alinear se deja de lado la duración. Uso DTW porque alinea las series aunque tengan distinta cantidad de muestras, y A es el mismo gesto que Q con una fase más lenta.

a) Cálculo completo de una celda de Q contra A: $D(2, 2) = |1 - 1| + \min\{D(1, 2), D(2, 1), D(1, 1)\} = 0 + \min\{1, 1, 0\} = 0$. El resultado es DTW(Q, A) = 0.0000 y DTW(Q, B) = 2.0000, así que el gesto más parecido es A.

Matriz acumulada de Q contra A (entre paréntesis, el valor de cada muestra)

Q / A	0	1 (0)	2 (1)	3 (1)	4 (2)	5 (1)	6 (0)
0	0	∞	∞	∞	∞	∞	∞
1 (0)	∞	0	1	2	4	5	5
2 (1)	∞	1	0	0	1	1	2
3 (2)	∞	3	1	1	0	1	3
4 (1)	∞	4	1	1	1	0	1
5 (0)	∞	4	2	2	3	1	0

Matriz acumulada de Q contra B (entre paréntesis, el valor de cada muestra)

Q / B	0	1 (0)	2 (1)	3 (0)	4 (1)	5 (0)
0	0	∞	∞	∞	∞	∞
1 (0)	∞	0	1	1	2	2
2 (1)	∞	1	0	1	1	2
3 (2)	∞	3	1	2	2	3
4 (1)	∞	4	1	2	2	3
5 (0)	∞	4	2	1	2	2

b) Un camino óptimo para Q contra A es (1, 1), (2, 2), (2, 3), (3, 4), (4, 5), (5, 6), con costo total 0. La muestra 2 de Q, que vale 1, se repite: se alinea con las muestras 2 y 3 de A.

c) La comparación punto a punto necesita la misma cantidad de muestras, y Q tiene 5 y A tiene 6. Aunque se recorte A, desde la fase lenta en adelante todo queda corrido: con las primeras 5 muestras de A la suma de diferencias da 3, aunque es el mismo gesto. Si dos series distintas tienen DTW igual a cero, como Q y A, se incumple la identidad: en una métrica $d(x, y) = 0$ solo si $x = y$.

d) Agregaría una banda de Sakoe-Chiba, que es una ventana que limita cuánto se puede alejar el camino de la diagonal, o una penalización por cada paso horizontal o vertical. También guardaría la duración como un dato aparte y exigiría que la diferencia de duración no pase de cierto valor.

Actividad complementaria. Coseno en búsqueda de documentos

Cada documento se representa con un vector de frecuencias de tres términos. Se pierden el orden de las palabras y los demás términos. Uso coseno porque compara la dirección de los vectores, es decir las proporciones entre términos, sin importar la extensión del documento.

a) Cálculo completo para C: el producto interno de q y C es 1, $\|q\| = \sqrt{2}$ y $\|C\| = \sqrt{2}$, entonces $dcos(q, C) = 1 - 1/2 = 0.5000$. Los 2 documentos más cercanos son A y B.

Documento	Vector	dcos
A	(1, 1, 0)	0.0000
B	(10, 10, 0)	0.0000
C	(1, 0, 1)	0.5000
D	(0, 0, 5)	1.0000

b) A y B dan 0 porque tienen la misma proporción de términos: B repite diez veces lo de A. Hablan de lo mismo y B es simplemente más largo. Es útil que la longitud no decida porque, si contara, un documento largo sobre el tema quedaría lejos: con la euclidiana B queda a 12.7279 de q y C, que trata de otra cosa, a 1.4142.

c) E tiene norma 0 y la fórmula divide por la norma, así que queda una división por cero. Un vector nulo no tiene dirección. Lo trataría como un documento sin términos: no lo indexo y no lo devuelvo en las búsquedas. Si hace falta un valor, le asigno la distancia máxima, 1.

d) No implica que sean idénticos. Distancia 0 solo dice que los vectores son proporcionales: A y B dan 0 y tienen distintas frecuencias. Incluso con el mismo vector los documentos podrían ser distintos, porque se ignoran el orden y los demás términos. Tampoco se puede usar sin más en un índice métrico, porque no es métrica: no cumple la identidad ni la desigualdad triangular. Por ejemplo d(q, D) = 1.0000, pero d(q, C) + d(C, D) = 0.5000 + 0.2929 = 0.7929. Para usarla habría que normalizar los vectores a largo 1 y pasar a la distancia angular (el arco coseno de la similitud), que sí cumple la desigualdad triangular.

Cierre integrador

Ejercicio 1: conjuntos, con Jaccard

a) Se buscan clientes con hábitos de compra parecidos. La representación conserva qué categorías compró cada uno en el mes y descarta las cantidades, los precios y el orden.

b) Dos clientes son parecidos si gran parte de lo que compraron es lo mismo. Jaccard lo refleja porque compara lo compartido con el total que compraron los dos, y no cuenta lo que ninguno compró.

c) Manhattan sobre las unidades compradas daría un resultado poco útil: un cliente que compra diez veces más de lo mismo quedaría muy lejos, aunque tenga los mismos hábitos.

d) Necesita k vecinos, porque para sugerir productos alcanza con una cantidad fija de clientes parecidos, como los 2 de este ejercicio.

Ejercicio 5: histogramas, con Wasserstein

a) Se buscan imágenes en escala de grises con intensidades parecidas. El histograma conserva qué proporción de la imagen está en cada nivel y descarta dónde está cada píxel, así que dos imágenes distintas con el mismo histograma quedan a distancia 0.

b) Dos imágenes son parecidas si se puede pasar de una a otra moviendo poca masa a niveles cercanos. Wasserstein mide justo ese costo.

c) Chi cuadrado o Manhattan comparan casilla por casilla y no ven la distancia entre niveles. Las dos dan 2.0000 para Q contra A y para Q contra B, aunque A está a un nivel de distancia y B a dos.

d) Un buscador necesita k vecinos, para mostrar las imágenes más parecidas en orden, haya o no alguna muy cercana.

Ejercicio 10: series temporales, con DTW

a) Se buscan gestos parecidos registrados por una pulsera. La serie conserva la forma y el orden del movimiento, y al alinear con DTW se deja de lado el ritmo.

b) Dos gestos son parecidos si siguen la misma forma, aunque uno sea más lento. DTW lo refleja porque estira o comprime el tiempo para alinear las series.

c) Una comparación punto a punto como Manhattan pide la misma longitud y penaliza el desfase. Recortando A a 5 muestras daría 3.0000 contra Q y B daría 2.0000, así que elegiría B, que es otro movimiento.

d) Necesita una consulta de rango: el gesto se reconoce solo si está suficientemente cerca de la referencia, y si no hay ninguno no se reconoce nada. El umbral representa el costo acumulado de desalineación que se tolera, en unidades de la característica normalizada. Con radio 1, por ejemplo, entra A y no entra B.