Trabajo Práctico III

Preprocesamiento y extracción de características para búsquedas por similitud

Objetivo. Construir representaciones de imágenes, textos y sonidos; utilizarlas para recuperar objetos similares y evaluar cómo las decisiones de preprocesamiento y extracción modifican los resultados. Se reutilizan las funciones de distancia de los TP anteriores.

Modalidad. Resolver los ejercicios 1 a 9 mediante notebooks o scripts reproducibles. No se requiere entrenar redes, desarrollar una interfaz ni implementar un índice aproximado. Los modelos se utilizan preentrenados y congelados, en modo evaluación.

Ejercicio 1 Preparar tres colecciones de búsqueda

Se implementarán tres buscadores independientes. Las etiquetas sirven únicamente para evaluar la recuperación; no se incorporan a los vectores ni se usan para entrenar clasificadores.

Modalidad	Colección y consultas	Qué significa relevante
Imágenes	6 objetos físicos, con 3 fotos de base y 1 foto de consulta por objeto: 18 + 6 imágenes.	Otra fotografía del mismo objeto físico.
Texto	Los 12 documentos y las 6 consultas incluidos en el ejercicio 4.	Un documento que responda la consulta, según la lista de relevancia.
Sonido	4 frases, con 3 grabaciones de base y 1 de consulta por frase: 12 + 4 audios.	Otra grabación de la misma frase, aunque cambie el ritmo.

a) Crear carpetas separadas para originales, datos procesados, características y resultados. Asignar identificadores estables y registrar en un manifiesto: ID, archivo, modalidad, base o consulta, objeto/frase de origen y condiciones de captura.

b) En imágenes, incluir objetos de color parecido pero distinta forma y objetos de forma parecida pero distinto color. Tomar fotos separadas, variando moderadamente fondo, iluminación y ángulo. Las consultas deben ser capturas nuevas, no copias de fotos de la base.

c) Para sonido, usar las frases del ejercicio 7. Mantener un mismo hablante en el experimento principal para estudiar ritmo y representación. Grabar cada repetición por separado, con voz natural y duración de 2 a 5 segundos.

d) Definir antes de ejecutar los buscadores los pares consulta-documento relevantes. En imagen y sonido, cada consulta tiene exactamente 3 objetos relevantes en la base. Conservar esta definición durante todas las comparaciones.

Reglas comunes de implementación

Ajustar paletas, vocabularios, IDF y estadísticas de estandarización solamente con la base. Guardarlos y reutilizarlos sin reajustar para las consultas. No comparar vectores de extractores distintos, aunque tengan la misma dimensión. Resolver empates por ID ascendente y excluir las consultas de la base.

La evaluación usa búsqueda exhaustiva: comparar cada consulta con toda la base. Descargar los pesos una vez y reutilizarlos; procesar de a un objeto si la memoria es limitada.

Ejercicio 2 Imágenes con píxeles e histogramas

Una oficina quiere encontrar otras fotos de un objeto extraviado. Primero se probarán dos descriptores sencillos para observar cuándo el fondo o el color pesan más que la identidad del objeto.

a) Leer las imágenes como RGB; si se usa OpenCV, convertir desde BGR. Mantener los originales y generar una versión de 224 × 224 píxeles. Elegir y documentar una política común de recorte o conservación de proporciones.
b) Descriptor de píxeles: escalar los valores a [0,1], aplanar y normalizar a norma L2 unitaria. Informar su dimensión y explicar qué representa cada coordenada.
c) Descriptor de color: ajustar una única paleta k-means de 25 colores con una muestra reproducible de píxeles de la base. Asignar cada píxel al centro más cercano, contar y dividir por el total de píxeles. Guardar la paleta y el orden de sus centros. Verificar que cada histograma tiene 25 componentes y suma 1.
d) Recuperar los 3 vecinos más cercanos de cada consulta con cada descriptor, usando distancia coseno y euclidiana para ambos. Mostrar una grilla con la consulta y los resultados. Explicar por qué entrenar una paleta diferente para cada imagen invalida la comparación coordenada a coordenada.
e) Para una consulta, comparar el histograma original con el obtenido al reordenar aleatoriamente sus píxeles. Explicar qué información pierde el histograma y por qué esto importa al buscar el mismo objeto.

Ejercicio 3 Imágenes con un extractor aprendido

Se busca mejorar la recuperación cuando cambian el fondo o la iluminación. Usar ResNet50 preentrenada con los pesos IMAGENET1K_V2 de la presentación, sin modificar los pesos ni utilizar la salida de clasificación.

a) Aplicar el preprocesamiento asociado a esos pesos directamente sobre la imagen RGB original. No alimentar el modelo con la versión aplanada ni agregar suavizado. Activar modo evaluación y deshabilitar el cálculo de gradientes.
b) Extraer los mapas de layer2 y layer4. Para una imagen, registrar sus formas antes de reducirlos y explicar el significado de canales, alto y ancho. Aplicar promedio global espacial por canal y normalizar cada vector a norma L2: se obtienen 512 y 2048 componentes, respectivamente.
c) Construir un buscador separado para cada capa usando distancia coseno y obtener los top 3 de las seis consultas. Comparar con píxeles e histogramas mediante el protocolo del ejercicio 9. No comparar directamente un vector de layer2 con otro de layer4.
d) Generar dos variantes de una consulta: una con menor brillo y otra con ruido suave de semilla fija. Mantener la base sin cambios. Comparar el ranking original y los dos nuevos rankings para cada descriptor y explicar qué cambios tolera mejor cada uno.
a) Evidencia a entregar: ejemplos antes y después del preprocesamiento, dimensiones, comprobaciones de normalización, grillas de resultados y análisis de al menos un acierto y un error. Los rankings de las variantes se analizan aparte de las seis consultas principales.

Ejercicio 4 Texto y decisiones de preprocesamiento

Un portal de soporte universitario busca respuestas a consultas escritas en español. Utilizar el siguiente corpus completo como base, conservando una copia literal de cada documento.

ID	Documento
D01	Para restablecer una contraseña olvidada, ingresá tu correo en la opción Recuperar acceso.
D02	Si no recordás la clave, solicitá un enlace de recuperación por correo electrónico.
D03	Para cambiar una contraseña conocida, ingresá a tu perfil y elegí Seguridad.
D04	La biblioteca presta libros a domicilio durante siete días.
D05	El préstamo de libros de la biblioteca dura una semana y puede renovarse.
D06	La sala de lectura de la biblioteca abre de lunes a viernes.
D07	El curso de C++ requiere conocimientos previos de programación.
D08	Para inscribirse en C++ es necesario saber programar.
D09	El curso introductorio de Python no requiere conocimientos previos de programación.
D10	Python inicial está destinado a personas que nunca programaron.
D11	La beca de transporte cubre viajes en colectivo para asistir a clases.
D12	Para pedir ayuda económica para el transporte, completá el formulario de becas.

ID	Consulta	Relevantes
Q1	Olvidé mi contraseña. ¿Cómo recupero el acceso?	D01, D02
Q2	No recuerdo mi clave. ¿Me pueden enviar un enlace?	D01, D02
Q3	¿Cuántos días puedo llevarme un libro a casa?	D04, D05
Q4	¿Puedo cursar C++ sin saber programar?	D07, D08
Q5	Nunca programé. ¿Hay un curso para empezar con Python?	D09, D10
Q6	¿Qué ayuda hay para pagar el colectivo a la facultad?	D11, D12

a) Construir una función de tokenización y normalización para la búsqueda léxica. Decidir minúsculas, Unicode, puntuación y stop words; conservar tildes, la negación y el término C++. Mostrar tokens antes y después para D07 y D09.
b) Aplicar stemming o lematización a tres documentos, mostrando sus resultados. Comparar qué formas reúne cada técnica y elegir si se incorpora a la representación léxica. Registrar herramienta y recursos lingüísticos.
c) Explicar cómo una limpieza que elimina “no” o los signos “++” puede cambiar la búsqueda. Aclarar por qué D07 y D08 son relevantes para Q4 aunque la respuesta a la posibilidad planteada sea negativa.

Ejercicio 5 Bolsa de palabras y TF IDF

El objetivo es construir vectores interpretables para el portal y observar cómo la frecuencia y la rareza de las palabras afectan el ranking. Usar la misma función de preprocesamiento del ejercicio 4 en base y consultas.

a) Construir el vocabulario solamente con D01 a D12 y fijar un orden. Generar una matriz de bolsa de palabras con frecuencias crudas. Mostrar el vocabulario, la dimensión y el vector de un documento, identificando sus coordenadas no nulas.
b) Construir TF-IDF con frecuencia cruda e IDF suavizada según la fórmula inferior. Normalizar cada vector a norma L2. Mostrar el cálculo manual del peso del término “biblioteca” (o su forma normalizada) en D04, antes de normalizar, y comprobarlo con el programa. En el corpus aparece en 3 de los 12 documentos.
c) Transformar las seis consultas usando el vocabulario y los IDF guardados. Obtener top 3 por distancia coseno para bolsa de palabras y TF-IDF. Mostrar los puntajes y calcular las métricas del ejercicio 9.
d) Procesar además la consulta “xilófono submarino”. Mostrar qué ocurre si ningún término pertenece al vocabulario. Devolver un estado explícito de consulta sin términos conocidos, sin presentar vecinos arbitrarios como respuestas útiles.
e) En una copia de D04, repetir diez veces la palabra “biblioteca”. Comparar el vector y su posición para Q3 manteniendo congelados vocabulario e IDF. Explicar por qué aumentar una frecuencia no necesariamente mejora la calidad de la respuesta.

$$idf(t) = ln((1 + N)/(1 + df(t))) + 1$$
$$w(t,d) = tf(t,d) \times idf(t)$$

N es la cantidad de documentos de la base; df(t), la cantidad de documentos que contienen t; tf(t,d), sus apariciones en d. El experimento de repetición se evalúa aparte y no modifica la base principal.

Ejercicio 6 Embeddings de texto y paráfrasis

Utilizar el modo denso de BGE-M3 presentado en clase, con pesos congelados. Se pretende recuperar respuestas aunque la consulta use expresiones diferentes de las del documento.

a) Codificar los textos originales, sin aplicar automáticamente la eliminación de stop words ni el stemming del buscador léxico. Usar el tokenizer y la receta del modelo. Obtener un vector por documento y consulta, normalizarlo a norma L2 y verificar su dimensión de 1024.
b) Recuperar el top 3 por coseno para las mismas seis consultas. Comparar con TF-IDF: identificar una paráfrasis, una consulta con un término específico y un caso con negación. Explicar resultados observados sin asumir que el modelo aprendido siempre será superior.
c) Si los documentos fueran extensos, proponer fragmentos de 512 tokens con solape de 64. Calcular el avance entre fragmentos y definir qué metadatos conservar para recuperar documento y posición. Explicar por qué no deben contarse los fragmentos repetidos como respuestas independientes al evaluar documentos.

Ampliación opcional. Incorporar BM25 como ranking léxico, registrar sus parámetros y compararlo sobre las mismas consultas. Sus puntajes son afinidades, no distancias; se ordenan de mayor a menor.

Ejercicio 7 Sonido con MFCC y orden temporal

Un archivo de grabaciones permite buscar otra pronunciación de la misma frase. El interés está en el contenido hablado, no en identificar al hablante ni en reconocer una copia exacta del archivo. Se evaluará hasta dónde alcanzan descriptores acústicos para esa tarea.

ID de frase	Contenido
F1	La biblioteca abre por la mañana.
F2	La biblioteca cierra por la mañana.
F3	El laboratorio abre por la tarde.
F4	El laboratorio cierra por la tarde.

Grabar tres repeticiones independientes por frase para la base y una cuarta para consulta. Las consultas se pronuncian un poco más lentamente. Usar un mismo hablante, micrófono y ambiente en esta primera experiencia; incluir un breve silencio inicial y final. No generar las consultas copiando o editando un archivo de la base.

a) Inspeccionar tasa de muestreo, canales, cantidad de muestras, duración y amplitud máxima. Convertir a mono y remuestrear a 16 kHz con filtrado antialias. Verificar que duración ≈ cantidad de muestras / 16000.
b) Definir y registrar una regla de recorte del silencio inicial y final; inspeccionar que no se corten palabras. Conservar las pausas internas. Decidir si se normaliza amplitud y justificar qué información se pierde. Mostrar la onda antes y después para una grabación.
c) Calcular un espectrograma con ventana Hamming de 400 muestras, salto de 160 y FFT de 512. Relacionar estos parámetros con 25 ms y 10 ms a 16 kHz. Mostrar ejes y unidades. Registrar el centrado y el padding elegidos; no confundir la longitud de FFT con la duración de la ventana.
d) Extraer 13 MFCC por cuadro con la misma configuración para todos los audios. Registrar número de bandas Mel y demás parámetros. Mostrar la forma 13 × T y explicar por qué T puede cambiar entre archivos. Construir un vector de 26 valores concatenando media y desvío temporal de cada coeficiente, con desvío poblacional.
e) Construir también la secuencia de 39 características por cuadro: 13 MFCC, 13 deltas y 13 deltas de segundo orden. Registrar la ventana usada para deltas y comprobar que hay suficientes cuadros.

Dos buscadores sobre los mismos audios

Buscador A: estandarizar las 26 coordenadas usando media y desvío calculados sobre los 12 vectores de la base; reutilizar esas estadísticas en consultas. Para coordenadas con desvío cero, usar divisor 1. Recuperar por distancia euclidiana.

Buscador B: usar las secuencias de 39 características con DTW y costo local euclidiano. Estandarizar cada característica con estadísticas de todos los cuadros válidos de la base. Usar costo acumulado sin dividir por la longitud del camino, pasos horizontal/vertical/diagonal y extremos obligatorios. Informar el efecto posible de las duraciones diferentes.

Obtener top 3 para cada consulta en ambos buscadores. Graficar un camino DTW entre una consulta y una grabación relevante. Explicar qué información pierde el resumen de 26 valores y qué gana, en costo, frente a conservar una secuencia.

Ejercicio 8 Sonido con un encoder preentrenado

Se incorpora un extractor aprendido para comparar su representación con MFCC, sin entrenar un reconocedor de frases. Usar wav2vec 2.0 con el checkpoint facebook/wav2vec2-base indicado en la presentación. Su utilidad para estas frases en español debe evaluarse; no se presupone que el espacio codifique perfectamente su significado.

a) Utilizar los audios mono a 16 kHz del ejercicio anterior y el procesador asociado al checkpoint. Ejecutar el modelo en modo evaluación e inferencia. No convertir la matriz de MFCC en entrada de este modelo, que recibe la onda.
b) Procesar un archivo por vez, sin padding de lote. Extraer hidden_states[6], como en el ejemplo de clase, y registrar la forma T′ × D obtenida. Explicar por qué T′ no coincide con el número de muestras de la onda ni necesariamente con los cuadros MFCC.
c) Aplicar promedio sobre el eje temporal para obtener D componentes y normalizar a norma L2. Registrar D observado. Construir un segundo descriptor concatenando media y desvío temporal, de dimensión 2D, y normalizarlo. Mantener separados ambos espacios de representación.
d) Recuperar top 3 por distancia coseno para las cuatro consultas con los dos descriptores. Comparar con MFCC resumidos y MFCC con DTW. Analizar especialmente F1 frente a F2 y F3 frente a F4: comparten muchas palabras, pero una diferencia cambia el contenido.

Interpretación de las representaciones acústicas

Responder a partir de las observaciones de los ejercicios 7 y 8:

a) ¿Qué representación conserva el orden temporal y cuáles lo descartan al resumir? ¿Qué consecuencias tiene esa diferencia cuando solo cambia la velocidad de pronunciación?
b) ¿Los vecinos recuperados parecen compartir frase, timbre, duración o energía? Ilustrar la respuesta con dos pares concretos. Un buen resultado con un único hablante no demuestra que el buscador sea independiente de la voz.
c) Si se quisiera recuperar al mismo hablante diciendo frases diferentes, ¿seguiría siendo válida la relevancia definida en el ejercicio 1? Proponer una colección y una representación apropiadas.
d) Si se quisiera reconocer la misma grabación con ruido o compresión, ¿qué enfoque de la presentación sería más específico?

Ejercicio 9 Evaluar y justificar las representaciones

La calidad se evalúa con las consultas principales y los conjuntos relevantes definidos antes de ejecutar las búsquedas. Presentar resultados por modalidad; los puntajes de distintos espacios no son directamente comparables.

a) Para cada consulta y representación, registrar los 3 primeros IDs, su distancia, cuántos son relevantes, precisión en 3 y recall en 3. Mostrar también la respuesta humana a por qué cada resultado es o no útil.
b) Calcular la media de cada métrica sobre las consultas de la modalidad. Separar estos resultados de los experimentos con ruido, silencio, repetición de palabras o un segundo hablante. No reajustar parámetros para mejorar solo las consultas evaluadas.
c) Medir por separado extracción de la base, extracción de consultas y comparación de vectores o secuencias ya calculados. Excluir descargas y carga inicial del modelo. Realizar una ejecución de calentamiento y luego tres mediciones; informar mediana, equipo y tamaño del lote.
d) Calcular almacenamiento de las características usando 4 bytes por valor float32. Para matrices dispersas, informar los bytes de valores e índices; para secuencias, sumar los cuadros de todos los archivos. No confundir tamaño del modelo con tamaño de la colección de descriptores.
e) Elegir una representación por modalidad, justificando el equilibrio entre calidad, costo y limitaciones. Incluir un error que no se arreglaría únicamente cambiando la función de distancia.

$$Precisión@3 \;=\; relevantes\ entre\ los\ 3\ recuperados\ /\ 3$$

$$Recall@3 \;=\; relevantes\ entre\ los\ 3\ recuperados\ /\ total\ de\ relevantes\ en\ la\ base$$

En texto hay 2 relevantes por consulta: una recuperación perfecta obtiene Recall@3 = 1 y Precisión@3 = 2/3. En imágenes y sonido hay 3 relevantes: ambas métricas pueden llegar a 1. Si una consulta produce un vector nulo y no se devuelven resultados, registrar el caso y puntuar ambas métricas con 0 en el promedio principal.