Trabajo Práctico III

Preprocesamiento y extracción de características para búsquedas por similitud

MATERIA	Gestión Avanzada de Datos
CARRERA	Ingeniería en Sistemas de Información
FACULTAD	UTN Facultad Regional Concepción del Uruguay
ALUMNO	Manuel Riedel
FECHA	10 de noviembre de 2026

El código de todo el trabajo está en el notebook TP6-Extraccion-de-caracteristicas.ipynb, en la misma carpeta que este informe, junto con la carpeta datos (originales, procesados, características y resultados). Las tablas y figuras de este informe salen de esa carpeta. Las distancias están redondeadas a cuatro decimales, la búsqueda es exhaustiva (cada consulta contra toda la base), los empates se resuelven por ID ascendente y las consultas nunca están en la base. Uso punto decimal, igual que en la salida de Python.

Datos usados. Las fotos se armaron con objetos reales del dataset COIL-100 (Columbia University), recortados de su fondo negro y pegados sobre cuatro fondos (madera, mantel, pared y escritorio), con iluminación y ángulo distintos en cada foto. Los audios se generaron con la voz Eddy (español de México) del sintetizador de macOS, cada repetición por separado y a distinta velocidad, con un ruido de fondo leve. Los textos son los del enunciado.

Ejercicio 1. Preparar tres colecciones de búsqueda

a) La carpeta datos tiene cuatro subcarpetas: originales (fotos, audios y textos sin tocar), procesados (imágenes de 224 x 224 y audios mono de 16 kHz recortados), caracteristicas (vectores, paleta, vocabulario e IDF) y resultados (grillas, gráficos y tablas). Los IDs son estables y dicen qué es cada archivo: IMG_O1_B1 es la foto 1 de base del objeto 1, IMG_O1_Q es su consulta, SON_F2_B3 es la tercera grabación de base de la frase 2, y los textos usan los IDs del enunciado (D01 a D12 y Q1 a Q6). El manifiesto (datos/manifiesto.csv) registra para los 58 archivos el ID, el archivo, la modalidad, si es base o consulta, el objeto o frase de origen y las condiciones de captura.

b) Los seis objetos forman pares a propósito. Comparten forma con distinto color el aro rojo y el aro azul, el morrón rojo y el morrón verde, y el barco azul y el barco verde. Comparten color con distinta forma el aro rojo y el morrón rojo, el aro azul y el barco azul, y el morrón verde y el barco verde. Cada foto tiene otro fondo, otra luz y otro ángulo del objeto, así que la consulta no es copia de ninguna foto de la base. Los fondos se repiten entre objetos distintos para que el fondo solo no identifique al objeto.

Objeto	Descripción	Fotos de base (fondo, luz, ángulo)	Consulta
O1	aro rojo	madera, normal, 0° / mantel, tenue, 40° / pared, fuerte, 320°	escritorio, algo tenue, 20°
O2	aro azul	mantel, normal, 0° / pared, tenue, 40° / escritorio, fuerte, 320°	pared, algo tenue, 20°
O3	morrón rojo	pared, normal, 0° / escritorio, tenue, 40° / madera, fuerte, 320°	mantel, algo tenue, 20°
O4	morrón verde	escritorio, normal, 0° / madera, tenue, 40° / mantel, fuerte, 320°	madera, algo tenue, 20°
O5	barco azul	madera, normal, 0° / mantel, tenue, 40° / pared, fuerte, 320°	escritorio, algo tenue, 20°
O6	barco verde	mantel, normal, 0° / pared, tenue, 40° / escritorio, fuerte, 320°	pared, algo tenue, 20°

c) Las 16 grabaciones tienen la misma voz. Cada repetición se generó por separado con otra velocidad (175, 190 y 205 palabras por minuto en la base y 140 en la consulta, que queda más lenta) y con silencio al principio y al final. Duran entre 2.5 y 3.5 segundos.

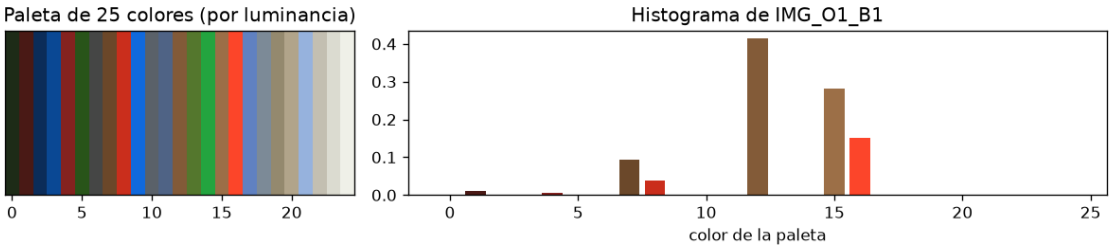
d) La relevancia quedó fijada en datos/relevancia.csv antes de correr los buscadores y no se cambió después. En imagen son relevantes las 3 fotos de base del mismo objeto, en sonido las 3 grabaciones de base de la misma frase, y en texto los dos documentos de la lista del enunciado.

Ejercicio 2. Imágenes con píxeles e histogramas

a) Leo cada imagen con PIL y la convierto a RGB (no uso OpenCV, así que no hay que pasar de BGR). Los originales no se tocan y la versión de 224 x 224 se guarda en datos/procesados. La política común es recortar el cuadrado central del lado menor (240 x 240 en una foto de 320 x 240) y reducirlo a 224 x 224 con interpolación bilineal. Así el objeto no se deforma, y como está cerca del centro el recorte solo saca fondo de los costados.

b) El vector de píxeles tiene 224 x 224 x 3 = 150528 coordenadas, con valores en [0,1] y norma L2 igual a 1 en las 24 imágenes. Cada coordenada es la intensidad de un canal (rojo, verde o azul) en un píxel fijo, recorriendo la imagen fila por fila. Por ejemplo, la coordenada 1000 es el canal verde del píxel de la fila 1 y columna 109.

c) Tomé 2000 píxeles al azar de cada una de las 18 fotos de base (semilla 0), 36000 en total, y ajusté k-means con 25 centros. La paleta está guardada en paleta_25.csv con los centros ordenados por luminancia, y ese orden define qué color es cada coordenada del histograma. Las consultas usan la misma paleta sin reajustar. Los 24 histogramas tienen 25 componentes y suman 1.

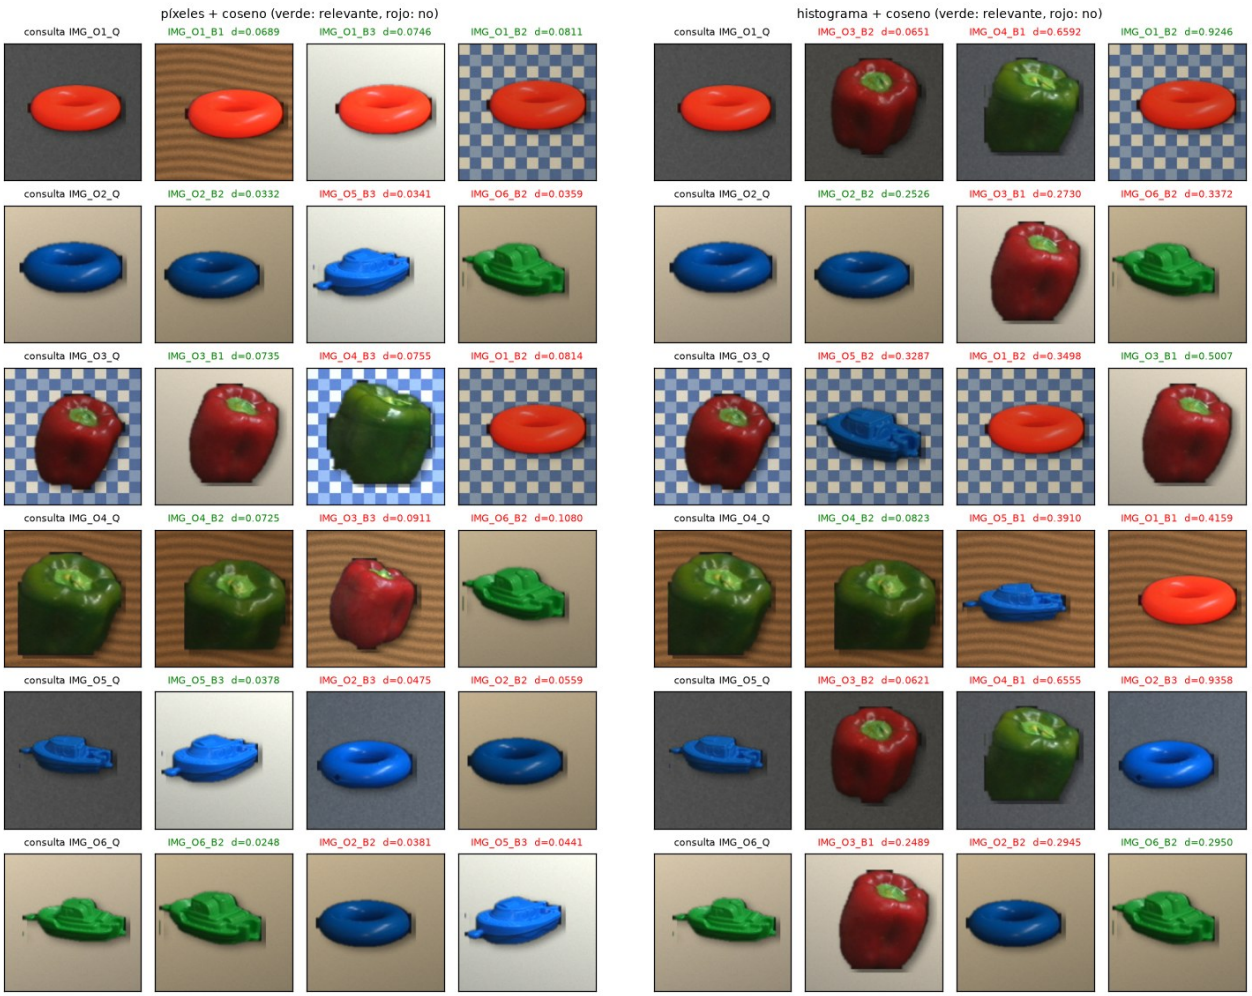


Paleta común de 25 colores e histograma de IMG_O1_B1.

d) Top 3 de cada consulta (entre paréntesis, cuántos son relevantes). Con píxeles, coseno y euclidiana dan exactamente el mismo ranking: como los vectores tienen norma 1, la euclidiana al cuadrado es 2 x (1 - coseno), así que ordenan igual.

Consulta	Píxeles, coseno y euclidiana	Histograma, coseno	Histograma, euclidiana
O1_Q	O1_B1, O1_B3, O1_B2 (3)	O3_B2, O4_B1, O1_B2 (1)	O3_B2, O4_B1, O3_B1 (0)
O2_Q	O2_B2, O5_B3, O6_B2 (1)	O2_B2, O3_B1, O6_B2 (1)	O3_B1, O2_B2, O6_B2 (1)
O3_Q	O3_B1, O4_B3, O1_B2 (1)	O5_B2, O1_B2, O3_B1 (1)	O5_B2, O1_B2, O3_B1 (1)
O4_Q	O4_B2, O3_B3, O6_B2 (1)	O4_B2, O5_B1, O1_B1 (1)	O4_B2, O4_B3, O1_B1 (2)
O5_Q	O5_B3, O2_B3, O2_B2 (1)	O3_B2, O4_B1, O2_B3 (0)	O3_B2, O4_B1, O4_B3 (0)
O6_Q	O6_B2, O2_B2, O5_B3 (1)	O3_B1, O2_B2, O6_B2 (1)	O3_B1, O2_B2, O6_B2 (1)

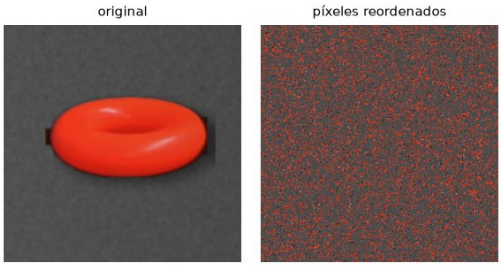
Con píxeles el primer resultado es correcto en las seis consultas, pero el segundo y el tercero casi siempre son otro objeto del mismo color o sobre el mismo fondo (P@3 media 0.4444). Con histograma la P@3 media baja a 0.2778 con las dos distancias y pesa más el fondo que el objeto: para IMG_O1_Q (aro rojo sobre escritorio) el más cercano es IMG_O3_B2 (morrón rojo sobre el mismo escritorio), y para IMG_O5_Q (barco azul sobre escritorio) los tres resultados son otros objetos sobre escritorio.



Grillas de píxeles con coseno (izquierda) e histograma con coseno (derecha). En verde los relevantes.

Si cada imagen tuviera su propia paleta, la coordenada 7 de una imagen podría ser rojo y la coordenada 7 de otra podría ser gris. Comparar coordenada a coordenada sería comparar cantidades de colores distintos y la distancia no tendría sentido. Con una paleta única, cada coordenada es el mismo color en todos los histogramas.

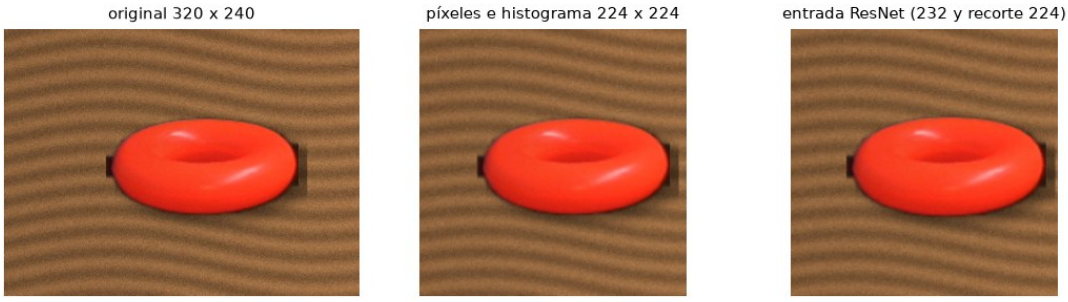
e) Reordené al azar los píxeles de IMG_O1_Q (semilla 0). El histograma no cambia en nada (diferencia máxima 0 y distancia coseno 0), así que la imagen mezclada recupera lo mismo que la original. El vector de píxeles, en cambio, queda a distancia coseno 0.1561. El histograma solo cuenta cuántos píxeles hay de cada color y pierde dónde está cada uno, o sea la forma y la posición del objeto. Para buscar el mismo objeto eso importa: un aro rojo y un morrón rojo pueden tener casi el mismo histograma, y un fondo grande pesa más en la cuenta que el objeto.



IMG_O1_Q original y con los píxeles reordenados: mismo histograma.

Ejercicio 3. Imágenes con un extractor aprendido

a) Uso ResNet50 con los pesos IMAGENET1K_V2 y su preprocesamiento asociado, aplicado sobre la foto original de 320 x 240: lleva el lado menor a 232, recorta el centro de 224 x 224, pasa a tensor en [0,1] y normaliza con la media y el desvío de ImageNet. No uso la versión aplanada ni agrego suavizado. El modelo está en modo evaluación, sin cálculo de gradientes, y no uso la salida de clasificación.



IMG_O1_B1 antes y después de cada preprocesamiento.

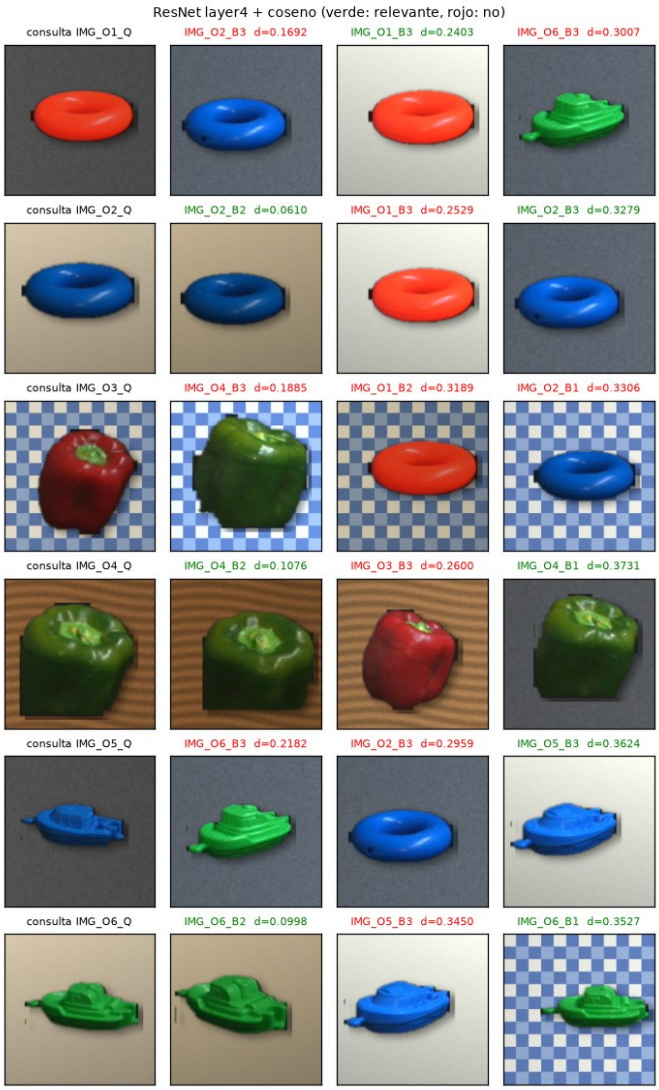
b) Para IMG_O1_B1, layer2 da (1, 512, 28, 28) y layer4 da (1, 2048, 7, 7). El 1 es el lote. Los canales son los filtros de la capa, cada uno responde a un patrón distinto: bordes y texturas en layer2, partes de objetos más abstractas en layer4. Alto y ancho son una grilla sobre la imagen, cada celda mira una zona (8 x 8 píxeles de la entrada en layer2 y 32 x 32 en layer4). El promedio global por canal deja vectores de 512 y 2048 componentes, y después de normalizar todos tienen norma 1.

c) Cada capa tiene su propio buscador con coseno. Top 3 de las seis consultas:

Consulta	ResNet layer2, coseno	ResNet layer4, coseno
O1_Q	O3_B2, O4_B1, O6_B3 (0)	O2_B3, O1_B3, O6_B3 (1)
O2_Q	O2_B2, O6_B2, O5_B3 (1)	O2_B2, O1_B3, O2_B3 (2)
O3_Q	O1_B2, O5_B2, O4_B3 (0)	O4_B3, O1_B2, O2_B1 (0)
O4_Q	O4_B2, O3_B3, O1_B1 (1)	O4_B2, O3_B3, O4_B1 (2)
O5_Q	O6_B3, O2_B3, O4_B1 (0)	O6_B3, O2_B3, O5_B3 (1)
O6_Q	O6_B2, O2_B2, O5_B3 (1)	O6_B2, O5_B3, O6_B1 (2)

Representación	P@3 media	R@3 media
píxeles + coseno	0.4444	0.4444
píxeles + euclidiana	0.4444	0.4444
histograma + coseno	0.2778	0.2778
histograma + euclidiana	0.2778	0.2778
ResNet layer2 + coseno	0.1667	0.1667
ResNet layer4 + coseno	0.4444	0.4444

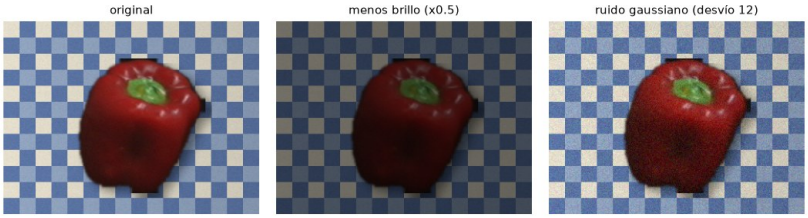
Con el protocolo del ejercicio 9, layer4 llega a una P@3 media de 0.4444, igual que píxeles, y layer2 queda última con 0.1667. Pero fallan distinto. El error típico de layer4 es confundir objetos de la misma forma y distinto color: IMG_O1_Q (aro rojo) recupera primero IMG_O2_B3 (aro azul) y IMG_O3_Q (morrón rojo) recupera primero IMG_O4_B3 (morrón verde). layer4 describe qué tipo de objeto es más que su color. layer2 está más cerca de texturas y del fondo: casi todo lo que recupera comparte fondo con la consulta.



Grilla de ResNet layer4 con coseno. En verde los relevantes.

Un acierto: IMG_O4_Q (morrón verde sobre madera) con layer4 recupera IMG_O4_B2 a 0.1076 y en tercer lugar IMG_O4_B1, que está sobre el escritorio, o sea que reconoce el objeto aunque cambien el fondo y la luz. Un error: IMG_O3_Q (morrón rojo sobre el mantel) con layer4 no recupera ninguna foto relevante. Los tres resultados (morrón verde, aro rojo y aro azul) están sobre el mantel, cuya textura cuadriculada pesa tanto como el objeto.

d) Las variantes son de IMG_O3_Q (morrón rojo): una con el brillo a la mitad y otra con ruido gaussiano de desvío 12 sobre 255 (semilla 0). La base no cambia. Todas con coseno:



IMG_O3_Q original, con menos brillo y con ruido.

Representación	Variante	Top 3	Posiciones de los 3 relevantes
ResNet layer2	original	O1_B2, O5_B2, O4_B3	6, 7, 16
ResNet layer2	menos brillo (x0.5)	O1_B2, O5_B2, O4_B3	6, 7, 16
ResNet layer2	ruido gaussiano (desvío 12)	O1_B2, O4_B3, O5_B2	6, 7, 16
ResNet layer4	original	O4_B3, O1_B2, O2_B1	5, 7, 9
ResNet layer4	menos brillo (x0.5)	O4_B3, O1_B2, O3_B1	3, 7, 9
ResNet layer4	ruido gaussiano (desvío 12)	O4_B3, O1_B2, O3_B1	3, 6, 7
histograma	original	O5_B2, O1_B2, O3_B1	3, 8, 10
histograma	menos brillo (x0.5)	O3_B2, O4_B1, O6_B3	1, 7, 9
histograma	ruido gaussiano (desvío 12)	O5_B2, O1_B2, O3_B1	3, 8, 10
píxeles	original	O3_B1, O4_B3, O1_B2	1, 9, 13
píxeles	menos brillo (x0.5)	O3_B1, O4_B3, O1_B2	1, 9, 13
píxeles	ruido gaussiano (desvío 12)	O3_B1, O4_B3, O1_B2	1, 9, 13

Píxeles con coseno no cambia el ranking en ninguna variante. Bajar el brillo multiplica todo el vector por un número y al normalizar ese factor desaparece, y el ruido suave se promedia entre 150528 coordenadas. Lo que no tolera es que el objeto cambie de lugar o de fondo. El histograma tolera el ruido pero no el brillo: con la imagen oscura los píxeles caen en otros colores de la paleta y el ranking cambia. Acá justo mejora (IMG_O3_B2, la foto de base con luz tenue, pasa al primer lugar), pero por parecerse en la luz y no en el objeto. ResNet tolera las dos variantes: layer2 deja los relevantes en las mismas posiciones y layer4 casi no cambia, porque la red se entrenó con fotos en condiciones de luz y calidad muy variadas.

Ejercicio 4. Texto y decisiones de preprocesamiento

a) Decisiones: paso el texto a Unicode NFC para que cada letra con tilde sea un solo carácter, y después a minúsculas. Las tildes se conservan. La puntuación se descarta porque la expresión regular solo toma palabras, salvo c++, que se toma completo antes que nada. Saco las stop words de la lista de NLTK para español, pero dejo afuera de esa lista las palabras de negación (no, ni, sin y nada), así que se conservan. Nunca no está en la lista, así que también queda.

Documento	Antes	Después
D07	El curso de C++ requiere conocimientos previos de programación.	curso, c++, requiere, conocimientos, previos, programación
D09	El curso introductorio de Python no requiere conocimientos previos de programación.	curso, introductorio, python, no, requiere, conocimientos, previos, programación

b) Stemming y lematización sobre tres documentos:

Documento	Tokens	Stemming (Snowball)	Lematización (spaCy)
D02	si, no, recordás, clave, solicitá, enlace, recuperación, correo, electrónico	si, no, recordas, clav, solicit, enlac, recuper, corre, electron	si, no, recordás, clave, solicitar, enlace, recuperación, correo, electrónico
D05	préstamo, libros, biblioteca, dura, semana, puede, renovarse	prestam, libr, bibliotec, dur, seman, pued, renov	préstamo, libro, biblioteca, duro, semana, poder, renovar él
D10	python, inicial, destinado, personas, nunca, programaron	python, inicial, destin, person, nunc, program	python, inicial, destinado, persona, nunca, programar

Sobre todo el corpus y las consultas, el stemming reúne beca y becas, libro y libros, olvidada y olvidé, puede, pueden y puedo, cursar y curso, programación, programar, programaron y programé, y recuperación, recuperar y recupero. La lematización reúne beca y becas, libro y libros, puede, pueden y puedo, programar y programaron, y recuperar y recupero.

Elijo stemming. Reúne más formas útiles para estas consultas: program es lo que une Q5 (programé) con D09 y D10, y recuper une Q1 (recupero) con D01 y D02. La lematización no junta programación con programar ni recuperación con recuperar, porque para el diccionario son palabras distintas, y además falla con el voseo y con algunas formas: deja recordás sin cambiar, convierte renovarse en "renovar él" y lematiza dura como duro. El stemming también tiene costos: junta conocida con conocimientos en conoc, que no tienen relación, y no une

recuerdo con recordás porque el verbo cambia la raíz. Snowball además saca las tildes al recortar (días queda dias), pero como se aplica igual a base y consultas no cambia las coincidencias. Herramientas: NLTK 3.10.4 con SnowballStemmer para español y su lista de stop words, y spaCy 3.8.18 con el modelo es_core_news_sm 3.8.0 para los lemas.

c) Si la limpieza saca el no, D09 ("no requiere conocimientos previos") queda con los mismos términos que D07 ("requiere conocimientos previos") más introductorio y Python, y el buscador ya no distingue un curso que pide saber programar de uno que no. Si saca los signos, C++ queda como c, una letra suelta que también podría venir de C o C#, y Q4 pierde su término más específico. Con la limpieza elegida c++ es un término propio que solo aparece en D07, D08 y Q4.

D07 y D08 son relevantes para Q4 porque contestan la pregunta: dicen que para C++ hay que saber programar. Que la respuesta sea "no, no podés" no la hace menos útil. La relevancia es si el documento responde lo que se pregunta, no si la respuesta es afirmativa.

Ejercicio 5. Bolsa de palabras y TF IDF

a) El vocabulario se arma solo con D01 a D12, con el preprocesamiento del ejercicio 4, y queda en orden alfabético. Tiene 62 términos, así que la matriz de bolsa de palabras es de 12 x 62: abre, acces, asist, ayud, bec, bibliotec, c++, cambi, clas, clav, colect, complet, conoc, contraseñ, corre, cubr, curs, destin, dias, domicili, dur, econom, electron, eleg, enlac, formulari, ingres, inicial, inscrib, introductori, lectur, libr, lun, necesari, no, nunc, olvid, opcion, ped, perfil, person, prest, prestam, previ, program, pued, python, recordas, recuper, renov, requier, restablec, sab, sal, segur, seman, si, siet, solicit, transport, viaj, viern.

D04 tiene 6 coordenadas no nulas, todas con frecuencia 1: 5 (bibliotec), 18 (dias), 19 (domicili), 31 (libr), 41 (prest) y 57 (siet). La, a y durante se fueron como stop words.

b) Cálculo manual para biblioteca (bibliotec) en D04: tf = 1, df = 3 y N = 12. idf = ln((1 + 12) / (1 + 3)) + 1 = ln(3.25) + 1 = 1.1787 + 1 = 2.1787. Entonces w = 1 x 2.1787 = 2.1787 antes de normalizar, que es lo mismo que da el programa. Después de normalizar D04 a norma 1 queda en 0.3291. Como control, la matriz coincide con la de TfidfVectorizer de scikit-learn, que usa la misma IDF suavizada.

c) Las consultas se transforman con el vocabulario y los IDF guardados, y los términos que no están en el vocabulario se ignoran:

Consulta	Bolsa de palabras: top 3 (distancia)	TF-IDF: top 3 (distancia)	Relev.	P@3	R@3
Q1	D01 (0.2929), D03 (0.8110), D02 (0.8333)	D01 (0.2929), D03 (0.8392), D02 (0.8619)	2 / 2	0.6667	1.0000
Q2	D02 (0.5000), D05 (0.8110), D09 (0.8232)	D02 (0.5059), D05 (0.7941), D09 (0.8406)	1 / 1	0.3333	0.5000
Q3	D04 (0.5286), D05 (0.5636), D01 (1.0000)	D04 (0.5444), D05 (0.5820), D01 (1.0000)	2 / 2	0.6667	1.0000
Q4	D08 (0.4000), D07 (0.4523), D09 (0.6838)	D08 (0.4589), D07 (0.5109), D09 (0.7471)	2 / 2	0.6667	1.0000
Q5	D10 (0.3876), D09 (0.4697), D07 (0.5918)	D10 (0.4370), D09 (0.5274), D07 (0.6492)	2 / 2	0.6667	1.0000
Q6	D11 (0.7327), D12 (0.7327), D01 (1.0000)	D11 (0.7221), D12 (0.7221), D01 (1.0000)	2 / 2	0.6667	1.0000

Bolsa de palabras y TF-IDF devuelven el mismo top 3 en las seis consultas, con P@3 media 0.6111 y R@3 media 0.9167. Cinco consultas recuperan sus dos relevantes. La que falla es Q2: recuerdo y recordás dan raíces distintas (recuerd y recordas), así que D01 no comparte ningún término con Q2, y en cambio entran D05 por pued y D09 por no. En Q6, D11 y D12 empatan porque cada uno comparte un solo término con el mismo IDF (colect y ayud) y el empate se resuelve por ID. El tercer resultado de Q3 y Q6 es D01 a distancia 1, o sea que no comparte nada con la consulta y aparece solo por completar el top 3. TF-IDF cambia los puntajes pero no el orden, porque en este corpus casi todos los términos aparecen en uno o dos documentos y tienen IDF parecidos.

d) Xilófono submarino queda como xilofon y submarin, y ninguno está en el vocabulario. El vector de la consulta es todo ceros, su norma es 0 y el coseno no se puede calcular (división por cero). Si se ordenara igual, aparecerían documentos cualquiera por el desempate de ID. Por eso la función de búsqueda devuelve el estado "consulta sin términos conocidos" y una lista vacía de resultados.

e) En una copia de D04 escribí biblioteca diez veces, así que tf pasa de 1 a 10. Con el vocabulario y los IDF congelados, los pesos normalizados quedan así:

Término	D04	D04 con biblioteca x 10
bibliotec	0.3291	0.9612
dias	0.4338	0.1267
domicili	0.4338	0.1267
libr	0.3726	0.1088
prest	0.4338	0.1267
siet	0.4338	0.1267

Como el vector sigue teniendo norma 1, cuando sube bibliotec bajan todos los demás. Q3 no dice biblioteca, coincide con D04 en días y libro, y esos son justo los términos que perdieron peso. La distancia de Q3 a D04 sube de 0.5444 a 0.8669 y D04 baja del puesto 1 al 2, detrás de D05. Repetir una palabra no agrega información, solo hace que el vector apunte casi todo hacia esa palabra, y el documento termina respondiendo peor a consultas que no la usan. Este experimento queda aparte de la base principal.

Ejercicio 6. Embeddings de texto y paráfrasis

a) Uso el tokenizer y el modelo BAAI/bge-m3 con transformers, en modo evaluación. La receta del modo denso es tomar el estado oculto del primer token (el que hace de CLS) en la última capa y normalizarlo a L2. Los textos entran tal cual, con mayúsculas, tildes, puntuación y stop words, sin el stemming del buscador léxico. El tokenizer los parte en subpalabras (C++ queda partido en C y ++). Cada documento y cada consulta dan un vector de 1024 componentes con norma 1.

b) BGE-M3 recupera los dos relevantes en las seis consultas (P@3 media 0.6667 y R@3 media 1, que es el máximo posible en texto).

Consulta	TF-IDF: top 3 (distancia)	BGE-M3: top 3 (distancia)
Q1	D01 (0.2929), D03 (0.8392), D02 (0.8619) [2 relev.]	D02 (0.2256), D01 (0.2264), D03 (0.2927) [2 relev.]
Q2	D02 (0.5059), D05 (0.7941), D09 (0.8406) [1 relev.]	D02 (0.1821), D01 (0.3752), D03 (0.4113) [2 relev.]
Q3	D04 (0.5444), D05 (0.5820), D01 (1.0000) [2 relev.]	D04 (0.2739), D05 (0.3584), D06 (0.4920) [2 relev.]
Q4	D08 (0.4589), D07 (0.5109), D09 (0.7471) [2 relev.]	D08 (0.2570), D07 (0.3062), D09 (0.4746) [2 relev.]
Q5	D10 (0.4370), D09 (0.5274), D07 (0.6492) [2 relev.]	D10 (0.2470), D09 (0.2500), D07 (0.4776) [2 relev.]
Q6	D11 (0.7221), D12 (0.7221), D01 (1.0000) [2 relev.]	D11 (0.3527), D12 (0.4387), D04 (0.5767) [2 relev.]

Paráfrasis: Q2 ("No recuerdo mi clave. ¿Me pueden enviar un enlace?"). TF-IDF solo encuentra D02 y no ve D01, que habla de "contraseña olvidada" y "Recuperar acceso" sin usar ninguna palabra de la consulta. BGE-M3 pone D02 primero y D01 segundo, porque en su espacio olvidar la clave y recuperar el acceso quedan cerca.

Término específico: Q4 (C++). Los dos buscadores devuelven D08 y D07 primero. En TF-IDF lo decide c++, que solo está en esos dos documentos y tiene IDF alto. BGE-M3 parte C++ en subpalabras y llega al mismo resultado. Acá no hay diferencia, y el léxico gana en costo y en que se puede explicar término por término.

Negación: Q5 ("Nunca programé") frente a D09 ("no requiere conocimientos previos") y D07 ("requiere conocimientos previos"), que solo se diferencian por el no. Los dos ponen D09 antes que D07, pero en TF-IDF la diferencia viene de que D09 dice Python y no del no, porque Q5 dice nunca y no comparte esa palabra. BGE-M3 separa más los dos documentos (0.2500 contra 0.4776). En Q4 el sin queda fuera del vocabulario y TF-IDF directamente lo ignora.

No asumo que el modelo aprendido sea siempre mejor. En 5 de las 6 consultas TF-IDF ya encuentra los mismos documentos, BGE-M3 necesita un modelo de más de 2 GB y tarda bastante más por consulta (ejercicio 9), y sus distancias son menos claras: en Q1, D03 (cambiar una contraseña que se conoce) queda a 0.2927, casi tan cerca como los relevantes (0.2256 y 0.2264). En un corpus más grande un documento parecido pero que no responde podría pasar adelante.

c) El avance es 512 - 64 = 448 tokens: el fragmento k empieza en el token 448 k y termina en el mínimo entre 448 k + 512 y el largo del documento, así que cada fragmento repite los últimos 64 tokens del anterior. Un documento de L tokens (L mayor que 512) da 1 + techo((L - 512) / 448) fragmentos. Como ejemplo usé el corpus repetido ocho veces, que tiene 1400 tokens y queda en 3 fragmentos:

Documento	Fragmento	Token inicio	Token fin	Carácter inicio	Carácter fin
DOC_LARGO	0	0	512	0	2528
DOC_LARGO	1	448	960	2191	4727
DOC_LARGO	2	896	1400	4411	6911

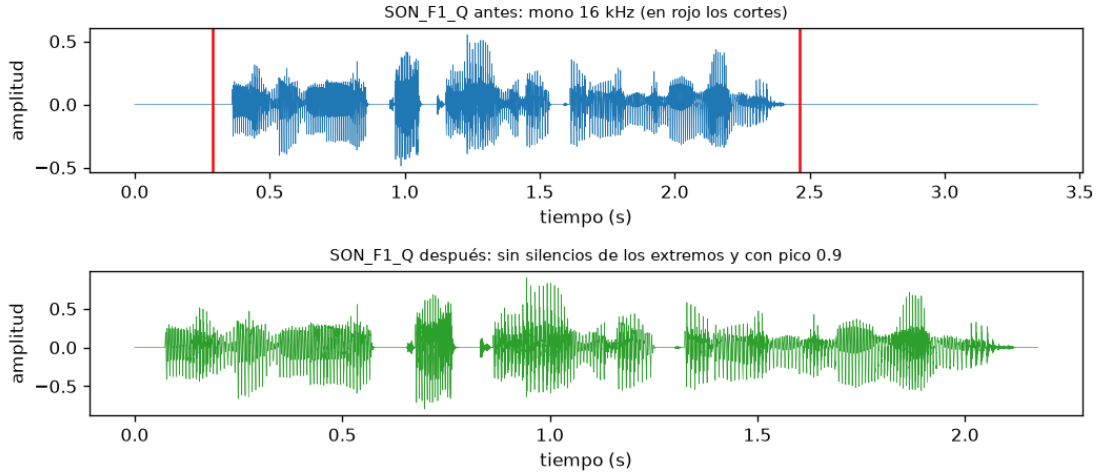
Metadatos a guardar por fragmento: ID del documento, número de fragmento, token de inicio y de fin, y carácter de inicio y de fin en el texto original. Con eso se vuelve al documento y se puede mostrar el pasaje exacto. Al evaluar documentos, varios fragmentos del mismo documento son una sola respuesta. Si se contaran por separado, una consulta que trae tres fragmentos del mismo documento relevante tendría P@3 = 1 con un solo documento encontrado, y el top 3 quedaría ocupado por repeticiones. Hay que agrupar por ID de documento, quedarse con la mejor distancia de cada uno y recién ahí armar el top 3.

Ejercicio 7. Sonido con MFCC y orden temporal

a) Los 16 archivos son WAV estéreo de 44100 Hz, con entre 110779 y 153820 muestras (de 2.512 a 3.488 s) y amplitud máxima entre 0.4781 y 0.8431. Los paso a mono promediando los dos canales y los remuestreo a 16 kHz con librosa usando soxr_hq, que antes de bajar la tasa aplica un filtro pasabajos para sacar lo que está por encima de 8 kHz y que no aparezca aliasing. En todos los archivos la duración original coincide con la cantidad de muestras a 16 kHz dividida por 16000.

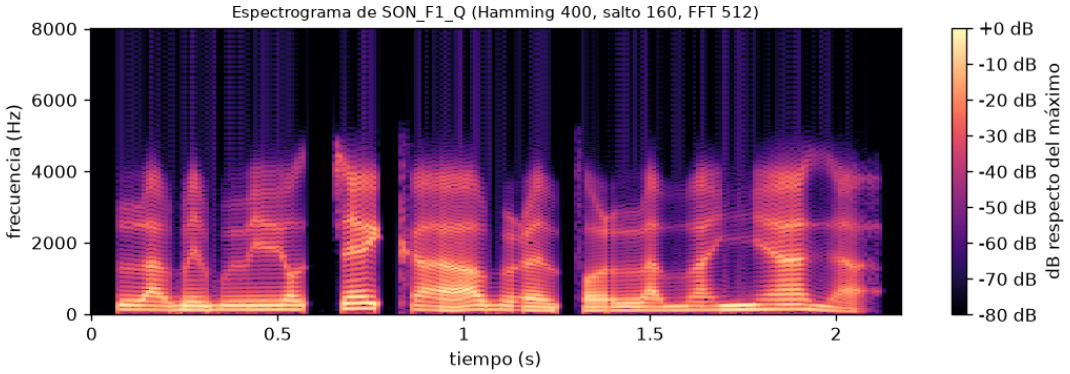
ID	Muestras (44.1 kHz)	Duración (s)	Amplitud máx.	Muestras (16 kHz)	Muestras / 16000	Corte inicio (s)	Corte final (s)	Duración final (s)	Cuadros T
SON_F1_B1	124891	2.832	0.7841	45312	2.832	0.168	0.790	1.875	188
SON_F1_B2	119952	2.720	0.8277	43520	2.720	0.258	0.658	1.805	181
SON_F1_B3	115012	2.608	0.5150	41728	2.608	0.178	0.746	1.685	169
SON_F2_B1	130536	2.960	0.7853	47360	2.960	0.168	0.798	1.995	200
SON_F2_B2	125596	2.848	0.7053	45568	2.848	0.258	0.676	1.915	192
SON_F2_B3	119246	2.704	0.8431	43264	2.704	0.178	0.742	1.785	179
SON_F3_B1	120657	2.736	0.7921	43776	2.736	0.178	0.794	1.765	177
SON_F3_B2	115718	2.624	0.6674	41984	2.624	0.258	0.672	1.695	170
SON_F3_B3	110779	2.512	0.8221	40192	2.512	0.178	0.740	1.595	160
SON_F4_B1	126302	2.864	0.4965	45824	2.864	0.178	0.792	1.895	190
SON_F4_B2	121363	2.752	0.4781	44032	2.752	0.258	0.670	1.825	183
SON_F4_B3	116424	2.640	0.7412	42240	2.640	0.178	0.758	1.705	171
SON_F1_Q	147470	3.344	0.5750	53504	3.344	0.288	0.882	2.175	218
SON_F2_Q	153820	3.488	0.7094	55808	3.488	0.288	0.886	2.315	232
SON_F3_Q	142531	3.232	0.5113	51712	3.232	0.298	0.880	2.055	206
SON_F4_Q	149587	3.392	0.7309	54272	3.392	0.298	0.900	2.195	220

b) Regla de recorte: divido la señal en cuadros de 25 ms cada 10 ms, calculo la energía RMS y tomo como voz los cuadros que están a menos de 35 dB del cuadro más fuerte. Corto antes del primero y después del último de esos cuadros, dejando 50 ms de margen. Como solo se cortan los extremos, las pausas internas quedan. Se cortan entre 0.168 y 0.298 s al principio y entre 0.658 y 0.900 s al final, y revisando las ondas el corte cae siempre en silencio, antes y después de la voz. Normalizo la amplitud al pico 0.9, así una grabación hecha con otra ganancia o más lejos del micrófono no parece distinta. Lo que se pierde es la intensidad absoluta de cada grabación, o sea qué tan fuerte se habló, que para buscar la misma frase no importa.



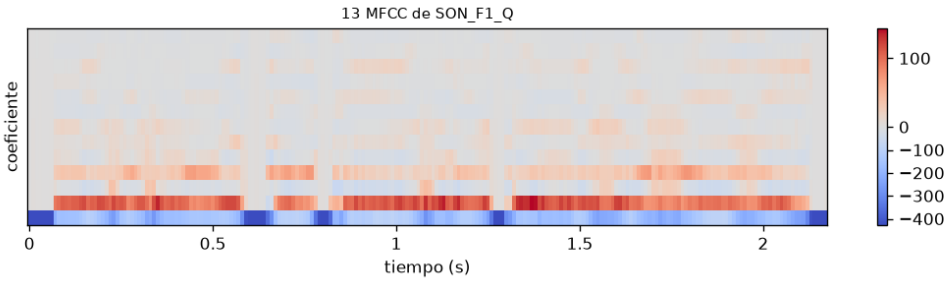
SON_F1_Q antes (mono a 16 kHz, en rojo los cortes) y después del recorte y la normalización.

c) A 16 kHz, 400 muestras son 400 / 16000 = 0.025 s = 25 ms de ventana, y 160 muestras son 10 ms de salto, o sea un cuadro nuevo cada 10 ms con 15 ms de solape. La FFT de 512 no cambia la duración de la ventana: a las 400 muestras se les agregan 112 ceros y lo que cambia es la cantidad de frecuencias calculadas, 257 bandas separadas 31.25 Hz entre 0 y 8000 Hz. Uso centrado, así que el cuadro t está centrado en la muestra 160 t, con padding de ceros en los bordes. El espectrograma de SON_F1_Q tiene forma 257 x 218.



Espectrograma de SON_F1_Q: tiempo en segundos, frecuencia en Hz e intensidad en dB respecto del máximo.

d) Parámetros de los MFCC, iguales para los 16 audios: 13 coeficientes, 40 bandas Mel entre 0 y 8000 Hz, espectro de potencia, DCT tipo 2 ortonormal y la misma ventana Hamming de 400, salto de 160, FFT de 512 y centrado del espectrograma. Cada audio da una matriz 13 x T con T = 1 + muestras // 160 por el centrado (última columna de la tabla). T cambia porque cada grabación dura distinto, y las consultas, que se dijeron más lento, tienen más cuadros. El vector de 26 junta la media y el desvío poblacional de cada coeficiente a lo largo del tiempo.



Matriz de 13 MFCC de SON_F1_Q (13 x 218).

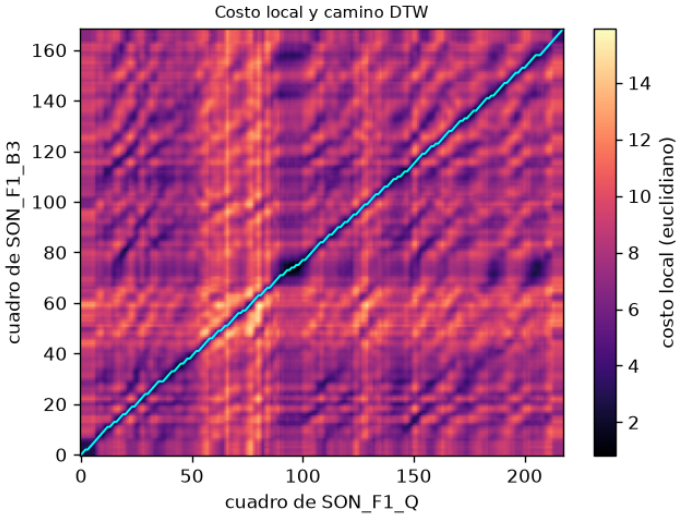
e) Las deltas de primer y segundo orden usan una ventana de 9 cuadros (4 a cada lado, 90 ms). El audio más corto tiene 160 cuadros, mucho más que 9, así que alcanza en todos. La secuencia de SON_F1_Q queda de 39 x 218.

Dos buscadores sobre los mismos audios

Buscador A: la media y el desvío de las 26 coordenadas salen de los 12 vectores de base y se reutilizan para las consultas. Ninguna coordenada tuvo desvío cero (el código usa divisor 1 en ese caso). Distancia euclidiana. Buscador B: cada una de las 39 características se estandariza con la media y el desvío de los 2160 cuadros de la base, y DTW usa costo local euclidiano, pasos horizontal, vertical y diagonal, extremos obligatorios y costo acumulado sin dividir por el largo del camino.

Consulta	MFCC 26 + euclidiana	MFCC 39 + DTW	wav2vec2 media	wav2vec2 media y desvío
F1_Q	F1_B1, F1_B2, F1_B3 (3)	F1_B1, F1_B2, F1_B3 (3)	F1_B1, F1_B2, F2_B2 (2)	F1_B1, F1_B2, F2_B2 (2)
F2_Q	F2_B2, F2_B1, F2_B3 (3)	F2_B1, F2_B2, F2_B3 (3)	F2_B1, F2_B2, F2_B3 (3)	F2_B1, F2_B2, F2_B3 (3)
F3_Q	F3_B3, F3_B2, F3_B1 (3)	F3_B1, F3_B2, F3_B3 (3)	F3_B2, F3_B3, F3_B1 (3)	F3_B2, F3_B3, F3_B1 (3)
F4_Q	F4_B2, F4_B3, F4_B1 (3)	F4_B1, F4_B2, F4_B3 (3)	F4_B2, F4_B1, F4_B3 (3)	F4_B2, F4_B1, F4_B3 (3)

Los dos buscadores MFCC recuperan las tres grabaciones de la misma frase en las cuatro consultas (P@3 = R@3 = 1). La tabla incluye también los buscadores del ejercicio 8. En DTW se ve el efecto de las duraciones: como el costo se suma paso a paso y no se divide por el largo, para las cuatro consultas la grabación de base más cercana es B1 (la más lenta, 175 palabras por minuto) y la más lejana es B3 (la más rápida, 205), por ejemplo 424.29 contra 538.15 para SON_F1_Q. Cuanto más distinta la duración, más pasos horizontales o verticales necesita el camino y más costo junta, aunque sea la misma frase. Con estas grabaciones igual alcanza, porque la frase equivocada más cercana queda mucho más lejos (de SON_F1_Q a las grabaciones de F2 hay entre 694.79 y 756.62).



Costo local y camino DTW entre SON_F1_Q y SON_F1_B3.

El camino entre SON_F1_Q (218 cuadros) y SON_F1_B3 (169 cuadros) sigue la zona de costo bajo en una diagonal con pendiente menor que 1: como la consulta tiene más cuadros, cada tanto el camino da un paso horizontal y dos cuadros de la consulta se alinean con el mismo cuadro de la base. Esos pasos están repartidos en toda la frase porque la consulta es más lenta de manera pareja.

El resumen de 26 valores pierde el orden temporal y la duración de cada parte: la media y el desvío serían iguales si los cuadros se dijeran en otro orden. A cambio, cada audio es un vector fijo de 26 números (1248 bytes toda la base contra 336960 de las secuencias) y comparar dos audios son 26 restas. Con DTW cada par necesita llenar una matriz de T1 x T2 celdas (218 x 169 = 36842 en el ejemplo), cada una con una distancia de 39 dimensiones.

Ejercicio 8. Sonido con un encoder preentrenado

a) Uso el procesador y el modelo del checkpoint facebook/wav2vec2-base. Entran las ondas mono de 16 kHz ya recortadas y normalizadas del ejercicio 7, y el procesador las lleva a media 0 y desvío 1. El modelo está en modo evaluación e inferencia, sin gradientes. Al modelo le paso la onda, no los MFCC.

b) Cada archivo entra solo, sin padding. hidden_states[6] es la salida de la sexta capa del transformer (el índice 0 es la entrada al transformer) y da T' x 768, por ejemplo 108 x 768 para SON_F1_Q, y T' va de 79 a 115 entre los 16 audios. T' es mucho menor que la cantidad de muestras porque el codificador convolucional de wav2vec 2.0 resume la onda con un paso total de 320 muestras (20 ms a 16 kHz) y una ventana de unas 400 (25 ms), así que T' es aproximadamente muestras / 320. Los MFCC usan un salto de 160 muestras (10 ms) y centrado, así que tienen casi el doble de cuadros: 218 contra 108 en SON_F1_Q.

c) D observado = 768. El promedio en el tiempo da un vector de 768 y la concatenación de media y desvío uno de 1536, los dos normalizados a norma 1. Son dos buscadores separados, nunca se compara un vector de un espacio con uno del otro.

d) Los dos descriptores de wav2vec aciertan 11 de 12 (P@3 media 0.9167), contra 12 de 12 de los dos buscadores MFCC (tabla del ejercicio 7). El error es el mismo en los dos: para SON_F1_Q el tercer resultado es SON_F2_B2, la frase que solo cambia abre por cierra, y SON_F1_B3 queda fuera del top 3. Distancia media de cada consulta a las tres grabaciones de cada frase:

Representación	Consulta	F1	F2	F3	F4
MFCC 26 + euclidiana	F1_Q	4.1044	7.8680	6.8599	9.9617
MFCC 26 + euclidiana	F2_Q	7.8778	2.8477	7.7977	5.7052
MFCC 26 + euclidiana	F3_Q	7.5045	8.6234	2.8367	6.8634
MFCC 26 + euclidiana	F4_Q	10.7946	7.2227	7.2128	2.6410
MFCC 39 + DTW	F1_Q	481.75	717.21	1203.02	1416.44
MFCC 39 + DTW	F2_Q	765.72	521.65	1445.69	1242.72
MFCC 39 + DTW	F3_Q	1187.29	1358.51	457.91	700.59
MFCC 39 + DTW	F4_Q	1415.28	1213.26	754.14	502.25
wav2vec2 media + coseno	F1_Q	0.0588	0.0626	0.1074	0.1222
wav2vec2 media + coseno	F2_Q	0.1272	0.0526	0.1439	0.1026
wav2vec2 media + coseno	F3_Q	0.1434	0.1398	0.0450	0.0654
wav2vec2 media + coseno	F4_Q	0.1764	0.1191	0.0850	0.0389
wav2vec2 media y desvío + coseno	F1_Q	0.0123	0.0136	0.0246	0.0270
wav2vec2 media y desvío + coseno	F2_Q	0.0246	0.0102	0.0301	0.0213
wav2vec2 media y desvío + coseno	F3_Q	0.0302	0.0290	0.0100	0.0144
wav2vec2 media y desvío + coseno	F4_Q	0.0353	0.0233	0.0185	0.0084

F1 frente a F2: SON_F1_Q queda casi igual de cerca de F1 que de F2 con wav2vec (0.0588 contra 0.0626 con la media), mientras que con MFCC la diferencia es clara (4.1044 contra 7.8680 con el resumen y 481.75 contra 717.21 con DTW). F3 frente a F4 se separa mejor en todas (SON_F3_Q: 0.0450 contra 0.0654 con wav2vec). Al promediar en el tiempo, abre o cierra es una palabra de seis y cambia poco el promedio. Además wav2vec2-base se preentrenó con audio en inglés y sin etiquetas, así que no hay garantía de que su espacio separe bien palabras en español. DTW, en cambio, compara cuadro a cuadro y la palabra distinta suma costo en su tramo.

Interpretación de las representaciones acústicas

a) Solo MFCC 39 con DTW conserva el orden temporal, porque compara las secuencias cuadro a cuadro y el alineamiento puede estirar o comprimir partes. MFCC 26 y los dos descriptores de wav2vec resumen con media (y desvío) y descartan el orden. Cuando solo cambia la velocidad, el resumen casi no cambia, porque los mismos sonidos duran más pero sus promedios se parecen. DTW absorbe el cambio con pasos horizontales o verticales, pero como el costo no se divide por el largo, la consulta lenta suma más costo con las grabaciones más rápidas: para SON_F1_Q el costo con B1 (175 palabras por minuto) es 424.29 y con B3 (205) es 538.15.

b) Los vecinos comparten sobre todo la frase. Dentro de la misma frase, en DTW los ordena la duración: SON_F1_Q (2.175 s) tiene más cerca a SON_F1_B1 (1.875 s, la base más larga) que a SON_F1_B3 (1.685 s), y lo mismo pasa en las otras tres consultas. Con wav2vec, el par SON_F1_Q y SON_F2_B2 (0.0519) muestra que el vecino puede compartir casi todo el sonido y no la frase, porque solo cambia una palabra. La energía no explica los vecinos porque está normalizada al pico y las energías RMS quedan todas entre 0.1551 y 0.1827. El timbre no se puede evaluar porque todas las grabaciones tienen la misma voz, y encima es una voz sintetizada que dice cada sonido casi igual. Por eso que funcione acá no demuestra que el buscador sea independiente de la voz: con otra persona cambian el timbre, la altura y la forma de pronunciar, y un buscador acústico podría acercar grabaciones de la misma voz antes que de la misma frase.

c) No. La relevancia del ejercicio 1 es "otra grabación de la misma frase", y para buscar al mismo hablante lo relevante sería cualquier grabación de esa persona, diga lo que diga. Habría que armar una colección con varios hablantes (por ejemplo 10), cada uno diciendo frases distintas en sesiones distintas, con consultas que sean frases que ese hablante no tenga en la base, y definir como relevantes las grabaciones del mismo hablante. Como representación usaría un embedding de hablante (tipo x-vector o ECAPA) promediado en el tiempo, que está entrenado para capturar la voz e ignorar el contenido. Sin ese modelo, MFCC resumidos con media y desvío también sirven como base, porque guardan el timbre y descartan el orden de las palabras.

d) Para reconocer la misma grabación con ruido o compresión lo más específico es una huella acústica (audio fingerprinting, como Shazam): se buscan los picos del espectrograma y se arman hashes con pares de picos y su diferencia de tiempo. Resiste ruido y compresión porque los picos fuertes sobreviven, y no busca otras pronunciaciones, solo la misma grabación.

Ejercicio 9. Evaluar y justificar las representaciones

a) Para cada consulta y representación quedaron registrados los 3 primeros IDs con su distancia, cuántos son relevantes, P@3, R@3 y la explicación de por qué cada resultado sirve o no. Los top 3 están en las tablas de cada ejercicio y la tabla completa, con las explicaciones, está en el anexo (y en datos/resultados/ej9_resultados_por_consulta.csv). Ninguna consulta principal tuvo vector nulo.

b) Medias sobre las consultas principales de cada modalidad:

Modalidad	Representación	P@3 media	R@3 media
imagen	píxeles + coseno	0.4444	0.4444
imagen	píxeles + euclidiana	0.4444	0.4444
imagen	histograma + coseno	0.2778	0.2778
imagen	histograma + euclidiana	0.2778	0.2778
imagen	ResNet layer2 + coseno	0.1667	0.1667
imagen	ResNet layer4 + coseno	0.4444	0.4444
texto	bolsa de palabras + coseno	0.6111	0.9167
texto	TF-IDF + coseno	0.6111	0.9167
texto	BGE-M3 denso + coseno	0.6667	1.0000
sonido	MFCC 26 + euclidiana	1.0000	1.0000
sonido	MFCC 39 + DTW	1.0000	1.0000
sonido	wav2vec2 media + coseno	0.9167	0.9167
sonido	wav2vec2 media y desvío + coseno	0.9167	0.9167

Los puntajes no se comparan entre modalidades. En imagen P@3 y R@3 son iguales porque hay 3 relevantes. En texto el máximo de P@3 es 2/3 = 0.6667, que BGE-M3 alcanza. Los experimentos (variantes de brillo y ruido de IMG_O3_Q, la consulta xilófono submarino y la repetición de biblioteca en D04) están aparte y no entran en estos promedios. No reajusté nada después de ver los resultados: la paleta, el vocabulario, los IDF, las estadísticas de estandarización, la regla de recorte y los parámetros de MFCC y DTW se fijaron antes de correr las búsquedas.

c) Tiempos en milisegundos, mediana de tres mediciones después de una de calentamiento. Equipo: Apple M5, Darwin arm64, solo CPU, 4 hilos de torch, lote de 1 objeto. La extracción incluye leer el archivo y preprocesarlo, y no incluye descargas ni la carga inicial de los modelos. La comparación se mide con los vectores o

secuencias ya calculados (6 consultas contra 18 imágenes, 6 contra 12 documentos y 4 contra 12 audios).

Modalidad	Representación	Extracción base (ms)	Extracción consultas (ms)	Comparación (ms)
imagen	píxeles	25.009	8.236	6.521
imagen	histograma	279.244	91.262	0.019
imagen	ResNet50 (layer2 y layer4, una pasada)	263.461	88.334	0.096
texto	bolsa de palabras	0.488	0.206	0.012
texto	TF-IDF	0.525	0.212	0.014
texto	BGE-M3 denso	456.015	225.135	0.033
sonido	MFCC 26	22.043	8.741	0.012
sonido	MFCC 39 (secuencia)	24.846	9.666	143.081
sonido	wav2vec2 (media y media+desvío, una pasada)	398.998	156.801	0.061

Los modelos aprendidos son los más caros para extraer: BGE-M3 tarda unos 38 ms por consulta, contra menos de un milisegundo de bolsa de palabras y TF-IDF para todas juntas. En la comparación solo pesa DTW: 143.1 ms contra 0.012 ms del resumen de 26 valores, unas 11760 veces más.

d) Almacenamiento de las características de la base con 4 bytes por valor:

Modalidad	Representación	Tamaño	Bytes	Detalle
imagen	píxeles	18 x 150528	10838016	
imagen	histograma	18 x 25	1800	
imagen	ResNet layer2	18 x 512	36864	
imagen	ResNet layer4	18 x 2048	147456	
texto	bolsa de palabras (dispersa)	12 x 62, 82 no nulos	708	valores 328 B, índices de columna 328 B, punteros de fila 52 B (densa: 2976 B)
texto	TF-IDF (dispersa)	12 x 62, 82 no nulos	708	valores 328 B, índices de columna 328 B, punteros de fila 52 B (densa: 2976 B)
texto	BGE-M3 denso	12 x 1024	49152	
sonido	MFCC 26	12 x 26	1248	
sonido	MFCC 39 (secuencias)	2160 cuadros x 39	336960	suma de los cuadros de los 12 archivos
sonido	wav2vec2 media	12 x 768	36864	
sonido	wav2vec2 media y desvío	12 x 1536	73728	

Lo más grande son los píxeles, 10838016 bytes (10.3 MB) para 18 fotos, unos 588 KB por foto. Las matrices de bolsa de palabras y TF-IDF tienen 82 valores no nulos de 744, así que guardadas como dispersas ocupan 708 bytes contra 2976 si fueran densas. Las secuencias MFCC suman los cuadros de los 12 audios y ocupan 270 veces más que el resumen de 26 valores. El tamaño de los modelos es otra cosa y no depende de la colección: ResNet50 tiene 25557032 parámetros (97.5 MB), BGE-M3 567754752 (2165.8 MB) y wav2vec2-base 94371712 (360.0 MB), mucho más que cualquier colección de descriptores de este trabajo.

e) Imagen: ResNet50 layer4 con coseno. Empata con píxeles en P@3 (0.4444), pero píxeles necesita 150528 valores por foto y solo funciona si el objeto está en el mismo lugar y del mismo tamaño, mientras que layer4 usa 2048 valores, reconoce el objeto en algunos casos aunque cambie el fondo y toleró el cambio de brillo y el ruido. Su costo es pasar cada foto por la red una vez. Su limitación es que casi no tiene en cuenta el color y que un fondo con textura fuerte, como el mantel, todavía le pesa mucho.

Texto: BGE-M3 denso con coseno. Es el único que resuelve la paráfrasis de Q2 y llega al máximo posible en las seis consultas. La base se codifica una sola vez y cada consulta tarda unas decenas de milisegundos en CPU, que es aceptable para un portal de soporte. La limitación es el tamaño del modelo y que no se puede explicar por qué un documento quedó cerca, cosa que con TF-IDF sí se puede. Si el costo fuera un problema, TF-IDF es la alternativa razonable porque falla solo en Q2.

Sonido: MFCC 26 con euclidiana. Acierta lo mismo que DTW (12 de 12) con una fracción del costo, en almacenamiento y sobre todo en comparación. La limitación es que descarta el orden, así que dos frases con las mismas palabras en distinto orden quedarían muy cerca, y con una sola voz sintetizada el problema es más fácil de lo que sería con grabaciones reales.

Un error que no se arregla cambiando la distancia: IMG_O1_Q (aro rojo) recupera primero el aro azul con layer4 y el morrón rojo sobre el mismo escritorio con histograma. El problema está en lo que guarda cada vector (layer4 casi no guarda el color y el histograma no guarda la forma y mezcla el objeto con el fondo), y eso no cambia midiendo con otra función. En píxeles se ve claro: coseno y euclidiana dan exactamente el mismo ranking. Habría que cambiar la representación, por ejemplo recortar el objeto antes de describirlo o combinar layer4 con un descriptor de color.

Anexo. Resultados por consulta y representación

Top 3 con su distancia, relevantes entre los 3, P@3, R@3 y por qué cada resultado sirve o no. Se omiten los prefijos IMG_ y SON_ de los IDs.

Representación	Consulta	Top 3 (distancia)	Rel.	P@3	R@3	Por qué
píxeles + coseno	O1_Q	O1_B1 (0.0689), O1_B3 (0.0746), O1_B2 (0.0811)	3	1.0000	1.0000	O1_B1: sí, otra foto del mismo objeto O1_B3: sí, otra foto del mismo objeto O1_B2: sí, otra foto del mismo objeto
píxeles + coseno	O2_Q	O2_B2 (0.0332), O5_B3 (0.0341), O6_B2 (0.0359)	1	0.3333	0.3333	O2_B2: sí, otra foto del mismo objeto O5_B3: no, es el barco azul, comparte el color y el fondo (pared) O6_B2: no, es el barco verde, comparte el fondo (pared)
píxeles + coseno	O3_Q	O3_B1 (0.0735), O4_B3 (0.0755), O1_B2 (0.0814)	1	0.3333	0.3333	O3_B1: sí, otra foto del mismo objeto O4_B3: no, es el morrón verde, comparte la forma y el fondo (mantel) O1_B2: no, es el aro rojo, comparte el color y el fondo (mantel)
píxeles + coseno	O4_Q	O4_B2 (0.0725), O3_B3 (0.0911), O6_B2 (0.1080)	1	0.3333	0.3333	O4_B2: sí, otra foto del mismo objeto O3_B3: no, es el morrón rojo, comparte la forma y el fondo (madera) O6_B2: no, es el barco verde, comparte el color
píxeles + coseno	O5_Q	O5_B3 (0.0378), O2_B3 (0.0475), O2_B2 (0.0559)	1	0.3333	0.3333	O5_B3: sí, otra foto del mismo objeto O2_B3: no, es el aro azul, comparte el color y el fondo (escritorio) O2_B2: no, es el aro azul, comparte el color
píxeles + coseno	O6_Q	O6_B2 (0.0248), O2_B2 (0.0381), O5_B3 (0.0441)	1	0.3333	0.3333	O6_B2: sí, otra foto del mismo objeto O2_B2: no, es el aro azul, comparte el fondo (pared) O5_B3: no, es el barco azul, comparte la forma y el fondo (pared)
píxeles + euclidiana	O1_Q	O1_B1 (0.3712), O1_B3 (0.3863), O1_B2 (0.4028)	3	1.0000	1.0000	O1_B1: sí, otra foto del mismo objeto O1_B3: sí, otra foto del mismo objeto O1_B2: sí, otra foto del mismo objeto
píxeles + euclidiana	O2_Q	O2_B2 (0.2575), O5_B3 (0.2612), O6_B2 (0.2678)	1	0.3333	0.3333	O2_B2: sí, otra foto del mismo objeto O5_B3: no, es el barco azul, comparte el color y el fondo (pared) O6_B2: no, es el barco verde, comparte el fondo (pared)
píxeles + euclidiana	O3_Q	O3_B1 (0.3833), O4_B3 (0.3887), O1_B2 (0.4035)	1	0.3333	0.3333	O3_B1: sí, otra foto del mismo objeto O4_B3: no, es el morrón verde, comparte la forma y el fondo (mantel) O1_B2: no, es el aro rojo, comparte el color y el fondo (mantel)
píxeles + euclidiana	O4_Q	O4_B2 (0.3809), O3_B3 (0.4269), O6_B2 (0.4648)	1	0.3333	0.3333	O4_B2: sí, otra foto del mismo objeto O3_B3: no, es el morrón rojo, comparte la forma y el fondo (madera) O6_B2: no, es el barco verde, comparte el color
píxeles + euclidiana	O5_Q	O5_B3 (0.2748), O2_B3 (0.3081), O2_B2 (0.3345)	1	0.3333	0.3333	O5_B3: sí, otra foto del mismo objeto O2_B3: no, es el aro azul, comparte el color y el fondo (escritorio) O2_B2: no, es el aro azul, comparte el color
píxeles + euclidiana	O6_Q	O6_B2 (0.2228), O2_B2 (0.2761), O5_B3 (0.2971)	1	0.3333	0.3333	O6_B2: sí, otra foto del mismo objeto O2_B2: no, es el aro azul, comparte el fondo (pared) O5_B3: no, es el barco azul, comparte la forma y el fondo (pared)
histograma + coseno	O1_Q	O3_B2 (0.0651), O4_B1 (0.6592), O1_B2 (0.9246)	1	0.3333	0.3333	O3_B2: no, es el morrón rojo, comparte el color y el fondo (escritorio) O4_B1: no, es el morrón verde, comparte el fondo (escritorio) O1_B2: sí, otra foto del mismo objeto
histograma + coseno	O2_Q	O2_B2 (0.2526), O3_B1 (0.2730), O6_B2 (0.3372)	1	0.3333	0.3333	O2_B2: sí, otra foto del mismo objeto O3_B1: no, es el morrón rojo, comparte el fondo (pared) O6_B2: no, es el barco verde, comparte el fondo (pared)
histograma + coseno	O3_Q	O5_B2 (0.3287), O1_B2 (0.3498), O3_B1 (0.5007)	1	0.3333	0.3333	O5_B2: no, es el barco azul, comparte el fondo (mantel) O1_B2: no, es el aro rojo, comparte el color y el fondo (mantel) O3_B1: sí, otra foto del mismo objeto
histograma + coseno	O4_Q	O4_B2 (0.0823), O5_B1 (0.3910), O1_B1 (0.4159)	1	0.3333	0.3333	O4_B2: sí, otra foto del mismo objeto O5_B1: no, es el barco azul, comparte el fondo (madera) O1_B1: no, es el aro rojo, comparte el fondo (madera)
histograma + coseno	O5_Q	O3_B2 (0.0621), O4_B1 (0.6555), O2_B3 (0.9358)	0	0.0000	0.0000	O3_B2: no, es el morrón rojo, comparte el fondo (escritorio) O4_B1: no, es el morrón verde, comparte el fondo (escritorio) O2_B3: no, es el aro azul, comparte el color y el fondo (escritorio)

Representación	Consulta	Top 3 (distancia)	Rel.	P@3	R@3	Por qué
histograma + coseno	O6_Q	O3_B1 (0.2489), O2_B2 (0.2945), O6_B2 (0.2950)	1	0.3333	0.3333	O3_B1: no, es el morrón rojo, comparte el fondo (pared) O2_B2: no, es el aro azul, comparte el fondo (pared) O6_B2: sí, otra foto del mismo objeto
histograma + euclidiana	O1_Q	O3_B2 (0.3000), O4_B1 (0.7937), O3_B1 (0.8897)	0	0.0000	0.0000	O3_B2: no, es el morrón rojo, comparte el color y el fondo (escritorio) O4_B1: no, es el morrón verde, comparte el fondo (escritorio) O3_B1: no, es el morrón rojo, comparte el color
histograma + euclidiana	O2_Q	O3_B1 (0.3438), O2_B2 (0.3827), O6_B2 (0.4416)	1	0.3333	0.3333	O3_B1: no, es el morrón rojo, comparte el fondo (pared) O2_B2: sí, otra foto del mismo objeto O6_B2: no, es el barco verde, comparte el fondo (pared)
histograma + euclidiana	O3_Q	O5_B2 (0.3501), O1_B2 (0.3695), O3_B1 (0.3925)	1	0.3333	0.3333	O5_B2: no, es el barco azul, comparte el fondo (mantel) O1_B2: no, es el aro rojo, comparte el color y el fondo (mantel) O3_B1: sí, otra foto del mismo objeto
histograma + euclidiana	O4_Q	O4_B2 (0.1912), O4_B3 (0.4489), O1_B1 (0.4532)	2	0.6667	0.6667	O4_B2: sí, otra foto del mismo objeto O4_B3: sí, otra foto del mismo objeto O1_B1: no, es el aro rojo, comparte el fondo (madera)
histograma + euclidiana	O5_Q	O3_B2 (0.3349), O4_B1 (0.8371), O4_B3 (0.9401)	0	0.0000	0.0000	O3_B2: no, es el morrón rojo, comparte el fondo (escritorio) O4_B1: no, es el morrón verde, comparte el fondo (escritorio) O4_B3: no, es el morrón verde, no comparte color, forma ni fondo
histograma + euclidiana	O6_Q	O3_B1 (0.3486), O2_B2 (0.4212), O6_B2 (0.4228)	1	0.3333	0.3333	O3_B1: no, es el morrón rojo, comparte el fondo (pared) O2_B2: no, es el aro azul, comparte el fondo (pared) O6_B2: sí, otra foto del mismo objeto
ResNet layer2 + coseno	O1_Q	O3_B2 (0.0087), O4_B1 (0.0136), O6_B3 (0.0144)	0	0.0000	0.0000	O3_B2: no, es el morrón rojo, comparte el color y el fondo (escritorio) O4_B1: no, es el morrón verde, comparte el fondo (escritorio) O6_B3: no, es el barco verde, comparte el fondo (escritorio)
ResNet layer2 + coseno	O2_Q	O2_B2 (0.0016), O6_B2 (0.0102), O5_B3 (0.0110)	1	0.3333	0.3333	O2_B2: sí, otra foto del mismo objeto O6_B2: no, es el barco verde, comparte el fondo (pared) O5_B3: no, es el barco azul, comparte el color y el fondo (pared)
ResNet layer2 + coseno	O3_Q	O1_B2 (0.0078), O5_B2 (0.0116), O4_B3 (0.0140)	0	0.0000	0.0000	O1_B2: no, es el aro rojo, comparte el color y el fondo (mantel) O5_B2: no, es el barco azul, comparte el fondo (mantel) O4_B3: no, es el morrón verde, comparte la forma y el fondo (mantel)
ResNet layer2 + coseno	O4_Q	O4_B2 (0.0029), O3_B3 (0.0172), O1_B1 (0.0322)	1	0.3333	0.3333	O4_B2: sí, otra foto del mismo objeto O3_B3: no, es el morrón rojo, comparte la forma y el fondo (madera) O1_B1: no, es el aro rojo, comparte el fondo (madera)
ResNet layer2 + coseno	O5_Q	O6_B3 (0.0100), O2_B3 (0.0110), O4_B1 (0.0114)	0	0.0000	0.0000	O6_B3: no, es el barco verde, comparte la forma y el fondo (escritorio) O2_B3: no, es el aro azul, comparte el color y el fondo (escritorio) O4_B1: no, es el morrón verde, comparte el fondo (escritorio)
ResNet layer2 + coseno	O6_Q	O6_B2 (0.0019), O2_B2 (0.0071), O5_B3 (0.0150)	1	0.3333	0.3333	O6_B2: sí, otra foto del mismo objeto O2_B2: no, es el aro azul, comparte el fondo (pared) O5_B3: no, es el barco azul, comparte la forma y el fondo (pared)
ResNet layer4 + coseno	O1_Q	O2_B3 (0.1692), O1_B3 (0.2403), O6_B3 (0.3007)	1	0.3333	0.3333	O2_B3: no, es el aro azul, comparte la forma y el fondo (escritorio) O1_B3: sí, otra foto del mismo objeto O6_B3: no, es el barco verde, comparte el fondo (escritorio)
ResNet layer4 + coseno	O2_Q	O2_B2 (0.0610), O1_B3 (0.2529), O2_B3 (0.3279)	2	0.6667	0.6667	O2_B2: sí, otra foto del mismo objeto O1_B3: no, es el aro rojo, comparte la forma y el fondo (pared) O2_B3: sí, otra foto del mismo objeto
ResNet layer4 + coseno	O3_Q	O4_B3 (0.1885), O1_B2 (0.3189), O2_B1 (0.3306)	0	0.0000	0.0000	O4_B3: no, es el morrón verde, comparte la forma y el fondo (mantel) O1_B2: no, es el aro rojo, comparte el color y el fondo (mantel) O2_B1: no, es el aro azul, comparte el fondo (mantel)
ResNet layer4 + coseno	O4_Q	O4_B2 (0.1076), O3_B3 (0.2600), O4_B1 (0.3731)	2	0.6667	0.6667	O4_B2: sí, otra foto del mismo objeto O3_B3: no, es el morrón rojo, comparte la forma y el fondo (madera) O4_B1: sí, otra foto del mismo objeto

Representación	Consulta	Top 3 (distancia)	Rel.	P@3	R@3	Por qué
ResNet layer4 + coseno	O5_Q	O6_B3 (0.2182), O2_B3 (0.2959), O5_B3 (0.3624)	1	0.3333	0.3333	O6_B3: no, es el barco verde, comparte la forma y el fondo (escritorio) O2_B3: no, es el aro azul, comparte el color y el fondo (escritorio) O5_B3: sí, otra foto del mismo objeto
ResNet layer4 + coseno	O6_Q	O6_B2 (0.0998), O5_B3 (0.3450), O6_B1 (0.3527)	2	0.6667	0.6667	O6_B2: sí, otra foto del mismo objeto O5_B3: no, es el barco azul, comparte la forma y el fondo (pared) O6_B1: sí, otra foto del mismo objeto
bolsa de palabras + coseno	Q1	D01 (0.2929), D03 (0.8110), D02 (0.8333)	2	0.6667	1.0000	D01: sí, habla de recuperar una contraseña olvidada D03: no, habla de cambiar una contraseña que se conoce D02: sí, habla de pedir un enlace para recuperar la clave
bolsa de palabras + coseno	Q2	D02 (0.5000), D05 (0.8110), D09 (0.8232)	1	0.3333	0.5000	D02: sí, habla de pedir un enlace para recuperar la clave D05: no, habla de la duración del préstamo de libros D09: no, habla de el curso de Python sin requisitos
bolsa de palabras + coseno	Q3	D04 (0.5286), D05 (0.5636), D01 (1.0000)	2	0.6667	1.0000	D04: sí, habla de el préstamo de libros a domicilio por siete días D05: sí, habla de la duración del préstamo de libros D01: no, habla de recuperar una contraseña olvidada
bolsa de palabras + coseno	Q4	D08 (0.4000), D07 (0.4523), D09 (0.6838)	2	0.6667	1.0000	D08: sí, habla de los requisitos para inscribirse en C++ D07: sí, habla de los requisitos del curso de C++ D09: no, habla de el curso de Python sin requisitos
bolsa de palabras + coseno	Q5	D10 (0.3876), D09 (0.4697), D07 (0.5918)	2	0.6667	1.0000	D10: sí, habla de el curso de Python para quien nunca programó D09: sí, habla de el curso de Python sin requisitos D07: no, habla de los requisitos del curso de C++
bolsa de palabras + coseno	Q6	D11 (0.7327), D12 (0.7327), D01 (1.0000)	2	0.6667	1.0000	D11: sí, habla de la beca de transporte D12: sí, habla de cómo pedir la ayuda para el transporte D01: no, habla de recuperar una contraseña olvidada
TF-IDF + coseno	Q1	D01 (0.2929), D03 (0.8392), D02 (0.8619)	2	0.6667	1.0000	D01: sí, habla de recuperar una contraseña olvidada D03: no, habla de cambiar una contraseña que se conoce D02: sí, habla de pedir un enlace para recuperar la clave
TF-IDF + coseno	Q2	D02 (0.5059), D05 (0.7941), D09 (0.8406)	1	0.3333	0.5000	D02: sí, habla de pedir un enlace para recuperar la clave D05: no, habla de la duración del préstamo de libros D09: no, habla de el curso de Python sin requisitos
TF-IDF + coseno	Q3	D04 (0.5444), D05 (0.5820), D01 (1.0000)	2	0.6667	1.0000	D04: sí, habla de el préstamo de libros a domicilio por siete días D05: sí, habla de la duración del préstamo de libros D01: no, habla de recuperar una contraseña olvidada
TF-IDF + coseno	Q4	D08 (0.4589), D07 (0.5109), D09 (0.7471)	2	0.6667	1.0000	D08: sí, habla de los requisitos para inscribirse en C++ D07: sí, habla de los requisitos del curso de C++ D09: no, habla de el curso de Python sin requisitos
TF-IDF + coseno	Q5	D10 (0.4370), D09 (0.5274), D07 (0.6492)	2	0.6667	1.0000	D10: sí, habla de el curso de Python para quien nunca programó D09: sí, habla de el curso de Python sin requisitos D07: no, habla de los requisitos del curso de C++
TF-IDF + coseno	Q6	D11 (0.7221), D12 (0.7221), D01 (1.0000)	2	0.6667	1.0000	D11: sí, habla de la beca de transporte D12: sí, habla de cómo pedir la ayuda para el transporte D01: no, habla de recuperar una contraseña olvidada
BGE-M3 denso + coseno	Q1	D02 (0.2256), D01 (0.2264), D03 (0.2927)	2	0.6667	1.0000	D02: sí, habla de pedir un enlace para recuperar la clave D01: sí, habla de recuperar una contraseña olvidada D03: no, habla de cambiar una contraseña que se conoce
BGE-M3 denso + coseno	Q2	D02 (0.1821), D01 (0.3752), D03 (0.4113)	2	0.6667	1.0000	D02: sí, habla de pedir un enlace para recuperar la clave D01: sí, habla de recuperar una contraseña olvidada D03: no, habla de cambiar una contraseña que se conoce
BGE-M3 denso + coseno	Q3	D04 (0.2739), D05 (0.3584), D06 (0.4920)	2	0.6667	1.0000	D04: sí, habla de el préstamo de libros a domicilio por siete días D05: sí, habla de la duración del préstamo de libros D06: no, habla de el horario de la sala de lectura
BGE-M3 denso + coseno	Q4	D08 (0.2570), D07 (0.3062), D09 (0.4746)	2	0.6667	1.0000	D08: sí, habla de los requisitos para inscribirse en C++ D07: sí, habla de los requisitos del curso de C++ D09: no, habla de el curso de Python sin requisitos
BGE-M3 denso + coseno	Q5	D10 (0.2470), D09 (0.2500), D07 (0.4776)	2	0.6667	1.0000	D10: sí, habla de el curso de Python para quien nunca programó D09: sí, habla de el curso de Python sin requisitos D07: no, habla de los requisitos del curso de C++
BGE-M3 denso + coseno	Q6	D11 (0.3527), D12 (0.4387), D04 (0.5767)	2	0.6667	1.0000	D11: sí, habla de la beca de transporte D12: sí, habla de cómo pedir la ayuda para el transporte D04: no, habla de el préstamo de libros a domicilio por siete días

Representación	Consulta	Top 3 (distancia)	Rel.	P@3	R@3	Por qué
MFCC 26 + euclidiana	F1_Q	F1_B1 (2.4324), F1_B2 (4.3204), F1_B3 (5.5605)	3	1.0000	1.0000	F1_B1: sí, otra grabación de la misma frase F1_B2: sí, otra grabación de la misma frase F1_B3: sí, otra grabación de la misma frase
MFCC 26 + euclidiana	F2_Q	F2_B2 (2.4336), F2_B1 (2.7261), F2_B3 (3.3833)	3	1.0000	1.0000	F2_B2: sí, otra grabación de la misma frase F2_B1: sí, otra grabación de la misma frase F2_B3: sí, otra grabación de la misma frase
MFCC 26 + euclidiana	F3_Q	F3_B3 (2.4876), F3_B2 (2.8450), F3_B1 (3.1774)	3	1.0000	1.0000	F3_B3: sí, otra grabación de la misma frase F3_B2: sí, otra grabación de la misma frase F3_B1: sí, otra grabación de la misma frase
MFCC 26 + euclidiana	F4_Q	F4_B2 (1.8130), F4_B3 (2.8594), F4_B1 (3.2507)	3	1.0000	1.0000	F4_B2: sí, otra grabación de la misma frase F4_B3: sí, otra grabación de la misma frase F4_B1: sí, otra grabación de la misma frase
MFCC 39 + DTW	F1_Q	F1_B1 (424.2882), F1_B2 (482.8105), F1_B3 (538.1541)	3	1.0000	1.0000	F1_B1: sí, otra grabación de la misma frase F1_B2: sí, otra grabación de la misma frase F1_B3: sí, otra grabación de la misma frase
MFCC 39 + DTW	F2_Q	F2_B1 (480.2789), F2_B2 (508.6463), F2_B3 (576.0188)	3	1.0000	1.0000	F2_B1: sí, otra grabación de la misma frase F2_B2: sí, otra grabación de la misma frase F2_B3: sí, otra grabación de la misma frase
MFCC 39 + DTW	F3_Q	F3_B1 (436.5398), F3_B2 (446.7869), F3_B3 (490.3972)	3	1.0000	1.0000	F3_B1: sí, otra grabación de la misma frase F3_B2: sí, otra grabación de la misma frase F3_B3: sí, otra grabación de la misma frase
MFCC 39 + DTW	F4_Q	F4_B1 (470.4769), F4_B2 (477.5568), F4_B3 (558.7093)	3	1.0000	1.0000	F4_B1: sí, otra grabación de la misma frase F4_B2: sí, otra grabación de la misma frase F4_B3: sí, otra grabación de la misma frase
wav2vec2 media + coseno	F1_Q	F1_B1 (0.0302), F1_B2 (0.0430), F2_B2 (0.0519)	2	0.6667	0.6667	F1_B1: sí, otra grabación de la misma frase F1_B2: sí, otra grabación de la misma frase F2_B2: no, es F2, cambia abre por cierra
wav2vec2 media + coseno	F2_Q	F2_B1 (0.0366), F2_B2 (0.0381), F2_B3 (0.0831)	3	1.0000	1.0000	F2_B1: sí, otra grabación de la misma frase F2_B2: sí, otra grabación de la misma frase F2_B3: sí, otra grabación de la misma frase
wav2vec2 media + coseno	F3_Q	F3_B2 (0.0343), F3_B3 (0.0479), F3_B1 (0.0526)	3	1.0000	1.0000	F3_B2: sí, otra grabación de la misma frase F3_B3: sí, otra grabación de la misma frase F3_B1: sí, otra grabación de la misma frase
wav2vec2 media + coseno	F4_Q	F4_B2 (0.0264), F4_B1 (0.0440), F4_B3 (0.0463)	3	1.0000	1.0000	F4_B2: sí, otra grabación de la misma frase F4_B1: sí, otra grabación de la misma frase F4_B3: sí, otra grabación de la misma frase
wav2vec2 media y desvío + coseno	F1_Q	F1_B1 (0.0068), F1_B2 (0.0087), F2_B2 (0.0117)	2	0.6667	0.6667	F1_B1: sí, otra grabación de la misma frase F1_B2: sí, otra grabación de la misma frase F2_B2: no, es F2, cambia abre por cierra
wav2vec2 media y desvío + coseno	F2_Q	F2_B1 (0.0073), F2_B2 (0.0074), F2_B3 (0.0160)	3	1.0000	1.0000	F2_B1: sí, otra grabación de la misma frase F2_B2: sí, otra grabación de la misma frase F2_B3: sí, otra grabación de la misma frase
wav2vec2 media y desvío + coseno	F3_Q	F3_B2 (0.0076), F3_B3 (0.0107), F3_B1 (0.0117)	3	1.0000	1.0000	F3_B2: sí, otra grabación de la misma frase F3_B3: sí, otra grabación de la misma frase F3_B1: sí, otra grabación de la misma frase
wav2vec2 media y desvío + coseno	F4_Q	F4_B2 (0.0059), F4_B1 (0.0093), F4_B3 (0.0101)	3	1.0000	1.0000	F4_B2: sí, otra grabación de la misma frase F4_B1: sí, otra grabación de la misma frase F4_B3: sí, otra grabación de la misma frase