Apunte Investigación Operativa

Tobias Grandi

March 2024

1 Construcción de modelos de optimización

Un modelo de optimización dicta el comportamiento para una organización que le permitirá alcanzar mejor sus metas. Para esto, trata de encontrar valores que optimicen (maximicen o minimicen) una función objetivo que satisfagan las restricciones dadas.

1.1 Elementos de un modelo de optimización

1. *Función(es) objetivo*

   Es la función que se desea optimizar, ya sea maximizar o minimizar. En la mayoría de casos, esta función está sujeta a restricciones que deben cumplirse.

2. *Variables de decisión*

   Son variables cuyos valores están bajo nuestro control e influyen en el desempeño del sistema. Se debe hallar el o los valores que optimicen nuestra función objetivo.

3. *Restricciones*

   Son las restricciones a las que están sujetas las variables de decisión. Son condiciones que limitan las soluciones factibles. Si una solución cumple estas condiciones, entonces se la considera solución válida y se encuentra dentro de la región factible.

1.2 Tipos de modelos

1.2.1 Modelos estáticos y dinámicos

1. *Modelos estáticos*

   Se ocupan de determinar una respuesta para una serie de condiciones fijas que no cambiarán significativamente a corto plazo. La solución está basada en una condición estática.

2. *Modelos dinámicos*

   Se ocupan de determinar una respuesta para una serie de condiciones fijas que cambiarán con el tiempo, factor que juega un rol importante en este tipo de modelos.

1.2.2 Modelos lineales y no lineales

1. *Modelos lineales*

   La función objetivo es lineal.

2. *Modelos no lineales*

   La función objetivo es no lineal.

1.2.3 Modelos enteros y no enteros

1. *Modelos enteros*

   Una o más variables de decisión solo toman valores enteros.

2. *Modelos no enteros*

   Todas las variables de decisión pueden tomar tanto valores enteros como no enteros.

1.2.4 Modelos determinísticos y estadístas

1. *Modelos determinísticos*

   Para cualquier valor de las variables de decisión se conoce con certeza el valor de la función objetivo y si las restricciones se cumplen o no. No hay incertidumbre sobre las entradas del modelo y los resultados son constantes y predecibles.

2. *Modelos estadístas*

   Se incorpora la incertidumbre y la variabilidad en las entradas del modelo. Se utilizan distribuciones de probabilidad para representar la aleatoriedad en los datos.

1.3 Construcción del modelo

1. *Actividades*

   Se comienza identificando las distintas actividades que se realizan en el problema dado

2. *Variables de decisión*

   Identificar las variables de decisión $(x_1, x_2, ..., x_n)$ que afectan en qué medida se realizan las actividades

3. *Parámetros*

   Hallar los parámetros del problema. Son valores que permiten ajustar el modelo a una situación particular (precios, cantidad de materia prima por unidad, tiempo de fabricado por unidad, etc.)

4. *Restricciones*

   Hallar las condiciones que limitan las soluciones factibles del problema. Serán condiciones a las que estará sujeta la función objetivo al momento de optimizarla. Pueden ser limitaciones de recursos, de capacidad, de tiempo, etc.

5. *Función objetivo*

   Hallar la función objetivo, aquella que deberá ser maximizada o minimizada según el contexto del problema.

1.4 Formas de representación de modelos

Existen distintas formas de representar un mismo modelo. Dependiendo el contexto, será útil utilizar una u otra forma.

Dado un problema con n variables de decisión $x_1, x_2, ..., x_n$ y m restricciones, se modela:

1.4.1 Modelo en forma canónica

Un modelo se encuentra en forma canónica si las restricciones son ecuaciones o inecuaciones.

$$\max[\min]\ Z = c_1x_1 + c_2x_2 + \cdots + c_nx_n$$

Sujeto a

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &\leq [\geq; =] b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &\leq [\geq; =] b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &\leq [\geq; =] b_m \\ x_1, x_2, \ldots, x_n, &\geq 0 \end{aligned}$$

1.4.2 Modelo en forma estándar

Un modelo se encuentra en su forma estándar si:

1. Todas las variables son no negativas.
2. Todas las restricciones son igualdades.
3. Todos los términos independientes de las restricciones son no negativos.

$$\max[\min]\ Z = c_1x_1 + c_2x_2 + \cdots + c_nx_n + 0x_{n+1} + \cdots + 0x_{n+m}$$

Sujeto a

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \pm x_{n+1} &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \pm x_{n+2} &= b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \pm x_{n+m} &= b_m \\ x_1, x_2, \ldots, x_n, x_{n+1}, x_{n+2}, \ldots, x_{n+m} &\geq 0 \end{aligned}$$

Donde:

- $x_{n+1}, x_{n+2}, \ldots, x_{n+m}$ son *variables slack* o *variables de excedente*, dependiendo el tipo de restricción.

1.4.3 Modelo en forma matricial

Un modelo se encuentra en su forma matricial si, dado el modelo en formato estandar, se escribe de la siguiente manera:

$$\max[\min]\ Z = C\mathbf{x}$$

Sujeto a

$$A\mathbf{x} = \mathbf{b}$$

$$\mathbf{x} \geq 0$$

Donde:

$$C = \begin{bmatrix} c_1 & c_2 & \ldots & c_n & c_{n+1} & \ldots & c_{n+m} \end{bmatrix} \qquad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ x_{n+1} \\ x_{n+2} \\ \vdots \\ x_{n+m} \end{bmatrix}$$

$$A = \begin{bmatrix} a_{11} & a_{12} & \ldots & a_{1n} & 1 & 0 & \ldots & 0 \\ a_{21} & a_{22} & \ldots & a_{2n} & 0 & 1 & \ldots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \ldots & a_{mn} & 0 & 0 & \ldots & 1 \end{bmatrix} \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

Notar que la matriz identidad incluída dentro de A corresponde a las variables slack o de excedente, si existieran.

1.4.4 Convertir modelo de forma canónica a estándar

1. Convertir cada restricción en una igualdad.
2. Agregar una *variable slack o variable excedente* con restricción de no negatividad por cada restricción convertida en igualdad. También entrará a la función objetivo con coeficiente 0.
    - El signo de cada variable de slack o de excedente estará dado por el tipo de restricción. Será positiva si la restricción corresponde a $\leq$ (*variable slack*) o negativa si corresponde a $\geq$ (*variable de excedente*).

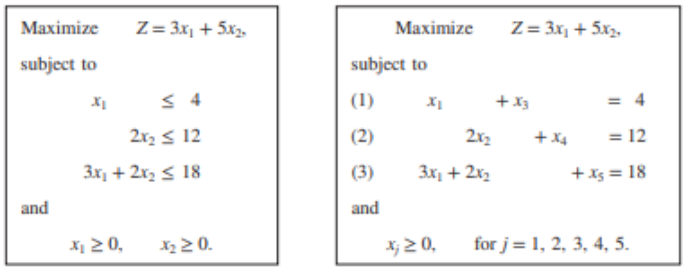


Figure 1: Forma canónica (izquierda) vs Forma estándar (derecha)

1.4.5 Modelo en forma tabular

Representar el modelo en formato de tabla

			c_1	c_2	$\dots$	c_n	
c_{bk}	x_{bk}	b_k	A_1	A_2	$\cdots$	A_n	θ
c_{b1}	x_{b1}	b_1	a_{11}	a_{12}	$\cdots$	a_{1n}	θ_1
c_{b2}	x_{b2}	b_2	a_{21}	a_{22}	$\cdots$	a_{2n}	θ_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
c_{bm}	x_{bm}	b_m	a_{m1}	a_{m2}	$\cdots$	a_{mn}	θ_m
$Z = \sum_{i=1}^{m} c_{bi}x_{bi}$			$z_1 - c_1$	$z_2 - c_2$	$\dots$	$z_n - c_n$	

Donde:

- c_{bk} es la columna de los coeficientes de las m variables básicas.
- x_{bk} es la columna de las m variables básicas.
- b_k es la columna de los m valores de restricciones (Términos independientes de las ecuaciones).
- $c_1, c_2, \dots, c_n$ son los valores de los coeficientes de las n variables básicas.

- A_n es la columna que contiene los coeficientes que acompañan a la variable n en las m restricciones.
- a_{mn} es el valor del coeficiente que acompaña a la variable n en la restricción m.
- Z es el valor de la función en la solución actual.
- z_n se define como $\sum_{i=1}^{m} c_{bi}a_{in}$. Se puede pensar como el producto punto (producto escalar) entre los vectores c_{bk} y A_n.
- $z_n - c_n$ también llamado *renglón cero*. Indica los costos reducidos y los precios sombra o valores marginales.
- $\theta_m = \frac{b_m}{a_{mn}} \geq 0$

1.5 Interpretación de los modelos

- Z es el valor de la función objetivo.
- x_n es la variable de decisión, que mide el nivel de la actividad n.
- $x_{n+1} \dots x_{n+m}$ son las variables slack o de excedente.
- c_n es el incremento en Z por unidad de actividad de x_n.
- b_m es la cantidad de recursos m disponibles. Término independiente de cada restricción. Aquellos b_m valores que estén en la tabla, dan el valor óptimo de actividad de las variables que están en la base (variables básicas), son los únicos $b_m \neq 0$.
- a_{mn} es la cantidad de recursos m consumidos por cada unidad de actividad n.

2 Programación Lineal

La programación lineal es una herramienta para resolver problemas de optimización. En dichos problemas de optimización, ocurre lo siguiente:

1. Se intenta maximizar (o minimizar) una función objetivo, que tiene de característica que es de tipo *lineal* y depende de las variables de decisión.
2. Los valores de las variables de decisión deben satisfacer un conjunto de *restricciones*, donde cada una de ellas es una *ecuación lineal* o una *desigualdad lineal*. No pueden existir restricciones con desigualdades estrictas ($<, >$).
3. Cada variable de decisión tiene una *restricción de no negatividad*, es decir, $x_i \geq 0$ con $i = 1, ..., n$

2.1 Supuestos básicos de la programación lineal

La programación lineal se basa en una serie de supuestos básicos que deben cumplirse para que sus técnicas y metodologías sean aplicables de manera efectiva. Se dice que un problema se puede modelar con programación lineal si cumple todos los supuestos. Mientras menos supuestos cumpla, menos preciso será el resultado obtenido por el modelado de PL.

2.1.1 Proporcionalidad

Los cambios en las variables de decisión resultan en cambios proporcionales en las funciones objetivo y las restricciones. El cambio en la actividad x_j en la función objetivo estará dado por el término $c_j x_j$, mientras que en la restricción i estará dado por el término $a_{ij} x_j$ perteneciente a ella.

2.1.2 Aditividad

La contribución tanto a la función objetivo como a las restricciones para cualquier variable de decisión es independiente de los valores de las otras variables de decisión. No importa cuál es el valor de la actividad x_i, la contribución de x_j será siempre la misma para un mismo valor de variable. Las variables solamente se suman entre sí y tienen exponente 1.

2.1.3 Divisibilidad

Todas las variables de decisión pueden asumir valores fraccionarios, caso contrario estaríamos en un problema de *programación entera*.

2.1.4 Certidumbre

El valor de cada parámetro es una constante conocida.

2.2 Terminología

- *Región factible*

  Es el conjunto de todos los puntos que satisfacen las limitaciones y las restricciones de signo del problema de programación matemática.

- *Solución factible*

  Cualquier punto que pertenezca a la región factible

- *Solución óptima*

  Un punto perteneciente a la región factible es una solución óptima si maximiza (o minimiza) la función objetivo. Las soluciones óptimas siempre se encontrarán en un punto esquina de la región factible. Un problema de programación lineal puede tener más de una solución óptima e incluso no tener en absoluto.

  La cantidad máxima de soluciones óptimas que podrá tener un PL está dada por: $C_m^n = \frac{n!}{m!(n-m)!}$

- *Restricción activa*

  Una restricción es activa u obligatoria si tanto el primer como el segundo miembro de la restricción son iguales cuando los valores óptimos de las variables de decisión se sustituyen en la restricción.

- *Valor económico*

  Una variable tiene valor económico si su coeficiente en la función objetivo es mayor que 0.

- *Valor físico*

  Una variable tiene valor físico si su coeficiente en al menos una restricción es mayor que 0.

2.3 Teoremas asociados

2.3.1 Teorema 1

El conjunto de todas las soluciones factibles a un problema de programación lineal es un conjunto convexo

2.3.2 Teorema 2

La función objetivo alcanza su máximo o mínimo en un punto extremo del conjunto convexo de soluciones factibles. Si alcanza ese máximo o mínimo en más de un punto extremo, entonces la función objetivo tiene el mismo valor para cualquier combinación convexa de esos puntos extremos.

Es decir, si se optimiza en más de un punto, entonces la función tendrá el mismo valor óptimo para cualquier punto que pertenezca a la recta que une los puntos extremos.

2.3.3 Teorema 3

Si se puede encontrar un conjunto de $k = m$ (m cantidad de restricciones) vectores $A_1, A_2, \ldots, A_k$ que es linealmente independiente y tal que $x_1A_1+x_2A_2+\cdots+x_kA_k = \mathbf{b}$ con $x_i \geq 0, i = 1 \ldots k$, entonces es un punto extremo del conjunto de soluciones posibles. X es un vector n-dimensional cuyos últimos $n-k$ elementos son 0.

Es decir, si se pueden encontrar valores para $x_1, x_2, \ldots, x_k$ tales que cumplan con $x_1A_1 + x_2A_2 + \cdots + x_kA_k = \mathbf{b}$ y con $A_1, A_2, \ldots, A_k$ linealmente independientes, entonces el punto dado por $x_1A_1 + x_2A_2 + \cdots + x_kA_k$ será una solución que optimice la función objetivo del problema. Tener en cuenta los valores de los últimos $n-k$ es 0 debido a que se trata de las *variables no básicas*.

2.3.4 Teorema 4

Si $X = (x_1, x_2, \ldots, x_n)$ es un punto extremo del conjunto convexo de soluciones del problema, entonces los vectores asociados con los componentes $x_i \geq 0$ forman un conjunto linealmente independiente.

Es decir, ninguna variable puede ser eliminada o reemplazada por una combinación del resto. Cada variable contribuye de manera única y necesaria al punto extremo.

2.3.5 Teorema 5

$X = (x_1, x_2, \ldots, x_n)$ es un punto extremo conjunto convexo de soluciones del problema si y sólo si las componentes $x_i \geq 0$ están asociadas con vectores linealmente independientes tales que $\sum_{j=1}^{n} x_jA_j = \mathbf{b}$.

2.4 Métodos de resolución

2.4.1 Método Gráfico

La solución gráfica sólo es factible si se tratase de un problema con hasta dos variables de decisión, esto se debe a que a mayor número de variables se vuelve imposible de graficar la región factible.

El método se basa en dos pasos:

1. *Determinar la región factible*

   Para ello, se deben graficar las inecuaciones pertenecientes a las restricciones y hallar aquella área donde todas se satisfacen al mismo tiempo.

2. *Determinar la solución óptima entre todos los puntos localizados en la región factible*

   Para ello se graficará una recta en la que todos los puntos tengan el mismo valor Z, llamada *recta de isoutilidad*, para problemas de maximización (*recta de isocostos*, para problemas de minimización). Es decir,

se le da un valor arbitrario a Z y se grafica la recta. Luego hay que desplazar la recta (con distintos valores de Z) hasta hallar la última que toque la región factible en un solo punto esquina (recordar que los valores óptimos siempre se encuentran en puntos esquina), en este punto se habrá alcanzado el valor óptimo de Z y deberemos calcular el valor de las variables de manera algebráica para conocer cuáles la optimizan. Por otro lado, en un problema de minimización, habrá que buscar la primera recta que toque la región factible en un solo punto esquina.

Notar que para cualquier valor de Z la recta siempre tendrá la misma pendiente, por lo que todas las rectas posibles serán paralelas. Esto significa que una vez trazada la primera, es posible encontrar todas las otras desplazándose de forma paralela a esta.

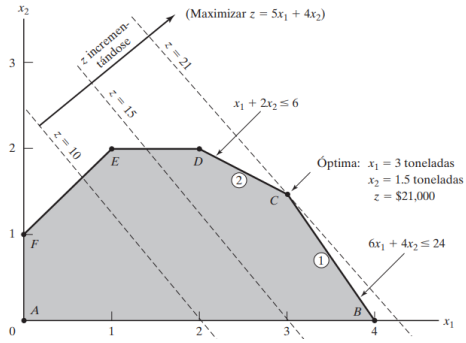


Figure 2: Gráfica con región factible y recta de isoutilidad

2.4.2 Método Simplex

El algoritmo Simplx se usa para resolver problemas de programación lineal aún con miles de restricciones y variables. Para ello, el modelo del problema debe estar en su forma estándar.

2.4.2.1 Terminología

- *Solución básica*

  Es el conjunto de $n - m$ variables arbitrariamente elegidas (donde m es la cantidad de restricciones y n es la cantidad de variables) iguales a 0. Notar que al elegir distintas variables no básicas (iguales a 0), se obtienen distintas soluciones básicas.

- *Variables básicas*

  Son las m variables no negativas pertenecientes a la solución básica.

- *Variables no básicas*

  Son las $n-m$ variables iguales a 0 pertenecientes a la solución básica.

- *Variables reales*

  Son las variables no slack ni de excedente.

- *Matriz de la base*

  Si mi base está formada por las variables básicas x_2, x_4 y x_1, la matriz de la base será aquella cuyas columnas sean A_2, A_4 y A_1.

- *Matriz inversa de la base*

  Se le halla la inversa a la matriz de la primera solución básica factibile (primera tabla). Si en la primer tabla la matriz estaba formada por A_2, A_4 y A_1, su inversa también lo estará, pero con los vectores A pertenecientes a la tabla óptima.

- *Soluciones factibles básicas adyacentes*

  Dos soluciones factibles básicas son *adyacentes* si sus conjuntos de variables básicas tienen $m - 1$ variables básicas en común.

- *Solución factible básica*

  Cualquier solución básica en la cual todas las variables son no negativas.

- *Soluciones degeneradas*

  Un PL es degenerado si tiene por lo menos una solución factible básica en la cual una variable básica es igual a cero. Dichas soluciones son degeneradas.

- *Solución alternativa*

  Un PL tiene solución alternativa cuando se optimiza en más de un punto. La función objetivo tomará el mismo valor óptimo para todos los valores de las variables básicas que pertenezcan al segmento que une los puntos extremos. Existen más 0 en el renglón cero que variables básicas.

- *Costos reducidos*

  Enlazado a las variables reales. Indica en cuanto va a disminuir (aumentar, en problema de minimización) la función objetivo por cada unidad extra de dicha variable. También representa cuanto va a aumentar (disminuir, en problema de minimización) la función objetivo por una unidad menos de la variable. Se puede interpretar como el aumento (disminución) que hay que hacerle al coeficiente de dicha variable para que convenga producirlo.

- *Precios sombras o valores marginales*

  Enlazado a las variables no reales. Mide en cuanto va a aumentar (disminuir, en problema de minimización) la función objetivo por una unidad extra del recurso (restricción) que representa dicha variable. También representa cuanto va a disminuir (aumentar, en problema de minimización)

la función objetivo por una unidad menos del recurso. Las restricciones del tipo $\leq$ siempre tendrán un precio sombra > 0, las del tipo $\geq$ tendrán siempre un precio sombra < 0

- *Condición de optimalidad*

  El óptimo se alcanza en la iteración en la cual todos los valores del renglón creo son no negativos (no positivos, en problemas de minimización).

  Si no se alcanza un óptimo, indica qué variable no básica entra en la próxima iteración, es decir, se convierte en básica. La variable entrante será aquella cuyo valor en el renglón cero sea el mayor en valor absoluto.

- *Condición de factibilidad*

  Indica cual es la variable básica que se convierte en no básica, es decir, aquella que sale de la base en la próxima iteración. La variable de salida será aquella que tenga asociado el mínimo valor $\theta \geq 0$.

  Si existe más de un mínimo valor de θ, se debe elegir de manera arbitraria alguna forma de elegir cuál de las variables con este valor mínimo sale (Variable con mayor coeficiente, menor coeficiente, etc.), debe ser algo a mantener durante toda la ejecución del algoritmo.

2.4.2.2 Método de la M

Se utiliza cuando no es fácil encontrar una solución básica factible. Para ello, se suman *variables artificiales* al problema que, en la solución óptima, serán cero y no participarán del problema.

1. Por cada restricción de $\geq$ se agrega una variable artificial μ con su restricción de signo ≥ 0.

2. Por cada variable artificial agregada, se agrega a la función objetivo dicha variable acompañada de un coeficiente M negativo para problemas de maximización, positivo para problemas de minimización. El coeficiente se presupone un valor positivo muy grande (tener en cuenta para la condición de optimalidad). La función objetivo queda de la forma:

$$\max \ Z = c_1x_1 + c_2x_2 + \cdots + c_nx_n - M_1\mu_1 - M_2\mu_2 - \cdots - M_i\mu_i$$

2.4.2.3 Algoritmo de resolución

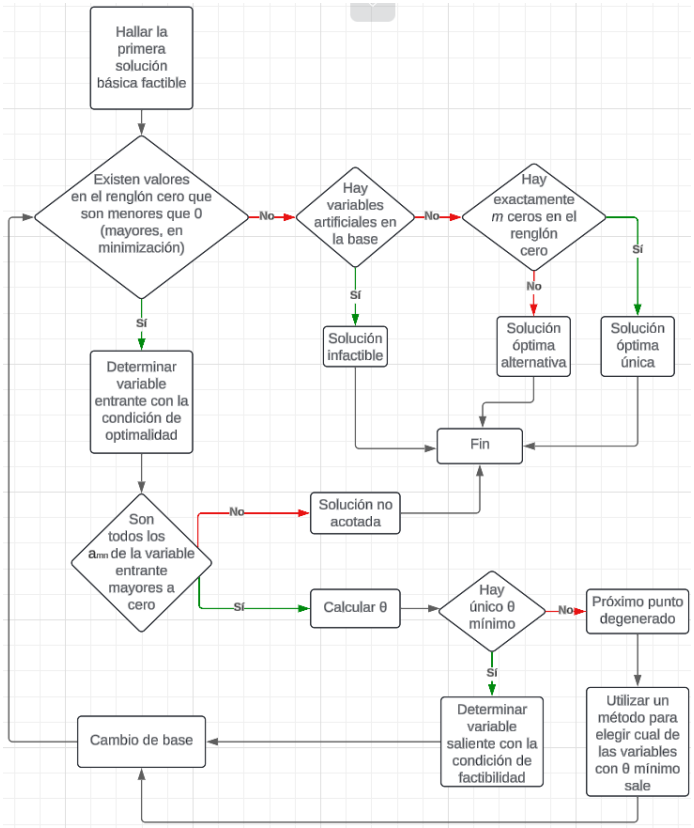


Figure 3: Diagrama de flujo algoritmo simplex

Al realizar el cambio de base, se deben volver a calcular los a_{mn} y los b_k. Para ello:

- Se elige un *pivote*, que será aquel a_{mn} que está en la fila de la variable saliente y en la columna de la variable entrante.
- Los valores a_{mn} pertenecientes a la fila del pivote, en la próxima iteración tomarán su valor dividido por el pivote. Incluido el mismo pivote que, por lo tanto, tomará valor 1.
- Los valores a_{mn} pertenecientes a la columna del pivote, pero que no son el mismo pivote, tomarán valor 0.
- Los valores a_{mn} que no pertenecen ni a la fila ni a la columna del pivote tomarán el valor de $a'_{mn} = a_{mn} - \frac{a_{me}a_{kn}}{a_{ke}}$.

  Donde:

  - a'_{mn} es el nuevo valor de a_{mn}
  - a_{mn} es el valor del elemento a transformar
  - a_{me} es el valor que está en la fila del elemento a transformar y en la columna del pivote
  - a_{kj} es el valor que está en la fila del pivote y en la columna del elemento a transformar.
  - a_{ke} es el pivote

- El b_k de la variable entrante tomará el valor del θ de la variable saliente.
- Los valores de c_{bk} tomarán siempre los valores que tienen en la función objetivo, no se modifican.
- Notar que las columnas A_n pertenecientes a las variables básicas siempre tendrán valores $a_{mn} = 1$ en la fila de la variable básica y 0 en el resto.

3 Dualidad

Asociado a cada PL primal, existe un problema dual con el que comparte ciertas características.

3.1 Hallar problema dual asociado a un primal

- El dual tiene una variable real por cada restricción del problema primal.
- El dual de un PL de maximización es un problema de minimización y viceversa.
- Los términos independientes de las restricciones del dual son los coeficientes de la función objetivo del primal.
- Los coeficientes de la función objetivo del dual son los términos independientes del primal.
- Las filas de coeficientes a_{mn} del problema dual son las columnas de coeficientes a_{mn} en el primal.
- Las desigualdades siguen las siguientes reglas según en qué forma se encuentre el PL:

CASO	FORMA	DIRECTO	DUAL	TIPO
1	CANÓNICA	MAX CX S.a $AX \leq b$ con X ≥ 0	MIN bY S.a $A^t Y \geq C$ con Y ≥ 0	SIMÉTRICO
2	CANÓNICA	MIN CX S.a $AX \geq b$ con X ≥ 0	MAX bY S.a $A^t Y \leq C$ con $Y \geq 0$	SIMÉTRICO
3	ESTÁNDAR	MAX CX S.a $AX = b$ con X ≥ 0	MIN bY S.a $A^t Y \geq C$	ASIMÉTRICO
4	ESTÁNDAR	MIN CX S.a $AX = b$ con X ≥ 0	MAX bY S.a $A^t Y \leq C$	ASIMÉTRICO

Figure 4: Reglas de pasaje PL dual

Notar que cuando se hace el pasaje desde forma estándar, las variables de decisión y no poseen restricción de signo ni de valor.

Dado un PL primal en forma canónica:

$$\max Z = c_1 x_1 + c_2 x_2 + \cdots + c_n x_n$$

Sujeto a

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &\leq b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &\leq b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &\leq b_m \\ x_1, x_2, \ldots, x_n, &\geq 0 \end{aligned}$$

Su PL dual asociado será, entonces:

$$\min Z = b_1y_1 + b_2y_2 + \cdots + b_my_m$$

Sujeto a

$$\begin{aligned} a_{11}y_1 + a_{21}y_2 + \cdots + a_{n1}y_m &\geq c_1 \\ a_{12}y_1 + a_{22}y_2 + \cdots + a_{n2}y_m &\geq c_2 \\ &\vdots \\ a_{1m}y_1 + a_{2m}x_2 + \cdots + a_{nm}y_m &\geq c_n \\ y_1, y_2, \ldots, y_m, &\geq 0 \end{aligned}$$

3.2 Teoremas asociados

3.2.1 Teorema fundamental de la dualidad

Si el PL primal tiene solución óptima finita, entonces el problema dual correspondiente a él también lo tendrá (y viceversa) y el valor de la función objetivo, en el óptimo, será el mismo para ambas funciones.

Establece, además, que si la solución del PL primal tiene solución no acotada, entonces la solución del PL dual es incompatible, y viceversa. Por otro lado, si el primal tiene solución alternativa, la solución del dual es degenerada, y viceversa.

	Primal	**Dual**
Valor en el óptimo	Valor del dual en el óptimo	Valor del primal en el óptimo
Solución	No acotada	Incompatible
Solución	Alternativa	Degenerada

Table 1: Tabla teorema fundamental de la dualidad

3.2.2 Teorema de la holgura complementaria

Siempre que en la k-ésima restricción de uno de los problemas la variable de holgura o slack tome valor distinto de cero, entonces la k-ésima variable del otro problema desaparece de la base. Por otro lado, si la k-ésima variable de uno de los dos problemas es mayor que cero, en la k-ésima restricción del otro problema la variable de slack o de holgura de esa restricción es igual a cero.

Quiere decir que siempre por cada par de variables primal-dual asociadas, una será básica (distinta de cero) y la otra será no básica (igual a cero)

3.2.3 Correspondencia de variables

- La k-ésima variable real del problema primal estará asociada a la k-ésima variable de excedente o slack del problema dual. Las variables no reales del problema dual miden el costo reducido de la actividad a la que está ligada la variable real a la que está asociada.

- La k-ésima variable no real del problema primal estará asociada a la k-ésima variable real del problema dual. Las variables reales del problema dual miden el valor marginal de la restricción a la que está ligada la variable de slack o excedente a la que está asociada.

3.2.4 Valores en el óptimo en el dual sabiendo el primal

Conociendo el renglón cero de la solución óptima del PL primal podemos conocer los valores de las variables el óptimo de la solución dual.

Basándonos en la correspondencia de variables, el valor del renglón cero de cada variable en el PL primal en la solución óptima nos dará el valor que tomará su variable asociada (real o no) en el óptimo del problema dual.

3.3 Pasaje en modo tabular

La tabla se arma de la misma manera teniendo en cuenta las consideraciones anteriores. Se puede armar la tabla de la última iteración del PL dual sabiendo la tabla de la última iteración del PL primal, teniendo en cuenta lo siguiente:

- Cada valor a_{nk} estará en la fila de una variable básica x_i y en la columna de una variable no básica x_k. Si cada una de estas variables tienen asociadas una variable no básica y una básica y_m e y_j pertenecientes al problema dual, entonces el valor a_{nk} del problema primal ahora se encontrará en la fila de la variable básica y_m y en la columna de la variable no básica y_j, pero cambiado de signo. Tener en cuenta que x_k no debe ser una variable básica.

- Los valores a_{mn} que queden sin completar en la tabla del dual, son los correspondientes a las columnas de las variables básicas. Estas se completan sabiendo que valen 1 en la fila de la variable básica y 0 en el resto

- Cada valor del renglón cero estará asociado a una variable x_k básica en el problema primal. Dicho valor se encontrará cambiado de signo en el renglón cero de la variable y_j no básica asociada a la variable x_k.

- El valor c_{bk} (b_k, en el problema primal) de una variable básica y_k tomará el valor, con el mismo signo, de la variable no básica x_j asociada del PL primal.

- Los valores del renglón cero que falten completar son los correspondientes a las variables básicas del problema dual. Por dicho motivo, valdrán 0.

4 Análisis de sensibilidad

El análisis de sensibilidad estudia el efecto en la solución óptima con el cambio de parámetros.

4.1 Parámetros

Los parámetros que varían en el análisis de sensibilidad son:

- Los coeficientes tecnológicos a_{mn}
- Los coeficientes de la función objetivo c_n
- Los términos independientes de las restricciones b_m

4.2 Rangos

Una vez hallada la base óptima, existen ciertos rangos en los cuales los parámetros pueden variar sin cambiar dicha base. Es decir, las variables básicas seguirán siendo las mismas y con el mismo valor, pero cambiará el valor de la función objetivo en el óptimo.

4.2.1 Rangos para c_j

Si me salgo del rango de variación de c_j, entonces perderé optimidad. Es decir, fuera del rango las soluciones seguirán siendo factibles, pero no serán óptimas. Gráficamente, al variar cada c_j varía la pendiente de la recta de isoutilidad o isocostos. Cuando c_j toma el valor de uno de los extremos del rango, entonces se hallará una solución alternativa.

- Si c_j es una variable básica
  - $c_j - \left|\frac{z_n - c_n}{a_{jn}}\right| \leq c_j \leq c_j + \left|\frac{z_n - c_n}{a_{jn}}\right|$
  - Donde
    - Para problemas de maximización se buscará el mínimo cociente con $a_{jn} > 0$ para el límite inferior y con $a_{jn} < 0$ para el límite superior.
    - Para problemas de minimización se buscará el máximo cociente con $a_{jn} < 0$ para el límite inferior y con $a_{jn} > 0$ para el límite superior.
    - $a_{jn} \neq a_{jj}$
    -

	a_{jn}		$\frac{z_n - c_n}{a_{jn}}$	
	max	min	max	min
Lim inf	+	−	Mínimo	Máximo
Lim sup	−	+	Mínimo	Máximo

- Tener en cuenta que $z_n - c_n$ no es otra cosa que cualquiera de los valores del renglón cero, y a_{jn} es cualquier valor de la columna del renglón cero que se esté analizando, pero de la fila de la variable a la que se le está hallando el rango. No necesariamente $z_n - c_n$ tiene que ser el renglón cero de la variable básica a la que se le está buscando el rango (Raramente lo será, ya que su renglón cero tiene valor 0).

- Si c_j es una variable no básica
  - Maximización
    - $-\infty \leq c_j \leq c_n + (z_n - c_n)$
    - La forma de interpretar esto es que si, por ejemplo, no me conviene producir un producto, deberé aumentar su precio un cierto valor para que sí convenga. Este valor está dado por su costo reducido $z_n - c_n$, que se lo tendré que sumar a su valor actual c_n. Por otro lado, si no me conviene producirlo por su precio, puedo disminuirlo todo lo que quiera que tampoco me va a convenir $(-\infty)$.
  - Minimización
    - $c_n - (z_n - c_n) \leq c_j \leq \infty$

4.2.2 Rangos para b_m

Paso el problema a dual, donde el término independiente b_m pasa a ser un coeficiente c_m de la función objetivo. A partir de acá utilizo el planteo anterior para buscar rangos a los coeficientes funcionales. Cuando b_m toma un valor fuera del rango, entonces se comienzan a tener soluciones no factibles, gráficamente la recta de isoutilidad o isocostos no tiene intersección con la región factible.

4.3 Reoptimización

Si al cambiar los parámetros o al sumar una actividad o restricción cambia la base de la solución óptima, entonces hay que reoptimizar. Esto se realiza partiendo desde el óptimo anterior, pero con los nuevos valores.

4.4 Suma de nueva actividad (c_n)

La suma de una nueva actividad se agregará como una nueva restricción en el problema dual. En el problema primal, se agregará una nueva columna en las restricciones (Por lo tanto, en la tabla también) y un nuevo coeficiente en la función objetivo. El ingreso de la nueva actividad se hace en el PL primal.

4.4.1 Lucro cesante

Para agregar una nueva actividad, tengo que liberar recursos que se están utilizando. Para esto, tengo que verificar si realmente tengo la cantidad de recursos

disponibles para liberar. Es decir, si conviene realmente producir esta nueva actividad. Esto me lo determinará el lucro cesante.

En un problema de maximización, la valoración de los recursos para cada actividad debe ser menor que su precio de venta. Es por esto que para que me convenga producir unidades de la nueva actividad tengo que calcular la valoración de los recursos para ella, es decir, la sumatoria del producto del requerimiento (Horas) de cada recurso por unidad producida con el valor marginal de dicho recurso debe ser menor o igual al precio de venta de esta nueva actividad.

En un problema de minimización, la sumatoria anterior deberá ser mayor o igual.

Básicamente, es calcular el renglón cero en la tabla óptima del primal y ver si es $0 >$ o $0 <$. Si es negativo y es un problema de maximización, conviene realizar la nueva actividad. Si es positivo y es un problema de minimización, conviene realizar la nueva actividad. Caso contrario no sirve.

En caso de que el lucro cesante se cumpla, quiere decir que me convendrá producir la nueva actividad, por lo que la base óptima cambiará y entrará esta nueva actividad. Caso contrario, no convendrá producir la actividad ya que generará pérdidas.

4.4.2 Ingresando la nueva actividad

Si el lucro cesante se cumple, entonces hay que ingresar la nueva actividad a la tabla para luego seguir reoptimizando. Se conoce el vector A_k de la nueva actividad x_k en la primer tabla, pero se necesita el vector A_k de la tabla óptima. Para obtenerlo hay que realizarle un cambio de base. Para dicho cambio de base, se realiza el producto de la matriz inversa de la base de la tabla que tiene la primer solución básica factible (Primera tabla) con el vector A_k de la primer tabla. El vector columna resultante será el que ingresará en la tabla óptima para seguir reoptimizando.

4.5 Suma de una restricción

La suma de una restricción se agregará como una nueva variable y una nueva columna en las restricciones en el problema dual. Por lo tanto, será una nueva restricción en el problema primal.

4.5.1 Lucro cesante

Para evaluar si esta nueva restricción me cambiará la base óptima, basta con verificar si al reemplazar los valores óptimos de las variables básicas en la restricción, la misma se cumple o no. Si la restricción se cumple, entonces mi base no cambiará. En caso contrario, se deberá ingresar esta nueva variable del problema dual a la base del mismo PL dual.

4.5.2 Ingresando la nueva restricción

Como para ingresar la nueva restricción debo agregar una nueva variable al problema dual, se procede como en `4.4.2`

4.6 Relajar o estrechar restricciones

- *Relajar*

  Relajar una restricción es hacerla más fácil de cumplir. En una restricción de $\leq$ es hacer el lado derecho más grande y en una restricción de $\geq$ es hacerlo más chico. Gráficamente se agregan puntos a la región factible.

- *Estrechar*

  Estrechar una restricción es hacerla más difícil de cumplir. En una restricción de $\leq$ es hacer el lado derecho más chico y en una restricción de $\geq$ es hacerlo más grande.

4.6.1 Impacto en el valor de la función objetivo

Se puede obtener el nuevo valor Z' que tendrá la función objetivo luego de relajar o estrechar una restricción. En un problema de maximización, $Z' = Z + \Delta b_i * y_i$, y en una minimización $Z' = Z - \Delta b_i * y_i$. Es decir, se suma (resta, minimización) el producto de la variación de la restricción (Δb_i) con el valor del precio sombra (y_i) de esa misma restricción.

Cuestiones a tener en cuenta:

- b_i representa la restricción i que se está haciendo variar.
- $\Delta b_i = b_{actual} - b_{anterior}$, es decir, es la diferencia entre el valor de la restricción después del cambio y antes.
- Los signos de los precios sombra y_i se respetan. En restricciones de $\leq$ siempre serán > 0 y en las de $\geq$ serán < 0.

Teniendo en cuenta los signos de la fórmula ($+$ si es una maximización y $-$ si es minimización), de la variación de b_i y del precio sombra y_i, se puede concluir lo siguiente:

Relajar				**Estrechar**			
max		min		max		min	
$\leq$	$\geq$	$\leq$	$\geq$	$\leq$	$\geq$	$\leq$	$\geq$
$Z' > Z$	$Z' < Z$	$Z' < Z$	$Z' > Z$	$Z' < Z$	$Z' > Z$	$Z' > Z$	$Z' > Z$

5 Redes

Se basa en modelar distintas situaciones con redes para luego optimizar. Una red es un grafo (o digrafo) con ponderación y/o característica.

5.1 Terminología grafos

- *Grafo ponderado:* Un grafo es ponderado si cada una de sus aristas tiene un valor (ponderación) asociado.
- *Grafo con característica:* Un grafo con característica tiene un valor asociado a cada uno de sus vértices.
- *Camino:* Es una sucesión de vértices y aristas, que empieza y termina en vértices y cada arista incide sobre los vértices que le preceden y siguen en la secuencia.
- *Sendero:* Camino que no repite arista.
- *Trayectoria:* Sendero que no repite vértice. Camino que no repite ni vértice ni arista.
- *Camino cerrado:* Camino que empieza y termina en el mismo vértice.
- *Circuito:* Camino cerrado que no repite arista y su longitud es mayor o igual a 1.
- *Circuito simple:* Circuito que no repite vértice salvo el primero al final. Camino cerrado que no repite ni arista ni vértice, salvo el primero al final y su longitud es mayor o igual a 1.
- *Circuito de euler:* Circuito que recorre todas las aristas exactamente una vez.
- *Circuito de hamilton:* Circuito que visita todos los vértices exactamente una vez, excepto el primero que se visita dos veces (Principio y final).
- *Grafo conexo:* Un grafo es conexo si existe al menos un camino entre todos los pares de vértices.
- *Grafo simple:* Un grafo es simple si no tiene aristas paralelas ni bucles.
- *Árbol:* Es un grafo conexo y acíclico (No tiene circuito).
- *Árbol de expansión:* Es el subgrafo resultante de quitar aristas, pero no vértices tal que se forme un árbol.

5.2 Problemas clásicos de redes

5.2.1 Problema de la trayectoria más corta

Dados un digrafo ponderado simple y dos vértices del digrafo llamados inicio y fin, se busca la trayectoria desde inicio hasta fin que minimiza la suma de las ponderaciones correspondientes a los arcos de tal trayectoria.

5.2.1.1 Resolución

- Variable de decisión
  - x_{ij}: Valdrá 1 si la trayectoria recorre el arco (i, j) o 0 si no.
- Función objetivo
  - $min\ Z = \sum_{(i,j)\in A} \phi_{ij} x_{ij}$: Donde A es el conjunto de arcos y ϕ_{ij} es la ponderación del arco (i, j)
- Restricción
  - $I_d X = b$: Donde I_d es la matriz de incidencia, X es el vector compuesto por todos los x_{ij} y b es un vector de dimensión $i = cant\ nodos$ donde b_i valdrá 1 si i es el nodo de inicio, -1 si es el nodo de fin y 0 en cualquier otro caso.

5.2.2 Problema del árbol de expansión mínima

Dado un grafo ponderado, se busca el árbol de expansión cuya sumatoria de pesos sea mínima

5.2.3 Problema de flujo máximo

Dado un digrafo ponderado, donde la ponderación representa la capacidad del arco y dos vértices uno fuente y otro sumidero, se busca el flujo máximo que puede circular por la red.

5.2.3.1 Resolución

- Variable de decisión
  - x_{ij}: Que representa el flujo que pasará por cada arco (i, j) (capacidad).
- Función objetivo
  - $max\ Z = x_0$: Donde x_0 es un arco artificial que incide positivamente sobre el sumidero (nodo final) y negativamente sobre el nodo fuente (nodo inicial). Este arco tiene una capacidad muy alta, para que no sea el culpable de limitar el flujo que puede atravesar el grafo.

- Restricción
  - $x_{ij} <= C(i,j)$: Es decir, el flujo que atraviesa cada arco debe ser menor o igual a la capacidad de este arco.
  - Flujo entrante de cada nodo debe ser igual al flujo saliente de ese mismo nodo.

5.2.4 Problema de transporte

Dado un grafo bipartito ponderado y con característica, donde la ponderación representa costos y la característica representa oferta o demanda de un bien, se busca la distribución de tal bien desde los vértices denominados orígenes hacia los denominados destinos, con el costo mínimo y tal que se satisfaga toda la demanda.

5.2.4.1 Resolución

- Variable de decisión
  - x_{ij}: Que representa el número de unidades enviadas por el arco (i,j).
- Función objetivo
  - $min\ Z = \sum_{i=1}^{m} \sum_{j=1}^{n} c_{ij} x_{ij}$: Donde c_{ij} representa el costo de enviar una unidad a través del arco (i,j) y n y m son la cantidad de nodos de orígen y destino, respectivamente.
- Restricción
  - $\sum_{j=1}^{n} x_{ij} \leq s_i$: Restricción de suministro (también llamado oferta). s_i representa la cantidad de suministro (oferta) que el nodo i es capaz de dar. Representa que cada arco (i,j) no puede llevar más suministro hacia el demandante j que el que proporciona i.
  - $\sum_{i=1}^{m} x_{ij} \geq d_j$: Restricción de demanda. d_j representa la demanda que el nodo j necesita. Representa que cada arco (i,j) debe llevar desde i hacia el demandante j al menos lo mínimo que demanda, puede llevar por demás.
- Supuestos
  - Los costos son proporcionales a la cantidad que envío (No hay descuento por cantidad).
  - Distribuyo siempre el mismo bien
- Consideraciones
  - $\sum s_j < \sum d_j$: Problema infactible, la oferta no puede ser menor a la demanda.

- $\sum s_j > \sum d_j$: Hay sobrante de oferta
- $\sum s_j = \sum d_j$: Problema balanceado, las restricciones quedan con el signo =.
- Si no existe arco que vincule el ofertante a con el demandante b, creo un arco artificial con un costo muy alto, para que no sea útil utilizarlo.

5.2.5 Ruta crítica o trayectoria más larga

Dado un digrafo con característica se quiere hallar la ruta crítica (trayectoria más larga). Se utiliza para realizar la estimación de la duración de proyectos, ya que la duración es igual a la longitud de la ruta más larga a través de la red. Donde los nodos son actividades obligatorias a realizar, y ninguna actividad podrá comenzar hasta que sus actividades predecesoras hayan terminado, a su vez existe un nodo inicio y un nodo fin . Cada nodo tendrá cuatro valores asociados:

- *D:* Duración de la actividad, los nodos inicio y fin tienen duración 0. La duración no necesariamente tiene que estar en días, se pueden utilizar distintos periodos (semanas, años).
- *IC:* Tiempo de inicio más cercano para una actividad dada. Se calcula como el mayor TC de los predecesores inmediatos.
- *TC:* Tiempo de terminación más cercano para una actividad dada. Se calcula como la suma de IC y D.
- *IL:* Tiempo de inicio más lejano para una actividad dada. Representa el tiempo más lejano posible para comenzar sin retrasar la terminación del proyecto, suponiendo que no hay retrasos subsecuentes. Se calcula como la diferencia entre TL y D.
- *TL:* Tiempo de terminación mas lejano para una actividad dada. Se calcula como el IL de sus sucesores inmediatos.
- *H:* Holgura. Se calcula como la diferencia entre TL y TC o entre IL e IC, es indistinto. Indica cuánto tiempo se puede retrasar una actividad sin afectar el tiempo de finalización estimado. La trayectoria que recorre las actividades con $H = 0$ se la conoce como ruta crítica, ya que cualquier retraso a lo largo de ella afectará el tiempo estimado para el proyecto.

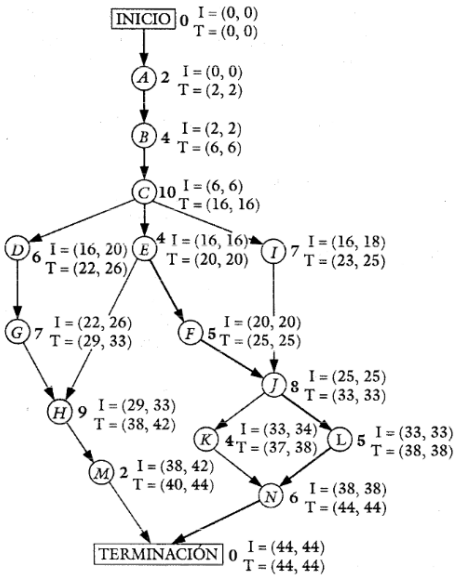


Figure 5: Ejemplo. I=(IC, IL), T=(TC, TL). Ruta crítica en negrita (**INICIO-A-B-C-E-F-J-L-N-FIN**)

6 Métodos Numéricos

6.1 Método Newton-Raphson

Es un algoritmo para encontrar aproximaciones de las raíces de una función real. También se puede usar para hallar puntos críticos de una función, encontrando las raíces de su primera derivada.

6.1.1 En una variable

Pasos:

1. Definir x_0 arbitrario.
2. Calcular $f(x_0)$.
3. Calcular la recta tangente en $f(x_0)$.
4. Hallar la raíz de la recta tangente en $f(x_0)$. Llamémosla x_1.
5. Repetir desde *2*, pero reemplazando x_0 con x_1.

Con las sucesivas iteraciones, los $f(x_n)$ calculados se aproximarán cada vez más a la raíz de $f(x)$.
Para ahorrar cálculos, de la ecuación de la recta conociendo un punto y la pendiente, se puede obtener la fórmula de recurrencia para una variable:

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

6.1.2 Multivariable

De manera generalizada, y mediante Teorema de Taylor, se puede escribir la fórmula de recurrencia generalizada:

$$x_{n+1} = x_n - \nabla f(\vec{x}) H^{-1}(\vec{x})$$

6.2 Método de la sección áurea

Método para hallar el máximo función unimodal.
La idea es que, dado un intervalo de incertidumbre (a, b), generar dos puntos pertenecientes al intervalo $x_1 = b - r(b - a)$, $x_2 = a + r(b - a)$, para algún r elegido de forma conveniente. Según los valores que tomen $f(x_1)$ y $f(x_2)$, nuestro intervalo de incertidumbre en el siguiente paso será (a, x_2) o (x_1, b). Se tomará $r = \frac{1}{\phi} = \frac{2}{1+\sqrt{5}} \approx 0,61803$, ya que es el valor que nos permitirá que x_1 coincida con el x_2 de la iteración anterior, o bien x_2 coincida con el x_1 de la iteración anterior.
Pasos:

1. Fijar $\epsilon > 0$ (error tolerado), $r = \frac{2}{1+\sqrt{5}} \approx 0,61803$. Calcular $x_1 = a + (1 - r)(b - a)$, $x_2 = a + r(b - a)$, $f(x_1)$ y $f(x_2)$.

2. Si $b - a < \epsilon$, se para. $[a, b]$ es el intervalo buscado. Caso contrario ir a 3.

3. Calcular $x_1 = b - r(b - a)$ o $x_2 = a + r(b - a)$, según corresponda.

4. Si $f(x_1) \geq f(x_2)$, entonces hacer $[a, b] = [a, x_2]$ y tener en cuenta que el próximo x_2 será igual al actual x_1, es decir, fijar $x_2 = x_1$. Volver a 2.

5. Si $f(x_1) < f(x_2)$, entonces hacer $[a, b] = [x_1, b]$ y tener en cuenta que el próximo x_1 será igual al actual x_2, es decir, fijar $x_1 = x_2$. Volver a 2.

Notar que la longitud del intervalo para la iteración k es r veces menor que la longitud del intervalo en la iteración $k - 1$. Es decir $L_k = rL_{k-1}$.
Si se quiere saber la cantidad mínima de iteraciones (n) para cumplir con el error, se puede calcular a través de $n < \log_r \frac{\epsilon}{b-a}$.

6.2.1 Función Unimodal

Una función es unimodal en un intervalo dado si y solo si presenta un único valor máximo o mínimo en dicho intervalo. Es cóncava o convexa.

6.3 Método del ascenso escalonado

Sirve para encontrar máximos o mínimos de una función. Es un método basado en el gradiente de la función a optimizar.

Como sabemos, $\nabla f(\vec{x_0})$ nos dará la dirección de mayor crecimiento de la función en el punto $\vec{x_0}$, es decir, nos indicará hacia donde hay que moverse para hallar el máximo de la función si me encuentro en el punto $\vec{x_0}$. Tomando esta idea, es lógico pensar que si constantemente me muevo en la dirección del gradiente, voy a terminar en el máximo. Esta es la idea principal del método del ascenso escalonado.

Por otro lado, $-\nabla f(\vec{x_0})$ dará la dirección de menor crecimiento de la función, es decir, indicará hacia donde hay que moverse para hallar el mínimo de la función. Se puede hacer el mismo razonamiento.
Pasos para hallar el máximo de la función:

1. Calcular $f(\vec{x_k})$ y $\nabla f(\vec{x_k})$. $\vec{x_k}$ es el punto desde donde me voy a mover.

2. Calcular el criterio de corte. Si se cumple, $\vec{x_k}$ es el extremo buscado. Uno posible es $\nabla f(\vec{x_k}) = \vec{0}$.

3. Calcular el siguiente punto dependiente de un parámetro a calcular, $\vec{x_{k+1}}(\alpha) = \vec{x_k} + \alpha \nabla f(\vec{x_k})$. Notar que el siguiente punto estará dado por el punto anterior x_k, la dirección del movimiento $\nabla f(\vec{x_k})$ y el tamaño del paso que voy a dar α.

4. El objetivo ahora es hallar α. La idea es encontrar un α que maximice el tamaño del paso que se dará a lo largo de la función $f(\vec{x})$. Por lo tanto, ahora hay que calcular:

$$\max \alpha^* = f(\vec{x_{k+1}}(\alpha)) = f(\vec{x_k} + \alpha \nabla f(\vec{x_k}))$$

Sujeto a

$$\alpha \geq 0$$

La restricción sirve para asegurarnos que nos movemos en la dirección del gradiente.
Es decir, hay que evaluar la función en el siguiente punto y maximizarla con el objetivo de encontrar α. Este paso se puede resolver mediante los criterios de derivadas o mediante métodos numéricos.

5. Calcular $\vec{x_{k+1}}(\alpha^*) = \vec{x_{k+1}} = \vec{x_k} + \alpha^* \nabla f(\vec{x_k})$ y repetir.

En el caso que se quisiera hallar el mínimo de la función en lugar del máximo, $\vec{x_{k+1}}(\alpha)$ se calculará como $\vec{x_{k+1}}(\alpha) = \vec{x_k} - \alpha \nabla f(\vec{x_k})$. Esto se debe a que hay que moverse en la dirección de $-\nabla f(\vec{x_0})$.

7 Análisis Funcional

7.1 Determinar concavidad

7.1.1 Convexidad

Una función es convexa en un intervalo $[a, b]$ si y solo si $f''(x) \geq 0$ para toda $x \in [a, b]$.
Gráficamente, una función es convexa si la gráfica de la función hace una cara contenta.

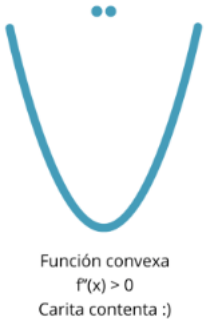


Figure 6: Función convexa

7.1.2 Cóncava

Una función es cóncava en un intervalo $[a, b]$ si y solo si $f''(x) \leq 0$ para toda $x \in [a, b]$.
Gráficamente, una función es cóncava si la gráfica de la función hace una cara triste.



Figure 7: Función cóncava

7.2 Matriz Hessiana

Es la matriz cuadrada cuyos elementos son las derivadas de segundo órden de una función multivariable

$$H(\vec{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} = \begin{bmatrix} H_{1,1} & H_{1,2} & \cdots & H_{1,n} \\ H_{2,1} & H_{2,2} & \cdots & H_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ H_{n,1} & H_{n,2} & \cdots & H_{n,n} \end{bmatrix}$$

Para el criterio de la segunda derivada, es útil considerar las submatrices angulares H_k, es decir:

$$H_1 = \begin{bmatrix} H_{1,1} \end{bmatrix}, H_2 = \begin{bmatrix} H_{1,1} & H_{1,2} \\ H_{2,1} & H_{2,2} \end{bmatrix}, H_3 = \begin{bmatrix} H_{1,1} & H_{1,2} & H_{1,3} \\ H_{2,1} & H_{2,2} & H_{2,3} \\ H_{3,1} & H_{3,2} & H_{3,3} \end{bmatrix}, H_k = \begin{bmatrix} H_{1,1} & H_{1,2} & \cdots & H_{1,k} \\ H_{2,1} & H_{2,2} & \cdots & H_{2,k} \\ \vdots & \vdots & \ddots & \vdots \\ H_{k,1} & H_{k,2} & \cdots & H_{k,k} \end{bmatrix}$$

7.2.1 Criterio de la Hessiana

Si se cumple que $\nabla f(\vec{x_0}) = 0$, entonces hay que verificar qué tipo de extremo es. Para ello se utiliza el criterio de la hessiana.

- Si todas las submatrices angulares de la matriz hessiana tienen determinante positivo en $\vec{x_0}$, entonces x_0 es un *mínimo local*.
- Si todas las submatrices angulares de la matriz hessiana tienen en $\vec{x_0}$ determinantes de signos alternados, comenzando por un valor negativo, entonces entonces x_0 es un *máximo local*.

7.3 Extremos - Condiciones analíticas de óptimo - Criterio de las derivadas

7.3.1 Una variable

1. *Condición de 1er orden*
   Para que x_0 sea un punto crítico de $f(x)$, es condición necesaria que $f'(x_0) = 0$
2. *Condición de 2do orden*
   Para que x_0 sea un máximo o mínimo de $f(x)$, es condición suficiente que $f'(x_0) = 0$ y que $f''(x_0) < 0$ para máximos o $f''(x_0) > 0$ para mínimo. Si $f''(x_0) = 0$, se utiliza el criterio de la derivada de orden superior.

- **Criterio de la derivada de orden superior**
  Si $f'(x_0) = 0$ y $f''(x_0) = 0$, entonces hay que seguir derivando hasta encontrar la primer derivada que, evaluada en x_0, sea $\neq 0$. Si la derivada número n cumplió lo anterior, entonces:
  - Si n es par, se toma el mismo criterio que para $f''(x_0)$:
    - $f^n(x_0) < 0$, entonces x_0 es un máximo local
    - $f^n(x_0) > 0$, entonces x_0 es un mínimo local
  - Si n es impar, entonces es un punto de inflexión:
    - $f^n(x_0) < 0$, entonces x_0 es un punto de inflexión decreciente
    - $f^n(x_0) > 0$, entonces x_0 es un punto de inflexión creciente

7.3.2 Multivariable

1. *Condición de 1er orden*
   Para que $\vec{x_0}$ sea un punto crítico de $f(\vec{x})$, es condición necesaria que $\nabla f(\vec{x_0}) = \vec{0}$

2. *Condición de 2do orden*
   Para la condición de segundo orden, se tiene que cumplir la de 1er orden y también utilizar algún criterio para determinar la naturaleza del punto crítico. Uno de los criterios posibles es el Criterio de la Hessiana

7.4 Multiplicadores de Lagrange

Es un método que nos permite reformular un problema de optimización con restricciones de igualdad a uno sin restricciones.
Dado el problema de maximizar o minimizar una función de n variables con m restricciones:

$$\max[\min]\ Z = f(x_1, x_2, \ldots, x_n)$$

Sujeto a

$$\begin{aligned} g_1(x_1, x_2, \ldots, x_n) &= b_1 \\ g_2(x_1, x_2, \ldots, x_n) &= b_2 \\ &\vdots \\ g_m(x_1, x_2, \ldots, x_n) &= b_m \end{aligned}$$

Se reformula el problema mediante los multiplicadores de Lagrange de la siguiente manera:

$$\max[\min]\ \lambda(\vec{x}, \vec{\lambda}) = f(\vec{x}) + \lambda_1(b_1 - g_1(\vec{x})) + \lambda_2(b_2 - g_2(\vec{x})) + \cdots + \lambda_m(b_m - g_m(\vec{x}))$$

$$= f(\vec{x}) + \sum_{i=1}^{m} \lambda_i (b_i - g_i(\vec{x}))$$

Con $\vec{x} = (x_1, x_2, \ldots, x_n)$ y $\vec{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_m)$.

Es decir, se pasa de la función $f(\vec{x})$ con m restricciones a una función $\lambda(\vec{x}, \vec{\lambda})$ sin restricciones. Esta nueva función estará dada por la suma de $f(\vec{x})$ con m términos, donde cada término corresponderá al producto de una nueva variable λ_i por la diferencia entre cada término independiente y su restricción asociada $b_i - g_i(\vec{x})$.

Para su resolución, se puede emplear el criterio de las derivadas. Cualquier punto $\vec{x_0}$ que sea un extremo de $\nabla\lambda(\vec{x}, \vec{\lambda})$ también lo será, y del mismo tipo, en $f(\vec{x})$.

Consideraciones a tener en cuenta para el criterio de las derivadas

- Condición de 1er orden
  - $\nabla\lambda(\vec{x}, \vec{\lambda}) = (\frac{\partial\lambda}{\partial x_j}, \frac{\partial\lambda}{\partial\lambda_i}) = \vec{0}$

    Donde:
    - $\frac{\partial\lambda}{\partial x_j} = \frac{\partial f}{\partial x_j} - \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j} = 0, \ \forall j = 1 \ldots n$
      - De aquí se puede ver que $\frac{\partial f}{\partial x_j} = \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j}$. Esto nos indica que las derivadas parciales de f son combinación lineal de las derivadas parciales de g.
    - $\frac{\partial\lambda}{\partial\lambda_i} = b_i - g_i(\vec{x}) = 0, \ \forall i = 1 \ldots m$
      - Es decir, las derivadas parciales de λ respecto de λ_i no es más que la diferencia entre el término independiente b_i y la restricción correspondiente g_i. Esto ahorra cálculos de derivadas.

- Condición de 2do orden
  - Para la condición de segundo orden no es necesario utilizar el hessiano de $\lambda(\vec{x}, \vec{\lambda})$. Se puede utilizar el hessiano de $f(\vec{x})$.

8 Regresión

Es una parte de la estadística inferencial y una de las técnicas de analíticas más conocida y usada en estadística. Se usa para caracterizar la relación entre *variables explicativas* (variables de entrada) y *una variable de respuesta* (variable de salida).
Puede usarse para:

- Testeo de hipótesis, es decir, explicación.
- Para realizar pronósticos.

Dos términos similares pero distintos son:

- *Regresión*: Intenta describir la dependencia de una variable de respuesta a partir de una o más variables explicativas
- *Correlación*: Indica el grado de asociación entre variables.

8.1 Regresión Lineal Simple

Es el caso de regresión donde hay una variable explicativa y una de respuesta. Se trata de hallar la recta que mejor ajuste la relación entre la variable explicativa y la de respuesta.
Tiene la forma:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i = \hat{y}_i + \epsilon_i$$

Con:

- $\beta_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$
- $\beta_0 = \bar{y} - \beta_1 \bar{x}$

Donde:

- y_i: Es el i-ésimo valor de la variable de respuesta. Valor ya conocido de las observaciones.
- x_i: Es el i-ésimo valor de la variable explicativa. Valor ya conocido de las observaciones.
- $\hat{y}_i$: Es el valor predicho por el modelo en el instante i.
- ϵ_i: Es el error de medición. La diferencia entre el valor obtenido de la regresión y el conocido.
- β_1: Es la pendiente de la recta de regresión.
- $beta_0$: Es la ordenada al origen de la recta de regresión.

- $\bar{y}, \bar{x}$: Son el promedio de la variable de respuesta y explicativa, respectivamente.

Sabiendo que buscamos la recta que minimice el error entre el valor medido y el generado por la regresión, podemos obtener β_0 y β_1 de resolver el problema de programación no lineal sin restricciones:

$$\min \sum_{i=1}^{n} \epsilon_i^2 \ = \sum_{i=1}^{n} (y_i - \hat{y}_i) = \sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 x_i))$$

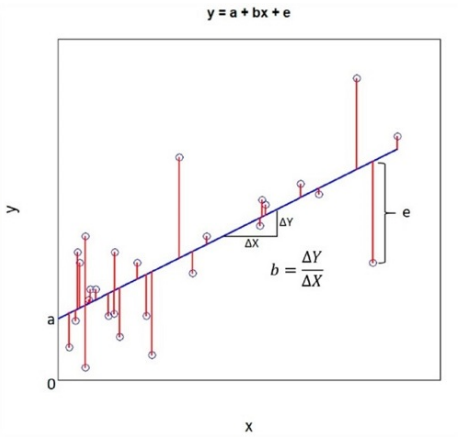


Figure 8: Gráfico de dispersión con la recta de regresión.

8.2 Regresión Lineal Múltiple

Es el caso de regresión donde hay más de una variable explicativa y una de respuesta.
Tiene la forma:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + \epsilon_i = \hat{y}_i + \epsilon_i$$

Donde:

- y_i: Es el i-ésimo valor de la variable de respuesta. Valor ya conocido de las observaciones,
- $\hat{y}_i$: Es el valor predicho por el modelo en el instante i.
- x_{ji}: Es el valor de la variable x_j en el instante i. Valor ya conocido de las observaciones.
- β_j: Se puede interpretar como el incremento de y si el valor de la variable x_j se incrementa en 1 y todas las demás variables explicativas permanecen constante.

Se busca elegir los β_j que minimicen $\sum \epsilon_i^2$.

8.3 Cómo saber si un modelo es bueno

Existen muchas métricas, una de las más utilizadas es el coeficiente de determinación R^2. Su propósito es determinar la fuerza de relación entre las variables explicativas y la de respuesta. Mientras más cercano a 1 es, mayor relación tendrán. Mientras más fuerza de relación, más se pueden explicar los cambios de la variable de respuesta en función de los cambios de las variables explicativas.

- $R^2 = \frac{SSR}{SST} \in [0, 1]$
  - $SSR = \sum(\hat{y}_i - \bar{y})^2$
  - $SST = \sum(y_i - \bar{y})^2$

8.4 Supuestos de un modelo de regresión

Existen cuatro supuestos a tener en cuenta para que el modelo de regresión funcione como es esperado.

8.4.1 Homocedasticidad

Los valores de los errores del modelo deben ser aproximadamente los mismos, sin importar el valor de la(s) variable(s) explicativa(s).

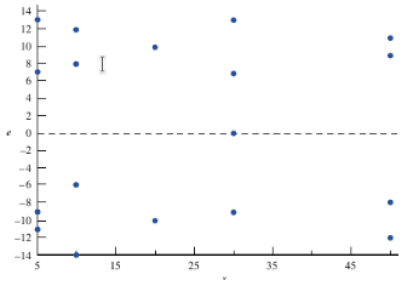


Figure 9: Gráfico de $\epsilon(x)$. Hay homocedasticidad.

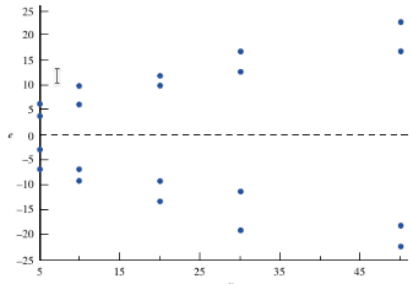


Figure 10: Gráfico de $\epsilon(x)$. Hay heterocedasticidad, no homocedasticidad.

8.5 Normalidad

Los errores de la variable explicativa siguen una distribución normal o gaussiana.

8.6 Independencia

Todos los valores de errores son independientes, no existe autocorrelación entre ellos (autocorrelación negativa). Los errores contiguos tienden siempre a diferir en signo, no necesariamente debe ser uno positivo y uno negativo, pero si deben estar altamente alternados.

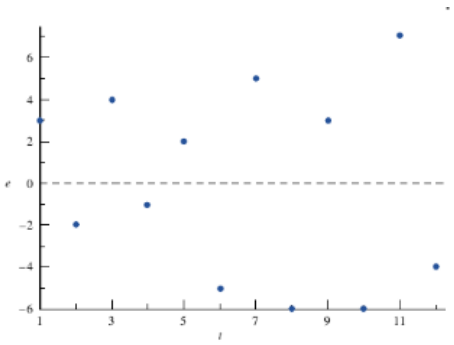


Figure 11: $\epsilon(x)$. Autocorrelación negativa

8.7 Multicolinealidad

Las variables explicativa no tienen correlación lineal.

9 Programación No Lineal

En programación lineal el objetivo era maximizar o minimizar una función lineal sujeta a restricciones lineales. En programación no lineal, tanto la función objetivo como las restricciones pueden no ser lineales.
En este tipo de problemas, se relajan los supuestos de proporcionalidad y de aditividad, es decir, pueden no cumplirse. A su vez, a diferencia de en PL, en PNL una solución óptima puede no estar en la frontera del conjunto convexo de la región factible. Esta solución óptima, en PL, podría ser cualquier extremo relativo, sin embargo, en PNL, esto puede no ser cierto.

9.1 Forma canónica general

$$\max[\min]\ Z = f(x_1, x_2, \ldots, x_n)$$

Sujeto a

$$\begin{aligned} g_1(x_1, x_2, \ldots, x_n) &\leq [\geq; =] b_1 \\ g_2(x_1, x_2, \ldots, x_n) &\leq [\geq; =] b_2 \\ &\vdots \\ g_m(x_1, x_2, \ldots, x_n) &\leq [\geq; =] b_m \end{aligned}$$

9.2 PNL univariable

Es aquel caso en donde se tiene una sola variable, es decir:

$$\max[\min]\ Z = f(x)$$

Sujeto a

$$x \in [a, b]$$

Este tipo de problemas tiene 3 casos en donde encontrar *candidatos a extremos*:

- Puntos donde $f'(x) = 0$, con $a < x < b$
  - En estos casos, se aplica el criterio de la segunda derivada para evaluar el tipo de punto extremo.
  - También se puede evaluar si $f'(x)$ pasa de positiva a negativa a medida que va pasando por x, entonces x es un máximo local. Viceversa para mínimo local.
- Puntos frontera de la región factible, es decir, $f(a)$ y $f(b)$
  - Se presentan los cuatro casos posibles:

$f'(a) > 0$	a es un mínimo local
$f'(a) < 0$	a es un máximo local
$f'(b) > 0$	b es un máximo local
$f'(b) < 0$	b es un mínimo local

Table 2: Determinar si un punto frontera de la región factible es máximo local o mínimo local

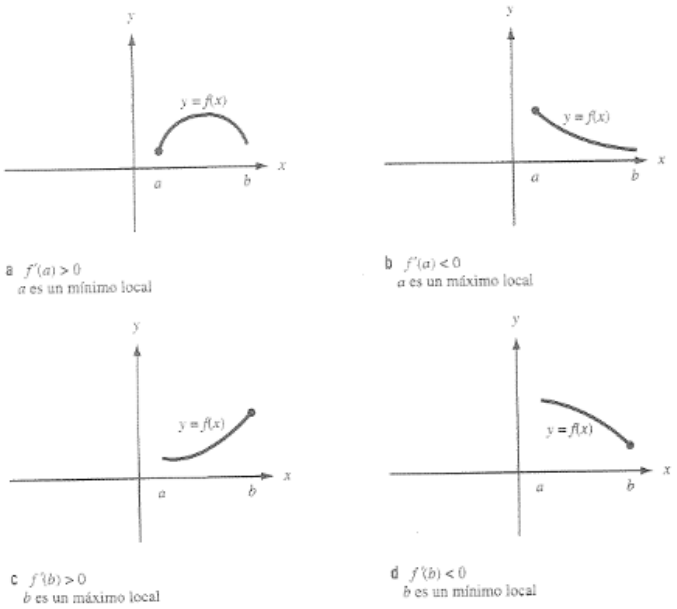


Figure 12: Tipos de extremos en puntos frontera de la región factible

- Puntos donde no existe la derivada
  - En los casos donde no existe la derivada en $f(x)$, se toman puntos $x_1 < x$ y $x_2 > x$, cercanos a x y se toman los siguientes cuatro casos posibles:

Relación entre $f(x), f(x_1)$ **y** $f(x_2)$	x
$f(x) > f(x_1)$ y $f(x) < f(x_2)$	No es extremo local
$f(x) < f(x_1)$ y $f(x) > f(x_2)$	No es extremo local
$f(x) \geq f(x_1)$ y $f(x) \geq f(x_2)$	Máximo local
$f(x) \leq f(x_1)$ y $f(x) \leq f(x_2)$	Mínimo local

Table 3: Determinar si un punto donde $f'(x)$ no existe es un máximo local o un mínimo local

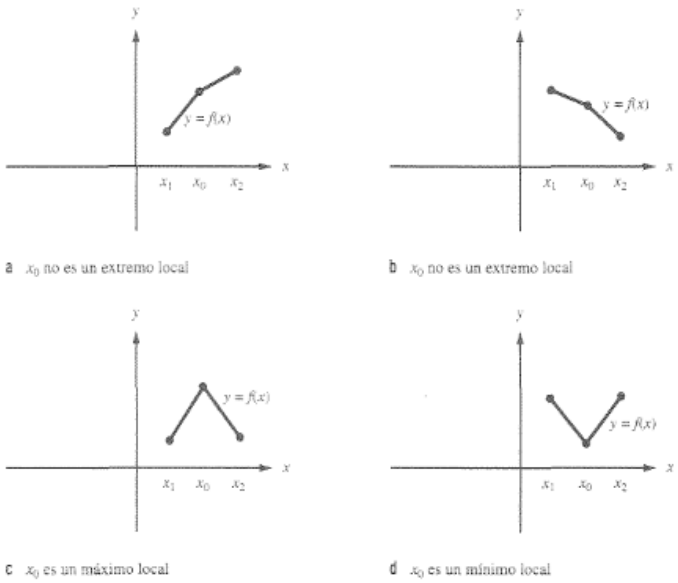


Figure 13: Tipo de extremos en puntos donde no existe la derivada

9.3 PNL Multivariable sin restricciones

Para el caso de un PNL Multivariable sin restricciones, se podrán emplear el criterio de las derivadas para optimizar la función objetivo.

9.4 PNL Multivariable con restricciones de igualdad

Para el caso de un PNL Multivariable con restricciones de igualdad, se podrá emplear el método de los Multiplicadores de Lagrange.

9.4.1 Precios sombra

Se pueden analizar los precios sombras asociados a un PNL Multivariable. Sabiendo que por condición de 1er orden se cumple que $\frac{\partial f}{\partial x_j} = \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j}$, se puede demostrar aplicando regla de la cadena que:

$$\lambda_i = \frac{\partial f}{\partial g_i}$$

Lo que implica que λ_i mide el cambio de f cuando varía la restricción g_i. Por lo tanto, λ_i es el precio sombra asociado a la restricción g_i cuando la restricción varía en un infinitésimo.

9.5 PNL Multivariable con restricciones de desigualdad

Para el caso de un PNL Multivariable con restricciones de desigualdad, hay que trabajarlo para llevarlo a la forma de restricciones con igualdades. Si tengo el PNL:

$$\max[\min]\ Z = f(x_1, x_2, \ldots, x_n)$$

Sujeto a

$$\begin{aligned} g_1(x_1, x_2, \ldots, x_n) &\leq b_1 \\ g_2(x_1, x_2, \ldots, x_n) &\geq b_2 \\ g_3(x_1, x_2, \ldots, x_n) &= b_3 \\ &\vdots \\ g_m(x_1, x_2, \ldots, x_n) &\leq b_m \end{aligned}$$

Para pasar de las desigualdades a igualdades, se realiza lo siguiente:

1. Se multiplican por -1 las restricciones $\geq$
2. Se desarman las igualdades en dos desigualdades

Es decir:

$$\max[\min]\ Z = f(x_1, x_2, \ldots, x_n)$$

Sujeto a

$$\begin{aligned} g_1(x_1, x_2, \ldots, x_n) &\leq b_1 \\ -g_2(x_1, x_2, \ldots, x_n) &\leq -b_2 \\ g_3(x_1, x_2, \ldots, x_n) &\leq b_3 \\ -g_3(x_1, x_2, \ldots, x_n) &\leq -b_3 \\ &\vdots \\ g_m(x_1, x_2, \ldots, x_n) &\leq b_m \end{aligned}$$

9.5.1 Condiciones KT - Kuhn-Tucker

Las condiciones de Kuhn-Tucker son condiciones para que un punto $\vec{x}$ sea solución del PNL. Se usan cuando hay restricciones $\leq$, ya que no se pueden usar los multiplicadores de Lagrange.
El hecho de que no se cumplan estas condiciones, no quiere decir que no exista solución. Existen condiciones necesarias y suficientes:

- **Condiciones necesarias para un problema sin restricciones de no negatividad - KT**
  Las condiciones necesarias siguientes son aquellas que se pueden aplicar a PNL que no tengan variables con restricción de no negatividad.

- *Maximización*
  Si se trata de maximizar la función objetivo, entonces la condición necesaria será que deberá existir $\vec{x} = (x_1, x_2, \ldots, x_n)$ y $\vec{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_m)$ que satisfagan lo siguiente:
  * $\frac{\partial f}{\partial x_j} - \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j} = 0, \forall j = 1 \ldots n$
  * $\lambda_i [b_i - g_i(\vec{x})] = 0, \forall i = 1, \ldots, m$
  * $\lambda_i \geq 0, \forall i = 1, \ldots, m$
- *Minimización*
  Si se trata de minimizar la función objetivo, entonces la condición necesaria será que deberá existir $\vec{x} = (x_1, x_2, \ldots, x_n)$ y $\vec{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_m)$ que satisfagan lo siguiente:
  * $\frac{\partial f}{\partial x_j} + \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j} = 0, \forall j = 1 \ldots n$
  * $\lambda_i [b_i - g_i(\vec{x})] = 0, \forall i = 1, \ldots, m$
  * $\lambda_i \geq 0, \forall i = 1, \ldots, m$
- Notar que en ambas condiciones es lo mismo, sólo cambia el signo del primer ítem. Este primer ítem es básicamente la condición de primer orden de los Multiplicadores de Lagrange, solo que en la minimización se resta en lugar de sumar.
- El segundo ítem de ambas condiciones corresponde a la holgura complementaria de cada restricción.

- **Condiciones necesarias para un problema con restricciones de no negatividad - KT**
  Las condiciones necesarias siguientes son aquellas que se pueden aplicar a PNL que tengan variables con restricción de no negatividad.
  - *Maximización*
    Si se trata de maximizar la función objetivo con restricciones de no negatividad, entonces la condición necesaria será que deberá existir $\vec{x} = (x_1, x_2, \ldots, x_n)$ y $\vec{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_m)$ que satisfagan lo siguiente:
    * $\frac{\partial f}{\partial x_j} - \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j} \leq 0, \forall j = 1 \ldots n$
    * $\lambda_i [b_i - g_i(\vec{x})] = 0, \forall i = 1, \ldots, m$
    * $[\frac{\partial f}{\partial x_j} - \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j}] x_j = 0, \forall j = 1 \ldots n$
    * $\lambda_i \geq 0, \forall i = 1, \ldots, m$
  - *Minimización*
    Si se trata de minimizar la función objetivo con restricciones de no negatividad, entonces la condición necesaria será que deberá existir

$\vec{x} = (x_1, x_2, \ldots, x_n)$ y $\vec{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_m)$ que satisfagan lo siguiente:

  * $\frac{\partial f}{\partial x_j} + \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j} \geq 0, \forall j = 1 \ldots n$
  * $\lambda_i [b_i - g_i(\vec{x})] = 0, \forall i = 1, \ldots, m$
  * $[\frac{\partial f}{\partial x_j} + \sum_{i=1}^{m} \lambda_i \frac{\partial g_i}{\partial x_j}] x_j = 0, \forall j = 1 \ldots n$
  * $\lambda_i \geq 0, \forall i = 1, \ldots, m$

- **Condiciones suficientes - KT**
  Las condiciones suficientes presentadas sirven para problemas con y sin restricciones de no negatividad

  – *Maximización*

    * Se tiene que cumplir la condición necesaria para maximización
    * A su vez, la función objetivo debe ser cóncava y todas las restricciones deben ser funciones convexas.

  – *Minimización*

    * Se tiene que cumplir la condición necesaria para minimización
    * A su vez, la función objetivo debe ser convexa y todas las restricciones deben ser funciones convexas.

10 Modelos de pronóstico

Los modelos de pronóstico se usan para predecir, generalmente, demandas. El objetivo es construir un modelo que use datos del pasado y pronostique la demanda futura. Existen dos grandes tipos:

- Series Temporales
  Predicen el próximo valor de una variable basándose en los valores antiguos de esa misma variable.
- Causales
  Predicen el valor de una variable con el valor antiguo de otras variables.

En general, un método de pronóstico es bueno si da mayor peso a las observaciones más recientes, ya que son más representativas de las condiciones actuales frente a las observaciones antiguas.

10.1 Series Temporales

Son datos registrados equiespaciados registrados durante el tiempo. Existen cuatro tipos de modelos de series de tiempo. Para cada uno de estos modelos tendremos tres componentes comunes:

1. D_t: Valor real medido del modelo en el instante t.
2. F_t: Valor pronosticado para el instante t.
3. ϵ_t: Es el error en el instante t, entre D_t y F_t. Se supone que son errores aleatorios y que promedian 0.

Se supone que las variaciones, es decir, los errores ϵ_t, no tienen explicación causal.
Pueden tener hasta cuatro componentes:

- Nivel
- Tendencia
- Estacionalidad
- Error aleatorio

10.1.1 Modelos de Nivel

Son útiles cuando la demanda es relativamente constante alrededor de un valor fijo.
En estos modelos:

- $D_t = A + \epsilon_t$
- $F_t = A$

Donde

- A Es el valor fijo alrededor del cual la demanda es relativamente constante.

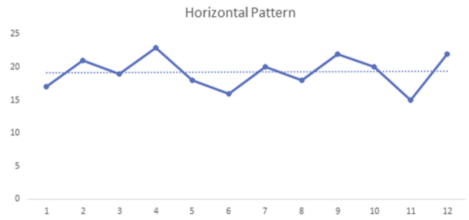


Figure 14: Gráfico modelo de nivel

10.1.1.1 Métodos de pronóstico para un modelo de nivel

- **Promedio**: Se calcula como el promedio de todas las observaciones. Por lo tanto, el pronóstico para el siguiente periodo es:

$$\frac{\sum_{i=1}^{n} D_i}{n}$$

  Esta estimación es muy buena si el proceso es muy estable. Sin embargo, si ocurre algún cambio repentino en los últimos valores observados, el promedio varía muy poco de un periodo al siguiente, por lo que no sería útil ya que estos valores diferenciados no tendrían tanto peso como deberían.

- **Medias móviles**: Se calcula como el promedio de las últimas k observaciones. Por lo tanto, el pronóstico para el siguiente periodo es:

$$\frac{\sum_{i=n-k+1}^{n} D_i}{k}$$

  La ventaja de este método es que le da más peso a los últimos valores observados que el método del promedio. Una desventaja es que coloca el mismo peso sobre D_{n-k+1} que sobre D_n.
  Para elegir un k adecuado, se pueden considerar distintos valores y evaluarlos según las Medidas de rendimiento

- **Suavizado exponencial**: Utiliza el error de pronóstico en un periodo para corregir y mejorar el pronóstico del siguiente periodo.

$$F_t = F_{t-1} + \alpha(D_{t-1} - F_{t-1}), \alpha \in [0, 1]$$

  Donde α es una *constante de suavizado*, a mayor valor de α más se tiende a copiar los errores antiguos. Por lo tanto, $\alpha(D_{t-1} - F_{t-1})$ es la fracción del error anterior que voy a utilizar para ajustar la siguiente medición.
  Generalmente se utiliza algún valor tal que $\alpha \in [0.1, 0.3]$, ya que son valores que suelen andar bien.

10.1.2 Modelos de Tendencia

Son útiles cuando la demanda muestra un patrón creciente o decreciente en el tiempo. Este patrón (tendencia) puede ser lineal o no lineal.
En estos modelos:

- $D_t = A + Bt + \epsilon_t$
- $F_t = A + Bt$

Donde

- A es el primer valor medido. Por lo tanto, es constante.
- B es el factor de tendencia. Es la pendiente de la recta del modelo de pronóstico.

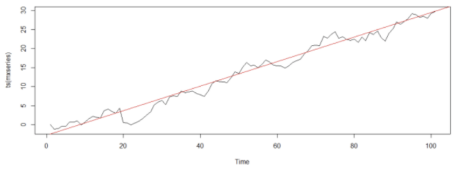


Figure 15: Gráfico modelo de tendencia

10.1.2.1 Métodos de pronóstico para un modelo de tendencia

- **Regresión lineal**: Se puede utilizar una regresión lineal simple o múltiple. Sin embargo, este método da el mismo peso a todos los datos, sean más recientes o no, por lo que no es la mejor recomendación en todos los casos.
- **Suavizado exponencial para modelos de tendencia** o **Método de Holt**: Teóricamente, es la misma técnica que el suavizado exponencial para un modelo de nivel, pero con un factor de suavizado por tendencia. Se calcula como:

  $$F_t = L_{t-1} + B_{t-1}$$

  Donde:

  - $L_t = F_t + \alpha(D_t - F_t), \alpha \in [0, 1]$: Es la estimación de la demanda para el periodo t.
  - $B_t = B_{t-1} + \beta[(L_t - L_{t-1}) - B_{t-1}], \beta \in [0, 1]$: Es la estimación de la tendencia para el periodo t.

  En este caso, α y β son las constantes de suavizado de nivel y de tendencia, respectivamente. Se puede observar que $L_t - L_{t-1}$ es la tendencia para el periodo t.
  Las estimaciones iniciales L_0 y β_0 se pueden obtener de una regresión lineal. No es la única manera.
  Si se quiere obtener el pronóstico para los próximos k periodos:

  $$F_{t+k} = L_t + kB_t$$

10.1.3 Modelos Estacionales

Son útiles cuando la demanda tiene un patrón que se repite en un marco de tiempo (En ciertos meses del año, por ejemplo).
En estos modelos:

- $D_t = AS_k + \epsilon_t$
- $F_t = AS_k$

Donde

- A es el primer valor medido. Por lo tanto, es constante.
- S_k Es el factor de estacionalidad.

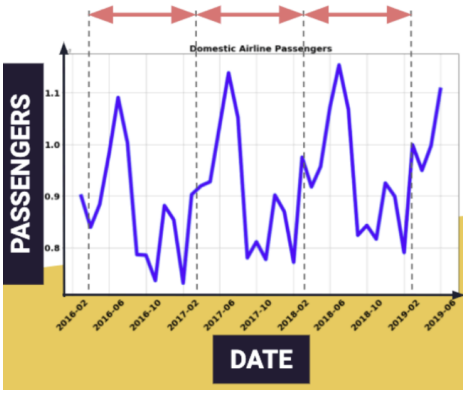


Figure 16: Gráfico modelo estacional

10.1.4 Modelos Estacionales de Tendencia

Son útiles cuando la demanda muestra tanto una tendencia como un efecto estacional
En estos modelos:

- $D_t = (A + B_t)S_k + \epsilon_t$
- $F_t = (A + B_t)S_k$

Donde

- A es el primer valor medido. Por lo tanto, es constante.
- B es el factor de tendencia.
- S_k es el factor de estacionalidad.

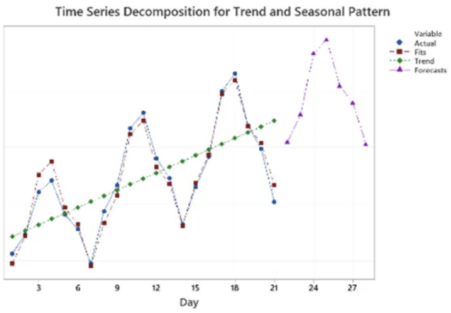


Figure 17: Gráfico de modelo estacional de tendencia

10.1.4.1 Métodos de pronóstico para un modelo de estacionalidad con tendencia

- **Suavizado exponencial para modelos de estacionalidad con tendencia o Método de Winter**: Misma técnica que el suavizado exponencial para modelo de nivel o para modelo de tendencia. En este caso hay un factor de nivel, tendencia y estacionalidad.
  Se calcula como:

  $$F_{t+1} = (L_t + k \cdot B)s_{t+1-c}$$

  Donde:

  - c : Es el número de periodos que dura el patrón estacional.
  - $s_t = k$ Indica que las ventas son, en el periodo t, k veces las ventas de un mes promedio.
  - $L_t = \alpha \frac{D_T}{s_{t-c}} + (1-\alpha)(L_{t-1} + B_{t-1}), \alpha \in [0, 0.5]$: Es la estimación de la demanda para el periodo t.
  - $B_t = \beta(L_t - L_{t-1}) + (1-\beta)B_{t-1}, \beta \in [0, 0.5]$: Es la estimación de la tendencia para el periodo t.
  - $s_t = \gamma \frac{D_t}{L_t} + (1-\gamma)s_{t-c}, \gamma \in [0, 1]$: Es la estimación de la estacionalidad para el periodo t.
  - $\frac{D_t}{s_{t-c}}$: Es la observación del periodo t sin la estacionalidad. Es la observación *desestacionalizada*.
  - $L_{t-1} + B_{t-1}$: Es la estimación del nivel base antes de observar D_t.
  - $\frac{D_t}{L_t}$: Es una estimación del factor de estacionalidad para el periodo t.
  - s_{t-c}: Es la estimación más reciente de la estacionalidad del periodo t.

  En este caso, α, β y γ son las constantes de suavizado de nivel, tendencia y estacionalidad, respectivamente. Tanto α como β se encuentran el rango $[0, 0.5]$ debido a que, si se les permite un rango mayor, pueden empezar a compensar el modelo y no dejar que γ actue como corresponda. Es decir,

el modelo podrá estar estimando valores de nivel y tendencia, pero no de modelo, ya que es probable que le asigne $\gamma = 0$ o muy cercano a 0. Esto se lo conoce como *overfitting*.
Si se quiere obtener el pronóstico para el periodo $t + k$:

$$F_{t+k} = (L_t + k \cdot B_t)s_{t+k-c}$$

Es decir, se multiplica la estimación base correspondiente al periodo $t+k$, $(L_t + k \cdot B_t)$, por la estimación del factor de estacionalidad s_{t+k-c} más reciente correspondiente al periodo $t + k$.

- **Estimaciones iniciales** Para realizar las estimaciones iniciales, se necesitan dos periodos completos de datos.
  - $B_0 = \frac{1}{c}(\sum_{i=-c}^{-1} \frac{D_i}{c} - \sum_{i=-2c}^{-c+1} \frac{D_i}{c})$: Es decir, la demanda promedio en el periodo -1 menos la demanda promedio en el periodo -2 sobre la duración del patrón estacional.
  - $L_0 = \frac{1}{c}(D_{-c} + D_{-c+1} + \cdots + D_{-1}) + \frac{c}{2}B_0$.
  - $s_0 = \frac{D_{-c}}{\sum_{i=-c}^{-1} \frac{D_i}{c}}$
  - $s_1 = \frac{D_{-c+1}}{\sum_{i=-c}^{-1} \frac{D_i}{c}}$
  - $\vdots$
  - $s_{C-1} = \frac{D_{c-1}}{\sum_{i=-c}^{-1} \frac{D_i}{c}}$

10.2 Mediciones de rendimiento

Antes de utilizar un modelo para predecir demandas futuras, hay que analizar su funcionamiento sobre los datos ya existentes. De esta manera, podemos determinar si el modelo utilizado es correcto.
Existen distintas medidas de rendimiento:

10.2.1 RMSE - Root Mean Squared Error

Es la desviación estándar de los errores de pronóstico.
Por lo tanto, puede utilizarse el RMSE para construir intervalos de confianza para demandas futuras. Para esto:

1. Elegir un nivel de confianza $\alpha \in [0, 1]$.
2. Usar el modelo para obtener el pronóstico F_t.
3. El intervalo de confianza asociado es $F_t \pm (z \cdot RMSE)$. z es el valor de tal forma que el área a la izquierda de z bajo la curva normal estándar es $1 - \frac{\alpha}{2}$.

Se calcula como:

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}(D_t - F_t)^2}{n}}$$

10.2.2 MAE - Mean Absolute Error

Nos sirve para saber cuánto va a ser nuestro error en promedio.
Se calcula como:

$$\frac{\sum_{i=1}^{n} |D_t - F_t|}{n}$$

10.2.3 MAPE - Mean Absolute Percentage Error

Es igual a MAE, pero en términos porcentuales.
Se calcula como:

$$\frac{100 \sum_{i=1}^{n} \frac{|D_t - F_t|}{D_t}}{n}$$

10.2.4 Sesgo

Se calcula como:

$$\frac{\sum_{i=1}^{n} (D_t - F_t)}{n}$$

Habrá dos casos:

- $Sesgo > 0$: El modelo *subestima*. El valor de predicción es, en promedio, menor al valor real.
- $Sesgo < 0$: El modelo *sobreestima*. El valor de predicción es, en promedio, mayor al valor real.

Por lo tanto, siempre nos va a interesar que el sesgo sea lo más cercano a 0 posible.

11 Modelos de Inventario

La función principal de los inventarios (stock) es la de absorber las fluctuaciones de la demanda, fabricación y distribución que se verifican como consecuencia de la aleatoriedad de los procesos y por las diferencias en el tiempo y en la distribución física entre la oferta y la demanda. Es por esto que es conveniente tener un modelo matemático que describa el comportamiento de los inventarios para luego elaborar *políticas de inventario, que señalen cuándo y cuánto conviene reabastecer.*
La base del modelo de inventario es una función de costos genérica que tiene la siguiente forma

$$\left(\begin{array}{c}\text{Costo total}\\ \text{del inventario}\end{array}\right) = \left(\begin{array}{c}\text{Costo de}\\ \text{adqusición}\end{array}\right) + \left(\begin{array}{c}\text{Costo de}\\ \text{almacenamiento}\end{array}\right) + \left(\begin{array}{c}\text{Costo de}\\ \text{agotamiento}\end{array}\right) + \left(\begin{array}{c}\text{Costo de la}\\ \text{orden}\end{array}\right)$$

Cada modelo de inventario tiene *cuatro componentes*:

1. **Demanda (d, D):** Que puede ser independiente o dependiente, constante o variable, conocida o incierta (aleatoria).

2. **Costos:**

   (a) De adquisición b: Es el costo unitario del producto que se adquiere. Tiene unidades $\frac{\$}{u}$, es decir, unidad monetaria por unidad de producto. Puede ser constante o variable (según la cantidad que se compra).

   (b) De almacenamiento de mantenimiento c_1: Es el costo de tener una unidad del producto almacenada durante un periodo de tiempo. Es un *costo de oportunidad*, ya que no se están pudiendo obtener beneficios en alguna oportunidad de inversión con el capital que representa el costo de adquisición del producto. Está expresado en unidades monetarias por unidad de producto y unidad de tiempo $\frac{\$}{u \cdot t}$.
   Se calcula como $c_1 = c_1^{'} + b \cdot i$, donde $c_1^{'}$ es el costo operativo de mantenimiento en stock (incluye costos de espacio de almacenamiento y/o impuestos a los inventarios, entre otros) e i es la tasa de inmovilización de capital (puede ser el costo del dinero o la tasa de retorno sobre la inversión de capital).
   Este costo puede ser constante o variable en función de la cantidad.

   (c) De agotamiento o déficit c_2: Es el costo cuando se agota el stock y, en consecuencia, no se puede satisfacer la demanda del producto. Está expresado en unidad monetaria por unidad de producto y unidad de tiempo $\frac{\$}{u \cdot t}$, en unidad monetaria por unidad de producto $\frac{\$}{u}$, en unidad monetaria por cada vez que se alcanza el agotamiento o en alguna combinación de ellas.

   (d) De orden k: Es el costo por cada pedido de fabricación que se emite o costo de emisión de orden de compra. Está expresado en unidades monetarias por pedido $\frac{\$}{p}$. Generalmente es fijo, pero puede llegar a ser variable en función de la cantidad.

3. **Tiempo de reaprovisionamiento:** El plazo de entrega o el *lead time*.
4. **Política:** Las decisiones.
5. **Ciclos:** Las cantidades de unidades mantenidas en stock generalmente tienen un comportamiento cíclico.

11.1 Caracterización de la demanda

La complejidad de los modelos de inventario depende de si la demanda es determinística o probabilística. Dentro de estas categorías, la demanda puede variar o no con el tiempo.
Se utilizará un coeficiente de variación para determinar la naturaleza de la demanda.

$$V = \frac{Desviación\ estándar}{Media} \cdot 100$$

- Si $V < 20\%$, entonces V es pequeño.
- Si $V > 20\%$, entonces V es alto.

La clasificación supone la disponibilidad de datos confiables para pronosticar la futura demanda.

11.1.1 Determinística y constante con el tiempo

Es decir, la demanda es siempre el mismo valor a lo largo del tiempo. Menos probable que ocurra en la práctica.
Será el caso cuando la demanda mensual promedio (registrada a lo largo de varios años) es "de manera aproximada" constante y V es pequeño.

11.1.2 Determinística y variable con el tiempo

La demanda puede seguir un patrón estacional, por ejemplo.
Será el caso cuando la demanda mensual promedio varía de manera apreciable entre los distintos meses, pero V sigue siendo pequeño en todos los meses.

11.1.3 Probabilística y estacionaria a lo largo del tiempo

La demanda sigue siempre una misma distribución de probabilidad a lo largo del tiempo.
Será el caso cuando la demanda mensual promedio es constante y V es alto, pero aproximadamente constante.

11.1.4 Probabilística y no estacionaria a lo largo del tiempo

La demanda no sigue siempre una misma distribución de probabilidad a lo largo del tiempo.
Será el caso cuando los promedios y V varían apreciablemente mes a mes.

	Determinística y constante	**Determinística y variable**	**Probabilística y estacionaria**	**Probabilística y no estacionaria**
Demanda mensual	Constante	Variable	Constante	Variable
V	Pequeño	Pequeño	Alto	Variable

Table 4: Tabla categorización de la demanda

11.2 Modelos determinísticos

Son aquellos modelos en donde la demanda es conocida.

11.2.1 Modelo EOQ básico o Modelo de Wilson

11.2.1.1 Supuestos

- Se administra un único ítem.
- El producto es de demanda independiente.
- La demanda es conocida y se efectúa a tasa constante.
- El plazo de entrega o lead time es conocido y constante.
- La reposición se hace exactamente cuando el nivel de stock es cero.
- El reaprovisionamiento es instantáneo.
- El horizonte de planeamiento es de largo plazo.
- $c_2 \to \infty$, es decir, el costo de agotamiento tiende a ser muy grande.
- Los demás costos (orden, adquisición y almacenamiento) son independientes de la cantidad a ordenar.
- Todos los parámetros monetarios están expresados en moneda constante.
- El producto en estudio se mide en una unidad continua.

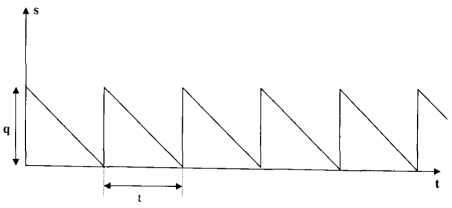


Figure 18: Gráfica del stock en función del tiempo en un modelo EOQ básico.

11.2.1.2 Modelado

- **Parámetros**
  - D : Es la demanda del producto referida a un periodo de tiempo (año, semestre, etc). Generalmente, se utiliza año. Para alguna unidad de tiempo más chica (días, semanas, etc.) se utiliza d.
  - b : Costo unitario de adquisición.
  - c_1 : Costo unitario de almacenamiento.
  - k : Costo de una orden.
  - $T = 1$: Parámetro de dimensionamiento que sirve para referenciar todos los parámetros temporales a la misma unidad de tiempo. Su unidad es igual a 1 pedido.
  - LT : Lead Time.
- **Variables**
  - q : Es el tamaño del lote. Es la variable de decisión básica.
  - t : Es el intervalo de un ciclo. Tiempo que transcurre entre un restock y el siguiente.
  - CTE : Es el *Costo Total Esperado* referido a un periodo de tiempo. Es la función objetivo.
  - SR : Es el stock de reorden, es decir, el nivel de stock que hace que, una vez alcanzado, se emita la orden de reposición.
- **Costo total esperado de un periodo** i

$$CTE_i(q) = b \cdot q + \frac{1}{2} \cdot q \cdot c_1 \cdot t + K$$

- **Costo total esperado anual**

$$CTE(q) = b \cdot D + \frac{1}{2} \cdot q \cdot c_1 \cdot T + K \cdot \frac{D}{q}$$

  Optimizando:

$$CTE(q_0) = CTE_0 = b \cdot D + \sqrt{2 \cdot K \cdot D \cdot c_1 \cdot T}$$

- **Valor óptimo de** q
  Es la cantidad óptima a ordenar, que minimiza CTE.

$$q_0 = \sqrt{\frac{2 \cdot K \cdot D}{c_1 \cdot T}}$$

- **Stock de reorden**

$$SR = LT \cdot d$$

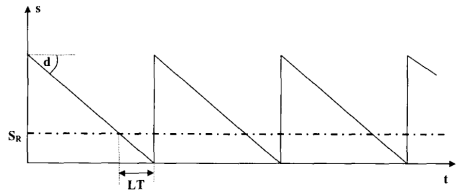


Figure 19: Gráfica SR

- **Número de ciclos por periodo**
  Es decir, la cantidad de veces que se pide en un periodo.

$$n = \frac{D}{q} = \frac{T}{t}$$

  Optimizando:

$$n_0 = \frac{D}{q_0} = \sqrt{\frac{T \cdot c_1 \cdot D}{2 \cdot K}}$$

- **Valor óptimo del intervalo t**

$$t_0 = \frac{T}{D} \cdot q_0 = \sqrt{\frac{2 \cdot k \cdot T}{D \cdot c_1}}$$

- **Donde**
  - CTE, el costo total esperado, es la suma de los costos parciales. $b \cdot D$ corresponde al costo de adquisición, $\frac{1}{2} \cdot q \cdot c_1 \cdot T$ corresponde al costo de almacenamiento y $K \cdot \frac{D}{q}$ corresponde al costo de orden.
  - CTE_0 Es el mejor costo esperado anual que se puede obtener.

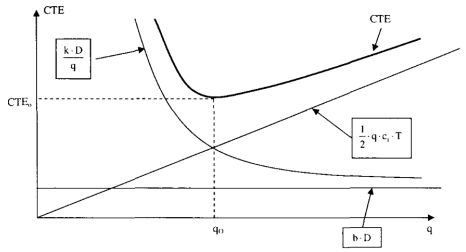


Figure 20: Gráfica de las componentes de CTE. Notar que q_0 es la intersección del costo de orden y de almacenamiento.

- **Análisis de Sensibilidad**
  Sirve para ver cómo varía CTE si realizamos un pedido q' distinto al óptimo q_0.

$$q' = \alpha \cdot q_0, \alpha \geq 0$$

  Donde α nos indica cuánto nos desviamos del óptimo. Tener en cuenta que q' puede ser mayor o menor que q_0.
  Para cuantificar la variación, se define una relación de sensibilidad

$$\lambda = \frac{CVTE(q')}{CVTE(q_0)} = \frac{CTE(q') - b \cdot D}{CTE_0 - b \cdot D} = \frac{1}{2} \cdot (\alpha + \frac{1}{\alpha})$$

  También se puede calcular el error relativo ε

$$\varepsilon = \lambda - 1 = \frac{1}{2} \cdot (\alpha + \frac{1}{\alpha}) - 1$$

  Dado un incremento tolerable de costo o bien un error relativo tolerable, se puede determinar un rango entre un valor mínimo y un valor máximo del lote a solicitar, es decir, un intervalo de operación. Este intervalo estará dado por dos α

$$\alpha_{1,2} = \varepsilon + 1 \pm \sqrt{\varepsilon^2 + 2 \cdot \varepsilon}$$

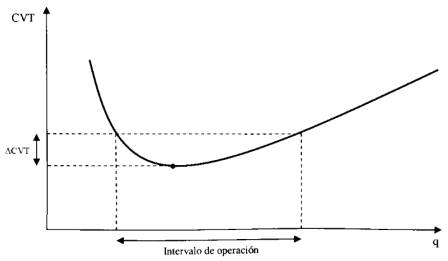


Figure 21: Gráfica intervalo de operación

  - El modelo es poco sensible, para grandes variaciones de la variable de decisión q, la variación en el costo CTE es baja.
  - Hay mayor sensibilidad por izquierda que por derecha. Es decir, hay más variación para $\alpha < 0$ que para $\alpha > 0$.

11.2.2 Modelo con Stock de Protección

El *Stock de Protección* es un nivel de inventario que se mantiene para absorber situaciones imprevistas (Huelgas, fluctuaciones imprevistas de demanda, plazos de reposición largos, etc.).

11.2.2.1 Supuestos

- Se administra un único ítem.
- El producto es de demanda independiente.
- La demanda es conocida y se efectúa a tasa constante.
- El plazo de entrega o lead time es conocido y constante.
- Se mantiene un stock de seguridad que no se utiliza operativamente, sólo frente a situaciones imprevistas.
- El reaprovisionamiento es instantáneo.
- El horizonte de planeamiento es de largo plazo.
- $c_2 \to \infty$, es decir, el costo de agotamiento tiende a ser muy grande.
- Los demás costos (orden, adquisición y almacenamiento) son independientes de la cantidad a ordenar.
- Todos los parámetros monetarios están expresados en moneda constante.
- El producto en estudio se mide en una unidad continua.

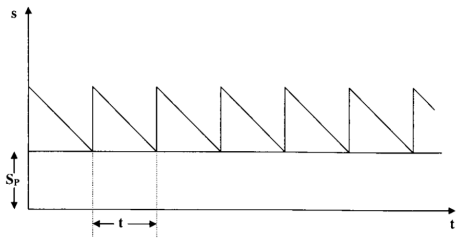


Figure 22: Gráfica de stock en función del tiempo en un modelo con stock de protección.

11.2.2.2 Modelado

- **Parámetros**
  - D : Es la demanda del producto referida a un periodo de tiempo (año, semestre, etc). Generalmente, se utiliza año. Para alguna unidad de tiempo más chica (días, semanas, etc.) se utiliza d.
  - b : Costo unitario de adquisición.
  - c_1 : Costo unitario de almacenamiento.
  - k : Costo de una orden.

- $T = 1$: Parámetro de dimensionamiento que sirve para referenciar todos los parámetros temporales a la misma unidad de tiempo. Su unidad es igual a 1 pedido.
- S_p : Stock de protección.
- LT : Lead Time.

- **Variables**
  - q : Es el tamaño del lote. Es la variable de decisión básica.
  - t : Es el intervalo de un ciclo. Tiempo que transcurre entre un restock y el siguiente.
  - CTE : Es el *Costo Total Esperado* referido a un periodo de tiempo. Es la función objetivo.
  - SR : Es el stock de reorden, es decir, el nivel de stock que hace que, una vez alcanzado, se emita la orden de reposición.
  - S : Stock máximo.

- **Costo total esperado de un periodo** i

$$CTE_i(q) = b \cdot q + \frac{1}{2} \cdot q \cdot c_1 \cdot t + K + S_p \cdot c_1 \cdot t$$

- **Costo total esperado anual**

$$CTE(q) = b \cdot D + \frac{1}{2} \cdot q \cdot c_1 \cdot T + K \cdot \frac{D}{q} + S_p \cdot c_1 \cdot T$$

  Optimizando:

$$CTE(q_0) = CTE_0 = b \cdot D + \sqrt{2 \cdot K \cdot D \cdot c_1 \cdot T} + S_p \cdot c_1 \cdot T$$

- **Valor óptimo de** q
  Es la cantidad óptima a ordenar, que minimiza CTE.

$$q_0 = \sqrt{\frac{2 \cdot K \cdot D}{c_1 \cdot T}}$$

- **Stock de reorden**

$$SR = LT \cdot d + S_p$$

- **Número de ciclos por periodo**
  Es decir, la cantidad de veces que se pide en un periodo.

$$n = \frac{D}{q} = \frac{T}{t}$$

  Optimizando:

$$n_0 = \frac{D}{q_0} = \sqrt{\frac{T \cdot c_1 \cdot D}{2 \cdot K}}$$

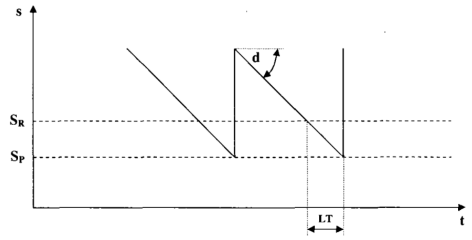


Figure 23: Gráfica de SR

- **Valor óptimo del intervalo t**

$$t_0 = \frac{T}{D} \cdot q_0 = \sqrt{\frac{2 \cdot k \cdot T}{D \cdot c_1}}$$

- **Donde**
  - CTE, el costo total esperado, es la suma de los costos parciales. $b \cdot D$ corresponde al costo de adquisición, $\frac{1}{2} \cdot q \cdot c_1 \cdot T$ corresponde al costo de almacenamiento, $K \cdot \frac{D}{q}$ corresponde al costo de orden y $S_p \cdot c_1 \cdot T$ es el costo correspondiente al stock de protección.
  - CTE_0 Es el mejor costo esperado anual que se puede obtener.

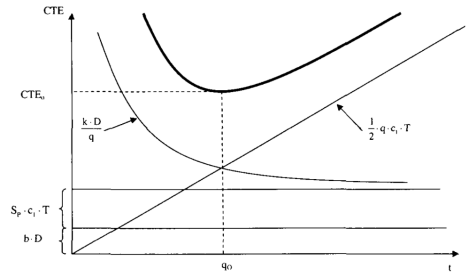


Figure 24: Gráfica de las componentes de CTE

11.2.3 Modelos con agotamiento admitido

Existirá agotamiento de stock cuando no quedan unidades disponibles para satisfacer la demanda. En estas situaciones, se agrega un *costo de agotamiento*, que puede ser variable, fijo o una combinación. Una vez alcanzado el nivel de cero de inventario, la empresa no satisface los pedidos de forma inmediata, pero los acumula de manera que cuando recibe el producto no solo repone la cantidad insatisfecha, sino también el nivel de stock inicial.
Será útil admitir agotamiento cuando, por ejemplo, se tiene un costo alto de almacenamiento respecto del costo de faltante.

11.2.3.1 Supuestos

- Se administra un único ítem.
- El producto es uno terminado y de demanda independiente.
- La demanda es conocida y se efectúa a tasa constante.
- El plazo de entrega o lead time es conocido y constante.
- El reaprovisionamiento es instantáneo.
- El horizonte de planeamiento es de largo plazo.
- El agotamiento está permitido con un costo c_2. Está dado solamente por el costo en el que se incurre por unidad de tiempo de déficit, no hay costo fijo de agotamiento ni costo por cantidad de unidades agotadas independiente del tiempo.
- Los demás costos (orden, adquisición y almacenamiento) son independientes de la cantidad a ordenar.
- Todos los parámetros monetarios están expresados en moneda constante.
- El producto en estudio se mide en una unidad continua.

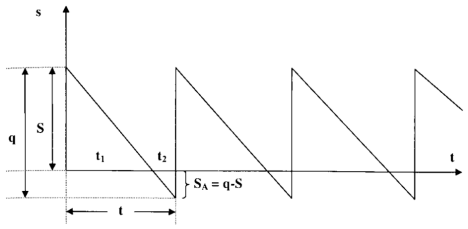


Figure 25: Gráfica del stock en función del tiempo en un modelo con agotamiento.

11.2.3.2 Modelado

- **Parámetros**
  - D : Es la demanda del producto referida a un periodo de tiempo (año, semestre, etc). Generalmente, se utiliza año. Para alguna unidad de tiempo más chica (días, semanas, etc.) se utiliza d.
  - b : Costo unitario de adquisición.
  - c_1 : Costo unitario de almacenamiento.
  - c_2 : Costo unitario de agotamiento por unidad de tiempo de demora.
  - k : Costo de una orden.

- $T = 1$: Parámetro de dimensionamiento que sirve para referenciar todos los parámetros temporales a la misma unidad de tiempo. Su unidad es igual a 1 pedido.
- S_p : Stock de protección.
- LT : Lead Time.

- **Variables**
  - q : Es el tamaño del lote. Es la variable de decisión básica.
  - t : Es el intervalo de un ciclo. Tiempo que transcurre entre un restock y el siguiente.
  - t_1 : Periodo de entrega de mercadería.
  - t_2 : Periodo de déficit de mercadería.
  - CTE : Es el *Costo Total Esperado* referido a un periodo de tiempo. Es la función objetivo.
  - SR : Es el stock de reorden, es decir, el nivel de stock que hace que, una vez alcanzado, se emita la orden de reposición.
  - S : Stock máximo o stock inicial.
  - SA : Cantidad máxima de unidades agotadas.

- **Costo total esperado de un periodo** i

$$CTE_i(q,S) = b \cdot q + \frac{1}{2} \cdot S^2 \cdot c_1 \cdot \frac{t}{q} + \frac{1}{2} \cdot (q-S)^2 \cdot c_2 \cdot \frac{t}{q} + k$$

- **Costo total esperado anual**

$$CTE(q,S) = b \cdot D + \frac{1}{2} \cdot \frac{S^2}{q} \cdot c_1 \cdot T + \frac{1}{2} \cdot \frac{(q-S)^2}{q} \cdot c_2 \cdot T + K \cdot \frac{D}{q}$$

  Optimizando:

$$CTE(q_0,S_0) = CTE_0 = b \cdot D + \sqrt{2 \cdot K \cdot D \cdot c_1 \cdot T} \cdot \sqrt{\frac{c_2}{c_1 + c_2}}$$

- **Stock de agotamiento**

$$S_A = q - S$$

  Optimizando:

$$S_{A0} = q_0 - S_0 = q_0 \cdot \frac{c_1}{c_1 + c_2}$$

- **Valor óptimo de** q
  Es la cantidad óptima a ordenar, que minimiza CTE junto con S_0. Notar que si $c_2 \to \infty$, la raíz tiende a 1, y estaríamos en el caso del modelo EOQ.

$$q_0 = \sqrt{\frac{2 \cdot K \cdot D}{c_1 \cdot T}} \cdot \sqrt{\frac{c_1 + c_2}{c_2}}$$

- **Valor óptimo de S**
  Es el stock máximo óptimo, que minimiza CTE junto con q_0. Notar que si $c_2 \to \infty$, la raíz tiende a 0, y estaríamos en el caso del modelo EOQ.

$$S_0 = \sqrt{\frac{2 \cdot K \cdot D}{c_1 \cdot T}} \cdot \sqrt{\frac{c_2}{c_1 + c_2}}$$

- **Stock de reorden**

$$SR = LT \cdot d - S_{A0}$$

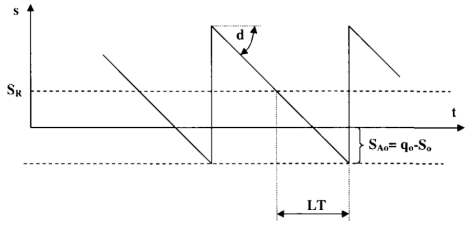


Figure 26: Gráfica SR

- **Número de ciclos por periodo**
  Es decir, la cantidad de veces que se pide en un periodo.

$$n = \frac{D}{q} = \frac{T}{t}$$

  Optimizando:

$$n_0 = \frac{D}{q_0} = \sqrt{\frac{T \cdot c_1 \cdot D}{2 \cdot K}}$$

- **Valor óptimo del intervalo t**

$$t_0 = \frac{T}{D} \cdot q_0 = \sqrt{\frac{2 \cdot k \cdot T}{D \cdot c_1}}$$

- **Valor del intervalo t_1**

$$t_1 = \frac{S \cdot t}{q}$$

  Optimizando:

$$t_{10} = \frac{S_0 \cdot t_0}{q_0} = \frac{S_0}{D}$$

- **Valor del intervalo t_2**

$$t_2 = \frac{(q - S) \cdot t}{q}$$

  Optimizando:

$$t_{20} = \frac{(q_0 - S_0) \cdot t_0}{q_0}$$

- **Donde**
  - CTE, el costo total esperado, es la suma de los costos parciales. $b \cdot D$ corresponde al costo de adquisición, $\frac{1}{2} \cdot \frac{S^2}{q} \cdot c_1 \cdot T$ corresponde al costo de almacenamiento, $K \cdot \frac{D}{q}$ corresponde al costo de orden y $\frac{1}{2} \cdot \frac{(q-S)^2}{q} \cdot c_2 \cdot T$ es el costo correspondiente al agotamiento.
  - CTE_0 Es el mejor costo esperado anual que se puede obtener.

11.2.4 Modelo con precio de adquisición b variable con descuentos discretos

Hasta ahora se venía asumiendo que el precio de adquisición b era constante para la cantidad q de productos a comprar. En la práctica esto no es tan habitual, ya que a mayor lote de fabricación, mejor se aprovechan los recursos de producción. Se analizará el caso de la variación b con descuentos discretos.

11.2.4.1 Supuestos

- Se administra un único ítem.
- El producto de demanda independiente.
- La demanda es conocida y se efectúa a tasa constante.
- El plazo de entrega o lead time es conocido y constante.
- La reposición se hace exactamente cuando el nivel de stock es cero.
- El reaprovisionamiento es instantáneo.
- El horizonte de planeamiento es de largo plazo.
- El costo de adquisición b varía con relación a q según la ley de descuentos:
  - Para $0 \leq q < Q_1$, el precio de adquisición es b_1.
  - Para $Q_1 \leq q < Q_2$, el precio de adquisición es b_2.
  - Para $Q_2 \leq q$, el precio de adquisición es b_3.
- $c_2 \to \infty$, es decir, el costo de agotamiento tiende a ser muy grande.
- Los demás costos (orden y almacenamiento) son independientes de la cantidad a ordenar.
- Todos los parámetros monetarios están expresados en moneda constante.
- El producto en estudio se mide en una unidad continua.

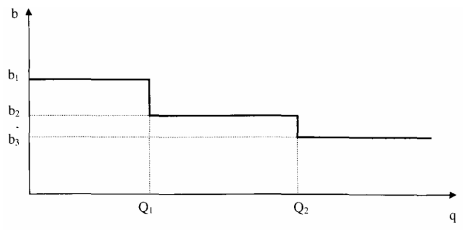


Figure 27: Gráfica de variación de b en función de q

11.2.4.2 Modelado

- **Parámetros**
  - D : Es la demanda del producto referida a un periodo de tiempo (año, semestre, etc). Generalmente, se utiliza año. Para alguna unidad de tiempo más chica (días, semanas, etc.) se utiliza d.
  - b_i : Costo unitario de adquisición i.
  - c_1 : Costo unitario de almacenamiento.
  - k : Costo de una orden.
  - $T = 1$: Parámetro de dimensionamiento que sirve para referenciar todos los parámetros temporales a la misma unidad de tiempo. Su unidad es igual a 1 pedido.
  - LT : Lead Time.
- **Variables**
  - q : Es el tamaño del lote. Es la variable de decisión básica.
  - t : Es el intervalo de un ciclo. Tiempo que transcurre entre un restock y el siguiente.
  - CTE : Es el *Costo Total Esperado* referido a un periodo de tiempo. Es la función objetivo.
  - SR : Es el stock de reorden, es decir, el nivel de stock que hace que, una vez alcanzado, se emita la orden de reposición.
- **Costo total esperado anual**
  Es el costo de solicitar una cantidad q a un precio b_i.

$$CTE_i = b_i \cdot D + \frac{1}{2} \cdot q \cdot (c_1^{'} + b_i \cdot i) \cdot T + K \cdot \frac{D}{q}$$

Optimizando:

$$CTE(q_0, b_i) = CTE_{0i} = b_i \cdot D + \sqrt{2 \cdot K \cdot D \cdot (c_1^{'} + b_i \cdot i) \cdot T}$$

- **Valor óptimo de q**
  Es la cantidad óptima a ordenar, que minimiza CTE.

$$q_{0i} = \sqrt{\frac{2 \cdot K \cdot D}{T \cdot (c_1' + b_i \cdot i)}}$$

- **Stock de reorden**

$$SR = LT \cdot d$$

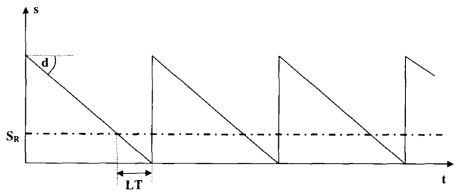


Figure 28: Gráfica SR

- **Número de ciclos por periodo**
  Es decir, la cantidad de veces que se pide en un periodo.

$$n = \frac{D}{q} = \frac{T}{t}$$

  Optimizando:

$$n_0 = \frac{D}{q_0} = \sqrt{\frac{T \cdot (c_1' + b_i \cdot i) \cdot D}{2 \cdot K}}$$

- **Valor óptimo del intervalo t**

$$t_0 = \frac{T}{D} \cdot q_0 = \sqrt{\frac{2 \cdot k \cdot T}{D \cdot (c_1' + b_i \cdot i)}}$$

- **Donde**
  - CTE, el costo total esperado, es la suma de los costos parciales. $b_i \cdot D$ corresponde al costo de adquisición, $\frac{1}{2} \cdot q \cdot (c_1' + b_i \cdot i) \cdot T$ corresponde al costo de almacenamiento y $K \cdot \frac{D}{q}$ corresponde al costo de orden.
  - CTE_0 Es el mejor costo esperado anual que se puede obtener.
  -

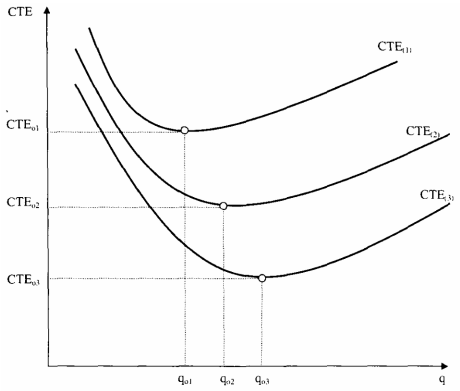


Figure 29: Gráfica de CTE para b variable discreto

- **Análisis de precios de corte**
  Se llamará cantidad de corte Q_i a aquella cantidad que separa dos costos de adquisición distintos.
  Dado que $b_1 > b_2 > b_3$, se tendrá que $CTE_1 > CTE_2 > CTE_3$, $q_{01} < q_{02} < q_{03}$ y $CTE_{01} > CTE_{02} > CTE_{03}$
  Habrá tres casos:

  - $q_{01} \leq Q_1 \leq q_{02} \leq Q_2 \leq q_{03}$
    Si el lote óptimo q_{03} para el precio b_3 es mayor o igual a Q_2, entonces lo óptimo será solicitar una cantidad q_{03}, ya que es la que produce el menor CTE.

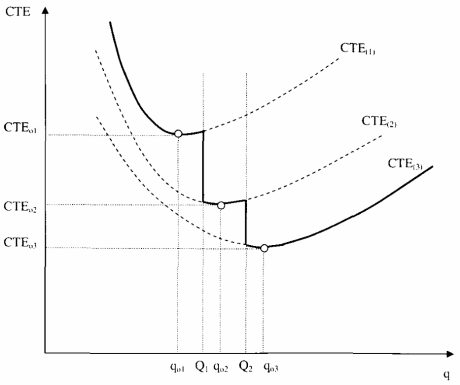


Figure 30: Gráfica $q_{01} \leq Q_1 \leq q_{02} \leq Q_2 \leq q_{03}$

  - $q_{01} \leq Q_1 \leq q_{02} < q_{03} < Q_2$
    Si se cumple que $q_{03} < Q_2$, entonces se pueden dar dos casos
    * $q_{02} \geq Q_1$: En este caso habrá que comparar $CTE(Q_2, b_3)$ con CTE_{02} y elegir q que genere menor costo.

* $q_02 < Q_1$: En este caso habrá que comparar $CTE(Q_2, b_3)$, $CTE(Q_1, b_2)$ y CTE_{01} y elegir q que genere el menor costo.

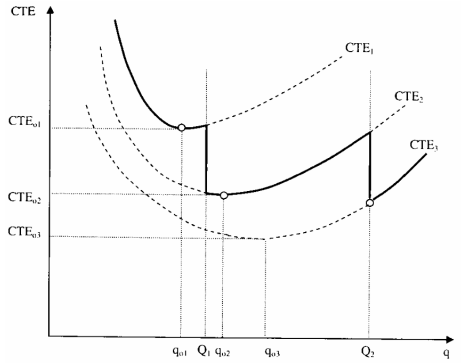


Figure 31: Gráfica $q_{01} \leq Q_1 \leq q_{02} < q_{03} < Q_2$

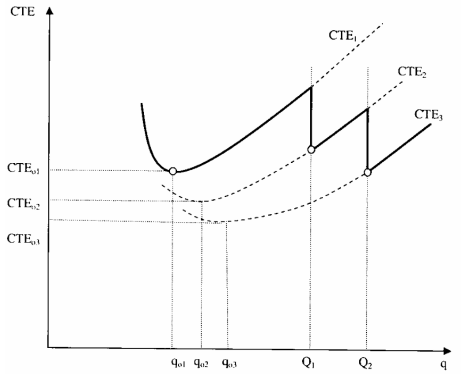


Figure 32: Gráfica $q_{01} < q_{02} < q_{03} < Q_1 \leq Q_2$

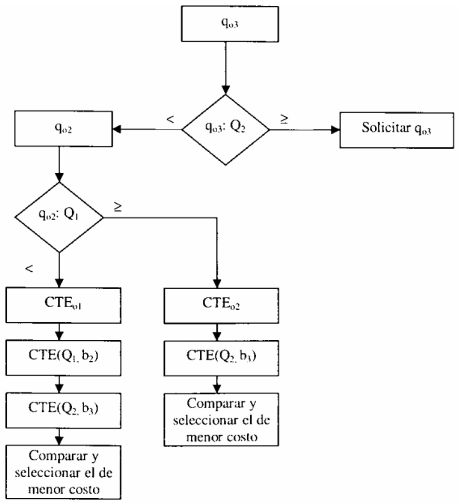


Figure 33: Diagrama de flujo para la elección de q

11.3 Restricciones

11.3.1 Restricción de superficie

En el caso de que exista una restricción de superficie, se deberá cumplir que:

$$s \cdot q \leq S_t$$

Donde s será la superficie ocupada por unidad de artículo y S_t es la superficie total disponible.
Si q_0 satisface la restricción, entonces este será el lote óptimo. En caso contrario, el lote óptimo será:

$$q^* = \frac{S_t}{s}$$

11.3.2 Restricción de monto máximo a inmovilizar

Si se quiere restringir un capital máximo de dinero, se deberá cumplir que:

$$b \cdot q \leq TM$$

Donde TM es el capital máximo a inmovilizar.
Si q_0 satisface la restricción, entonces este será el lote óptimo. En caso contrario, el lote óptimo será:

$$q^* = \frac{TM}{b}$$

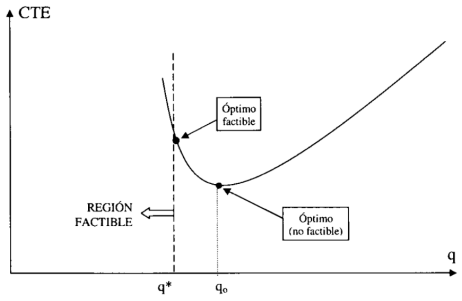


Figure 34: Región factible para restricciones de superficie e inmovilización

11.3.3 Restricción de cantidad de órdenes a emitir

Si se quiere restringir la cantidad de órdenes a emitir, se deberá cumplir que:

$$\frac{D}{q} \leq TO$$

Donde TO es el número máximo de órdenes n a emitir en el periodo de referencia. Si q_0 satisface la restricción, entonces este será el lote óptimo. En caso contrario, el lote óptimo será:

$$q^* = \frac{D}{TO}$$

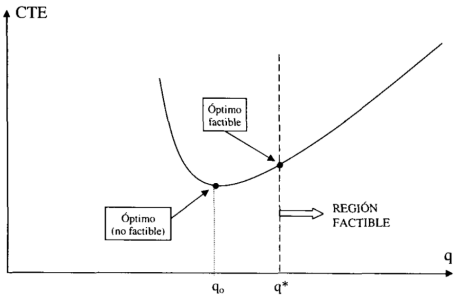


Figure 35: Región factible para restricción de órdenes a emitir

11.4 Modelos probabilísticos

Son modelos con demanda incierta.

Como base se supondrá el modelo con agotamiento admitido y, a su vez:

- Revisión continua.
  - Se coloca un pedido cuando el nivel de inventario llega al stock de reorden SR.

- Demanda aleatoria.
- Tiempo de entrega distinto de 0 ($LT \neq 0$).

La *política de inventario* exige pedir la cantidad q, siempre que la cantidad de inventario disponible se reduzca a un nivel SR.
En este caso:

$$\begin{pmatrix} \text{Costo total} \\ \text{del inventario} \end{pmatrix} = \begin{pmatrix} \text{Costo de} \\ \text{almacenamiento} \end{pmatrix} + \begin{pmatrix} \text{Costo de} \\ \text{agotamiento} \end{pmatrix} + \begin{pmatrix} \text{Costo de la} \\ \text{orden} \end{pmatrix}$$

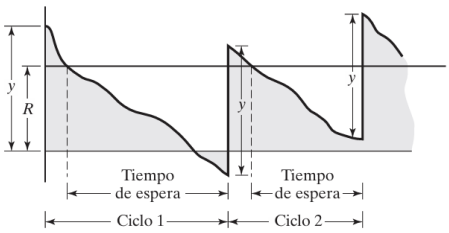


Figure 36: Gráfico stock en función del tiempo. Aquí $y = q$ y $R = SR$. Es decir, y es la cantidad y R el stock de reorden.

- **Parámetros**
  - $f(x)$ es la función de densidad de probabilidad de la demanda x durante el tiempo de espera. Se puede derivar a partir del LT y la demanda original.
  - D es la demanda esperada por unidad de tiempo.
  - c_1 es el costo de almacenamiento por unidad de inventario por unidad de tiempo.
  - c_2 es el costo de agotamiento por unidad de inventario.
  - K es el costo de la orden.
- **Costos**
  - Costo de la orden
  $$\frac{K \cdot D}{q}$$
  - Costo de almacenamiento esperado
  $$c_2 \cdot I$$
  Donde I es el nivel de inventario promedio, calculado como:
  $$I = \frac{(q + E[SR - x]) + E[SR - x]}{2} = \frac{q}{2} + SR - E[x]$$

Donde $q + E[SR - x]$ es el nivel de inventario al inicio de un ciclo (Dado que es la suma de la cantidad pedida q y lo que se espera tener después de satisfacer la demanda $E[SR - x]$) y $E[SR - x]$ es el nivel de inventario al final del ciclo, luego de una demanda x.

– Costo por agotamiento esperado
Los agotamientos ocurren cuando la demanda es mayor al stock de reorden, es decir, $x > SR$.
Por ciclo:

$$c_2 \cdot S$$

Por unidad de tiempo:

$$\frac{c_2 \cdot D \cdot S}{q}$$

La cantidad de unidades faltantes por ciclo se calcula como:

$$S = \int_{SR}^{\infty} (x - SR) f(x) dx$$

Donde, como x es la demanda y SR el stock de reorden, $x - SR$ es la demanda insatisfecha por quedarse sin stock

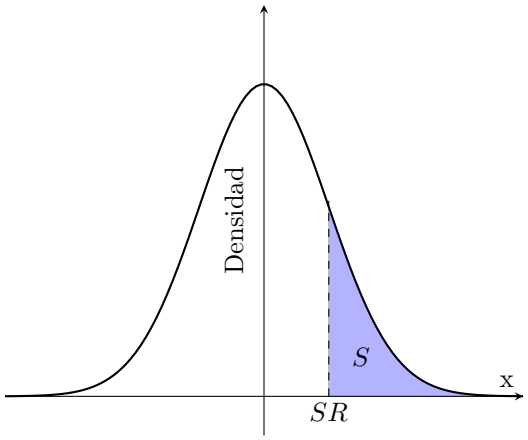


Figure 37: Curva de probabilidad

- **Costo total esperado**

$$CTE(q, SR) = \frac{K \cdot D}{q} + c_1(\frac{q}{2} + SR - E[x]) + \frac{c_2 D}{q} \int_{SR}^{\infty} (x - SR) f(x) dx$$

11.4.1 Algoritmo de Hadley y Whitin

Si se utilizan las condiciones analíticas de óptimo en CTE, se obtiene que q_0 y SR_0, es decir, la cantidad óptima de pedido y el stock de reorden óptimo,

dependen una de otra.
Es por eso, que para obtener ambos valores se debe recurrir a este algoritmo.

11.4.1.1 Convergencia El algoritmo convergerá si y solo sí

$$\tilde{q} \geq \hat{q}$$

Donde:

$$\tilde{q} = \frac{c_2 \cdot D}{c_1}$$

$$\hat{q} = \sqrt{\frac{2D(K + c_2 \cdot E[x])}{c_1}}$$

En el caso que no se cumpla, se deberá utilizar otro método para obtener q_0 y SR_0.

11.4.1.2 Pasos Dadas las siguientes ecuaciones que se derivan de aplicar las condiciones de óptimo en CTE:

$$q_0 = \sqrt{\frac{2D(K + c_2 \cdot S)}{c_1}} \tag{1}$$

$$\int_{SR}^{\infty} f(x)dx = \frac{c_1 \cdot q_0}{c_2 \cdot D} \tag{2}$$

Para los pasos del algoritmo, SR_0 corresponde al SR del paso 0, no al SR óptimo.

- *Paso 0*
  Usar la solución inicial $q_1 = \sqrt{\frac{2KD}{c_1}}$ y $SR_0 = 0$.
  Hacer $i = 1$ y continuar

- *Paso i*
  Usar q_i para determinar SR_i a partir de la ecuación (2).
  Si $SR_i \approx SR_{i-1}$, detenerse y usar q_i y SR_i.
  Caso contrario, usar SR_i en (1) para calcular q_{i+1}.
  Hacer $i = i + 1$ y repetir el paso i.

11.4.2 Método del nivel de servicio

Es otra manera de obtener el SR_0 es estableciendo una probabilidad máxima admitida de faltantes. Mientras más baja esta probabilidad, será menos probable que la demanda supere a SR.

$$P(x \geq SR) = \int_{SR}^{\infty} f(x)dx \leq \alpha$$

Es decir, la probabilidad de que la demanda sea mayor al stock de reorden debe ser menor o igual a un nivel de servicio α previamente establecido. Para esto, se utiliza:

$$q_0 = \sqrt{\frac{2KD}{c_1}}$$

Además, con este método, es posible calcular el stock de seguridad proporcionado por el SR calculado. Es decir, el nivel de inventario esperado justo antes de que la cantidad ordenada se reciba.

$$\textit{Stock de seguridad} = SR - E[x]$$

11.5 Modelos Multi-ítems

Los modelos de stock Multi-ítems son aquellos que permiten la administración de más de un producto.

11.5.1 Análisis ABC

El análisis ABC nos sirve para determinar cuáles productos son los que deberán ser administrados con mayor esfuerzo y con una frecuencia de revisión de stock mayor. Aplicando el *Principio de Pareto*, se puede determinar que el 20% de los productos representan el 80% de la demanda.

- **Clase A:** Son el 20% de los ítems, que representarán el 80% de la demanda. Se los deberá administrar de cerca y realizarles una revisión de stock con mucha frecuencia.
- **Clase B:** Son el 30% de los ítems, que representarán el 15% de la demanda.
- **Clase C:** Son el 50% de los ítems, que representarán el 5% de la demanda.

La clasificación de los tres grupos es totalmente arbitraria, podrían existir más clases e incluso variar los porcentajes de cada categoría. Lo importante es tener en cuenta que la mayor parte del stock puede ser muy bien controlada monitoreando con mayor intensidad un porcentaje muy bajo de los ítems (Los de categoría A).

11.5.1.1 Categorización

1. Listar los ítems con su respectivo precio b y demanda D.
2. Calcular la *Demanda Valorizada*, que es el producto entre el precio y la demanda.
3. Calcular qué porcentaje de demanda valorizada tiene cada producto sobre el total. $\%DV_i = \frac{DV_i \cdot 100}{\sum DV}$.
4. Ordenar la demanda valorizada porcentual de mayor a menor.

5. Calcular la demanda valorizada porcentual acumulada. La demanda valorizada porcentual acumulada de cada producto será la suma de su $\%DV$ y las $\%DV$ de los productos que están más arriba en la tabla, es decir, aquellos que tengan una $\%DV$ mayor o igual a la suya.

6. A partir de acá, podemos categorizar.

   (a) **A:** Aquellos cuya $\%DV$ acumulada sea menor o igual a 80%.

   (b) **B:** Aquellos cuya $\%DV$ acumulada sea mayor a 80% y menor o igual a 95%.

   (c) **C:** Aquellos cuya $\%DV$ acumulada sea mayor a 95% y menor o igual a 100%.

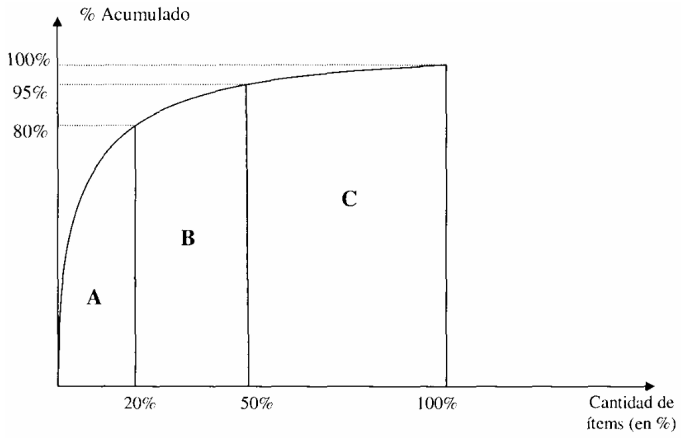


Figure 38: Curva ABC

11.5.2 Análisis XYZ

Es un análisis similar al ABC. En este caso, las distintas categorías nos indicarán la variabilidad de la demanda de cada producto.
La categorización se hará utilizando el coeficiente de variación $V = \frac{\text{Desviacion estándar}}{\text{Media}}$. 100.

11.5.2.1 Categorización

- **X:** Aquellos productos que cumplan $V \leq 10\%$. Serán los productos cuya demanda es más estable.
- **Y:** Aquellos productos que cumplan $10\% \leq V \leq 25\%$. La demanda no es tan estable, generalmente son productos de temporada.
- **Z:** Aquellos productos que cumplan $V \geq 25\%$. La demanda es muy volátil, es recomendable vender estos productos bajo pedidos.

11.5.3 Análisis ABC-XYZ

Se basa en combinar los dos análisis anteriores. Es literalmente juntar la categoría de ABC con la de XYZ de cada producto. De este análisis, se desprenden 9 categorías

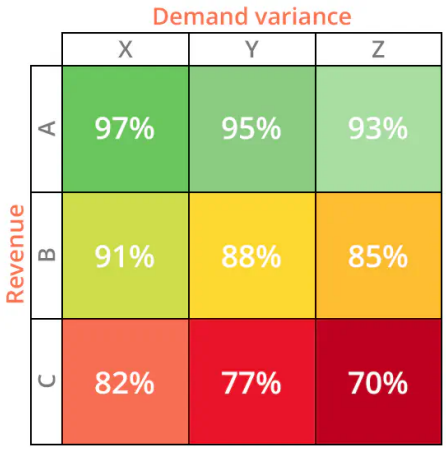


Figure 39: Tabla ABC-XYZ

Donde:

- **AX, BX, AY:** Representan la mayor parte de las ventas del negocio. Es recomendable tenerlos disponibles.
- **AZ, BY, CX:** Si bien son productos que generan buenos ingresos, son más difíciles de pronosticar. Lo ideal es convertirlos en productos de la categoría anterior.
- **BZ, CY, CZ:** Son productos cuya ganancia es baja y la demanda es más bien incierta. Muchos de ellos se podrían eliminar de la oferta, otros se los podría estimular para mejorar su categoría.

12 Programación Lineal Entera

Un problema de programación lineal entera es un PL en el cual se requiere que al menos una variable solo tome valores enteros no negativos. En este caso, *se relaja el supuesto de divisibilidad* de la programación lineal clásica.

- **Problema puro de programación con enteros:** Aquellos donde todas las variables deben tomar valores enteros.
- **Problema mixto de programación con enteros:** Aquellos donde solo algunas variables toman valores enteros, pero no todas.
- **Problema binario de programación con enteros:** Aquellos donde todas las variables solo pueden tomar valores de 0 o 1. También puede ser puro o mixto.

12.1 Región factible

Cualquier PE se puede considerar como un PL al cual se le aplican restricciones de enteros. Esto implica que *la región factible de cualquier PE debe estar contenida en la región factible de su PL correspondiente.*
Si la región factible del PL asociado de un PE puro es acotada, entonces la región factible del PE será una nube de puntos de la región, por lo que no será conexa.

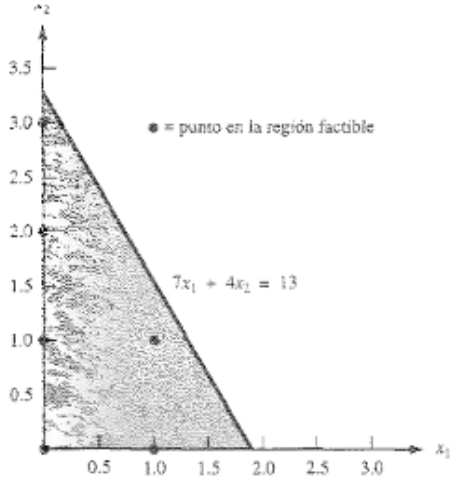


Figure 40: Región factible - Nube de puntos

Para cualquier PE de maximización, se cumple que:

$$\text{Valor óptimo del PL asociado} \geq \text{Valor óptimo del PE}$$

Lo mismo para minimización, pero con $\leq$.

12.2 Restricciones

Generalmente las restricciones de un PE binario se podrán expresar en términos de lógica proposicional.

- **Si...Entonces:** Si x_1 entonces se debe cumplir x_2. Esto se puede expresar como $x_1 \leq x_2$.
- **Si...Entonces no:** Si se cumple x_1 entonces no se debe cumplir x_2. Esto se puede expresar como $x_1 \leq 1 - x_2$.
- **Si (múltiple)...Entonces:** Si x_1 y x_2 entonces se debe cumplir x_3. Esto se puede expresar como $x_1 + x_2 - x_3 \leq 1$.

12.2.1 Traducción a PM

Se sabe que cualquier expresión lógica se puede reescribir en forma de disyunciones de literales, es decir, en su forma normal conjuntiva. Para esto, se deben aplicar propiedades de equivalencias lógicas. Esta es la manera general de traducir todas las restricciones.
Así, si se tiene, por ejemplo: x_1 o x_2, entonces x_3, se puede reescribir como:

$$x_1 \vee x_2 \rightarrow x_3 \equiv \neg(x_1 \vee x_2) \vee x_3 \text{ Por definición de condicional}$$

$$\neg(x_1 \vee x_2) \vee x_3 \equiv (\neg x_1 \wedge \neg x_2) \vee x_3 \text{ Por LDDM}$$

$$(\neg x_1 \wedge \neg x_2) \vee x_3 \equiv (\neg x_1 \vee x_3) \wedge (\neg x_2 \vee x_3) \text{ Por distributiva}$$

De donde se pueden obtener las siguientes dos restricciones:

$$(1 - x_1) + x_3 \geq 1 \text{ Del primer término de la disyunción}$$

$$(1 - x_2) + x_3 \geq 1 \text{ Del segundo término de la disyunción}$$

12.2.2 Restricciones "o bien" - Relajación de la gran M

Es el caso en el que se deben cumplir exactamente n restricciones de un conjunto de m restricciones (podrían existir restricciones que no estén afectadas por el "o bien").
Para esto se utiliza el método de la gran M. Esta técnica nos indica que a cada una de las restricciones del conjunto de restricciones que están afectadas por el "o bien" le debo sumar una nueva variable multiplicada por un valor muy grande M.
Por lo tanto, si quiero que se cumplan n restricciones del conjunto de m restricciones afectadas por el "o bien", se debe transformar esto:

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1j}x_j \leq b_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2j}x_j \leq b_2$$

$$\vdots$$

$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mj}x_j \leq b_m$$

En esto:

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1j}x_j \leq b_1 + My_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2j}x_j \leq b_2 + My_2$$

$$\vdots$$

$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mj}x_j \leq b_m + My_m$$

$$y_1 + y_2 + \cdots + y_m = m - n$$

Porque quiero que se cumplan n restricciones, que valgan $y = 1$

12.3 Métodos de resolución

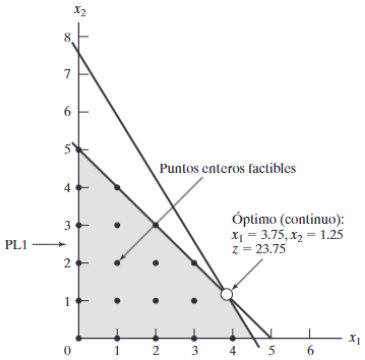
12.3.1 Enumeración de soluciones

Se basa en listar cada una de las soluciones factibles y verificar cual es la óptima. Sin embargo, generalmente, los PE tienen demasiadas soluciones como para tomar en consideración este método de resolución.

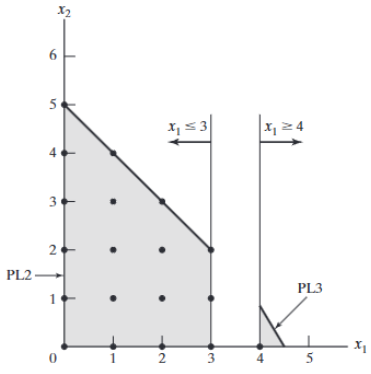
12.3.2 Algoritmo de ramificación y acotamiento

Se basa en ir descomponiendo el PL asociado al PE que se quiere resolver.

1. Resolver el primer PL asociado al PE a optimizar.
2. Resolver el actual PL.
   (a) Si todas las variables que requieren ser enteras lo son y el resultado de la función objetivo es mejor que el conocido, apartar el resultado de la función para futuras comparaciones. Si todavía no se tiene ningún resultado y es el primero, apartarlo también. Seguir.
   (b) Si no todas las variables que se requieren enteras lo son, seguir.
   (c) Si se obtuvieron todas las variables necesarias enteras y el funcional es peor, cortar la rama.
   (d) Si no se hallaron soluciones factibles, cortar la rama.
3. Tomar una variable que aún no es entera x_i y lo debe ser. Generar dos nuevos PL a resolver, uno tendrá como nueva restricción $x_i \leq \lfloor x_i \rfloor$ y otro $x_i \leq \lceil x_i \rceil$ (función piso y función techo). Este proceso es la *ramificación*, cada nuevo PL es una rama.
4. Repetir para cada rama nueva obtenida hasta llegar a las condiciones de corte en (2).



(a) Región factible sin ramificación



(b) Región factible con ramificación

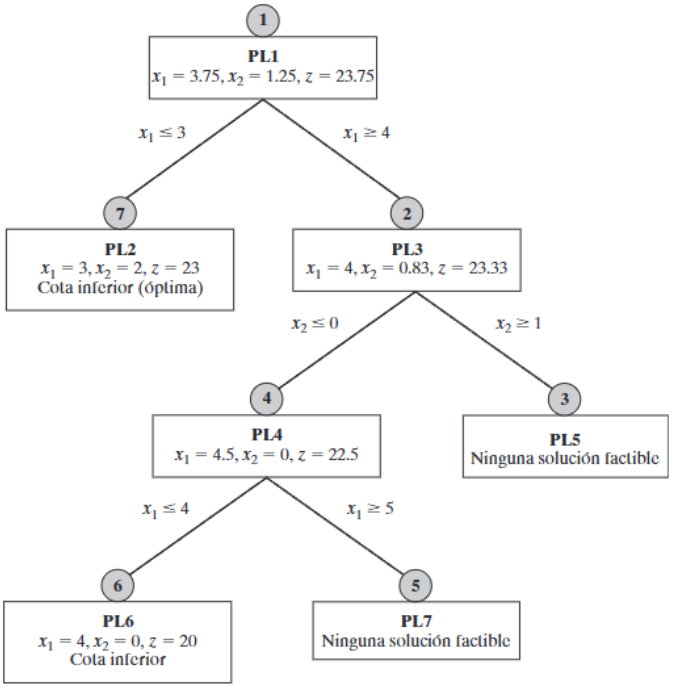


Figure 42: Ramificación

13 Optimización Combinatoria

Un problema de combinatoria se puede pensar como un conjunto de elementos a posicionar en ciertos lugares, donde existen igual cantidad de lugares que de elementos. Por lo tanto, la cantidad de soluciones es finita.
Existen diversos problemas de optimización combinatoria, en los cuales se busca encontrar la mejor solución entre un conjunto finito de posibles soluciones.

13.1 Problema de la Mochila - Knapsack Problem

Se trata de llenar una mochila incapaz de soportar más de un peso determinado con todos o parte de un conjunto de objetos. Cada uno de estos elementos tiene un peso y un valor específico. El objetivo del problema es maximizar el valor total de dentro de la mochila sin exceder el peso máximo

$$\text{Max } Z = \sum_{i=1}^{n} c_i x_i$$

S.T

$$\sum_{i=1}^{n} Q_i x_i \leq b$$

$$x_i \in \{0, 1\}$$

Donde

- x_i indica si el elemento i se lleva o no en la mochila
- c_i es el valor del elemento i.
- Q_i es el espacio que ocupa el elemento i.
- b es el espacio total de la mochila.

13.2 Problema del viajante - Travelling Salesman Problem

Dada una lista de ciudades y distancias entre cada par de ellas, se trata de buscar la ruta más corta posible que visite cada ciudad exactamente una vez y al finalizar regrese a la ciudad de origen. Es decir, busca el camino de Hamilton óptimo para el grafo que representa la situación.

$$\text{Min } Z = \sum_{i=0, i\neq j}^{n} \sum_{j=0, j\neq i}^{n} c_{ij} x_{ij}$$

S.T

$$\text{[Arcos salientes]} \sum_{j=0, j\neq i}^{n} x_{ij} = 1 \ \forall \ i = 0, 1, 2, \ldots, n$$

$$\text{[Arcos entrantes]} \sum_{i=0, i\neq j}^{n} x_{ij} = 1 \ \forall \ j = 0, 1, 2, \ldots, n$$

$$\text{[Orden] } U_i - U_j + n \cdot x_{ij} \leq n - 1 \ \forall \ i, j \in V$$

$$x_{ij} \in \{0, 1\}$$

Donde

- x_{ij} indica si se recorre el arco i, j
- c_{ij} es el costo del arco i, j. Puede ser la distancia.
- La condición de orden es la condición de *Miller-Tucker-Zemlin* que evita que existan subtours en la solución. También evita que se vuelva a visitar nodos ya visitados.
  - U_i representa el orden o posición del nodo i en el recorrido.
  - V es el conjunto de nodos.
  - $n = |V|$ es el número de nodos.

13.3 Cobertura de conjuntos - Set Cover Problem

Se tiene un conjunto universal con todos los elementos en cuestión, se trata de elegir aquellos subconjuntos del universal que entre todos contengan a todos los elementos del universal y que a su vez minimicen el costo asociado que tiene cada uno de estos subconjuntos. Es decir, escoger los subconjuntos que contengan todos los elementos, pero de la manera más eficiente posible. Variantes

- **Cobertura:** Cada elemento del universal debe estar cubierto al menos una vez por los subconjuntos elegidos
- **Partición:** Los subconjuntos elegidos deben ser disjuntos, cada elemento del universal debe pertenecer exactamente a un subconjunto.
- **Packing:** Los subconjuntos elegidos deben ser disjuntos, puede haber elementos del universal que no pertenezcan a ningun subconjunto.